

1. 商業理解 (Business Understanding) - (科目一 L21)

- * 首要目標: 建立一個能預測生產良率並找出關鍵影響因子的 AI 模型。

- * 最高指導原則：KNOW-HOW 保護

- * 威脅分析: 最大的風險不是模型不準，而是公司的核心製程參數、供應鏈組合等 KNOW-HOW，透過數據或訓練好的模型被外洩。

- * 架構決策:

- * 數據層:

- 數據絕對不能離開公司內部的私有環境。若多個廠區數據需整合，應優先考慮在安全的私有雲或地端數據中心進行集中，

- 而非直接使用公有雲。

- * 模型層: 訓練好的模型本身就是 KNOW-HOW 的結晶。因此，模型產出物（如 .pkl 或 .h5 檔案）必須被視為最高級別的商業機密，進行加密儲存和嚴格的存取控制。

- * 成功指標:

- * 商業指標: 最終良率提升百分比、因瑕疵造成的客服成本下降率。

- * 模型指標:

- * 預測能力: RMSE / MAE (若預測良率數值)，或 F1-Score (若預測「良品/不良品」分類)。

- * 診斷能力: 模型的特徵重要性 (Feature Importance) 報告，此項指標與預測能力同等重要。

2. & 3. 資料理解與準備 (Data Understanding & Preparation) - (科目二 L22)

- * 數據源整合:

 - * 結構化數據: 生產線感測器數據、維修料件更換紀錄、品保部採購的零件供應商資訊。

 - * 非結構化數據: 客戶回饋中心的文本紀錄（需 NLP 技術進行特徵提取）。

- * 特徵工程:

根據各部門數據，建立有意義的特徵。例如：[零件 A 供應商]、[操作機台的班別]、[距離上次維修的天數]、[客服文字中出現"破損"的次數]。

- * 數據治理: 嚴格遵守 ISO27001 規範，所有數據的存取、處理、與串接，都必須留下可追蹤的日誌 (Log)。

4. 模型建立 (Modeling) - (科目三 L23)

- * 演算法適合性 (導入前考量):

 - * 第一階段首選：可解釋的樹模型 (XGBoost / LightGBM / 隨機森林)

* 原因:

在這個專案的初期，「找出原因」比「精準預測」更重要。樹模型能提供清晰的特徵重要性排序，讓公司能快速知道「是哪個供應商的零件最有問題？」或「是哪個製程參數影響最大？」，從而立即採取改善行動。

> 請以最簡單案例情境，搭配圖示方式，舉例要如何解釋的樹模型 (XGBoost / LightGBM / 隨機森林)，找出產品不良率？

◆ 好的，這是一個非常實用的問題，它直接展示了樹模型如何將「數據」轉化為「可解釋的 **KNOW-HOW**」。

我將以一個最簡單的製造業情境為例，搭配圖示，來詳細解說樹模型如何幫助我們找出產品不良率高的原因。

案例情境：小零件製造廠的不良率分析

公司背景: 一家製造手機小零件的工廠，生產線上偶爾會出現不良品。

目標: 希望找出影響產品不良率的關鍵因素，從而提高生產良率。

收集到的簡化數據: 我們收集了每批產品的幾個關鍵資訊：

- * 原料供應商: 供應商 **A** 或 供應商 **B**
- * 機台溫度: 低 或 高
- * 操作班次: 白天 或 夜班
- * 產品不良率: 目標變數，簡化為 高 或 低

模型: 我們訓練了一個決策樹模型來預測產品不良率。

如何從樹模型中提取 **KNOW-HOW** 與行動建議

決策樹的每一個「路徑」，都是一條可以直接轉化為「**If-Then**」形式的商業規則，這些規則就是我們從數據中學到的 **KNOW-HOW**。

1. 發現「高不良率」的 **KNOW-HOW** (路徑一)

- * 規則: 如果 (原料供應商 == 'A') 並且 (機台溫度 == '高'), 那麼 [預測: 高不良率 (機率 85%)]

- * 解讀: 這是一條非常明確的問題診斷規則。它告訴我們，當供應商 **A** 的原料與高溫機台結合時，產品不良率就會飆高。

- * 行動建議:

 - * 立即檢查「供應商 **A**」的原料品質規格，與高溫機台的相容性。

 - * 調整 **SOP**，避免在機台高溫時使用「供應商 **A**」的原料，或為供應商 **A** 的原料設定不同的機台溫度標準。

2. 發現「低不良率」的 **KNOW-HOW** (路徑二)

- * 規則: 如果 (原料供應商 == 'A') 並且 (機台溫度 == '低'), 那麼 [預測: 低不良率 (機率 95%)]

- * 解讀: 這是一條最佳實踐規則。它告訴我們，使用供應商 **A** 的原料時，只要控制機台溫度在低

點，就能維持極佳的良率。

- * 行動建議: 將這條規則作為標準作業程序，推廣至所有使用「供應商 A」原料的批次。

3. 發現「特定供應商」的 **KNOW-HOW** (路徑三)

- * 規則: 如果 (原料供應商 == 'B')，那麼 [預測: 低不良率 (機率 90%)]

- * 解讀: 這條規則直接顯示，無論機台溫度如何，只要使用「供應商 B」的原料，不良率都相對較低。

- * 行動建議:

- * 分析「供應商 B」原料的特性和採購成本，考慮增加「供應商 B」的採購比例。

- * 研究「供應商 B」的原料為何對機台溫度不敏感，這可能隱含了更有價值的 **KNOW-HOW**。

總結：樹模型如何揭示公司 **KNOW-HOW**

- * 可解釋性:

決策樹最大的優勢，就是它能將複雜的數據關係，轉化為人類可讀、可理解的「**If-Then**」規則。這些規則就是從數據中提取出來

的、關於「什麼導致不良率高/低」的公司 **KNOW-HOW**。

* 特徵重要性:

在這棵樹中，「原料供應商」出現在最頂部，說明它是影響不良率最重要的因素。其次是「機台溫度」。模型會自動告訴你哪些變

數對結果影響最大。

* 實務應用: **XGBoost** 或 **LightGBM**

等更強大的樹模型，雖然是多棵樹的集成，其單棵樹本身仍保持可解釋性。更重要的是，它們會提供一個整體性的「特徵重要性

(**Feature Importance**)」報告，直接指出哪些是影響良率的 **Top N** 因素，讓企業可以針對性地去優化製程。

透過這種方式，樹模型不僅僅是「預測不良率」，更重要的是它幫助公司「理解不良率的成因」，從而能採取具體、可行動的措施去

提高生產良率，這就是 **AI** 賦能製造業的核心價值。

我將在之前案例的基礎上，更細緻地呈現「原始表格數據如何被準備，並輸入 AI 模型，最終產生可解釋的

KNOW-HOW」的整個過程，並搭配圖示。

案例情境：小零件製造廠的不良率分析

目標: 找出影響產品不良率的關鍵因素，提高生產良率。

1. 原始生產數據 (表格形式)

企業在生產過程中，會不斷地收集數據。這些數據在輸入 AI 模型之前，首先會被整理成類似以下的結構化表格：

1	A	高	白天	高	
2	A	低	白天	低	
3	B	高	夜班	低	
4	A	高	夜班	高	
5	B	低	白天	低	
...	...	...	...	...	

*** 說明:**

- * 批次 ID 是一個識別碼，AI 模型通常不直接使用。
- * 原料供應商, 機台溫度, 操作班次 是我們的特徵 (Features)。
- * 產品不良率 是我們想要預測或解釋的目標 (Target)。

2. 如何將這些資訊輸入 AI 模型 (特徵編碼)

AI 模型（特別是傳統機器學習模型如決策樹）通常只能處理數值資料。因此，表格中的「原料供應商 (A/B)」、「機台溫度 (高/低)」、「操作班次 (白天/夜班)」這些類別特徵 (Categorical Features)，必須先轉換成數值。

* 特徵編碼策略：獨熱編碼 (One-Hot Encoding)

這是最常用的方法之一。每個類別會被轉換成一個新的二元（0 或 1）特徵欄位。


生產數據表 (One-Hot Encoding)							
批次 ID	供應商_A	供應商_B	溫度_高	溫度_低	班次_白天	班次_夜班	產品不良率 (0=低, 1=高)
001	1	0	0	1	1	0	0.05
002	0	1	1	0	0	1	0.12
003	1	0	1	1	1	0	0.08
004	0	1	0	0	0	1	0.15
005	1	0	0	1	0	1	0.03
006	0	1	1	1	1	0	0.10
007	1	0	1	0	0	1	0.07
008	0	1	0	1	1	0	0.11
009	1	0	0	0	0	1	0.06
010	0	1	1	1	0	0	0.13

數據流範例

原始生產數據 (表格)

類別特徵

特徵工程 (編碼)



- * 數據收集 (A): 這就是您在工廠中，透過各種系統（MES, ERP 等）收集到的原始數據。
- * 數據清洗與轉換 (B): 這是科目二 (大數據處理分析) 的核心工作。AI 模型不能直接理解「供應商_A」，它需要「供應商_A」這個數值特徵（1 或 0）。這個步驟至關重要，做不好會影響後續模型效果。
- * 輸入模型 (C): 編碼後的數值表格（稱為 X_train 和 y_train），就是 AI 模型的「教科書」。
- * AI 學習 (D):
決策樹演算法會自動閱讀這本「教科書」，並從中找出「最佳的分裂點」。例如，它會發現「供應商_A」這個特徵欄位，能最好地區分「高不良率」和「低不良率」。
- * KNOW-HOW 輸出 (E): 學習過程的結果，就是我們之前看到的決策樹圖。這張圖的每一個分支、每一個節點，都代表著 AI 從您的生產數據中自動挖掘出的、關於「如何控制不良率」的可解釋的 KNOW-HOW。

這個流程清晰地展示了：您的原始生產數據（表格），經過數據準備（特徵編碼）後，成為 AI 模型（決策樹）的輸入，最終模型學習到的結果，就是可以指導生產的 KNOW-HOW。

- * 決策: 相較於「黑箱」的深度學習模型，XGBoost

能在提供高精度的同時，給出極具商業價值的洞察，是此類問題的最佳起點。

- * 硬體配置框架: 樹模型主要依賴 CPU 和 RAM。初期可採用高核心數、大記憶體的服務器，無需立即投資昂貴的 GPU。

- * 流程標準化: 必須使用 Scikit-learn Pipeline

將「數據預處理」（如補缺、標準化）和「模型訓練」打包成單一物件，以確保流程的穩健與可重複性。

5. 模型評估 (Evaluation) - (科目三 L23)

- * 指標: 根據目標（迴歸或分類）選擇 RMSE 或 F1-Score。

- * 驗證:

除了用測試集驗證預測精度，更重要的是，將模型產出的特徵重要性排序，交給品保部、維修部的領域專家進行交叉驗證，確認其結果是否符合他們的實務經驗。

6. 部署與 MLOps (Deployment & MLOps) - (科目一 L21)

這是從「一次性分析」走向「企業級 AI 應用」的關鍵，也是導入後的持續成本所在。

- * 部署策略:

- * 將訓練好的 **Pipeline** 模型部署為一個內部 **API**，供 **MES** (製造執行系統) 或其他生產系統調用。

- * 整個服務必須部署在內部網路中，並有嚴格的 **API** 存取權限控制。

- * 持續維運成本與資料偏移:

- * 模型監控: 必須建立一個自動化監控系統。核心監控對象是「資料偏移 (**Data Drift**)」。

- * 原因:

- 製造業的環境是不斷變化的：新的原料批次、機器的自然耗損、新的操作員...這些都會導致線上收集到的新數據，其統計分佈與原始訓練數據產生差異。

- * 機制: 定期（如每日）計算線上新數據與訓練數據在各個特徵上的分佈距離（如 **KL** 散度或 **PSI** 指標）。一旦距離超過閾值，系統就應自動告警。

- * 模型再訓練 (**Retraining**):

- * 觸發: 當監控系統偵測到顯著的資料偏移，或模型的預測準確率隨時間推移而穩定下降時，就必須觸發再訓練流程。

- * 自動化: 這個「監控 -> 告警 -> 再訓練 -> 重新部署」的流程，應透過 **Airflow** 這類的工作流管理工具，將其自動化，形成一個閉環的 **MLOps** 系統。

* 持續成本: **MLOps** 不是一次性投資。它包含了雲端/伺服器的持續費用（用於監控與再訓練），以及維運人力（**MLOps** 工程師）的成本。在專案規劃初期就必須將這部分「隱性成本」納入總體 **ROI** 計算。