

iPAS AI 應用規劃師(中級)

科目二：大數據處理分析與應用

從試題出發

建立數據分析的機率統計思維



吳彥霖 博士



引言

本機率統計的概念整理，係依據 2025 年 [iPAS AI 應用規劃師\(中級\)能力鑑定](#) – 『大數據處理分析與應用』考題彙整而成，以「**數學與統計概念**×**解題邏輯**×**實務應用情境**」為設計核心，協助考生理解考題背後的統計意涵與判斷思路，且說明數據分析在**異常偵測**、**資料品質分析**、**機器學習模型建構**中的實際應用。

內容涵蓋：

- 統計指標與分佈：Z-Score、Skewness、Box-Cox Transformation
- 機率分佈與關聯：Binomial、Negative Binomial、Poisson、Exponential Distribution
- 樹模型核心指標：Gini Impurity
- 假設檢定於實務資料分析中的應用流程

內容適合【**不只通過鑑定，更將方法實際運用於 AI 與數據分析工作**】的學習者與實務工作者參考使用。

➤ 適合對象：準備 iPAS AI 應用規劃師(中級)能力鑑定、資料分析師、製程/商業數據分析人員

Z 分數

Z 分數

Z-Score

- 衡量樣本資料點偏離平均的標準化方法。
- 一樣本資料集 $D = \{x_i\}$ ，其平均值 μ 、標準差 σ ，則，每一個樣本點 z 分數的數學定義為：

$$z_i = \frac{x_i - \mu}{\sigma} .$$

- 應用


- 不同單位特徵的標準化。
- 異常偵測，例如：製程參數監控、金融交易異常監控等。

◆ $|z_i| > 3$ 通常會視為異常值

∴ 在理想常態分布的情況下，樣本跑出 $\pm 3\sigma$ 之外的機率極小，不到千分之三的機率。

$$P(|z_i| > 3) \approx 0.27\%$$

圖資料來源：[Standard score](#) .



Z 分數

Z-Score

114 年 AI 應用規劃師 - 大數據處理分析與應用

若某數據點的 Z 分數 (Z-Score) = 2，請問代表下列哪一種意涵？

- (A)代表該數據點之原始數值為 2；
- (B)該數據點比平均值低 2 個標準差；
- (C)代表數據為異常值；
- ✓ (D)該數據點比平均值高 2 個標準差

【解題】

Z 分數表示，該樣本點距離平均值有幾個標準差，其正值表示高過平均值，反之表示低於平均值。

114 年 AI 應用規劃師 - 大數據處理分析與應用

某金融科技公司以 Z 分數 (Z-Score) 監控交易金額異常狀況。若交易金額平均為新台幣 2,000 元，標準差為 400 元，某筆交易金額為 3,200 元，且公司以 $|Z| \geq 3$ 判定為異常值 (Outlier)，下列判斷何者最為正確？

- ✓ (A)該筆交易的 Z 分數為 3，應標記為異常值；
- (B)該筆交易的 Z 分數為 2.5，屬於合理變異範圍；
- (C)該筆交易的 Z 分數為 2，顯示模型標準差估計過高；
- (D)該筆交易的 Z 分數為 1.5，無須納入異常檢測

【解題】

$$Z = \frac{3,200 - 2,000}{400} = 3$$

∴ 該公司以 $|Z| \geq 3$ 作為異常值的判斷閾值

∴ 此筆交易應標記為異常值

偏度

偏度

Skewness

- 描述資料分佈的不對稱性。
- 分佈右偏(右側長尾) $\rightarrow skewness > 0$
分佈左偏(左側長尾) $\rightarrow skewness < 0$
- 數學定義

Fisher–Pearson Sample Skewness

$$skewness = \frac{N}{(N-1)(N-2)} \sum_{i=1}^N \left(\frac{x_i - \bar{X}}{s} \right)^3$$

其中


N : 樣本數

$\bar{X}$: 樣本平均值

s : 樣本標準差

- 許多統計方法，例如：ANOVA、線性迴歸模型、...等，具有常態分佈的假設前提。
偏度可用以判斷，特徵變數是否需要特徵轉換，或改用其他無母數的統計方法。

圖資料來源：[Skewness](#).




偏度

Skewness

114 年 AI 應用規劃師 - 大數據處理分析與應用

附圖為某資料之分佈圖，此圖資料之偏態（Skewness）值較有可能為下列哪個選項？



【解題】

觀察圖的資料分佈，存在少數的極小值(<0)，分佈呈現明顯的左偏，所以，

$$\text{Skewness} < 0。$$

- ✓ (A) $\text{Skewness} < 0$;
- (B) $\text{Skewness} > 0$;
- (C) $\text{Skewness} = 0$;
- (D) 無法計算 Skewness


Box-Cox 轉換

Box-Cox 轉換


Box-Cox Transformation

- 目的：降低數據分佈的偏態程度、穩定數據的變異。
- 適用於數據具有異質性 Heteroscedasticity 或為長尾分佈，轉換後使得數據分布，更似近常態分佈。
- 數學定義

$$y_i^\lambda = \begin{cases} \frac{y_i^\lambda - 1}{\lambda}, & \text{if } \lambda \neq 0, \\ \ln y_i, & \text{if } \lambda = 0. \end{cases}$$



Box-Cox Trans.



Box-Cox 轉換

Box-Cox Transformation

114 年 AI 應用規劃師 - 大數據處理分析與應用

某研究人員欲使用線性迴歸模型 (Linear Regression Model) 分析變數 Y 與 X 之間的關係，但發現 Y 的分佈明顯右偏，且其變異數隨 X 的增大而增加。為滿足模型假設並提升配適效果，下列哪一種前處理方法最為合適？

(A) 對 X 進行標準化 (Standardization)；

✓ (B) 對 Y 進行 Box - Cox 轉換 (Box - Cox Transformation)；

(C) 對資料進行一次差分 (First Differencing)；

(D) 將 Y 中變異較大的樣本移除


【解題】

基礎概念：迴歸模型的假設條件，殘差須滿足

- 常態性 Normality：殘差的期望值近似於 0 (無系統偏誤)
- 獨立性 Independency：殘差間互不影響無關聯
- 同質性 Homoscedasticity：殘差不隨 X 改變

此題 Y 明顯右偏，表示殘差也極可能右偏、違反常態。
所以，調整 Y 的分佈，才有機會讓模型更配適。


- (A) 標準化目的，在於統一不同特徵的尺度，轉換成無綱量可比較，不會改變 Y 的偏態情況。
- (B) 降低 Y 的偏態程度、穩定變異，能讓殘差符合迴歸模型的假設條件。
- (C) 適用於時間序列的分析。
- (D) 可能導致樣本的選擇偏誤，降低模型的泛化能力。



機率分佈

二項分佈與負二項分佈

Binomial and Negative Binomial Distribution



- 在固定的 N 次獨立試驗中，每次試驗成功的機率 P ，試驗成功次數 X 的分佈。

- 離散型機率分佈

- 機率質量函數 Probability Mass Function, PMF

$$P(X = k) = \binom{N}{k} P^k (1 - P)^{N-k}, k = 0, 1, 2, \dots, N.$$

- 應用：電商廣告投放模擬、產品檢測、...
- 當 $P = 0.5$ 時，二項分佈為完美對稱。

- 每次試驗成功的機率 P ，直到第 r 次成功為止，所需的試驗失敗次數 X 的分佈。


- 離散型機率分佈

- 機率質量函數 Probability Mass Function, PMF

$$P(X = k) = \binom{r+x-1}{x} P^r (1 - P)^x, k = 0, 1, 2, \dots$$

- 應用：設備故障件數、產品瑕疵數量、...

二項分佈與常態分佈的關聯



- 理論上，當樣本數 $N \rightarrow \infty$ 時，二項分佈會趨近常態分佈。
- 實務上，樣本的蒐集會考量時間與費用，很難先無止盡地蒐集資料，才進行研究。所以，實務的應用準則為：

當 $NP \geq 5$ 且 $N(1-P) \geq 5$ 時，
二項分佈可用常態分佈作近似。

成功次數
期望值

失敗次數
期望值




Figure 1. Univariate distribution relationships.

資料來源：

■ Lawrence M Leemis & Jacquelyn T McQueston (2008) Univariate Distribution Relationships, The American Statistician, 62:1, 45-53, DOI: [10.1198/000313008X270448](https://doi.org/10.1198/000313008X270448)

二項分佈與常態分佈的關聯

114 年 AI 應用規劃師 - 大數據處理分析與應用

某電商團隊觀察到，每位顧客對廣告推播的點擊行為可視為一次伯努利試驗 (Bernoulli Trial)，單次點擊成功機率為 $p=0.4$ 。當推播對象擴增至 5,000 位顧客時，團隊想快速預估「成功點擊總數」的分佈情形，以進行模型效能模擬與預測。若希望以常態分佈 (Normal Distribution) 近似原始分佈，下列哪一項判斷最為合理？


- (A) 因樣本數極大，可直接以常態分佈近似二項分佈 (Binomial Distribution)；
- ✓ (B) 只有當 np 與 $n(1-p)$ 皆大於 5 時，才能以常態分佈作近似；
- (C) 常態近似只適用於 $p=0.5$ 的情況；
- (D) 無論樣本數多大，二項分佈都不能以常態分佈近似

【解題】

- (A) 不能只考量樣本數，還須考慮機率 p 的大小。
- (B) 同時滿足 $NP \geq 5$ 與 $N(1 - P) \geq 5$ ，為實務的判斷準則。
- (C) 當 $p = 0.5$ 時，二項分佈會為完美的對稱分佈，但並不為常態分佈。
- (D) 中央極限定理：當 $N \rightarrow \infty$ 時，二項分佈會趨近常態分佈。

卜松分佈與指數分佈

Poisson and Exponential Distribution



卜瓦松分佈
Poisson Distribution

指數分佈
Exponential Distribution

- 描述在固定一段時間或空間內事件發生的次數
- 離散型機率分佈
- 機率質量函數 *Probability Mass Function, PMF*

$$P(x = k) = \frac{\lambda^k e^{-\lambda}}{k!}, k = 0, 1, 2, \dots$$

其中， λ 為單位時間(或空間)內事件發生的平均頻率。

- 應用：客戶來店數、網站來訪次數、...

- 描述發生下一次事件的等待時間
- 連續型機率分佈
- 機率密度函數 *Probability Density Function, PDF*

$$f(x) = \lambda e^{-\lambda x}, x \geq 0,$$

其中， λ 為單位時間內事件發生的平均頻率。

- 應用：客戶來店間隔、機器故障時間、...

卜松分佈

Poisson Distribution

114 年 AI 應用規劃師 - 大數據處理分析與應用

某家客服中心統計資料發現，平均每小時會接到約 20 通顧客來電，但每分鐘的來電數量不固定，可能為 0、1、2 通不等。這些來電事件彼此獨立，且在短時間內，發生的機率與時間長短成正比。若要以機率模型描述「每分鐘接到幾通來電」的機率分佈，下列哪一種最適合使用？

- (A) 均勻分佈 (Uniform distribution);
- (B) 指數分佈 (Exponential distribution);
- ✓ (C) 卜瓦松分佈 (Poisson distribution);
- (D) 常態分佈 (Normal distribution)

【解題】

現有統計資料具備的資訊：

- 平均每小時的來電數 ← 固定平均頻率
- 電數事件彼此獨立
- 來電發生機率與時間長短成正比
↑ Poisson Process

此機率模型要能描述「每分鐘接到來電數量」

⇒ 需為**離散型**的機率分佈，且描述單位時間內的發生次數。

- (A) 均勻分布的假設，每個來電數發生的機率都一樣，不符來電發生機率與時間成正比。
- (B) 指數分佈為連續型，且用來描述「下一通來電要等多久」的時間間隔。
- (D) 常態分佈為連續型。

卜松分佈

Poisson Distribution

114 年 AI 應用規劃師 - 大數據處理分析與應用

考慮某生產線每小時出現瑕疵品的個數符合卜瓦松分佈 (Poisson Distribution)，已知平均每小時產生 5 個瑕疵品，附圖程式碼展示資料處理，請問下列敘述何者正確？

```
import numpy as np
from scipy.stats import poisson
lambda_poisson = 5
print(poisson.pmf(5, lambda_poisson))
```

- (A) `lambda_poisson = 5` 表示每小時最多 5 個瑕疵品；
- (B) `poisson.pmf(5, lambda_poisson)` 表示小於 5 個瑕疵品的機率；
- ✓ (C) 卜瓦松分佈的適用條件為事件彼此獨立，且平均發生率固定；
- (D) `poisson.cdf(10, 5)` 表示大於或等於 10 個瑕疵品的機率

【解題】

- (A) λ 應為每小時平均 5 個瑕疵品
- (B) `poisson.pmf(5, 5)` 表示剛好 5 個瑕疵品的機率
- (D) `poisson.cdf(10, 5)` 表示小於或等於 10 個瑕疵品的機率

吉尼不純度

吉尼不純度

Gini Impurity

- 衡量一樣本資料集中分類的混亂程度。
- 若樣本資料集 D 中有 K 個類別，則，吉尼不純度 Gini Impurity 的數學定義為：

$$Gini(D) = 1 - \sum_{k=1}^K P_k^2 \in \left[0, 1 - \frac{1}{K}\right],$$

其中

K : 總類別數

P_{k_0} : 第 k_0 類佔在樣本資料集中的比例

- 正則化吉尼不純度 Normalized Gini Impurity

$$Gini(D)_{norm} = \frac{Gini(D)}{1 - \frac{1}{K}} \in [0, 1].$$

- 應用

- 樹模型的節點特徵分割、特徵重要度的計算邏輯指標。
- 資料品質分析，例如：客群分類。

$Gini(D) \searrow 0$ 表示資料集中的類別佔比越單純。
(類別不平衡 Class Imbalance 的風險越高)

Data Set	$Gini(D)$	$Gini(D)_{norm}$
	$1 - \left[\left(\frac{5}{10} \right)^2 + \left(\frac{5}{10} \right)^2 \right] = 0.5$	$\frac{0.5}{1 - \frac{1}{2}} = 1$
	$1 - \left[\left(\frac{8}{10} \right)^2 + \left(\frac{2}{10} \right)^2 \right] = 0.32$	$\frac{0.32}{1 - \frac{1}{2}} = 0.64$
	$1 - \left[\left(\frac{10}{10} \right)^2 + \left(\frac{0}{10} \right)^2 \right] = 0$	$\frac{0}{1 - \frac{1}{2}} = 0$

吉尼不純度

Gini Impurity

114 年 AI 應用規劃師 - 大數據處理分析與應用

某組資料共 10 項標籤如下：

A, A, A, A, A, B, B, B, B, B

若該標籤僅有 A、B 兩種，請問這組資料的「正規化吉尼不純度 (Normalized Gini impurity)」為何？

(A)0；

(B)0.42；

(C)0.84；

✓ (D)1

【解題】

∵ 資料的標籤只有兩類

∴ $K = 2$

計算吉尼不純度

$$\begin{aligned} Gini &= 1 - \sum_{k=1}^2 P_k^2 \\ &= 1 - \left[\left(\frac{5}{10} \right)^2 + \left(\frac{5}{10} \right)^2 \right] = 0.5, \end{aligned}$$

因此，正規化吉尼不純度為

$$Gini_{norm} = \frac{Gini}{1 - \frac{1}{2}} = 1.$$

機率分佈與假設檢定 的實務應用


實務案例

問題情境

瑕疵的數量是否與某製程測項有關係？

Defect Count

Feature 1



一個產品可能會有多個瑕疵

分析流程

Step 1：數值欄位的敘述統計量

Step 2：瑕疵數量的資料分布

Step 3：製程測項的資料分布

Step 4：有無瑕疵與製程測項的相關性

實務案例

問題情境

瑕疵的數量是否與某製程測項有關係？

Defect Count

Feature 1

分析流程

Step 1：數值欄位的敘述統計量

114 年 AI 應用規劃師 - 大數據處理分析與應用

非空值的資料筆數 -->

平均值 -->

標準差 -->

最小值 -->

第一四分位數(Q1) -->

中位數 -->

第三四分位數(Q3) -->

最大值 -->

Python 程式碼

```
data = pd.read_excel(file_path)
data.describe()
```

	feature_1	defect_count
count	3036.000000	3036.000000
mean	1281.238472	0.060935
std	6.551717	0.352785
min	1252.000000	0.000000
25%	1277.000000	0.000000
50%	1282.000000	0.000000
75%	1285.000000	0.000000
max	1306.000000	7.000000

瑕疵數量
絕大多數為 0

實務案例

問題情境


瑕疵的數量是否與某製程測項有關係？

Defect Count

Feature 1

分析流程

Step 2：瑕疵數量的資料分布



● 右偏態

Positive Skew

右側長尾，樣本主要集中於左側。

眾數	中位數	平均值
<i>Mode</i>	<i>Median</i>	<i>Mean</i>
0	0	0.06

● 零膨脹

Zero-Inflation

0 的占比遠高於其他數值的占比。

● 過度離勢

Overdispersion

變異程度遠大於平均值。

平均值	標準差
<i>Mean</i>	<i>Standard Deviation</i>
0.06	0.35

實務案例

問題情境




瑕疵的數量是否與某製程測項有關係？

Defect Count

Feature 1

分析流程

Step 3：製程測項的資料分布



- 常態性檢定
Normality Test

D'Agostino's K^2 test 註：其他常態性檢定的方法

$P Value < 0.05$ 拒絕 H_0

⇒ 製程測項的資料，不具常態分配的特性。

實務案例

問題情境




瑕疵的數量是否與某製程測項有關係？

Defect Count

Feature 1



分析流程

Step 4：有無瑕疵與製程測項的相關性



D'Agostino's K^2 test $P\text{ Value} < 0.05$ 拒絕 H_0

⇒ 在無瑕疵的樣本中，製程測項不具常態分配的特性。



D'Agostino's K^2 test $P\text{ Value} < 0.05$ 拒絕 H_0

⇒ 在有瑕疵的樣本中，製程測項不具常態分配的特性。

實務案例

問題情境



瑕疵的數量是否與某製程測項有關係？

Defect Count

Feature 1

分析流程

Step 4：有無瑕疵與製程測項的相關性



Mann-Whitney U test $P\text{ Value} \approx 0.0003 < 0.05$ 拒絕 H_0

⇒ 兩組子樣本的分布不相同，表示製程測項在有瑕疵與無瑕疵之間具有顯著差異。

能力鑑定不只為考試通過

更是 AI 數據分析概念與能力的養成 🛠✎



<https://www.linkedin.com/in/yenlinwu/>



yenlinwu1112@gmail.com