

AI 應用規劃師能力鑑定(初級)
科目一(L1-人工智慧基礎概論)

1. (評鑑主題 1-人工智慧概念).....	4
1.1. 知識學習列表.....	4
1.1.1. AI 的分類(分析型 AI、預測型 AI、生成型 AI).....	6
1.1.2. 數據清洗：遺缺值、重複值、錯誤值、離群值.....	7
1.1.3. 數據轉換：數據格式轉換、數據類型轉換、數據正規化/標準化、數據離散化、數據縮減.....	8
1.1.4. 數據分析的方法(敘述性分析、探索性分析、診斷性分析及預測性分析).....	9
1.1.4.1. 各種統計常用的圖形及其主要作用和特性.....	12
1.1.4.2. 各種統計方法/指標與各種數據分析方法之關係.....	13
1.1.5. AI 演算法(線性搜尋、二分搜尋、深度優先搜尋 (DFS)、廣度優先搜尋 (BFS)、線性迴歸、邏輯迴歸、K-最近鄰演算法 (KNN)).....	14
1.1.6. 機器學習 (Machine Learning, ML) 基本概念.....	17
1.1.7. 深度學習 (Deep Learning, DL) 基本概念.....	19
1.1.7.1. 何謂模式崩潰 (Mode Collapse).....	23
1.1.8. 神經網絡 (Neural Networks) 基本結構與運作原理、激活函數(Sigmoid、Tanh、ReLU).....	24
1.1.9. 強化學習 (Reinforcement Learning).....	26
1.1.10. 生成式人工智慧：訓練階段(數據準備、模型選擇與搭建、模型訓練)、微調階段(特定任務優化、數據精調).....	29
1.1.10.1. 模型訓練的損失函數(均方誤差 MSE、交叉熵、絕對誤差)、優化器、迭代訓練.....	31
1.1.10.2. 數據增強技術在生成式人工智慧中有哪些作用？.....	33
1.1.11. 人工智慧的核心目標(自動化、智能化、自主性、適應性).....	34
1.1.12. 人工智慧的隱私與安全性挑戰.....	36
1.1.13. 人工智慧的倫理挑戰.....	37
1.1.14. AI 治理框架 (AI Governance Framework).....	38
1.1.15. 歐盟的 AI 政策與法規.....	40
2. L21(評鑑主題 1- No code / Low code 概念).....	43
2.1. 知識學習列表.....	44
2.2. L21-0*-No Code / Low Code 的基本概念(指引版).....	44
2.2.1. No Code / Low Code 的基本概念(指引版)-概念介紹.....	44
2.3. L21-1-No Code / Low Code 的基本概念.....	45
2.3.1. No Code / Low Code 的基本概念-概念介紹.....	45
2.3.1.1. 更多關於 No Code 和 Low Code 工具的技術細節.....	47
2.3.1.2. 有那些 No Code 和 Low Code 的工具，以表格列示產品特性、優缺...etc. No Code 和 Low Code 分開列表.....	48
2.4. L21-2-No Code / Low Code 的優勢與限制.....	49
2.4.1. No Code / Low Code 的優勢與限制-概念介紹.....	49
2.4.1.1. 在使用 No Code / Low Code 工具時，如何確保應用程式的安全性和性能？.....	50
2.4.1.2. 如何選擇適合自己需求的 No Code / Low Code 工具？.....	51
3. L22*(評鑑主題 2-生成式 AI 應用領域與工具使用)(考前指引版).....	51
3.1. 知識列表.....	51
3.2. L22*-1-生成式 AI 的基本概念與市場價值(指引版).....	53
3.2.1. 生成式 AI 的基本概念與市場價值(指引版)-考前指引之補充資訊-生成式 AI 的訓練數據處理.....	53
3.2.2. 生成式 AI 的基本概念與市場價值(指引版)-考前指引之補充資訊-生成式 AI 的推理機制.....	54

3.2.2.1.	在什麼情況下應該選擇使用頂部採樣而不是核採樣？	56
3.2.3.	生成式 AI 的基本概念與市場價值(指引版)-考前指引之補充資訊-生成式 AI 實際應用面臨的挑戰	56
3.3.	L22*-2-AI 工具的技術進化及發展(指引版)	57
3.3.1.	AI 工具的技術進化及發展(指引版)-概念介紹(僅補充)	57
3.3.1.1.	生成對抗網路 (GAN) 和變分自編碼器 (VAE) 有何不同？	58
4.	L22(評鑑主題 2-生成式 AI 應用領域與工具使用)	60
4.1.	知識學習列表	60
4.2.	L22-1-生成式 AI 應用領域與常見工具	61
4.2.1.	生成式 AI 應用領域與常見工具-概念介紹	61
4.3.	L22-2-如何善用生成式 AI 工具	68
4.3.1.	如何善用生成式 AI 工具-概念介紹	68
5.	L23(評鑑主題 3-生成式 AI 導入評估規劃)	75
5.1.	L23-1-生成式 AI 導入評估	76
5.1.1.	知識學習列表	76
5.1.2.	生成式 AI 導入評估-概念介紹	76
5.2.	L23-2-生成式 AI 導入規劃	77
5.2.1.	生成式 AI 導入規劃-考前指引之補充	77
5.2.2.	生成式 AI 導入規劃-概念介紹	78
5.3.	L23-3-生成式 AI 風險管理	79
5.3.1.	生成式 AI 風險管理-概念介紹	79

評鑑主題：

- 人工智慧概念
- 資料處理與分析概念
- 機器學習概念
- 鑑別式 AI 與生成式 AI 概念

➢ 評鑑主題 1-人工智慧概念

內容	備註	評鑑能力
AI 的定義與分類		評鑑應考者是否能掌握人工智慧的基本概念與應用領域，瞭解人工智慧的定義、基本理論和核心目標，及 AI 技術在隱私、安全性與倫理層面可能面臨的挑戰。
AI 治理概念	如框架、歐盟、數位發展部《公部門人工智慧應用參考手冊》、金融監督管理委員會《金融業運用人工智慧（AI）指引》等國內外相關政策法規等	

➢ 評鑑主題 2-資料處理與分析概念

內容	備註	評鑑能力
資料基本概念與來源	大數據、資料型態與結構，如數值型資料、文字資料、圖像資料等	評鑑應考者是否具備基本的資料處理知識，包括資料收集、清洗、分析和視覺化等過程，並能夠理解資料在 AI 模型中扮演的角色與作用。
資料整理與分析流程	如資料收集、清理、分析和呈現等	
資料隱私與安全		

➢ 評鑑主題 3-機器學習概念

內容	備註	評鑑能力
機器學習基本原理	機器學習基本原理與目的	評鑑應考者是否理解機器學習的基本原理及其在 AI 中的作用，並熟悉常見的機器學習方法及其應用。
常見的機器學習模型	機器學習模型與評估，如監督式學習、非監督式學習、半監督式學習、強化式學習。	

➢ 評鑑主題 4-鑑別式 AI 與生成式 AI 概念

內容	備註	評鑑能力
鑑別式 AI 與生成式 AI 的基本原理	基本原理、運用技術、目的與特性	評鑑應考者是否能夠區分鑑別式 AI 和生成式 AI 的特性，並理解生成式 AI 的概念、基本原理及其相關應用。
鑑別式 AI 與生成式 AI 的整合應用	應用場域與情境，如電腦視覺、語音辨識、生成技術等。	

1. (評鑑主題 1-人工智慧概念)

內容	備註	評鑑能力
AI 的定義與分類		評鑑應考者是否能掌握人工智慧的 基本概念與應用領域，瞭解人工智慧 的定義、基本理論和核心目標，及 AI 技 術在隱私、安全性與倫理層面可能面 臨的挑戰。
AI 治理概念	如框架、歐盟、數位發展部《公部門人工智慧 應用參考手冊》、金融監督管理委員會《金融業 運用人工智慧 (AI) 指引》等國內外相關政策 法規等	

1.1. 知識學習列表

➤ 評鑑內容 1-AI 的定義與分類

1. 人工智慧的定義與分類

- **人工智慧 (Artificial Intelligence, AI)** 的定義：**人工智慧 (Artificial Intelligence, AI)** 是指機器模擬人類智能的能力，能夠執行需要人類智能的任務，如學習、推理、問題解決和理解自然語言。
- 根據功能的分類：
 - **分析型 AI**：主要用於數據分析和模式識別。分析型 AI 是指能夠對數據進行分析和處理的機器或系統，如數據蒐集、數據清洗、數據分析（敘述性分析、探索性分析、診斷性分析和預測性分析）等。
 - **預測型 AI**：用於預測未來事件或趨勢。預測型 AI 是指能夠根據數據進行預測的機器或系統，如線性迴歸、邏輯迴歸和 K-最近鄰演算法 (K-Nearest Neighbors, KNN) 等。
 - **生成型 AI**：能夠創造新的內容，如圖像、音樂或文本。生成型 AI 是指能夠生成新內容的機器或系統，如生成對抗網路 (Generative Adversarial Network, GAN) 等。
- 根據能力的分類：
 - **弱人工智慧 (Narrow AI)**：專注於特定任務的 AI。又稱狹義人工智慧 (Narrow AI)，是指專門針對特定任務設計的 AI 系統。這類 AI 系統只能在特定領域內執行任務，無法具備通用智能。例如，語音助手（如 Siri 和 Google Assistant）和推薦系統（如 Netflix 和 Amazon 的推薦演算法）都是弱人工智慧的例子。
 - **強人工智慧 (General AI)**：具有像人類一樣的廣泛智能。又稱通用人工智慧 (General AI)，是指具備與人類相當的智能，能夠在各種不同的領域中執行任務的 AI 系統。強人工智慧能夠理解、學習和適應新情況，並能夠自主地進行推理和決策。目前，強人工智慧仍然是一個理論概念，尚未實現。
 - **超人工智慧 (Super AI)**：超越人類智能的 AI。超人工智慧是指超越人類智慧的 AI 系統，能夠在所有領域中表現出超越人類的能力。這類 AI 系統能夠自主地進行創新、解決複雜問題，並具備高度的自我意識。超人工智慧目前僅存在於科幻小說和理論研究中。

2. 人工智慧的核心目標：自動化 (Automation)、智能化 (Intelligence)、自主性 (Autonomy)、適應性 (Adaptability)

3. 人工智慧的基本理論

- 資料處理與分析：
 - **數據蒐集**：收集相關數據以進行分析。

- **數據清洗**：清理數據以確保其質量。
- **數據分析**：包括敘述性分析、探索性分析、診斷性分析及預測性分析。
- **演算法**：
 - **線性搜尋**：從資料集的第一個元素開始，逐個與目標元素進行比較。如果找到匹配的元素，則搜尋成功；如果遍歷整個資料集後仍未找到，則搜尋失敗。
 - **二分搜尋**：首先將資料集的中間元素與目標元素進行比較。如果目標元素等於中間元素，則搜尋成功；如果目標元素小於中間元素，則在資料集的左半部分繼續搜尋；如果目標元素大於中間元素，則在資料集的右半部分繼續搜尋。重複以上步驟，直到找到目標元素或搜尋範圍為空。
 - **深度優先搜尋 (DFS)**：從起始節點開始，沿著一條路徑儘可能深入地探索所有可能的路徑。
 - **廣度優先搜尋 (BFS)**：從起始節點開始，首先訪問其所有相鄰的節點，逐層探索所有可能的路徑。
 - **線性迴歸**：預測**數值型**結果。
 - **邏輯迴歸**：預測**分類型**結果。
 - **K-最近鄰演算法 (KNN)**：基於**鄰近數據點**進行分類。
- **根據技術和應用領域的分類**：
 - 機器學習 (Machine Learning, ML) (1.1.6)
 - 深度學習 (Deep Learning, DL) (1.1.7)
 - 自然語言處理 (Natural Language Processing, NLP)
 - 計算機視覺 (Computer Vision, CV)：計算機視覺是 AI 的一個分支，專注於讓機器能夠從圖像和視頻中提取信息。計算機視覺技術應用於人臉識別、自動駕駛、醫學影像分析等領域。
 - 機器人技術 (Robotics)
 - 專家系統 (Expert Systems)：專家系統是基於知識庫和推理引擎的 AI 系統，模擬人類專家的決策過程。專家系統應用於醫療診斷、金融分析和故障診斷等領域。
- 機器學習 (Machine Learning, ML) (1.1.6)
 - 機器學習的基本概念
 - **監督式學習**：使用標記數據進行訓練。
 - **非監督式學習**：使用未標記數據進行訓練。
 - **強化學習 (RL)**：通過獎勵和懲罰進行學習。
- 深度學習 (Deep Learning, DL)
 - 深度學習的基本概念、神經網絡的基本結構與運作原理
 - **卷積神經網路 (CNN)**：主要用於**圖像識別**。
 - **循環神經網路 (RNN)**：主要用於**序列數據分析**。
 - **生成對抗網路 (GAN)**：用於**生成新內容**。

4. 人工智慧的應用領域

- **醫療保健** AI 技術在醫療保健領域的應用包括疾病診斷、個性化治療方案、醫學影像分析和藥物研發等。
- **金融** AI 在金融領域的應用包括風險管理、欺詐檢測、投資分析和自動交易等。
- **零售** AI 在零售領域的應用包括個性化推薦、庫存管理、需求預測和客戶服務等。
- **製造** AI 在製造領域的應用包括生產自動化、質量控制、預測性維護和供應鏈優化等。

- **交通運輸** AI 在交通運輸領域的應用包括自動駕駛、交通管理、路線規劃和物流優化等。
- **娛樂** AI 在娛樂領域的應用包括內容推薦、遊戲設計、虛擬現實和音樂生成等。

5. 人工智慧的隱私與安全性挑戰

- 數據隱私 (Data Privacy)
- 資料安全 (Data Security)
- 漏洞與攻擊 (Vulnerabilities and Attacks)

6. 人工智慧的倫理挑戰

- 偏見與歧視 (Bias and Discrimination)
- 透明度 (Transparency)
- 責任歸屬 (Accountability)
- 工作取代 (Job Displacement)

➤ 評鑑內容 2- AI 治理概念

- **AI 治理框架 (AI Governance Framework)**
- 歐盟的 AI 政策與法規
- 台灣數位發展部《公部門人工智慧應用參考手冊》
- 台灣金融監督管理委員會《金融業運用人工智慧 (AI) 指引》

1.1.1. AI 的分類(分析型 AI、預測型 AI、生成型 AI)

人工智慧的分類：分析型 AI、預測型 AI、生成型 AI

人工智慧 (Artificial Intelligence · AI) 是一個廣泛的領域，涵蓋了許多不同的技術和應用。為了更好地理解人工智慧，我們可以將其分為三大類型：分析型 AI、預測型 AI 和生成型 AI。這篇文章將詳細介紹這三種類型的 AI，並提供相關示例和實施步驟，幫助對此領域完全陌生的讀者理解這些概念。

分析型 AI

分析型 AI 主要用於數據分析和模式識別。這種類型的 AI 能夠從大量數據中提取有價值的資訊，並幫助我們做出更好的決策。分析型 AI 的核心在於其強大的數據處理能力和演算法。

示例：顧客行為分析

假設我們有一家零售公司，想要了解顧客的購物行為，以便提供更好的服務和產品。分析型 AI 可以幫助我們完成這項任務。首先，我們需要收集顧客的購物數據，包括購買的商品、購買時間、購買頻率等。接下來，我們可以使用數據清洗技術，確保數據的質量。然後，我們可以使用敘述性分析和探索性分析技術，找出顧客的購物模式。例如，我們可以發現某些商品在特定時間段的銷量較高，或者某些顧客更喜歡購買特定類型的商品。最後，我們可以根據這些分析結果，制定相應的營銷策略，提升顧客滿意度和銷售額。

實施步驟：

1. **數據蒐集**：收集顧客的購物數據。
2. **數據清洗**：清理數據，確保其質量。
3. **數據分析**：使用敘述性分析和探索性分析技術，找出顧客的購物模式。
4. **制定策略**：根據分析結果，制定相應的營銷策略。

預測型 AI

預測型 AI 主要用於預測未來事件或趨勢。這種類型的 AI 能夠根據歷史數據，預測未來的情況，幫助我們提前做出準備。預測型 AI 的核心在於其強大的預測能力和演算法。

示例：股票價格預測

假設我們有一家投資公司，想要預測股票的未來價格，以便做出更好的投資決策。預測型 AI 可以幫助我們完成這項任務。首先，我們需要收集股票的歷史價格數據，包括開盤價、收盤價、最高價、最低價等。接下來，我們可以使用數據清洗技術，確保數據的質量。然後，我們可以使用預測性分析技術，建立股票價格預測模型。例如，我們可以使用線性迴歸演算法，根據歷史價格數據，預測未來的股票價格。最後，我們可以根據預測結果，制定相應的投資策略，提升投資回報。

實施步驟：

1. **數據蒐集**：收集股票的歷史價格數據。
2. **數據清洗**：清理數據，確保其質量。
3. **建立模型**：使用預測性分析技術，建立股票價格預測模型。
4. **制定策略**：根據預測結果，制定相應的投資策略。

生成型 AI

生成型 AI 能夠創造新的內容，如圖像、音樂或文本。這種類型的 AI 能夠根據訓練數據，生成與訓練數據相似但又不完全相同的新的數據。生成型 AI 的核心在於其強大的生成能力和演算法。

示例：音樂生成

假設我們有一家音樂公司，想要生成新的音樂作品，以便吸引更多的聽眾。生成型 AI 可以幫助我們完成這項任務。首先，我們需要收集大量的音樂數據，包括不同風格的音樂作品。接下來，我們可以使用數據清洗技術，確保數據的質量。然後，我們可以使用生成對抗網路（GAN）技術，訓練音樂生成模型。例如，我們可以根據訓練數據，生成新的音樂作品，這些作品既有訓練數據的風格，又有創新的元素。最後，我們可以根據生成的音樂作品，制定相應的營銷策略，吸引更多的聽眾。

實施步驟：

1. **數據蒐集**：收集大量的音樂數據。
2. **數據清洗**：清理數據，確保其質量。
3. **訓練模型**：使用生成對抗網路（GAN）技術，訓練音樂生成模型。
4. **制定策略**：根據生成的音樂作品，制定相應的營銷策略。

1.1.2. 數據清洗：遺缺值、重複值、錯誤值、離群值

數據清洗：遺缺值、重複值、錯誤值和離群值處理

數據清洗（Data Cleaning）是數據分析過程中的重要步驟，旨在提高數據的質量和一致性，從而提升分析結果的準確性。數據清洗包括處理遺缺值（Missing Value）、重複值（Duplicate Value）、錯誤值（Error/Invalid Value）和離群值（Outlier Value）。本文將詳細介紹這些概念，並提供相關示例和實施步驟，幫助對此領域完全陌生的讀者理解這些概念。

遺缺值（Missing Value）處理

遺缺值是指數據集中缺少某些值的情況，可能是由於數據收集過程中的錯誤或遺漏。處理遺缺值的方法包括填補遺缺值和刪除記錄。

填補遺缺值：填補遺缺值是指使用某些方法來填補缺失的數據，以保持數據集的完整性。常見的填補方法包括使用**平均值**、**中位數**或**眾數**來填補缺失值。

刪除記錄：刪除記錄是指刪除包含遺缺值的數據記錄，以確保數據集的質量。這種方法適合遺缺值較多且無法填補的情況。

重複值 (Duplicate Value) 處理

重複值是指數據集中存在多個相同的數據記錄，可能是由於數據收集過程中的錯誤或重複輸入。處理重複值的方法包括識別重複值和刪除重複值。

識別重複值：識別重複值是指使用某些方法來識別數據集中的重複記錄。常見的識別方法包括使用**唯一標識符或數據匹配**技術。

刪除重複值：刪除重複值是指刪除數據集中的重複記錄，以確保數據集的質量。這種方法適合重複值較多且無法合併的情況。

錯誤值 (Error/Invalid Value) 處理

錯誤值是指數據集中存在不正確或無效的數據記錄，可能是由於數據收集過程中的錯誤或輸入錯誤。處理錯誤值的方法包括識別錯誤值和修正錯誤值。

識別錯誤值：識別錯誤值是指使用某些方法來識別數據集中的錯誤記錄。常見的識別方法包括使用**數據範圍檢查和數據一致性檢查**。

修正錯誤值：修正錯誤值是指修正數據集中的錯誤記錄，以確保數據集的質量。**這種方法適合錯誤值較少且可以修正的情況**。

離群值 (Outlier Value) 處理

離群值是指數據集中存在異常或極端的數據記錄，可能是由於數據收集過程中的錯誤或特殊情況。處理離群值的方法包括識別離群值和處理離群值。

識別離群值：識別離群值是指使用某些方法來識別數據集中的異常記錄。常見的識別方法包括使用**統計方法和機器學習技術(如支持向量機 SVM)**。

示例：銷售數據

假設我們有一家零售公司，最近發現銷售數據中有一些離群值。識別離群值可以幫助我們保持數據集的質量。首先，我們需要收集銷售數據，包括銷售額和銷售時間。接下來，我們可以使用統計方法來識別異常的銷售額，確保數據集的質量。

實施步驟：

- 1. **數據蒐集：**收集銷售數據，包括銷售額和銷售時間。
- 2. **離群值識別：**使用統計方法來識別異常的銷售額。

處理離群值：處理離群值是指處理數據集中的異常記錄，以確保數據集的質量。**這種方法適合離群值較多且無法修正的情況**。

結論

數據清洗是數據分析過程中的重要步驟，旨在提高數據的質量和一致性。遺缺值、重複值、錯誤值和離群值是數據清洗中的四個主要問題。通過理解這些問題的基本概念和實施步驟，我們可以更好地進行數據清洗，提升分析結果的準確性。

1.1.3. 數據轉換：數據格式轉換、數據類型轉換、數據正規化/標準化、數據離散化、數據縮減

已註解 [SC1]: 參 #初一教材補充

數據轉換：數據格式轉換、數據類型轉換、數據正規化/標準化、數據離散化、數據縮減

數據轉換 (Data Transformation) 是數據分析過程中的重要步驟，旨在提高數據的質量和一致性，從而提升分析結果的準確性。數據轉換包括數據格式轉換 (Data Format Transformation)、數據類型轉換 (Data Type Conversion)、數據正規化/標準化 (Data Normalization/Standardization)、數據離散化 (Data Discretization) 和數據縮減 (Data Reduction)。本文將詳細介紹這些概念，並提供相關示例和實施步驟，幫助對此領域完全陌生的讀者理解這些概念。

數據格式轉換 (Data Format Transformation)

數據格式轉換是指將數據從一種格式轉換為另一種格式，以便於分析和處理。常見的數據格式包括 CSV、JSON、XML 等。數據格式轉換的目標是確保數據的可讀性和一致性。

數據類型轉換 (Data Type Conversion)

數據類型轉換是指將數據從一種類型轉換為另一種類型，以便於分析和處理。常見的數據類型包括整數、浮點數、字符串等。數據類型轉換的目標是確保數據的可讀性和一致性。

數據正規化/標準化 (Data Normalization/Standardization)

數據正規化/標準化是指將數據轉換為統一的範圍或尺度，以便於分析和處理。數據正規化(Min-Max 標準化)的目標是將數據轉換為 0 到 1 之間的範圍，數據標準化(Zero-Score)的目標是將數據轉換為均值為 0、標準差為 1 的範圍。

數據離散化 (Data Discretization)

數據離散化是指將連續數據轉換為離散數據(例如：將年齡分為青年、中年、老年)，此方法稱為分箱 (Binning)，以便於分析和處理。常見的數據離散化方法包括等寬離散化和等頻離散化。數據離散化的目標是將連續數據轉換為有限的離散值。

數據縮減 (Data Reduction)

數據縮減是指將數據集的維度或大小縮減，以便於分析和處理。常見的數據縮減方法包括主成分分析 (Principal Components Analysis, PCA)。數據縮減的目標是保留數據中的重要信息，同時減少數據集的維度或大小。

1.1.4. 數據分析的方法(敘述性分析、探索性分析、診斷性分析及預測性分析)

數據分析：敘述性分析、探索性分析、診斷性分析及預測性分析

數據分析是一個重要的過程，幫助我們從大量數據中提取有價值的資訊，並做出更好的決策。數據分析可以分為四個主要類型：敘述性分析、探索性分析、診斷性分析及預測性分析。這篇文章將詳細介紹這四種類型的數據分析，並提供相關示例和實施步驟，幫助對此領域完全陌生的讀者理解這些概念。

敘述性分析(Descriptive Analysis) (了解狀況)

敘述性分析是數據分析的第一步，旨在描述數據的基本特徵。這種類型的分析主要用於了解數據的分佈情況、集中趨勢和變異程度。敘述性分析通常使用統計指標和圖表來呈現數據。

示例：顧客年齡分佈

假設我們有一家零售公司，想要了解顧客的年齡分佈，以便制定更好的營銷策略。敘述性分析可以幫助我們完成這項任務。首先，我們需要收集顧客的年齡數據。接下來，我們可以使用統計指標，如平均年齡、中位數和標準差，來描述顧客的年齡分佈。然後，我們可以使用圖表，如直方

圖和盒形圖，來視覺化顧客的年齡分佈。最後，我們可以根據這些分析結果，制定相應的營銷策略，吸引不同年齡段的顧客。

實施步驟：（詳指引 3-7 ~ 3-8）

1. **數據蒐集：**收集顧客的年齡數據。
2. **統計指標：**計算平均值、中位數、百分位數和標準差。
3. **圖表視覺化：**使用直方圖(Histogram)、散佈圖(Scatter plot)、折線圖(Line chart)和盒形圖(Box Plot)來視覺化顧客的年齡分佈。
4. **制定策略：**根據分析結果，制定相應的營銷策略。

探索性分析(Exploratory Analysis) (找出關係/關連)

探索性分析旨在**無需預設假設**的情況下，透過多角度探索數據，深入了解數據的結構和模式，並發現數據中的**異常值和關聯性**。這種類型的分析通常使用圖表和統計方法來**探索數據**。

示例：顧客購物行為

假設我們有一家零售公司，想要了解顧客的購物行為，以便提供更好的服務和產品。探索性分析可以幫助我們完成這項任務。首先，我們需要收集顧客的購物數據，包括購買的商品、購買時間、購買頻率等。接下來，我們可以使用散佈圖和熱圖，來視覺化顧客的購物行為。然後，我們可以使用統計方法，如相關分析和聚類分析，來探索顧客的購物模式。例如，我們可以發現某些商品在特定時間段的銷量較高，或者某些顧客更喜歡購買特定類型的商品。最後，我們可以根據這些分析結果，制定相應的營銷策略，提升顧客滿意度和銷售額。

實施步驟：（詳指引 3-9 ~ 3-10）

1. **數據蒐集：**收集顧客的購物數據。
2. **圖表視覺化：**使用散佈圖(Scatter Plot Matrix)、熱圖(Heatmap)、平行坐標圖(Parallel Coordinates Plot)、盒形圖(Box Plot)來視覺化顧客的購物行為。
3. **統計方法：**使用相關分析(如皮爾森相關係數 Pearson Correlation Coefficient)、聚類分析(如 K 均值聚類 K-Means、層次聚類 Hierarchical Clustering)、主成分分析(Principal Component Analysis, PCA)、異常檢測(Anomaly Detection，如離群值或罕見模式)來探索顧客的購物模式。
4. **制定策略：**根據分析結果，制定相應的營銷策略。

此類分析通常基於敘述性分析的結果，進一步深入了解數據背後的邏輯與影響因素

診斷性分析(Diagnostic Analysis) (找出原因)

診斷性分析旨在找出數據中的特定現象或因果關係，並解釋數據中的異常情況。此類分析通常基於敘述性分析的結果，進一步深入了解數據背後的邏輯與影響因素。

示例：銷售額下降原因

假設我們有一家零售公司，最近發現銷售額下降，想要找出原因並制定相應的對策。診斷性分析可以幫助我們完成這項任務。首先，我們需要收集銷售數據，包括銷售額、銷售時間、銷售地點等。接下來，我們可以使用統計方法，如回歸分析和因果分析，來找出銷售額下降的原因。例如，我們可以發現某些地區的銷售額下降，可能是因為當地競爭加劇或者顧客需求變化。然後，我們可以使用機器學習技術，如決策樹和隨機森林，來診斷銷售額下降的具體原因。最後，我們可以根據診斷結果，制定相應的對策，提升銷售額。

實施步驟：（詳指引 3-10）

1. **數據蒐集：**收集銷售數據。
2. **統計方法：**使用回歸分析和因果分析來找出銷售額下降的原因。**鑽取/向下分析(Dill-down Analysis)**、**關聯分析(Association Analysis)**、**因果分析(Causal Analysis)**。
3. **機器學習技術：**使用**決策樹**和**隨機森林**來診斷銷售額下降的具體原因。

4. 制定對策：根據診斷結果，制定相應的對策。

鑽取/向下分析 (Drill-down Analysis)

實施步驟：

1. 數據蒐集：收集銷售數據，包括銷售額、銷售時間、銷售地點等。
2. 高層次分析：從高層次的銷售額數據開始分析。
3. 深入分析：逐步深入到更詳細的數據層次，例如特定地區、特定時間段的銷售額。
4. 層次結構和分層分析：使用層次結構和分層分析技術，找出銷售額下降的根本原因。
5. 制定對策：根據分析結果，制定相應的對策。

關聯分析 (Association Analysis)

實施步驟：

1. 數據蒐集：收集顧客的購物數據，包括購買的商品、購買時間、購買頻率等。
2. 統計方法：使用相關分析和聚類分析，找出顧客購物行為中的關聯性。
3. 機器學習技術：使用決策樹和隨機森林，進一步分析顧客購物行為中的關聯性。
4. 制定策略：根據分析結果，制定相應的營銷策略。

因果分析 (Causal Analysis)

實施步驟：

1. 數據蒐集：收集顧客數據，包括顧客流失與否和影響顧客流失的自變量。
2. 統計方法：使用回歸分析和因果分析，找出顧客流失的原因。
3. 機器學習技術：使用決策樹和隨機森林，進一步分析顧客流失的具體原因。
4. 制定對策：根據分析結果，制定相應的對策。

預測性分析(Predictive Analysis)

預測性分析旨在根據歷史數據，預測未來的情況，幫助我們提前做出準備。這種類型的分析通常使用統計方法和機器學習技術來預測數據。

示例：銷售額預測

假設我們有一家零售公司，想要預測未來的銷售額，以便制定更好的營銷策略。預測性分析可以幫助我們完成這項任務。首先，我們需要收集歷史銷售數據，包括銷售額、銷售時間、銷售地點等。接下來，我們可以使用統計方法，如時間序列分析和回歸分析，來建立銷售額預測模型。例如，我們可以使用線性迴歸演算法，根據歷史銷售數據，預測未來的銷售額。然後，我們可以使用機器學習技術，如長短期記憶 (LSTM) 和支持向量機 (SVM)，來提升預測模型的準確性。最後，我們可以根據預測結果，制定相應的營銷策略，提升銷售額。

實施步驟：(詳指引 3-10 ~ 3-11)

1. 數據蒐集：收集歷史銷售數據。
2. 統計方法/模型：使用[迴歸模型](#)(Regression Models，線性迴歸、多元迴歸、邏輯迴歸)、[分類模型](#)(Classification Models，決策樹、隨機森林、支援向量機 SVM、深度學習如神經網路等)、[時間序列模型](#)(Time Series Models，ARIMA、SARIMA、使用長短期記憶 LSTM)、和[集成學習方法](#)(Ensemble Methods)來建立銷售額預測模型。
3. 制定策略：根據預測結果，制定相應的營銷策略。

自回歸整合移動平均模型(AutoRegressive Integrated Moving Average · ARIMA)

ARIMA 模型是一種常用的[時間序列模型](#)，用於分析和預測隨時間變化的數據。ARIMA 模型結合了自回歸 (AR)、移動平均 (MA) 和差分 (I) 技術，能夠捕捉數據中的趨勢和季節性。

差分 (1) 例子：以今天的數字減昨天的數字讓數據較穩定。所謂的"穩定"，指的是：

	第一天	第二天	第三天	第四天	
來客量	100	120	140	160	數字每天是在浮動的
差分		20	20	20	數字是穩定的

實施步驟：

1. 數據蒐集：收集歷史銷售數據，包括銷售額和時間。
2. 差分技術：去除數據中的趨勢和季節性。
3. 自回歸和移動平均技術：建立 ARIMA 模型，來預測未來的銷售額。
4. 制定策略：根據預測結果，制定相應的營銷策略。

季節性自回歸整合移動平均模型(Seasonal AutoRegressive Integrated Moving Average · SARIMA)

實施步驟：

1. 數據蒐集：收集歷史銷售數據，包括銷售額和時間。
2. 季節性差分技術：去除數據中的季節性。
3. 季節性自回歸和季節性移動平均技術：建立 SARIMA 模型，來預測未來的銷售額。
4. 制定策略：根據預測結果，制定相應的營銷策略。

長短期記憶(Long Short-Term Memory · LSTM)

LSTM 是一種深度學習模型，用於分析和預測隨時間變化的數據。LSTM 模型能夠捕捉數據中的長期和短期依賴關係，並且能夠處理具有季節性和趨勢的數據。

實施步驟：

1. 數據蒐集：收集歷史股票價格數據，包括開盤價、收盤價、最高價、最低價等。
2. 數據清洗技術：確保數據的質量。
3. LSTM 模型：訓練股票價格預測模型，來預測未來的股票價格。
4. 制定策略：根據預測結果，制定相應的投資策略。

結論

敘述性分析、探索性分析、診斷性分析及預測性分析是數據分析的四個主要類型。敘述性分析旨在描述數據的基本特徵，探索性分析旨在深入了解數據的結構和模式，診斷性分析旨在找出數據中的因果關係，預測性分析旨在根據歷史數據，預測未來的情況。這些數據分析技術在各個領域都有廣泛的應用，並且正在不斷發展和進步。

1.1.4.1. 各種統計常用的圖形及其主要作用和特性

圖形	主要作用	特性	應用比較	敘	探	診	預
直方圖 (Histogram)	顯示資料的分布情況	將資料分成多個區間，用長條形的高度表示每個區間內資料的頻率	適合用來估計資料的分布，能清楚顯示資料的集中程度和分散程度	Y	Y		

圖形	主要作用	特性	應用比較	敘	探	診	預
散佈圖(Scatter plot)	顯示兩個變數之間的關係	用點來表示每個資料點的位置，適合分析資料的相關性	雖然不直接顯示資料的分布，但可以通過觀察點的分布情況來推測資料的分布	Y	Y	Y	
雷達圖(Radar chart)	比較多個變數之間的關係	用多邊形表示不同個體在多個維度上的表現	不適合用來估計資料的分布，主要用來比較多個變數之間的關係		Y		
四分位數(Quartile)	描述資料的分布情況	將資料分成四個部分，每個部分包含相同數量的資料點	提供有關資料分布的有用信息，例如資料的集中程度和分散程度	Y		Y	
箱型圖(Box plot)	顯示資料的集中趨勢和分散情況	用箱型表示資料的四分位數和中位數，並顯示資料的異常值 適合用於資料分布不均勻 適合用於資料包含極端值	適合用來比較不同資料集的分布情況，能清楚顯示資料的集中趨勢和分散情況	Y	Y	Y	
折線圖(Line chart)	顯示資料隨時間的變化	用線段連接每個資料點，適合顯示資料的趨勢	適合用來分析資料隨時間的變化，能清楚顯示資料的趨勢	Y	Y		Y
圓餅圖(Pie chart)	顯示資料的比例分布	用圓餅的切片表示每個部分的比例	適合用來顯示資料的比例分布，但不適合顯示資料的分布情況	Y			
散佈圖矩陣(Scatter Plot Matrix)	顯示多個變數之間的關係	用多個散佈圖組成的矩陣來顯示多個變數之間的關係	適合用來分析多個變數之間的相關性	Y	Y	Y	
熱圖(Heatmap)	顯示資料的密度和分布情況	用顏色來表示資料的密度和分布情況 適合用於資料分布不均勻 適合用於資料包含極端值	適合用來顯示資料的集中程度和分散程度	Y	Y	Y	
平行坐標圖(Parallel Coordinates Plot)	顯示多個變數之間的關係	用多條平行線來表示不同變數之間的關係	適合用來比較多個變數之間的關係		Y	Y	


1.1.4.2. 各種統計方法/指標與各種數據分析方法之關係

此表所列的統計方法/指標，除了眾數(Mode)外，均主要用於處理數值型資料，而不是類別型資料。

統計方法/指標	定義	資料不均勻	有極端值	敘	探	診	預
平均值 (Mean)	資料的平均值			Y			Y
中位數 (Median)	資料的中間值	Y	Y	Y			

統計方法/指標	定義	資料不均勻	有極端值	敘	探	診	預
眾數 (Mode)	資料中出現頻率最高的值	Y		Y			
百分位數 (Percentile)	資料在某個特定百分比位置上的值	Y	Y	Y		Y	
標準差 (Standard Deviation)	資料的分散程度			Y		Y	
相關分析之皮爾森相關係數 (Pearson Correlation Coefficient)	測量兩個變數之間的線性相關性				Y	Y	
K-Means	一種聚類算法，用來將資料分成 K 個群組				Y	Y	
層次聚類 (Hierarchical Clustering)	一種聚類算法，通過建立層次樹來分群				Y	Y	
主成分分析 (PCA)	一種降維技術，用來減少資料的維度				Y	Y	
異常檢測 (Anomaly Detection)	用來識別資料中的異常值或罕見模式	Y	Y		Y	Y	

1.1.4.1. 平均值(Mean)、中位數(Median)及眾數(Mod) 與 正偏態(右偏態)、負偏態(左偏態)



1.1.5. [AI 演算法\(線性搜尋、二分搜尋、深度優先搜尋 \(DFS \)、廣度優先搜尋 \(BFS \)、線性迴歸、邏輯迴歸、K-最近鄰演算法 \(KNN\)\)](#)

線性搜尋(Linear Search · LS)

線性搜尋是一種基本的搜尋演算法，用於在未排序的數據集中逐一檢查每個元素，直到找到目標元素或遍歷完所有元素。這種演算法的時間複雜度為 $O(n)$ ，其中 n 是數據集的大小。

實施步驟：

1. **數據蒐集**：收集顧客名單。
2. **逐一檢查**：**逐一檢查**名單中的每個顧客，直到找到目標顧客或遍歷完所有顧客。

二分搜尋(Binary Search · BS)

二分搜尋是一種高效的搜尋演算法，用於在**排序好的數據集**中進行快速搜尋。這種演算法的時間複雜度為 $O(\log n)$ ，其中 n 是數據集的大小。二分搜尋通過反覆將搜尋範圍縮小一半，直到找到目標元素或確定目標元素不存在。

實施步驟：

1. **數據蒐集**：收集並排序商品名單。
2. **二分搜尋**：使用**二分搜尋**演算法，反覆將搜尋範圍縮小一半，直到找到目標商品或確定目標商品不存在。

深度優先搜尋(Depth-First Search · DFS)

深度優先搜尋 (DFS) 是一種圖形搜尋演算法，用於探索所有可能的路徑。

DFS 並不適合拿來找最短路徑，找最短路徑應用 BFS，或 BFS 改進版的 Dijkstra。

DFS 適合用來網路爬蟲(先爬取某一條連結路徑直到底，再....)

實施步驟：

1. **數據蒐集**：收集城市地圖數據，包括節點和邊。
2. **DFS**：使用 DFS 演算法，深入探索每個分支，直到找到最短路徑或遍歷完所有路徑。

廣度優先搜尋(Breadth-First Search · BFS)

廣度優先搜尋 (BFS) 是一種圖形搜尋演算法，用於逐層探索所有可能的路徑。

實施步驟：

1. **數據蒐集**：收集城市地圖數據，包括節點和邊。
2. **BFS**：使用 BFS 演算法，逐層探索每個分支，直到找到最短路徑或遍歷完所有節點。

線性迴歸(Linear Regression · LR)

線性迴歸是一種統計方法，用於**預測數值型**結果。線性迴歸通過建立自變量和因變量之間的線性關係，來預測因變量的值。

自變量：是因，是 input。

因變量：是果，是 output。又稱應變量。

實施步驟：

1. **數據蒐集**：收集歷史銷售數據，包括銷售額和影響銷售額的自變量。
2. **線性迴歸**：使用線性迴歸演算法，建立自變量和因變量之間的線性關係，來預測未來的銷售額。

邏輯迴歸(Logistic Regression · LR)

邏輯迴歸是一種統計方法，用於**預測分類型**結果。

實施步驟：

1. **數據蒐集**：收集顧客數據，包括顧客流失與否和影響顧客流失的自變量。
2. **邏輯迴歸**：使用邏輯迴歸演算法，建立自變量和因變量之間的邏輯關係，來預測顧客流失。

K-最近鄰演算法(K-Nearest Neighbors · KNN)

K-最近鄰演算法 (KNN) 是一種分類演算法，用於基於鄰近數據點進行分類。KNN 通過計算目標數據點與鄰近數據點之間的距離，來決定目標數據點的類別。在圖像識別方面具有很大的潛力。

這種演算法基於鄰近數據點進行分類，能夠有效地處理高維度數據，這使得它在圖像識別領域中非常有用。只需要選擇適當的距離度量方法 (如**歐氏距離**或**曼哈頓距離**)，並設置 **K 值** (鄰近數據點的數量)，即可進行圖像分類。根據鄰近數據點的類別，準確地分類目標數據點。這使得它在許多圖像識別任務中表現出色，如手寫字母識別、人臉識別和物體識別等。

示例：手寫字母識別

假設我們有一個手寫字母數據集，想要識別手寫字母。KNN 演算法可以幫助我們完成這項任務。首先，我們需要收集手寫字母數據，包括每個字母的像素值。接下來，我們可以使用 KNN 演算法，計算目標字母與鄰近字母之間的距離，並根據鄰近字母的類別，來識別目標字母。

實施步驟：

1. **數據蒐集：**收集手寫字母數據，包括每個字母的像素值。
2. **距離度量：**選擇適當的距離度量方法，如歐氏距離或曼哈頓距離。
3. **設置 K 值：**設置 K 值（鄰近數據點的數量）。
4. **KNN 演算法：**使用 KNN 演算法，計算目標字母與鄰近字母之間的距離，並根據鄰近字母的類別，來識別目標字母。

1.1.6. 機器學習 (Machine Learning, ML) 基本概念

機器學習 (Machine Learning, ML) 基本概念

機器學習是一種數據分析方法，通過建立數學模型來預測或分類數據。這些模型是基於訓練數據集 (Training Dataset) 來學習的，訓練數據集包含已知輸入和對應的輸出。機器學習的目標是找到一個模型，使其能夠對新數據進行準確的預測或分類。

機器學習可以根據學習方式分為三大類：監督學習 (Supervised Learning)、非監督學習 (Unsupervised Learning) 和強化學習 (Reinforcement Learning)。

1. 監督學習 (Supervised Learning)：

- 在監督學習中，模型是基於帶有標籤的訓練數據進行學習的。標籤是指數據的已知輸出。例如，給定一組房屋的特徵 (如面積、房間數量等) 和對應的價格，模型可以學習如何預測新房屋的價格。
- 常見的監督學習算法包括 [線性回歸 \(Linear Regression \)](#)、[支持向量機 \(Support Vector Machine, SVM \)](#) 和 [神經網絡 \(Neural Networks \)](#)。

2. 非監督學習 (Unsupervised Learning)：

- 在非監督學習中，模型是基於未標籤的數據進行學習的。目標是發現數據中的隱含結構或模式。例如，將客戶分群以便於市場營銷。
- 常見的非監督學習算法包括 [K 均值聚類 \(K-means Clustering \)](#) 和 [主成分分析 \(Principal Component Analysis, PCA \)](#)。

3. 強化學習 (Reinforcement Learning)：

- 強化學習是一種基於獎勵和懲罰的學習方法。模型 (或稱為代理人，Agent) 通過與環境互動來學習最佳行動策略，以最大化累積獎勵。例如，自動駕駛汽車學習如何在道路上行駛。
- 常見的強化學習算法包括 [Q 學習 \(Q-learning \)](#) 和 [深度強化學習 \(Deep Reinforcement Learning \)](#)。

機器學習的基本流程

機器學習的基本流程可以分為以下幾個步驟：

1. 數據收集 (Data Collection)：

- 收集相關的數據是機器學習的第一步。數據可以來自各種來源，如數據庫、網絡爬蟲、傳感器等。

2. 數據預處理 (Data Preprocessing)：

- 數據通常需要進行清洗和轉換，以便於模型的訓練。例如，處理缺失值、標準化數據、轉換類別變量等。

3. 特徵選擇 (Feature Selection)：

- 從數據中選擇對模型預測有用的特徵。特徵是數據的屬性或變量，如房屋的面積、房間數量等。

4. 模型訓練 (Model Training)：

- 使用訓練數據來訓練模型。模型會學習數據中的模式和關係，以便於對新數據進行預測。

5. 模型評估 (Model Evaluation)：

- 使用測試數據來評估模型的性能。常見的評估指標包括準確率 (Accuracy)、精確率 (Precision)、召回率 (Recall) 等。

6. 模型調整 (Model Tuning)：

- 根據評估結果調整模型的參數，以提高其性能。這個過程稱為超參數調整 (Hyperparameter Tuning)。

7. 模型部署 (Model Deployment) :

- 將訓練好的模型應用到實際場景中，如預測新數據、提供決策支持等。

機器學習的挑戰

儘管機器學習有很多優勢，但也面臨一些挑戰：

1. 數據質量 (Data Quality) :

- 機器學習模型的性能高度依賴於數據的質量。如果數據不完整或有噪音，模型的預測結果可能不準確。

2. 過擬合 (Overfitting) :

- 過擬合是指模型在訓練數據上表現很好，但在新數據上表現不佳。這通常是因為模型過於複雜，學習了數據中的噪音。

3. 解釋性 (Interpretability) :

- 有些機器學習模型（如深度學習）很難解釋其內部運作原理，這可能會影響其在某些應用中的可信度。

4. 倫理問題 (Ethical Issues) :

- 機器學習可能會引發一些倫理問題，如數據隱私、算法偏見等。例如，模型可能會基於種族、性別等因素做出不公平的決策。

1.1.7. 深度學習 (Deep Learning, DL) 基本概念

深度學習 (Deep Learning, DL) 基本概念

深度學習是一種機器學習 (Machine Learning, ML) 技術，通過[多層神經網絡](#)來學習數據中的複雜模式。這些神經網絡由多層神經元 (Neurons) 組成，每一層神經元都能夠從前一層學習到的特徵中提取更高層次的特徵。這種多層結構使得深度學習能夠處理大量的數據，並在[圖像識別](#)、[語音識別](#)、[自然語言處理](#)等領域取得了顯著的成果。

深度學習的基本結構

深度學習的核心是人工神經網絡，這些網絡由輸入層 (Input Layer)、隱藏層 (Hidden Layers) 和輸出層 (Output Layer) 組成。

1. 輸入層 (Input Layer) :

◦輸入層接收原始數據，如圖像的像素值或文本的詞向量。這些數據將被傳遞到隱藏層進行處理。

2. 隱藏層 (Hidden Layers) :

◦隱藏層是神經網絡的核心部分，負責從數據中提取特徵。[每一層隱藏層都能夠學習到前一層的輸出，並提取更高層次的特徵](#)。隱藏層的數量和每層的神經元數量是深度學習模型的重要參數。

3. 輸出層 (Output Layer) :

◦輸出層負責生成最終的預測結果，如圖像的分類標籤或文本的情感分析結果。輸出層的神經元數量通常與預測的類別數量相同。

深度學習的訓練過程

1. 前向傳播 (Forward Propagation) :

◦在前向傳播過程中，數據從輸入層傳遞到隱藏層，再傳遞到輸出層。每一層的神經元都會對接收到的數據進行加權求和，並通過[激活函數 \(Activation Function \) 進行非線性變換](#)，生成輸出。

2. 損失計算 (Loss Calculation) :

◦損失函數 (Loss Function) 用於衡量模型的預測結果與真實標籤之間的差距。常見的損失函數包括[均方誤差 \(Mean Squared Error, MSE, for 數值型 \)](#)和[交叉熵損失 \(Cross-Entropy Loss, for 類別型 \)](#)。

上述損失函數是針對[監督式學習\(預測結果與真實標籤之間的差距\)](#)

[非監督式學習](#)的損失函數，要根據資料[內部的特性](#)，e.g. 群聚：群內緊密、不同群分離

3. 反向傳播 (Backward Propagation) :

◦在反向傳播過程中，模型根據損失函數的值來調整每一層神經元的權重。這個過程通過梯度下降算法 (Gradient Descent) 來實現，目標是最小化損失函數的值。

4. 權重更新 (Weight Update) :

◦根據反向傳播計算出的梯度，模型會更新每一層神經元的權重。這個過程會反覆進行，直到模型的預測結果達到滿意的準確度。

深度學習的三大經典模型：

1. 卷積神經網絡 (Convolutional Neural Network · CNN)

CNN 是一種專門用於[圖像識別](#)的深度學習模型。

示例：手寫字母識別

假設我們有一個手寫字母數據集，想要識別手寫字母。首先，我們需要收集手寫字母數據，包括每個字母的像素值。我們可以使用卷積層，提取字母中的特徵，我們可以使用池化層，縮小特徵圖的尺寸，並保留重要信息。最後我們可以使用全連接層，將特徵圖轉換為分類結果，來識別手寫字母。

實施步驟：

1. **數據蒐集**：收集手寫字母數據，包括每個字母的像素值。
2. **卷積層(Convolutional Layer)**：使用卷積層，**提取字母中的特徵**。
3. **池化層(Pooling Layer)**：使用池化層，縮小特徵圖的尺寸，並保留重要信息。透過降維操作（如最大池化、平均池化），減少數據維度，防止過擬合。
4. **全連接層(Fully Connected Layer)**：使用全連接層，將**特徵圖轉換為分類結果**，來識別手寫字母。

優點：

- 適合處理高維數據，參數量相比全連接網路顯著減少。
- 能夠提取層次化特徵，從低層特徵（如邊緣）到高層語義（如物體形狀）。

應用場景：

- 影像辨識：如人臉辨識、手寫數字分類（MNIST）。
- 物件偵測：如自動駕駛中的障礙物檢測。
- 圖像分割：如醫學影像中的病變檢測。

2. 循環神經網路 (Recurrent Neural Network, RNN)

RNN 是一種專門用於**序列數據分析**的深度學習模型。

工作原理：

- RNN 的每個節點不僅接收當前的輸入，還會**記住前一時刻的狀態**，這使得 RNN 能夠捕捉數據的時間依賴關係。
- 網路的輸出取決於當前輸入和前面的上下文，適合處理**語音、文本等具有時間序列特性的數據**。

優點：

- 能夠有效捕捉序列數據中的長期依賴關係。
- 支持變長序列的處理，適用於多種場景。

缺點：

- 訓練過程容易出現**梯度消失 (Vanishing Gradient)** 或 **梯度爆炸 (Exploding Gradient)** 問題。
- 在處理長序列數據時，計算效率較低。

梯度消失：當誤差反向傳播時，梯度（即誤差對參數的導數）會逐層變小，導致：

- 前面幾層的權重幾乎不更新。
- 網路學不到深層特徵。
- 訓練變得非常慢甚至無法進行。

可以使用 ReLU 激活函數、批次正規化 (BatchNorm)、殘差連接 (ResNet) 解決

梯度爆炸：當反向傳播時，梯度逐層變大，導致：

- 權重更新過大。
- 模型不穩定，甚至出現 NaN。
- 損失函數震盪或無法收斂。

使用使用梯度裁剪、適當初始化權重、正則化解決

改進版本：

- 長短期記憶網路 (Long Short-Term Memory, LSTM)：透過引入**遺忘門 (forget gate)**、**輸入門 (input gate)** 和 **輸出門 (output gate)**，有效解決了梯度消失問題。（「**遺忘門 (Forget Gate)**」是**長短期記憶網路 (LSTM, Long Short-Term Memory)**中的一個重要組件，用來控制「**哪些資訊應該從記憶中被遺忘**」）
- 門控循環單元 (Gated Recurrent Unit, GRU)：結構比 LSTM 更簡單，但在大多數應用中效果相近。

應用場景：

- 自然語言處理：如機器翻譯、文本生成。
- 語音辨識：如語音助理中的語音轉文字。
- 時間序列分析：如股票價格預測。

3. 生成對抗網路 (Generative Adversarial Network , GAN)

GAN 是一種生成式人工智慧模型，能夠創造新的內容，如圖像、音樂或文本。GAN 通過生成器(Generator)和判別器(Discriminator)的對抗訓練，來生成與訓練數據相似但又不完全相同的新的數據。

示例：圖像生成

假設我們有一家設計公司，想要生成新的圖像作品。收集大量的圖像數據，包括不同風格的圖像作品後，我們可以使用生成器，根據訓練數據，生成新的圖像作品。然後我們可以使用判別器，判斷生成的圖像是否與訓練數據相似。通過生成器和判別器的對抗訓練，我們可以生成高質量的圖像作品。最後我們可以根據生成的圖像作品，制定相應的營銷策略，吸引更多的客戶。

實施步驟：

1. **數據蒐集**：收集大量的圖像數據，包括不同風格的圖像作品。
2. **生成器**：使用生成器，根據訓練數據，生成新的圖像作品。生成器接收隨機雜訊作為輸入，生成模擬的數據樣本。
3. **判別器**：使用判別器，判斷生成的圖像是否與訓練數據相似。判別器負責區分輸入數據是真實的還是生成的。
4. **對抗訓練**：生成器的目標是「欺騙」判別器，使其無法區分數據來源；而判別器則試圖最大化其判斷準確性。通過生成器和判別器的對抗訓練，生成高質量的圖像作品。
5. **制定策略**：根據生成的圖像作品，制定相應的營銷策略。

優點：

- 能夠生成高品質的數據樣本，適用於影像、文本、語音等多領域。
- 在數據增強和模擬中有極大的應用潛力。

缺點：

- 訓練過程不穩定，可能出現模式崩潰 (Mode Collapse)。模式崩潰是 GANs 中常見的一個問題。當模式崩潰發生時，生成器會生成有限或重複的輸出，未能捕捉到訓練數據的全部多樣性。這意味著生成器會重複生成相似或相同的樣本，而不是生成一系列獨特的樣本。
- 需要大量計算資源，對網路結構設計要求高。

應用場景：

- 圖像生成：如將草圖轉換為寫實圖片。
- 文本生成：如虛擬對話內容的創建。
- 語音合成：如生成逼真的語音樣本。

深度學習的應用

深度學習在各個領域都有廣泛的應用，以下是幾個常見的例子：

1. **圖像識別 (Image Recognition)**：
 - 深度學習可以用於圖像分類、物體檢測、人臉識別等。例如，通過分析醫療影像來檢測癌症。
2. **語音識別 (Speech Recognition)**：
 - 深度學習可以用於語音轉文字、語音合成、語音情感分析等。例如，智能助理 (如 Siri 、 Alexa) 通過語音識別來理解用戶的指令。
3. **自然語言處理 (Natural Language Processing, NLP)**：

深度學習可以用於文本分類、機器翻譯、情感分析等。例如，通過分析社交媒體上的文本來進行情感分析。

4. 自動駕駛 (Autonomous Driving):

深度學習可以用於路徑規劃、物體檢測、行為預測等。例如，自動駕駛汽車通過分析道路上的圖像來識別行人和車輛。

5. 推薦系統 (Recommendation Systems):

深度學習可以用於個性化推薦、廣告投放、內容過濾等。例如，根據用戶的觀看歷史推薦電影和電視節目。

常見的開發框架：TensorFlow、PyTorch 等

深度學習的挑戰

1. 數據需求 (Data Requirements):

深度學習模型需要大量的數據來進行訓練。如果數據不足，模型的性能可能會受到影響。

2. 計算資源 (Computational Resources):

深度學習模型的訓練需要大量的計算資源，如 GPU (圖形處理單元) 和 TPU (張量處理單元)。這可能會增加訓練成本。

3. 過擬合 (Overfitting):

過擬合是指模型在訓練數據上表現很好，但在新數據上表現不佳。這通常是因為模型過於複雜，學習了數據中的噪音。

4. 解釋性 (Interpretability):

有些深度學習模型 (如深度神經網絡) 很難解釋其內部運作原理，這可能會影響其在某些應用中的可信度。

5. 倫理問題 (Ethical Issues):

深度學習可能會引發一些倫理問題，如數據隱私、算法偏見等。例如，模型可能會基於種族、性別等因素做出不公平的決策。

1.1.7.1. 何謂模式崩潰 (Mode Collapse)

模式崩潰 (Mode Collapse) 是生成對抗網路 (Generative Adversarial Networks , GANs) 中常見的一個問題。當模式崩潰發生時，生成器 (Generator) 會生成有限或重複的輸出，未能捕捉到訓練數據的全部多樣性。這意味著生成器會重複生成相似或相同的樣本，而不是生成一系列獨特的樣本。

模式崩潰的原因

模式崩潰的原因有很多，以下是一些常見的原因：

1. **模型容量不足**：生成模型缺乏必要的複雜性或容量來捕捉數據分布的全部多樣性。這可能是由於模型的神經網路容量有限，無法表示訓練數據中的複雜和多樣的模式。
2. **訓練不穩定**：GANs 的訓練過程依賴於生成器和判別器之間的微妙平衡。如果判別器變得過於強大，生成器可能會選擇生成一小部分容易欺騙判別器的數據，而不是探索訓練數據的全部分布。
3. **訓練數據缺乏多樣性**：如果訓練數據本身缺乏多樣性，生成器可能會生成有限的輸出，未能捕捉到數據的全部分布。
4. **損失函數問題**：損失函數的設計不當可能會導致模式崩潰。例如，**過度正則化**可能會限制模型的能力，導致生成的內容缺乏多樣性。

模式崩潰的影響

模式崩潰會對生成模型的性能和應用產生負面影響，包括：

1. **生成樣本的多樣性有限**：生成器生成的樣本缺乏多樣性，未能捕捉到訓練數據的全部分布。
2. **生成內容的質量和真實性降低**：生成的內容質量和真實性降低，未能滿足應用需求。
3. **對應用的負面影響**：模式崩潰會影響生成模型在各種應用中的性能，如圖像生成、文本生成和音樂生成等。
4. **用戶體驗和客戶滿意度下降**：生成的內容缺乏多樣性和質量，可能會導致用戶體驗和客戶滿意度下降。
5. **對研究和開發的影響**：模式崩潰會影響生成模型的研究和開發，限制模型的應用範圍和性能。

解決模式崩潰的方法

以下是一些解決模式崩潰的方法：

1. **增加模型容量**：增加生成模型的神經網路容量，使其能夠表示訓練數據中的複雜和多樣的模式。
2. **改進訓練方法**：改進 GANs 的訓練方法，保持生成器和判別器之間的微妙平衡。例如，可以使用多判別器 (Multi-Discriminator) 或逐步訓練 (Progressive Training) 方法。
3. **增加訓練數據的多樣性**：增加訓練數據的多樣性，使生成器能夠捕捉到數據的全部分布。
4. **改進損失函數設計**：改進損失函數的設計，避免過度正則化，保持模型的能力。

1.1.8. 神經網絡 (Neural Networks) 基本結構與運作原理、激活函數(Sigmoid、Tanh、ReLU)

神經網絡 (Neural Networks) 基本結構與運作原理

神經網絡 (Neural Networks) 是人工智慧 (Artificial Intelligence, AI) 和機器學習 (Machine Learning, ML) 中的一個重要概念。神經網絡是一種計算模型，由大量互聯的神經元組成。這些神經元通過加權連接 (Weighted Connections) 傳遞信息，並通過激活函數 (Activation Function) 進行非線性變換。神經網絡的目標是從數據中學習模式和特徵，以進行預測或分類。

神經網絡的基本結構

神經網絡的基本結構包括輸入層 (Input Layer)、隱藏層 (Hidden Layers) 和輸出層 (Output Layer)。

1. 輸入層 (Input Layer) :
 - 輸入層接收原始數據，如圖像的像素值或文本的詞向量。這些數據將被傳遞到隱藏層進行處理。
2. 隱藏層 (Hidden Layers) :
 - 隱藏層是神經網絡的核心部分，負責從數據中提取特徵。每一層隱藏層都能夠學習到前一層的輸出，並提取更高層次的特徵。隱藏層的數量和每層的神經元數量是神經網絡的重要參數。
3. 輸出層 (Output Layer) :
 - 輸出層負責生成最終的預測結果，如圖像的分類標籤或文本的情感分析結果。輸出層的神經元數量通常與預測的類別數量相同。

神經網絡的運作原理

神經網絡的運作原理可以分為以下幾個步驟：

1. 前向傳播 (Forward Propagation) :
 - 在前向傳播過程中，數據從輸入層傳遞到隱藏層，再傳遞到輸出層。每一層的神經元都會對接收到的數據進行加權求和，並通過激活函數進行非線性變換，生成輸出。
2. 損失計算 (Loss Calculation) :
 - 損失函數 (Loss Function) 用於衡量模型的預測結果與真實標籤之間的差距。常見的損失函數包括均方誤差 (Mean Squared Error, MSE) 和交叉熵損失 (Cross-Entropy Loss)。
3. 反向傳播 (Backward Propagation) :
 - 在反向傳播過程中，模型根據損失函數的值來調整每一層神經元的權重。這個過程通過梯度下降算法 (Gradient Descent) 來實現，目標是最小化損失函數的值。
4. 權重更新 (Weight Update) :
 - 根據反向傳播計算出的梯度，模型會更新每一層神經元的權重。這個過程會反覆進行，直到模型的預測結果達到滿意的準確度。

神經網絡的激活函數

激活函數是神經網絡中的關鍵組成部分，負責將神經元的輸入轉換為輸出。常見的激活函數包括：

1. Sigmoid 函數 :
 - Sigmoid 函數將輸入轉換為 0 到 1 之間的值，常用於二分類問題。
2. ReLU (Rectified Linear Unit) 函數 :
 - ReLU 函數將輸入中的負值轉換為 0，正值保持不變，常用於隱藏層。
3. Tanh 函數 :
 - Tanh 函數將輸入轉換為 -1 到 1 之間的值，常用於隱藏層。

神經網絡的應用

1. **圖像識別 (Image Recognition) :**
 - 神經網絡可以用於圖像分類、物體檢測、人臉識別等。例如，通過分析醫療影像來檢測癌症。
2. **語音識別 (Speech Recognition) :**
 - 神經網絡可以用於語音轉文字、語音合成、語音情感分析等。例如，智能助理 (如 Siri、Alexa) 通過語音識別來理解用戶的指令。
3. **自然語言處理 (Natural Language Processing, NLP) :**
 - 神經網絡可以用於文本分類、機器翻譯、情感分析等。例如，通過分析社交媒體上的文本來進行情感分析。
4. **自動駕駛 (Autonomous Driving) :**
 - 神經網絡可以用於路徑規劃、物體檢測、行為預測等。例如，自動駕駛汽車通過分析道路上的圖像來識別行人和車輛。
5. **推薦系統 (Recommendation Systems) :**
 - 神經網絡可以用於個性化推薦、廣告投放、內容過濾等。例如，根據用戶的觀看歷史推薦電影和電視節目。

神經網絡的挑戰

儘管神經網絡有很多優勢，但也面臨一些挑戰：

1. **數據需求 (Data Requirements) :**
 - 神經網絡模型需要大量的數據來進行訓練。如果數據不足，模型的性能可能會受到影響。
2. **計算資源 (Computational Resources) :**
 - 神經網絡模型的訓練需要大量的計算資源，如 GPU (圖形處理單元) 和 TPU (張量處理單元)。這可能會增加訓練成本。
3. **過擬合 (Overfitting) :**
 - 過擬合是指模型在訓練數據上表現很好，但在新數據上表現不佳。這通常是因為模型過於複雜，學習了數據中的噪音。
4. **解釋性 (Interpretability) :**
 - 有些神經網絡模型 (如深度神經網絡) 很難解釋其內部運作原理，這可能會影響其在某些應用中的可信度。
5. **倫理問題 (Ethical Issues) :**
 - 神經網絡可能會引發一些倫理問題，如數據隱私、算法偏見等。例如，模型可能會基於種族、性別等因素做出不公平的決策。

1.1.9. 強化學習 (Reinforcement Learning)

強化學習 (Reinforcement Learning, RL) 是一種機器學習 (Machine Learning, ML) 技術，基於獎勵和懲罰的學習方法。模型 (或稱為代理人，Agent) 通過與環境互動來學習最佳行動策略。每當代理人執行一個行動，環境會給予相應的反饋 (獎勵或懲罰)，代理人根據這些反饋來調整其行動策略，以最大化累積獎勵。

強化學習的基本元素

1. **代理人 (Agent)** :
 - 代理人是執行行動並學習策略的實體。它可以是機器人、自動駕駛汽車、遊戲中的角色等。
2. **環境 (Environment)** :
 - 環境是代理人所處的外部世界。代理人通過與環境互動來獲取反饋。
3. **狀態 (State)** :
 - 狀態是環境在某一時刻的描述。它包含了代理人所需的所有信息，以便做出決策。
4. **行動 (Action)** :
 - 行動是代理人根據當前狀態所做出的選擇。行動會影響環境的狀態，並導致獎勵或懲罰。
5. **獎勵 (Reward)** :
 - 獎勵是環境對代理人行動的反饋。代理人的目標是最大化累積獎勵。
6. **策略 (Policy)** :
 - 策略是代理人在每一狀態下選擇動作的規則。策略可以是確定性的 (Deterministic)，即在每一狀態下總是選擇同一動作；也可以是隨機性的 (Stochastic)，即在每一狀態下根據某一概率分佈選擇動作。

強化學習的基本流程

1. **初始化** :
 - 代理人初始化其策略和價值函數 (Value Function)。策略是代理人選擇行動的規則，價值函數是對狀態或狀態-行動對的評估。
2. **觀察狀態** :
 - 代理人觀察當前的環境狀態，並根據策略選擇一個行動。
3. **執行行動** :
 - 代理人執行選定的行動，環境根據行動的結果更新狀態，並給予相應的獎勵。
4. **更新策略** :
 - 代理人根據獲得的獎勵和新的狀態來更新其策略和價值函數。這個過程通過強化學習算法來實現。
5. **重複** :
 - 代理人不斷重複觀察狀態、選擇行動、執行行動和更新策略的過程，直到策略收斂或達到預定的學習目標。

強化學習的示例 (訓練一個機器人學會走迷宮)

1. 定義環境

首先，我們需要定義迷宮的環境。迷宮可以用一個二維矩陣表示，其中 0 表示空地，1 表示牆壁，2 表示起點，3 表示終點。例如：

迷宮：

```
[  
[2, 0, 1, 0],  
[0, 1, 0, 0],
```

```
[0, 0, 0, 3],  
[1, 0, 1, 0]  
]
```

2. 定義狀態和動作

在這個示例中，狀態是機器人在迷宮中的位置，例如 (0, 0) 表示起點。動作是機器人可以執行的移動，例如向上、向下、向左、向右。

3. 定義獎勵

我們可以設置以下獎勵規則：

到達終點 (3): +10 分

撞到牆壁 (1): -1 分

其他情況: -0.1 分 (鼓勵機器人盡快找到終點)

4. 訓練代理人

代理人通過多次嘗試來學習最佳行動策略。在每一次嘗試中，代理人從起點開始，根據當前策略選擇動作，並根據環境的反饋更新策略。隨著訓練次數的增加，代理人會逐漸學會如何避開牆壁並找到終點。

強化學習的算法

1. 價值函數方法 (Value Function Methods):

◦價值函數方法通過估計每個狀態或狀態-行動對的價值來選擇最佳行動。常見的價值函數方法包括 Q 學習 (Q-learning) 和狀態-行動-回報 (SARSA)。

2. 策略梯度方法 (Policy Gradient Methods):

◦策略梯度方法直接學習策略，通過最大化累積獎勵來更新策略參數。常見的策略梯度方法包括 REINFORCE 和深度策略梯度 (Deep Policy Gradient)。

3. 混合方法 (Actor-Critic Methods):

◦混合方法結合了價值函數方法和策略梯度方法，通過同時學習價值函數和策略來提高學習效率。常見的混合方法包括 Actor-Critic 和深度確定性策略梯度 (Deep Deterministic Policy Gradient, DDPG)。

強化學習的應用

1. 遊戲 AI (Game AI):

◦強化學習可以用於訓練遊戲中的智能代理，如 AlphaGo 和 Dota 2 的 AI。這些代理可以通過與環境互動來學習最佳策略，並在遊戲中擊敗人類玩家。

2. 自動駕駛 (Autonomous Driving):

◦強化學習可以用於訓練自動駕駛汽車，通過學習最佳駕駛策略來應對複雜的交通情況。例如，Waymo 和 Tesla 都在使用強化學習技術來改進自動駕駛系統。

3. 機器人控制 (Robotics Control):

◦強化學習可以用於訓練機器人執行各種任務，如抓取物體、行走、導航等。這些機器人可以通過與環境互動來學習最佳行動策略，並在實際應用中提高效率。

4. 金融交易 (Financial Trading):

◦強化學習可以用於訓練智能交易代理，通過學習最佳交易策略來最大化投資回報。例如，對沖基金和投資銀行都在使用強化學習技術來改進交易策略。

5. 醫療保健 (Healthcare):

◦強化學習可以用於個性化治療方案的設計，通過學習最佳治療策略來提高患者的治療效果。例如，強化學習可以用於癌症治療中的放射治療計劃。

強化學習的挑戰

1. **探索與利用的平衡 (Exploration vs. Exploitation Trade-off):**
 - 代理人需要在探索新行動和利用已知最佳行動之間找到平衡。如果過度探索，學習效率會降低；如果過度利用，可能會錯過更好的策略。
2. **樣本效率 (Sample Efficiency):**
 - 強化學習模型通常需要大量的樣本來進行訓練，這可能會增加訓練成本。提高樣本效率是強化學習研究中的一個重要課題。
3. **穩定性 (Stability):**
 - 強化學習模型的訓練過程可能會不穩定，特別是在高維度和連續狀態空間中。如何提高訓練的穩定性是強化學習研究中的一個挑戰。
4. **解釋性 (Interpretability):**
 - 強化學習模型的決策過程通常很難解釋，這可能會影響其在某些應用中的可信度。提高模型的解釋性是強化學習研究中的一個重要方向。

1.1.10. 生成式人工智慧：訓練階段(數據準備、模型選擇與搭建、模型訓練)、微調階段(特定任務優化、數據精調)

生成式人工智慧 (Generative AI) 是一種能夠創造新內容的人工智慧技術，如圖像、音樂或文本。這種技術在許多領域中都有廣泛的應用，包括藝術創作、醫療診斷和自然語言處理等。本文將詳細介紹生成式人工智慧的訓練階段和微調階段，並提供相關示例和實施步驟，幫助對此領域完全陌生的讀者理解這些概念。

1. 訓練階段

訓練階段是生成式人工智慧的基礎，旨在通過大量數據訓練模型，使其能夠生成高質量的新內容。訓練階段包括數據準備、模型選擇與搭建、模型訓練三個主要步驟。

數據準備

數據準備是訓練階段的第一步，旨在收集和處理訓練數據。高質量的數據是生成式人工智慧成功的關鍵，因此數據準備過程非常重要。

示例：圖像生成

假設我們有一家設計公司，想要生成新的圖像作品。首先，我們需要收集大量的圖像數據，包括不同風格的圖像作品。接下來，我們需要對數據進行清洗和標記，確保數據的質量和一致性。然後，我們可以將數據分為訓練集和測試集，以便在訓練過程中評估模型的性能。

實施步驟：

1. **數據蒐集**：收集大量的圖像數據，包括不同風格的圖像作品。
2. **數據清洗**：清洗數據，確保數據的質量和一致性。
3. **數據標記**：標記數據，確保數據的準確性。
4. **數據分割**：將數據分為訓練集、驗證集和測試集。

模型選擇與搭建

模型選擇與搭建是訓練階段的第二步，旨在選擇合適的生成模型並搭建模型架構。生成模型的選擇取決於具體的任務和數據特徵。

示例：圖像生成

假設我們有一家設計公司，想要生成新的圖像作品。首先，我們需要選擇合適的生成模型，如生成對抗網路 (GAN)。接下來，我們需要搭建模型架構，包括生成器和判別器。生成器負責生成新圖像，判別器負責判斷生成的圖像是否與訓練數據相似。

實施步驟：

1. **模型選擇**：選擇合適的生成模型，如生成對抗網路 (GAN)、變分自編碼器 (VAE)、Transformer 等。
2. **模型搭建**：根據所選模型的結構，搭建模型的各個層級，包括輸入層、隱藏層和輸出層。如搭建模型架構(GAN)，包括生成器和判別器。

生成器和判別器，分別有各自的輸入層、隱藏層和輸出層。

模型訓練

模型訓練是訓練階段的第三步，旨在通過訓練數據訓練模型，使其能夠生成高質量的新內容。

模型訓練過程通常包括多次迭代，以不斷優化模型性能。

示例：圖像生成

假設我們有一家設計公司，想要生成新的圖像作品。首先，我們需要使用訓練集訓練生成器和判別器。生成器生成新圖像，判別器判斷生成的圖像是否與訓練數據相似。通過生成器和判別器的對抗訓練，我們可以不斷優化模型性能，生成高質量的圖像作品。

實施步驟：

1. **生成器訓練：**使用訓練集訓練生成器，生成新圖像。
2. **判別器訓練：**使用訓練集訓練判別器，判斷生成的圖像是否與訓練數據相似。
3. **對抗訓練：**通過生成器和判別器的對抗訓練，不斷優化模型性能。

2. 微調階段

微調階段是生成式人工智慧的進一步優化，旨在根據特定任務和數據進行模型微調。微調階段包括特定任務優化和數據精調兩個主要步驟。

特定任務優化

特定任務優化是微調階段的第一步，旨在於預訓練模型的基礎上，根據具體任務對模型進行優化。這種優化通常包括和結構(如在文本生成任務中，添加一個語言模型層)，以提高模型在特定任務中的性能。

示例：圖像生成

假設我們有一家設計公司，想要生成特定風格的圖像作品。首先，我們需要根據特定任務調整生成器和判別器的參數和結構。接下來，我們可以使用特定風格的圖像數據進行模型微調，以提高模型在生成特定風格圖像中的性能。

實施步驟：

1. **參數調整：**根據特定任務調整生成器和判別器的參數和結構。
2. **模型微調：**使用特定風格的圖像數據進行模型微調。

數據精調

數據精調是微調階段的第二步，旨在根據特定任務對數據進行精細調整。這種調整通常包括選擇高質量的數據和進行數據增強，以提高模型性能。

示例：圖像生成

假設我們有一家設計公司，想要生成特定風格的圖像作品。首先，我們需要選擇高質量的特定風格圖像數據。接下來，我們可以進行數據增強，如旋轉、縮放和翻轉圖像，以增加訓練數據的多樣性。然後，我們可以使用精調後的數據進行模型微調，以提高模型性能。

實施步驟：

1. **數據選擇：**選擇高質量的特定風格圖像數據。
2. **數據增強：**進行數據增強，如旋轉、縮放和翻轉圖像。
3. **模型微調：**使用精調後的數據進行模型微調。

1.1.10.1. 模型訓練的損失函數(均方誤差 MSE、交叉熵、絕對誤差)、優化器、迭代訓練

模型訓練：損失函數、優化器、迭代訓練

模型訓練是人工智慧和機器學習中至關重要的一部分，旨在使模型能夠從數據中學習並做出準確的預測。模型訓練過程包括損失函數、優化器和迭代訓練三個主要步驟。本文將詳細介紹這些概念，並提供相關示例和實施步驟，幫助對此領域完全陌生的讀者理解這些概念。

損失函數

損失函數 (Loss Function) 是模型訓練中的一個重要概念，用於衡量模型預測結果與真實值之間的差距。損失函數的目標是最小化這個差距，使模型能夠做出更準確的預測。常見的損失函數包括均方誤差 (Mean Squared Error · MSE)、交叉熵 (Cross-Entropy · 熵 Entropy 為熱力學函數) 和絕對誤差 (Absolute Error)。

示例：房價預測

假設我們有一個房價預測模型，想要預測未來的房價。損失函數可以幫助我們衡量模型預測結果與真實房價之間的差距。首先，我們需要收集歷史房價數據，包括房屋特徵和真實房價。接下來，我們可以使用均方誤差 (MSE) 作為損失函數，計算模型預測結果與真實房價之間的差距。然後，我們可以根據損失函數的值，調整模型參數，使模型能夠做出更準確的預測。

實施步驟：

1. **數據蒐集**：收集歷史房價數據，包括房屋特徵和真實房價。
2. **損失函數選擇**：選擇均方誤差 (MSE) 作為損失函數。
3. **損失計算**：計算模型預測結果與真實房價之間的差距。
4. **參數調整**：根據損失函數的值，調整模型參數。

優化器

優化器 (Optimizer) 是模型訓練中的另一個重要概念，用於調整模型參數，使損失函數的值最小化。優化器的目標是找到最佳的模型參數，使模型能夠做出最準確的預測。常見的優化器包括梯度下降 (Gradient Descent)、隨機梯度下降 (Stochastic Gradient Descent · SGD) 和 Adam 優化器。

示例：房價預測

假設我們有一個房價預測模型，想要預測未來的房價。優化器可以幫助我們調整模型參數，使損失函數的值最小化。首先，我們需要選擇合適的優化器，如梯度下降 (Gradient Descent)。接下來，我們可以使用優化器，根據損失函數的值，調整模型參數。然後，我們可以反覆進行這個過程，直到損失函數的值達到最小。

實施步驟：

1. **優化器選擇**：選擇合適的優化器，如梯度下降 (Gradient Descent)。
2. **參數調整**：使用優化器，根據損失函數的值，調整模型參數。
3. **迭代訓練**：反覆進行這個過程，直到損失函數的值達到最小。

考慮因素

1. **模型類型**：不同的模型可能需要不同的優化器。例如，深度神經網路通常使用 Adam 優化器，而簡單的線性模型可能使用梯度下降。
2. **數據集大小**：如果數據集非常大，隨機梯度下降 (SGD) 可能更適合，因為它能夠在每次迭代中使用一部分數據進行更新，減少計算量。
3. **計算資源**：一些優化器需要更多的計算資源。例如，Adam 優化器需要更多的內存和計算能力，但通常能夠提供更好的性能。

4. **訓練速度**：如果訓練速度是關鍵因素，您可能需要選擇能夠快速收斂的優化器，如 Adam 或 RMSprop。
5. **模型性能**：不同的優化器可能會影響模型的最終性能。通常需要進行實驗，測試不同優化器的效果，選擇性能最好的優化器。

常見優化器

1. 梯度下降 (Gradient Descent)

梯度下降是一種基本的優化器，用於調整模型參數，使損失函數的值最小化。它通過計算損失函數的梯度，逐步更新模型參數。梯度下降適合小型數據集和簡單模型。

優點：簡單易用、適合小型數據集

缺點：訓練速度慢、可能陷入局部最小值

2. 隨機梯度下降 (Stochastic Gradient Descent , SGD)

隨機梯度下降是一種改進的梯度下降優化器，每次迭代使用一部分數據進行更新。這種方法能夠減少計算量，適合大型數據集。

優點：訓練速度快、適合大型數據集

缺點：參數更新不穩定、需要調整學習率

3. Adam 優化器

Adam 優化器是一種常用的優化器，結合了動量和 RMSprop 的優點。它能夠自動調整學習率，適合深度神經網路和大型數據集。

優點：訓練速度快、自動調整學習率、適合深度神經網路

缺點：需要更多的計算資源、可能過度擬合

損失函數 vs 優化器

	用途	目標
損失函數	衡量模型預測結果與真實值之間的差距	最小化預測結果與真實值之間的差距，使模型能夠做出更準確的預測
優化器	調整模型參數，使損失函數的值最小化	找到最佳的模型參數，使模型能夠做出最準確的預測

迭代訓練

迭代訓練 (Iterative Training) 是模型訓練中的一個重要過程，旨在通過多次迭代，不斷優化模型參數，使模型能夠做出最準確的預測。迭代訓練過程通常包括多次訓練迭代，每次迭代都會根據損失函數的值，調整模型參數。

示例：房價預測

假設我們有一個房價預測模型，想要預測未來的房價。迭代訓練可以幫助我們不斷優化模型參數，使模型能夠做出最準確的預測。首先，我們需要設定訓練迭代的次數，如 100 次迭代。接下來，我們可以使用優化器，根據損失函數的值，調整模型參數。然後，我們可以反覆進行這個過程，直到訓練迭代次數達到設定值。

實施步驟：

1. **設定迭代次數**：設定訓練迭代的次數，如 100 次迭代。
2. **參數調整**：使用優化器，根據損失函數的值，調整模型參數。
3. **迭代訓練**：反覆進行這個過程，直到訓練迭代次數達到設定值。

1.1.10.2. 數據增強技術在生成式人工智慧中有哪些作用？

數據增強技術(如旋轉、縮放和翻轉圖像)在生成式人工智慧中扮演著重要的角色，主要作用包括提高模型性能、增加數據多樣性和減少過擬合。以下是數據增強技術在生成式人工智慧中的具體作用：

提高模型性能

數據增強技術通過對訓練數據進行各種變換，如旋轉、縮放、翻轉和裁剪等，來增加訓練數據的**多樣性**。這些變換能夠幫助模型更好地學習數據中的**特徵**，從而提高模型的性能。例如，在圖像生成任務中，通過對訓練圖像進行旋轉和縮放，可以使模型更好地識別和生成不同角度和大小的圖像。

增加數據多樣性

數據增強技術能夠增加訓練數據的多樣性，從而提高模型的泛化能力。通過對訓練數據進行各種變換，可以模擬出更多的數據樣本，這些樣本能夠幫助模型更好地適應不同的場景和情況。例如，在自然語言生成任務中，通過對訓練文本進行同義詞替換和句子結構變換，可以使模型更好地生成不同風格和語氣的文本。

減少過擬合

過擬合是指模型過度學習訓練數據中的噪音和特徵，導致在測試數據上的性能下降。數據增強技術能夠幫助減少過擬合，從而提高模型的泛化能力。通過對訓練數據進行各種變換，可以使模型更好地學習數據中的一般特徵，而不是過度依賴特定的數據樣本。例如，在音樂生成任務中，通過對訓練音樂進行音調和節奏變換，可以使模型更好地生成不同風格和節奏的音樂。

示例：圖像生成

假設我們有一家設計公司，想要生成新的圖像作品。數據增強技術可以幫助我們完成這項任務。首先，我們需要收集大量的圖像數據，包括不同風格的圖像作品。接下來，我們可以對訓練圖像進行旋轉、縮放、翻轉和裁剪等變換，以增加訓練數據的多樣性。然後，我們可以使用生成對抗網路（GAN）模型，訓練生成器和判別器，來生成高質量的圖像作品。最後，我們可以根據生成的圖像作品，制定相應的營銷策略，吸引更多的客戶。

實施步驟：

1. **數據蒐集**：收集大量的圖像數據，包括不同風格的圖像作品。
2. **數據增強**：對訓練圖像進行旋轉、縮放、翻轉和裁剪等變換。
3. **模型訓練**：使用生成對抗網路（GAN）模型，訓練生成器和判別器。
4. **制定策略**：根據生成的圖像作品，制定相應的營銷策略。

1.1.11. 人工智慧的核心目標(自動化、智能化、自主性、適應性)

人工智慧的核心目標

人工智慧 (Artificial Intelligence, AI) 是一個廣泛的領域，旨在讓機器能夠模仿人類的智能行為。AI 的核心目標包括自動化、智能化、自主性和適應性。這些目標不僅推動了技術的進步，也改變了我們的生活和工作方式。以下將詳細介紹這些核心目標，並用淺顯易懂的方式解釋相關概念。

自動化

自動化 (Automation) 是指利用技術來自動完成任務，減少或消除人類的干預。自動化的目標是提高效率、降低成本和減少錯誤。自動化技術已經在許多領域得到了應用，例如製造業中的機器人、自動化生產線，以及辦公室中的自動化流程。

自動化的優勢在於它能夠處理重複性高、規律性強的任務，從而釋放人類的時間和精力，使其能夠專注於更具創造性和價值的工作。例如，在製造業中，自動化生產線可以 24 小時不間斷地運行，極大地提高了生產效率。同時，自動化技術還能夠減少人為錯誤，提高產品質量。

然而，自動化也面臨一些挑戰。例如，某些複雜的任務仍然需要人類的判斷和決策。此外，自動化技術的引入可能會導致某些工作崗位的消失，這需要我們在推動技術進步的同時，關注社會影響，確保勞動力的轉型和再培訓。

智能化

智能化 (Intelligence) 是指機器能夠模仿人類的智能行為，如學習、推理、問題解決和決策。智能化的目標是讓機器能夠理解和處理複雜的信息，並做出合理的決策。智能化技術包括機器學習

(Machine Learning, ML)、深度學習 (Deep Learning, DL) 和自然語言處理 (Natural Language Processing, NLP) 等。

智能化的優勢在於它能夠處理大量的數據，並從中提取有價值的信息。例如，機器學習算法可以分析醫療數據，幫助醫生診斷疾病；自然語言處理技術可以理解生成人類語言，實現智能客服和語音助手等應用。

然而，智能化技術也面臨一些挑戰。例如，機器學習算法需要大量的數據來進行訓練，數據的質量和數量直接影響算法的性能。此外，智能化技術的決策過程有時難以解釋，這可能會影響其在某些應用中的可信度。

自主性

自主性 (Autonomy) 是指機器能夠在沒有人工干預的情況下，自主完成任務。自主性的目標是讓機器能夠在動態和不確定的環境中，自主做出決策和行動。自主性技術包括自動駕駛 (Autonomous Driving)、機器人技術 (Robotics) 和無人機 (Drones) 等。

自主性的優勢在於它能夠應對複雜和多變的環境，實現高效和靈活的操作。例如，自動駕駛汽車可以在城市道路上自主行駛，減少交通事故和擁堵；機器人可以在危險環境中執行任務，如救災和探測。然而，自主性技術也面臨一些挑戰。例如，自主系統需要具備高度的感知和決策能力，以應對各種突發情況。此外，自主系統的安全性和可靠性也是一個重要問題，需要通過嚴格的測試和驗證來確保。

適應性

適應性 (Adaptability) 是指機器能夠根據環境的變化，自主調整其行動策略。適應性的目標是讓機器能夠在動態和不確定的環境中，持續學習和改進。適應性技術包括強化學習 (Reinforcement Learning, RL) 和自適應控制 (Adaptive Control) 等。

適應性的優勢在於它能夠應對環境的變化，實現持續的優化和改進。例如，強化學習算法可以通過與環境的互動，不斷學習最佳行動策略；自適應控制技術可以根據系統的變化，自主調整控制參數，實現穩定和高效的控制。

然而，適應性技術也面臨一些挑戰。例如，適應性系統需要具備高度的學習能力，以應對環境的變化。此外，適應性系統的學習過程可能需要大量的計算資源，這可能會增加系統的成本。

1.1.12. 人工智慧的隱私與安全性挑戰

人工智慧的隱私與安全性挑戰

人工智慧 (Artificial Intelligence, AI) 技術的快速發展，為我們的的生活和工作帶來了許多便利。然而，隨著 AI 技術的廣泛應用，隱私與安全性挑戰也日益凸顯。本文將介紹人工智慧在數據隱私 (Data Privacy)、資料安全 (Data Security) 和漏洞與攻擊 (Vulnerabilities and Attacks) 方面的挑戰，並用淺顯易懂的方式詳細解釋相關概念。

數據隱私 (Data Privacy)

數據隱私是指保護個人數據不被未經授權的訪問、使用或披露。在 AI 技術中，數據隱私尤為重要，因為 AI 模型通常需要大量的數據來進行訓練和預測。這些數據可能包含個人的敏感信息，如姓名、地址、醫療記錄等。

數據隱私的挑戰主要來自於數據的收集、存儲和使用過程。例如，在收集數據時，如何確保數據的合法性和透明度？在存儲數據時，如何防止數據洩露和未經授權的訪問？在使用數據時，如何確保數據的匿名性和保密性？

為了解決這些挑戰，許多國家和地區制定了相關的法律法規，如歐盟的《通用數據保護條例》 (General Data Protection Regulation, GDPR) 和台灣的《個人資料保護法》。這些法規要求企業在收集、存儲和使用個人數據時，必須遵循一定的規範，並保護數據主體的權利。

資料安全 (Data Security)

資料安全是指保護數據免受未經授權的訪問、篡改或破壞。在 AI 技術中，資料安全同樣至關重要，因為 AI 模型的性能和準確性高度依賴於數據的完整性和可靠性。

資料安全的挑戰主要來自於數據的傳輸、存儲和處理過程。例如，在數據傳輸過程中，如何防止數據被攔截和篡改？在數據存儲過程中，如何防止數據被盜取和破壞？在數據處理過程中，如何確保數據的完整性和一致性？

為了解決這些挑戰，企業通常採用多種技術手段來保護數據安全，如加密技術、訪問控制、數據備份等。例如，通過加密技術，可以確保數據在傳輸和存儲過程中的機密性；通過訪問控制，可以限制只有授權用戶才能訪問數據；通過數據備份，可以防止數據丟失和破壞。

漏洞與攻擊 (Vulnerabilities and Attacks)

漏洞是指系統中存在的安全缺陷，攻擊是指利用這些漏洞進行的惡意行為。在 AI 技術中，漏洞與攻擊的風險同樣存在，並且隨著 AI 技術的發展，這些風險也在不斷增加。

漏洞與攻擊的挑戰主要來自於 AI 模型和系統的設計和實施過程。例如，如何防止 AI 模型被惡意攻擊和篡改？如何防止 AI 系統被未經授權的訪問和控制？如何防止 AI 模型的輸出結果被操縱和誤導？

為了解決這些挑戰，企業通常採用多種安全措施來保護 AI 模型和系統，如漏洞掃描、入侵檢測、行為分析等。例如，通過漏洞掃描，可以及時發現和修補系統中的安全缺陷；通過入侵檢測，可以及時發現和阻止惡意攻擊；通過行為分析，可以及時發現和防止 AI 模型的異常行為。

1.1.13. 人工智慧的倫理挑戰

人工智慧 (Artificial Intelligence, AI) 技術的快速發展，為我們的的生活和工作帶來了許多便利。然而，隨著 AI 技術的廣泛應用，倫理挑戰也日益凸顯。本文將介紹人工智慧在偏見與歧視 (Bias and Discrimination)、透明度 (Transparency)、責任歸屬 (Accountability) 和工作取代 (Job Displacement) 方面的挑戰，並用淺顯易懂的方式詳細解釋相關概念。

偏見與歧視 (Bias and Discrimination)

偏見與歧視是指 AI 系統在決策過程中，因為數據或算法的偏差，導致對某些群體的不公平對待。這種偏見可能來自於訓練數據中的偏差，也可能來自於算法設計中的不平衡。例如，如果一個 AI 招聘系統的訓練數據中，男性候選人的比例遠高於女性候選人，那麼這個系統可能會傾向於選擇男性候選人，從而導致性別歧視。

偏見與歧視的挑戰在於如何確保 AI 系統的公平性和公正性。為了解決這個問題，研究人員和開發者需要在數據收集、算法設計和系統測試的各個環節中，採取措施來減少偏見。例如，可以通過數據清洗和增強技術來平衡訓練數據，通過公平性指標來評估算法的表現，並通過多樣化的測試數據來檢測系統的偏見。

透明度 (Transparency)

透明度是指 AI 系統的決策過程應該是可理解和可解釋的。透明度的目標是讓用戶和監管機構能夠了解 AI 系統的運作原理，並對其決策進行監督和審查。例如，在醫療診斷中，醫生需要了解 AI 系統是如何得出診斷結果的，以便做出最終的治療決策。

透明度的挑戰在於如何讓複雜的 AI 系統變得可解釋。許多 AI 算法，特別是深度學習模型，具有高度的複雜性和非線性，這使得它們的內部運作原理難以理解。為了解決這個問題，研究人員和開發者需要開發解釋性技術，如可視化工具、模型解釋算法和透明度報告等，來幫助用戶理解 AI 系統的決策過程。

責任歸屬 (Accountability)

責任歸屬是指在 AI 系統出現錯誤或造成損害時，應該有明確的責任主體來承擔責任。責任歸屬的目標是確保 AI 系統的安全性和可靠性，並保護用戶的權益。例如，如果一個自動駕駛汽車發生交通事故，應該有明確的責任主體來承擔法律責任和經濟賠償。

責任歸屬的挑戰在於如何確定責任主體。AI 系統通常涉及多個參與方，如開發者、運營者和用戶，這使得責任的界定變得複雜。為了解決這個問題，法律和監管機構需要制定相關的法律法規，明確各方的責任和義務，並建立有效的責任追究機制。

工作取代 (Job Displacement)

工作取代是指 AI 技術的應用可能會導致某些工作崗位的消失，從而對勞動力市場產生影響。工作取代的目標是確保技術進步與社會發展的平衡，減少技術變革對勞動力的負面影響。例如，自動化技術的應用可能會取代一些重複性高、規律性強的工作崗位，如製造業中的流水線工人和辦公室中的數據錄入員。

工作取代的挑戰在於如何應對技術變革對勞動力市場的影響。為了解決這個問題，政府和企業需要採取措施來促進勞動力的轉型和再培訓，幫助受影響的勞動者適應新的工作崗位和職業。例如，可以通過職業培訓和教育計劃來提升勞動者的技能，通過就業支持和社會保障來減少失業風險。

1.1.14. AI 治理框架 (AI Governance Framework)

AI 治理框架 (AI Governance Framework)

隨著人工智慧 (Artificial Intelligence, AI) 技術的快速發展，AI 在各個領域的應用越來越廣泛。然而，AI 技術的廣泛應用也帶來了一系列的挑戰和風險，如數據隱私、倫理問題和安全性等。為了有效應對這些挑戰，確保 AI 技術的安全、透明和負責任的應用，AI 治理框架 (AI Governance Framework) 應運而生。本文將介紹 AI 治理框架的基本概念，並用淺顯易懂的方式詳細解釋相關內容。

什麼是 AI 治理框架？

AI 治理框架是一套系統化的政策、流程和工具，用於管理和監督 AI 技術的開發和應用。其目標是確保 AI 技術在符合倫理和法律規範的前提下，安全、透明和負責任地運行。AI 治理框架涵蓋了從數據收集、模型訓練到應用部署的整個 AI 生命周期，並強調多方參與和協作。

- 透明性 (Transparency)** : 確保 AI 系統的運作過程和決策過程是透明的，使用者可以理解 and 信任 AI 系統的運作。
- 問責性 (Accountability)** : 確保 AI 系統的開發者和使用者對其行為和決策負責，並能夠追溯和糾正錯誤。
- 公平性 (Fairness)** : 確保 AI 系統不會產生偏見或歧視，並能夠公平地對待所有使用者。
- 隱私保護 (Privacy Protection)** : 確保 AI 系統在處理個人數據時，遵守相關的隱私保護法規，並保護使用者的隱私權。

AI 治理框架的核心要素

AI 治理框架的核心要素包括數據治理、模型治理、倫理治理和法律治理。

1. **數據治理 (Data Governance)** :
 - 數據治理是 AI 治理框架的基礎，涉及數據的收集、存儲、處理和使用。數據治理的目標是確保數據的質量、完整性和安全性，並保護數據隱私。這包括制定數據隱私政策、實施數據加密和訪問控制等措施。
2. **模型治理 (Model Governance)** :
 - 模型治理涉及 AI 模型的開發、訓練、測試和部署。模型治理的目標是確保模型的準確性、可靠性和透明度。這包括模型的驗證和驗證、模型的監控和更新，以及模型的解釋性和可解釋性。
3. **倫理治理 (Ethical Governance)** :
 - 倫理治理涉及 AI 技術的倫理和社會影響。倫理治理的目標是確保 AI 技術的公平性、公正性和透明度，並防止偏見和歧視。這包括制定倫理指導原則、實施倫理審查和監督，以及促進多樣性和包容性。
4. **法律治理 (Legal Governance)** :
 - 法律治理涉及 AI 技術的法律和合規要求。法律治理的目標是確保 AI 技術符合相關法律法規，並保護用戶的權益。這包括遵守數據保護法、知識產權法和消費者保護法等。

AI 治理框架的實施步驟

實施 AI 治理框架需要多方參與和協作，並遵循以下步驟：

1. **制定政策和指導原則** :
 - 制定 AI 治理的政策和指導原則，明確 AI 技術的開發和應用標準。這些政策和指導原則應該涵蓋數據治理、模型治理、倫理治理和法律治理等方面。
2. **建立治理結構和流程** :

○建立 AI 治理的結構和流程，確保治理框架的有效實施。這包括設立治理委員會、制定治理流程和工具，以及確定各方的責任和義務。

3. 實施監控和評估：

○實施 AI 技術的監控和評估，確保其符合治理框架的要求。這包括定期審查和更新治理政策、監控 AI 模型的性能和風險，以及評估 AI 技術的倫理和社會影響。

4. 促進多方參與和協作：

○促進多方參與和協作，確保 AI 治理框架的全面性和有效性。這包括與政府、企業、學術界和社會組織等多方合作，共同制定和實施 AI 治理政策。

AI 治理框架的挑戰和未來發展

AI 治理面臨許多挑戰，包括技術、法律和倫理方面的問題。以下是一些主要挑戰：

- **技術挑戰：**AI 技術的快速發展，使得現有的治理框架和法規難以跟上技術的變化。需要不斷更新和完善治理框架，以應對新技術帶來的挑戰。
- **法律挑戰：**不同國家和地區的法律和法規存在差異，這使得跨國企業在開發和部署 AI 技術時，面臨複雜的法律環境。
- **倫理挑戰：**AI 技術的應用可能涉及倫理問題，如隱私保護、數據偏見和自動化決策等。需要在技術開發和應用過程中，充分考慮和解決這些倫理問題。

台灣的 AI 治理政策

台灣在 AI 治理方面也制定了相關政策和指導原則，以確保 AI 技術的安全和負責任使用。以下是一些重要的政策和法規：

- **台灣數位發展部《公部門人工智慧應用參考手冊》：**台灣數位發展部發布了《公部門人工智慧應用參考手冊》，該手冊旨在協助各機關善用 AI 技術解決業務痛點，並提供了 AI 技術應用的指引和建議。手冊強調了 AI 技術的透明性、公平性和責任性，並提出了相關的隱私保護和安全性措施 [1]。
- **《金融業運用人工智慧（AI）指引》：**台灣金融監督管理委員會發布了《金融業運用人工智慧（AI）指引》，該指引旨在鼓勵金融機構善用 AI 技術，以負責任創新為核心，發展可信賴的金融服務。指引強調了 AI 技術的風險管理、隱私保護和透明性，並提供了具體的實施建議 [2]。

1.1.15. 歐盟的 AI 政策與法規

歐盟的 AI 政策與法規

隨著人工智慧 (Artificial Intelligence, AI) 技術的快速發展，歐盟 (European Union, EU) 在 AI 政策與法規方面採取了積極的措施，以確保 AI 技術的安全、透明和負責任的應用。本文將介紹歐盟的 AI 政策與法規，並用淺顯易懂的方式詳細解釋相關概念。

歐盟的 AI 政策背景

歐盟一直致力於推動 AI 技術的發展，同時也關注其可能帶來的倫理和社會挑戰。為了確保 AI 技術的負責任應用，歐盟制定了一系列政策和法規，旨在建立一個以人為本、可信賴和透明的 AI 生態系統。

歐盟的 AI 政策框架

歐盟的 AI 政策框架主要包括以下幾個方面：

1. AI 倫理指導原則：

○歐盟於 2019 年發布了《可信賴 AI 倫理指導原則》(Ethics Guidelines for Trustworthy AI)，該指導原則強調 AI 技術應該符合倫理原則，包括尊重人類自主性、防止傷害、公正性和可解釋性。這些原則旨在確保 AI 技術的開發和應用符合倫理標準，並保護用戶的權益。

2. AI 白皮書：

○2020 年，歐盟發布了《人工智慧白皮書》(White Paper on Artificial Intelligence)，該白皮書提出了一系列政策措施，旨在促進 AI 技術的發展，同時確保其安全性和透明度。白皮書強調了建立 AI 治理框架的重要性，並提出了對高風險 AI 應用進行嚴格監管的建議。

3. AI 法規提案：

○2021 年，歐盟提出了《人工智慧法規提案》(Artificial Intelligence Act)，該提案旨在建立一個統一的 AI 法規框架，對 AI 技術的開發和應用進行監管。提案根據 AI 應用的風險程度，將其分為四個類別：不可接受風險、高風險、有限風險和最低風險，並對不同風險級別的 AI 應用提出相應的監管要求。

歐盟的 AI 法規內容

歐盟的 AI 法規提案涵蓋了以下幾個主要內容：

1. 風險分類：

○根據 AI 應用的風險程度，將其分為四個類別：

■**不可接受風險**：包括對人類安全、基本權利和民主制度構成威脅的 AI 應用，如社會信用評分系統(根據個人行為進行排名，影響其獲取服務)和遠程生物識別技術(除有特定豁免外，在公共場所使用即時遠端生物辨識，如臉部辨識)。

■**高風險**：包括對健康、安全和基本權利有重大影響的 AI 應用，如醫療診斷系統、自動駕駛汽車和招聘系統、人力資源管理、人臉辨識門禁及考勤系統(因用於特定場所的存取控制，故非不可接受風險，而歸為高風險；另因作為考勤監控的一部份，它將涉及人力資源管理，在 AI 法案中明定人力資源管理為高風險)。

■**有限風險**：包括對用戶有一定影響但風險較低的 AI 應用，如聊天機器人、生成式 AI、情緒識別、臉部特徵的情緒辨識(非身份的識別)。~~和推薦系統~~(推薦系統是低風險)。

■**最低風險**：包括對用戶影響最小的 AI 應用，如遊戲中的 AI 角色和簡單的數據分析工具、推薦系統、垃圾郵件分類。

2. 監管要求：

○對不同風險級別的 AI 應用提出相應的監管要求：

■**不可接受風險**：禁止使用。

■**高風險**：需要進行嚴格的合規審查，包括風險評估、數據治理、透明度和可解釋性要求。

- 有限風險**：需要提供基本的透明度信息，如告知用戶他們正在與 AI 系統互動。

- 最低風險**：不需要特別的監管要求。

3. 合規機制：

- 建立合規機制，確保 AI 技術的開發和應用符合法規要求。這包括設立 AI 監管機構，負責監督和執用法規，並對違規行為進行處罰。

4. 國際合作：

- 強調國際合作的重要性，促進全球範圍內的 AI 治理和標準化。歐盟將與其他國家和國際組織合作，共同制定和推動 AI 治理框架。

以下是一些重要的政策和法規：

- **《人工智慧法案》(Artificial Intelligence Act)**：該法案旨在建立一個統一的 AI 治理框架，涵蓋 AI 系統的開發、部署和使用，並確保其符合透明性、問責性和公平性的原則。
- **《通用數據保護條例》(General Data Protection Regulation , GDPR)**：該條例規定了 AI 系統在處理個人數據時，必須遵守的隱私保護標準。

歐盟 AI 政策與法規的影響

歐盟的 AI 政策與法規對 AI 技術的發展和應用具有深遠的影響。首先，這些政策和法規有助於建立一個以人為本、可信賴和透明的 AI 生態系統，保護用戶的權益。其次，這些政策和法規為 AI 技術的開發和應用提供了明確的指導和規範，有助於促進技術創新和產業發展。最後，這些政策和法規強調國際合作，促進全球範圍內的 AI 治理和標準化，有助於建立一個統一的 AI 治理框架。

AI 應用規劃師能力鑑定(初級)
科目二(L2-生成式 AI 應用與規劃)

1.	L21(評鑑主題 1- No code / Low code 概念).....	43
1.1.	知識學習列表.....	44
1.2.	L21-0*-No Code / Low Code 的基本概念(指引版).....	44
1.2.1.	No Code / Low Code 的基本概念(指引版)-概念介紹.....	44
1.3.	L21-1-No Code / Low Code 的基本概念.....	45
1.3.1.	No Code / Low Code 的基本概念-概念介紹.....	45
1.3.1.1.	更多關於 No Code 和 Low Code 工具的技術細節.....	47
1.3.1.2.	有那些 No Code 和 Low Code 的工具，以表格列示產品特性、優缺...etc. No Code 和 Low Code 分開列表.....	48
1.4.	L21-2-No Code / Low Code 的優勢與限制.....	49
1.4.1.	No Code / Low Code 的優勢與限制-概念介紹.....	49
1.4.1.1.	在使用 No Code / Low Code 工具時，如何確保應用程序的安全性和性能？.....	50
1.4.1.2.	如何選擇適合自己需求的 No Code / Low Code 工具？.....	51
2.	L22*(評鑑主題 2-生成式 AI 應用領域與工具使用)(考前指引版).....	51
2.1.	知識列表.....	51
2.2.	L22*-1-生成式 AI 的基本概念與市場價值(指引版).....	53
2.2.1.	生成式 AI 的基本概念與市場價值(指引版)-考前指引之補充資訊-生成式 AI 的訓練數據處理.....	53
2.2.2.	生成式 AI 的基本概念與市場價值(指引版)-考前指引之補充資訊-生成式 AI 的推理機制.....	54
2.2.2.1.	在什麼情況下應該選擇使用頂部採樣而不是核採樣？.....	56
2.2.3.	生成式 AI 的基本概念與市場價值(指引版)-考前指引之補充資訊-生成式 AI 實際應用面臨的挑戰.....	56
2.3.	L22*-2-AI 工具的技術進化及發展(指引版).....	57
2.3.1.	AI 工具的技術進化及發展(指引版)-概念介紹(僅補充).....	57
2.3.1.1.	生成對抗網路 (GAN) 和變分自編碼器 (VAE) 有何不同？.....	58
3.	L22(評鑑主題 2-生成式 AI 應用領域與工具使用).....	60
3.1.	知識學習列表.....	60
3.2.	L22-1-生成式 AI 應用領域與常見工具.....	61
3.2.1.	生成式 AI 應用領域與常見工具-概念介紹.....	61
3.3.	L22-2-如何善用生成式 AI 工具.....	68
3.3.1.	如何善用生成式 AI 工具-概念介紹.....	68
4.	L23(評鑑主題 3-生成式 AI 導入評估規劃).....	75
4.1.	L23-1-生成式 AI 導入評估.....	76
4.1.1.	知識學習列表.....	76
4.1.2.	生成式 AI 導入評估-概念介紹.....	76
4.2.	L23-2-生成式 AI 導入規劃.....	77
4.2.1.	生成式 AI 導入規劃-考前指引之補充.....	77
4.2.2.	生成式 AI 導入規劃-概念介紹.....	78
4.3.	L23-3-生成式 AI 風險管理.....	79
4.3.1.	生成式 AI 風險管理-概念介紹.....	79

評鑑主題：

- No code / Low code 概念
- 生成式 AI 應用領域與工具使用
- 生成式 AI 導入評估規劃

評鑑內容：

- 評鑑主題 1- No code / Low code 概念

內容	備註	評鑑能力
No Code / Low Code 的基本概念	No code / Low code 工具本身的基本認知與基礎概念	評鑑應考者是否理解 No Code / Low Code 工具的基本概念與應用，掌握其在生成式 AI 應用中的功用和優勢，並能運用工具進行 AI 解決方案的設計與測試。
No Code / Low Code 的優勢與限制	No code / Low code 一般基本的理論知識與實際在各場域應用的情況	

- 評鑑主題 2-生成式 AI 應用領域與工具使用

內容	備註	評鑑能力
生成式 AI 應用領域與常見工具	領域如文本、圖像和聲音等；工具如 OpenAI API、ChatGPT、Midjourney、Copilot Studio、VS Code for Copilot、Github Copilot 等	評鑑應考者是否熟悉生成式 AI 常見工具的基本操作，瞭解其應用領域及適用場景能有效選擇與應用。
如何善用生成式 AI 工具	如 Prompt、RAG 等	

- 評鑑主題 3-生成式 AI 導入評估規劃

➢ 內容	備註	評鑑能力
生成式 AI 導入評估	如技術或工具效能評估、適用解決方案選擇、成本效益分析等；經濟部產業發展署《AI 導入指引》相關資料等。	評鑑應考者是否能掌握生成式 AI 導入的初步規劃要領，包含需求確認、資源分配、試用測試等步驟等。
生成式 AI 導入規劃	如目標設置、資源分配等	
生成式 AI 風險管理	如生成式 AI 倫理風險、資料安全隱私與合規性等	

2. L21(評鑑主題 1- No code / Low code 概念)

內容	備註	評鑑能力
No Code / Low Code 的基本概念	No code / Low code 工具本身的基本認知與基礎概念。	評鑑應考者是否理解 No Code / Low Code 工具的基本概念與應用，掌握其在生成式 AI 應用中的功用和優勢，並能運用工具進行 AI 解決方案的設計與測試。
No Code / Low Code 的優勢與限制	No code / Low code 一般基本的理論知識與實際在各場域應用的情況	

2.1. 知識學習列表

評鑑內容 1-基本概念

1. **No Code / Low Code 工具的定義**：No Code 工具是指不需要撰寫程式碼即可開發應用程式的工具，而 Low Code 工具則是指只需要少量程式碼即可開發應用程式的工具。
2. **平台特色**：No Code / Low Code 平台通常具有視覺化開發介面、拖放式設計工具、預建模組與範本等特色。
3. **歷史與發展**：No Code / Low Code 工具的發展歷史，包括其起源、演變及目前的趨勢。
4. **核心技術**：No Code / Low Code 工具的核心技術，如視覺化開發介面、拖放式設計工具、預建模組與範本等。
5. **相關工具或產品**：No Code / Low Code 工具的相關產品，如 Microsoft Power Apps、OutSystems、Mendix 等。
6. **應用範圍**：No Code / Low Code 工具的應用範圍，包括但不限於企業應用、個人化應用、快速原型設計等。

評鑑內容 2-優勢與限制

1. **優勢**：No Code / Low Code 工具的優勢，包括降低開發成本、縮短開發周期、提高開發效率等。
2. **限制**：No Code / Low Code 工具的限制，包括功能擴展性有限、定制化能力不足等。
3. **選擇合適工具的考量**：選擇合適的 No Code / Low Code 工具時應考量的重點，如平台的技術整合能力、自訂性、購買成本等。
4. **基本步驟**：使用 No Code / Low Code 工具進行應用程式開發的基本步驟，如需求分析、設計、開發、測試等。
5. **成功的關鍵因素**：使用 No Code / Low Code 工具進行應用程式開發的成功關鍵因素，如**選擇合適的工具、合理的需求分析、有效的測試等**。
6. **失敗的主要原因**：使用 No Code / Low Code 工具進行應用程式開發失敗的主要原因，如需求分析不充分、工具選擇不當、測試不充分等。

➤使用 No Code 工具進行應用程式開發的成功關鍵因素是什麼？

使用 No Code 工具進行應用程式開發的成功關鍵因素包括以下幾點：

1. **選擇合適的工具**：不同的 No Code 平台有不同的功能和特點，選擇適合自己需求的工具是成功的第一步。例如，Webflow 適合建立自定義網站和應用程式，Bubble 則適合沒有編碼知識的使用者快速創建應用程式[1]。
2. **清晰的需求定義**：在開始開發之前，明確應用程式的需求和目標非常重要。這樣可以確保在開發過程中不會偏離方向，並且能夠充分利用 No Code 工具的功能[1]。
3. **良好的設計和用戶體驗**：No Code 工具通常提供視覺化的開發介面，這使得設計和用戶體驗變得更加重要。確保應用程式的界面簡潔、美觀且易於使用，可以提高用戶的滿意度[1]。
4. **持續的測試和迭代**：在開發過程中，持續進行測試和迭代是成功的關鍵。通過不斷改進和優化應用程式，可以確保其穩定性和性能[1]。
5. **團隊合作和溝通**：即使是使用 No Code 工具，團隊合作和溝通仍然非常重要。確保所有成員都了解項目的進展和需求，並且能夠有效地協作，可以提高開發效率[1]。

2.2. L21-0*-No Code / Low Code 的基本概念(指引版)

2.2.1. No Code / Low Code 的基本概念(指引版)-概念介紹

No Code 平台

No Code 平台是一種讓使用者能夠在不撰寫程式碼的情況下開發應用程式的工具。這些平台通常提供圖形化介面 (UI)，使用者可以通過拖放元件來設計和構建應用程式。No Code 平台的核心技術包括視覺化開發介面、拖放式設計工具、預建模組與範本等。這些技術使得即使沒有程式設計背景的使用者也能夠快速開發出功能強大的應用程式。

Low Code 平台

Low Code 平台則結合了簡單程式設計與視覺化工具，適合具備基本技術能力的使用者。這些平台通常提供一部分程式碼編寫的功能，但主要依靠圖形化介面進行開發。Low Code 平台的優勢在於它能夠加速開發過程，降低開發成本，同時保持一定的靈活性和擴展性。

生成式 AI 與 No Code / Low Code 的結合

生成式 AI（如 ChatGPT、DALL-E 等）與 No Code / Low Code 的結合是一個令人興奮的領域。這些 AI 技術能夠自動生成內容，如文本、圖像、程式碼等，並且可以與 No Code / Low Code 平台集成，進一步簡化開發過程。例如，使用者可以通過生成式 AI 自動生成應用程式的部分功能，然後使用 No Code / Low Code 平台進行整合和部署。

No Code / Low Code 在平台的選擇與評估

在選擇 No Code / Low Code 平台時，使用者需要考慮多種因素，包括平台的技術整合能力、自訂性、使用者友好性、成本等。技術整合能力指的是平台能否與現有系統（如 CRM、ERP 等）無縫連接，確保資料流通和業務流程的順暢。自訂性則是指平台是否能夠滿足特定業務需求，提供足夠的自訂選項來適應不同的應用場景。

生成式 AI 與 No Code / Low Code 結合所面臨的挑戰

儘管生成式 AI 與 No Code / Low Code 的結合具有巨大潛力，但也面臨一些挑戰。例如，使用者可能缺乏對 AI 的深層理解，可能引發模型偏差或誤用。此外，這些平台需要加強人員相關教育和規範，以確保生成的內容符合業務需求和合規性要求。

No Code / Low Code 的市場價值

No Code / Low Code 平台在市場上具有很高的價值。它們能夠降低開發成本、縮短上市時間、加速數位轉型，並且能夠幫助企業快速響應市場需求。這些平台的使用不僅能夠提高開發效率，還能夠促進創新，推動企業在競爭激烈的市場中保持領先地位。

AI 發展趨勢中的 No Code / Low Code

在 AI 發展趨勢中，No Code / Low Code 平台扮演著重要角色。這些平台的市場發展與效益顯著，未來發展方向與潛力巨大。隨著技術的不斷進步，No Code / Low Code 平台將會越來越強大，能夠支持更複雜的應用場景，並且能夠與更多的 AI 技術進行整合。

對 AI 民主化的影響

No Code / Low Code 平台對 AI 民主化具有深遠的影響。它們能夠降低技術門檻、擴大 AI 的可訪問性、推動跨領域創新、強化 AI 技術的普及化應用、啟動全球性影響。這些平台的使用使得更多人能夠接觸和使用 AI 技術，推動 AI 在各個領域的應用和發展。同時，AI 民主化也面臨一些挑戰，如需要加強教育和培訓、確保技術的合規性和安全性等。

2.3. L21-1-No Code / Low Code 的基本概念

2.3.1. No Code / Low Code 的基本概念-概念介紹

1. 引言

隨著科技的進步，軟體開發的門檻逐漸降低，No Code 和 Low Code 工具應運而生。這些工具旨在讓非技術背景的人也能參與軟體開發，從而加速數位轉型的進程。本文將介紹 No Code / Low Code 工具的基本概念、歷史與發展、核心技術以及應用範圍。

2. 定義

No Code 工具

是指不需要撰寫程式碼即可開發應用程式的工具。這些工具通常提供視覺化的開發介面，使用者可以通過拖放元件來設計和構建應用程式。這使得**即使沒有程式設計背景的人也能輕鬆地創建應用程式**。

Low Code 工具

則是指只需要少量程式碼即可開發應用程式的工具。這些工具通常提供預建模組和範本，使用者可以通過少量的程式碼來定制和擴展應用程式的功能。Low Code 工具適合那些有一定程式設計知識，但希望快速開發應用程式的人，可以在**節省開發時間的同時，實現更高的靈活性和自定義**。

3. 歷史與發展

No Code 和 Low Code 工具的概念最早可以追溯到 20 世紀 80 年代的**第四代程式語言 (4GL)**，這些語言旨在提高開發效率，減少程式碼的編寫量。隨著網際網路和雲端計算的普及，No Code 和 Low Code 工具在 21 世紀初開始迅速發展，並逐漸成為企業數位轉型的重要工具。

4. 核心技術/平台特色

視覺化開發介面

No Code 和 Low Code 工具通常提供視覺化的開發介面，使用者可以通過拖放元件來構建應用程式。這些介面通常包括**表單設計器、流程設計器和報表設計器等**。

拖放式設計工具

拖放式設計工具是 No Code 和 Low Code 工具的核心功能之一。使用者可以通過拖放預建的元件來構建應用程式，這些元件通常包括**按鈕、文本框、下拉選單等**。

預建模組與範本

No Code 和 Low Code 工具通常提供大量的預建模組和範本，使用者可以直接使用這些模組和範本來構建應用程式，從而大大減少開發時間。

自動化工作流

平台通常提供自動化工作流功能，使用者可以設計和管理應用程式的工作流。

整合能力

平台通常具有良好的整合能力，可以與其他系統和工具進行整合。

5. 相關工具或產品

以下是一些常見的 No Code / Low Code 工具和產品：

- **Microsoft Power Apps**：一個強大的 No Code / Low Code 平台，提供了視覺化開發介面和大量的預建模組和範本。
- **OutSystems**：一個高效的 Low Code 平台，提供了強大的整合能力和自動化工作流功能。
- **Mendix**：一個靈活的 Low Code 平台，提供了視覺化開發介面和大量的預建模組和範本。

6. 應用範圍

No Code 和 Low Code 工具的應用範圍非常廣泛，涵蓋了企業應用、個人應用和教育應用等多個領域。以下是一些常見的應用場景：

企業應用

企業可以使用 No Code 和 Low Code 工具來**快速開發內部管理系統**、客戶關係管理系統（CRM）和企業資源規劃系統（ERP）等應用程式，從而提高工作效率和管理水平。

個人應用

個人使用者可以使用 No Code 和 Low Code 工具來開發**個人網站、部落格和小型應用程式**，從而實現個性化的需求。

教育應用

教育機構可以使用 No Code 和 Low Code 工具來**開發教學管理系統**、在線學習平台和學生評估系統等應用程式，從而提高教學質量和管理效率。

結論

No Code 和 Low Code 工具的出現，讓更多的人能夠參與到軟體開發中來，從而加速了數位轉型的進程。這些工具不僅降低了開發的門檻，還提高了開發的效率和靈活性。未來，隨著技術的不斷進步，No Code 和 Low Code 工具將在更多的領域發揮重要作用。

2.3.1.1. 更多關於 No Code 和 Low Code 工具的技術細節

No Code 工具的技術細節

No Code 工具是一種完全不需要編寫程式碼的開發方法，主要針對企業數據和業務管理需求。這些工具通常包括以下技術特點：

1. **視覺化介面**：No Code 平台提供視覺化的開發介面，使用者可以通過拖放元件來構建應用程式。這些元件包括表單、按鈕、文本框等，使用者可以通過簡單的拖放操作來設計應用程式的界面和功能。
2. **預建元件庫**：No Code 平台通常提供豐富的預建元件庫，這些元件可以直接使用，無需編寫程式碼。這些元件包括數據庫連接、API 調用、報表生成等，使用者可以通過這些元件來實現複雜的業務邏輯。
3. **自動化部署**：No Code 平台提供自動化部署功能，使用者可以一鍵部署應用程式，無需手動配置伺服器 and 網路環境。這些平台通常會自動完成故障排除、安全更新和性能優化等任務，減少運維成本^[1]。

Low Code 工具的技術細節

Low Code 工具則允許使用者在視覺化開發的基礎上，通過少量的程式碼來實現更複雜的功能。這些工具通常包括以下技術特點：

1. **視覺化開發與程式碼編寫結合**：Low Code 平台提供視覺化開發介面，**同時允許使用者編寫程式碼來實現自定義功能**。這些平台通常支持多種程式語言，如 JavaScript、Python 等，使用者可以根據需求選擇合適的語言來編寫程式碼。
2. **模組化設計**：Low Code 平台通常採用模組化設計，使用者可以通過組合不同的模組來構建應用程式。這些模組包括數據庫模組、業務邏輯模組、用戶介面模組等，使用者可以根據需求選擇合適的模組來實現應用程式的功能。
3. **高擴展性**：Low Code 平台通常具有高擴展性，使用者可以通過插件或擴展包來增加平台的功能。這些插件和擴展包通常由第三方開發者提供，使用者可以根據需求選擇合適的插件來擴展平台的功能^[2]。

技術細節的應用

這些技術細節使得 No Code 和 Low Code 工具在各種應用場景中都能發揮重要作用。例如，企業可以使用這些工具來快速開發內部管理系統，個人使用者可以用來開發個人網站或部落格，教育機構可以用來開發教學管理系統等。

2.3.1.2. 有那些 No Code 和 Low Code 的工具，以表格列示產品特性、優缺...etc. No Code 和 Low Code 分開列表

當然，以下是 No Code 和 Low Code 工具的分開列表，列出了它們的產品特性、優缺點等資訊：

No Code 工具

工具名稱	產品特性	優點	缺點	適用對象
Adalo	簡單的移動應用開發工具，拖放式設計	易於使用，設計元素豐富	客戶服務較慢	初創企業、自由職業者
Appy Pie	網頁應用開發工具，無需編碼	快速開發，適合非技術人員	功能有限	中小企業
Webflow	網站設計工具，無需編碼	強大的設計功能，適合設計師	學習曲線較陡	設計師、自由職業者
Zapier	自動化工具，無需編碼	支持多種應用整合，易於使用	高級功能需要付費	企業、個人
Bubble	免費的 No Code 工具，適合初學者	開源，社區支持	功能有限	初學者、個人
Back4App	開源 No Code 工具，適合後端開發	高度可擴展	學習曲線較陡	開發者、企業
Pagecloud	小型企業網站建設工具	易於使用，設計靈活	功能有限	小型企業
Clickup	項目管理工具，無需編碼	實時協作，功能豐富	學習曲線較陡	團隊、企業

Low Code 工具

工具名稱	產品特性	優點	缺點	適用對象
Mendix	多雲 API 整合、AI 驅動自動化	企業級應用、支援 DevOps 和敏捷開發	成本較高	大型企業
OutSystems	全堆疊開發、OutSystems Forge、原生應用開發	適合複雜需求的大型企業	成本較高	大型企業
Microsoft Power Apps	Microsoft 365 和 Azure 整合、AI Builder、Dataverse	適合 Microsoft 生態系統中的企業	成本較低	Microsoft 生態系統中的企業
Zoho Creator	Zoho 套件整合、Deluge 腳本、離線訪問	簡單易用，適合中小企業	功能較少	中小企業
Pega	AI 驅動決策、RPA、下一步最佳行動、高級 BPM	適合金融服務和大型企業	成本較高	金融服務和大型企業
Salesforce Lightning	AppExchange 市場、全渠道路由、Salesforce Shield	適合 CRM 和銷售導向的組織	成本較高	CRM 和銷售導向的組織
ServiceNow App Engine	ITSM 整合、預測智能、虛擬代理	適合 IT 操作、HR 和客戶服務	成本較高	IT 操作、HR 和客戶服務
WaveMaker	開源、雙向 API 生成、微服務架構、DevOps 能力	高度自定義	成本較高	需要自定義的企業

2.4. L21-2-No Code / Low Code 的優勢與限制

2.4.1. No Code / Low Code 的優勢與限制-概念介紹

No Code / Low Code 工具的優勢與限制

1. No Code / Low Code 工具的基本概念

No Code 和 Low Code 工具是指那些允許用戶在不需要深入編程知識的情況下，通過視覺化界面和拖放式設計工具來開發應用程序的工具。這些工具通常提供預建模組和範本，讓用戶可以快速構建和部署應用程序。

2. No Code / Low Code 工具的優勢

簡化開發過程

No Code 和 Low Code 工具最大的優勢在於簡化了應用程式的開發過程。使用者不需要具備深厚的程式設計知識，只需通過視覺化介面進行操作即可完成開發。這大大降低了開發的門檻，使得更多人能夠參與到應用程式的創建中。

提高開發效率

這些工具提供了大量的預建模組和範本，使用者可以快速選擇並配置這些模組，從而大幅縮短開發時間。相比傳統的程式設計方法，No Code 和 Low Code 工具能夠顯著提高開發效率。

降低開發成本

由於不需要聘請專業的程式設計師，使用 No Code 和 Low Code 工具可以大幅降低開發成本。此外，這些工具通常提供免費或低成本的使用方案，進一步減少了開發的財務負擔。

增強靈活性

Low Code 工具允許使用者撰寫少量程式碼，這使得開發者能夠在視覺化介面之外進行更靈活的操作。這些工具能夠滿足不同層次的開發需求，從簡單的應用程式到複雜的企業級解決方案。

3. No Code / Low Code 工具的限制

- 功能限制：**雖然 No Code / Low Code 工具提供了豐富的功能，但在**某些複雜的應用場景中，這些工具可能無法滿足所有需求**。這時候可能需要結合傳統編程方法來實現。
- 性能問題：**由於這些工具生成的代碼可能不如手寫代碼那麼高效，因此在**處理大規模數據或高性能需求的應用中，可能會遇到性能瓶頸**。
- 安全性：**No Code / Low Code 工具的安全性取決於工具本身的設計和實施。**如果工具的安全措施不夠完善，可能會帶來安全風險**。
- 依賴性：**使用這些工具開發的應用程序可能會對特定平台或工具產生依賴，這可能會**限制應用程序的可移植性和靈活性**。
- 學習曲線：**雖然這些工具旨在降低技術門檻，但對於完全沒有技術背景的用戶來說，仍然需要一定的學習和適應過程。

4. No Code / Low Code 工具在生成式 AI 應用中的應用

No Code / Low Code 工具在生成式 AI 應用中具有廣泛的應用前景。這些工具可以幫助用戶快速構建和部署 AI 模型，實現自動化數據處理和分析，並生成有價值的洞見。例如，使用 No Code 工具可以快速構建一個自動化的數據分析平台，通過拖放式界面設置數據源、選擇分析模型，並生成可視化報告。

5. 如何選擇合適的 No Code / Low Code 工具

評估業務需求

在選擇 No Code 或 Low Code 工具時，首先需要評估業務需求。了解應用程式的功能需求、性能要求和安全性標準，選擇能夠滿足這些需求的工具。

考慮工具的技術整合能力

選擇 No Code 或 Low Code 工具時，需要考慮其技術整合能力。確保工具能夠與現有的系統和平台無縫整合，提供穩定和高效的開發環境。

評估工具的自訂性和擴展性

Low Code 工具通常提供更高的自訂性和擴展性，適合需要高度靈活性的應用程式開發。選擇工具時，需要評估其自訂性和擴展性，確保能夠滿足未來的業務需求。

考慮工具的市場評價和支持

選擇 No Code 或 Low Code 工具時，需要考慮其市場評價和支持。選擇市場評價良好、具有穩定支持和更新的工具，確保開發過程順利進行。

6. 使用 No Code / Low Code 工具進行應用程式開發的基本步驟

定義需求

首先，需要明確應用程式的需求，包括功能需求、性能要求和安全性標準。

選擇合適的工具

根據需求選擇合適的 No Code 或 Low Code 工具，確保工具能夠滿足需求並提供穩定的開發環境。

設計和開發

使用選定的工具進行應用程式的設計和開發。利用視覺化開發介面和拖放式設計工具，快速構建應用程式。

測試和部署

在開發完成後，進行應用程式的測試，確保其功能和性能符合需求。測試完成後，將應用程式部署到生產環境中。

監控和維護

應用程式部署後，需要進行持續的監控和維護，確保其穩定運行並及時解決問題。

結論

No Code / Low Code 工具為生成式 AI 應用提供了便捷、高效的開發方式，讓更多的非技術人員能夠參與到 AI 應用的開發和管理中。然而，這些工具也有其局限性，需要根據具體需求選擇合適的工具和方法。

2.4.1.1. 在使用 No Code / Low Code 工具時，如何確保應用程序的安全性和性能？

在使用 No Code / Low Code 工具時，確保應用程序的安全性和性能是非常重要的。以下是一些建議，幫助您在開發和部署應用程序時，保持高水平的安全性和性能：

確保應用程序的安全性

- 選擇可靠的工具：**選擇有良好聲譽和安全記錄的 No Code / Low Code 工具。這些工具通常會有內建的安全功能，如數據加密、身份驗證和權限管理。
- 定期更新和補丁：**確保您使用的工具和平台始終保持最新版本。開發者會定期發布安全更新和補丁，以修復已知的漏洞。
- 數據保護：**確保應用程序中的數據傳輸和存儲是加密的。使用 HTTPS 協議來保護數據在網絡上的傳輸，並確保數據庫中的敏感信息是加密存儲的。
- 權限管理：**實施嚴格的權限管理，確保只有授權用戶才能訪問和修改應用程序中的敏感數據和功能。使用角色和權限來控制用戶的訪問級別。
- 安全測試：**在部署應用程序之前，進行全面的安全測試，包括漏洞掃描和滲透測試，以識別和修復潛在的安全問題。

確保應用程序的性能

1. **優化代碼**：雖然 No Code / Low Code 工具生成的代碼可能不如手寫代碼那麼高效，但您可以通過優化應用程序的設計和配置來提高性能。例如，減少不必要的數據庫查詢和 API 調用。
2. **資源管理**：確保應用程序合理使用系統資源，如 CPU、內存和存儲。監控應用程序的資源使用情況，並根據需要進行調整。
3. **負載測試**：在部署應用程序之前，進行負載測試，以確保應用程序能夠在高流量情況下正常運行。這有助於識別性能瓶頸並進行優化。
4. **使用緩存**：通過使用緩存技術來減少數據庫查詢和網絡請求的次數，提高應用程序的響應速度。可以使用內存緩存或分佈式緩存來存儲常用數據。
5. **監控和調整**：部署應用程序後，持續監控其性能，並根據監控數據進行調整。使用性能監控工具來識別和解決性能問題。

2.4.1.2. 如何選擇適合自己需求的 No Code / Low Code 工具？

選擇適合自己需求的 No Code / Low Code 工具需要考慮多方面的因素。以下是一些建議，幫助您做出明智的選擇：

1. 確定需求和目標

首先，您需要明確自己的需求和目標。例如，您是希望快速開發一個簡單的應用程序，還是需要構建一個複雜的企業級應用？不同的需求會影響您對工具的選擇。

2. 評估工具的功能

不同的 No Code / Low Code 工具有不同的功能和特點。您需要評估這些工具是否能滿足您的需求。例如，某些工具可能更適合數據驅動的應用，而另一些工具則可能更適合流程自動化。

3. 考慮用戶界面和使用體驗

工具的用戶界面和使用體驗也是選擇的重要因素。您應該選擇一個界面直觀、易於使用的工具，這樣可以減少學習曲線，提高工作效率。

4. 檢查擴展性和靈活性

擴展性和靈活性是選擇 No Code / Low Code 工具時需要考慮的關鍵因素。確保工具能夠隨著您的需求變化而擴展，並且允許您進行自定義和擴展。

5. 評估社群和支持

選擇一個有活躍社群和良好支持的工具可以幫助您在遇到問題時快速找到解決方案。查看工具的官方文檔、論壇和用戶評價，了解其支持情況。

6. 考慮成本

最後，您需要考慮工具的成本。不同的 No Code / Low Code 工具有不同的定價模式，有些可能是免費的，有些則需要訂閱費用。根據您的預算選擇合適的工具。

3. L22*(評鑑主題 2-生成式 AI 應用領域與工具使用)(考前指引版)

3.1. 知識列表

評鑑內容 1-生成式 AI 的基本概念與市場價值

1. 生成式 AI 的基本概念：

- 深度學習網路 (Deep Learning Networks)：生成式 AI 的基礎技術，通過多層神經網路進行數據處理和分析。

- 訓練數據處理 (Training Data Processing): 生成式 AI 需要大量的訓練數據來進行模型訓練，數據的質量和多樣性對模型的性能有重要影響。
- 推理機制 (Inference Mechanism): 生成式 AI 通過已訓練的模型進行推理，生成新的數據或內容。
- 實際應用面臨的挑戰 (Challenges in Practical Applications): 生成式 AI 在實際應用中面臨數據隱私、倫理問題、模型偏差等挑戰。

2. 生成式 AI 的市場價值與影響力：

- 市場規模與增長趨勢 (Market Size and Growth Trends): 生成式 AI 市場正在快速增長，預計未來幾年將持續擴大。
- 創業與投資熱潮 (Entrepreneurship and Investment Boom): 生成式 AI 吸引了大量創業公司和投資者的關注。
- 市場發展趨勢 (Market Development Trends): 生成式 AI 技術不斷進步，應用領域越來越廣泛。
- 挑戰與風險 (Challenges and Risks): 生成式 AI 面臨技術、法律、倫理等方面的挑戰和風險。
- 產業轉型影響 (Impact on Industry Transformation): 生成式 AI 正在改變各行各業的運作方式。
- 就業市場變革 (Changes in the Job Market): 生成式 AI 技術的普及對就業市場產生了深遠影響。
- 經濟效益分析 (Economic Benefits Analysis): 生成式 AI 技術的應用帶來了顯著的經濟效益。
- 社會影響層面 (Social Impact): 生成式 AI 技術對社會各方面產生了重要影響。

評鑑內容 2-AI 工具的技術進化及發展

1. 生成式 AI 工具的技術進化：

- 生成對抗網路 (Generative Adversarial Networks, GAN): 一種生成式 AI 技術，通過兩個神經網路相互競爭來生成新數據。
- 變分自編碼器 (Variational Autoencoders, VAE): 通過編碼和解碼過程生成新數據的技術。
- 基於流的生成模型 (Flow-based Generative Models): 通過流變換生成新數據的技術。
- 變壓器 (Transformer): 一種基於自注意力機制的生成式 AI 技術，廣泛應用於自然語言處理。
- 強化學習與人類反饋 (Reinforcement Learning with Human Feedback, RLHF): 通過人類反饋優化生成式 AI 模型的技術。
- 超大語言模型 (Very Large Language Models, vLLM): 超大規模的語言模型，能生成高質量的文本內容。

2. 生成式 AI 工具的發展方向：

- 多模態生成 (Multimodal Generation): 生成式 AI 技術不僅限於文本生成，還包括圖像、音頻等多種模態的生成。
- 模型壓縮與量化 (Model Compression and Quantization): 通過壓縮和量化技術提高生成式 AI 模型的效率。
- 個人化客製化 (Personalization and Customization): 生成式 AI 技術能根據用戶需求生成個性化內容。
- 生成對抗網路與擴散模型的融合技術 (Fusion of GAN and Diffusion Models): 通過融合不同生成技術提高生成效果。
- 開放原始碼與社群合作 (Open Source and Community Collaboration): 生成式 AI 技術的開放原始碼促進了社群合作和技術進步。

3. 生成式 AI 工具的發展與趨勢：

- 專業化與垂直整合 (Specialization and Vertical Integration) : 生成式 AI 技術在各行業的專業化應用。
- 多模態整合與協同生成 (Multimodal Integration and Collaborative Generation) : 不同模態生成技術的整合和協同工作。
- AI 即服務 (AI as a Service, AaaS) : 生成式 AI 技術作為服務提供給用戶。
- 個人化生成與可控性提升 (Personalized Generation and Enhanced Controllability) : 生成式 AI 技術的個性化和可控性不斷提升。
- 安全性與隱私保護 (Security and Privacy Protection) : 生成式 AI 技術在安全性和隱私保護方面的進展。
- 效能優化與資源效率 (Performance Optimization and Resource Efficiency) : 生成式 AI 技術的效能和資源利用效率不斷提高。
- 生態系統建構與擴展 (Ecosystem Construction and Expansion) : 生成式 AI 技術的生態系統不斷擴展。
- 道德與法律規範 (Ethics and Legal Regulations) : 生成式 AI 技術的道德和法律規範逐步完善。

3.2. L22*-1-生成式 AI 的基本概念與市場價值(指引版)

3.2.1. 生成式 AI 的基本概念與市場價值(指引版)-考前指引之補充資訊-生成式 AI 的訓練數據處理

1. 生成式 AI 的訓練數據處理 (Training Data Processing)

生成式 AI (Generative AI) 是一種能夠生成新內容的人工智慧技術。這些新內容可以是文字、圖像、音樂等。生成式 AI 的訓練數據處理是其成功的關鍵之一。

2. 生成式 AI 的基本概念

生成式 AI 利用深度學習技術來生成新內容。這些技術包括生成對抗網路 (Generative Adversarial Networks · GAN)、變分自編碼器 (Variational Autoencoders · VAE) 等。生成式 AI 需要大量的訓練數據來學習和生成高品質的內容。

3. 訓練數據的定義與重要性

訓練數據是指用來訓練 AI 模型的數據集。這些數據集包含了模型需要學習的所有信息。訓練數據的質量直接影響生成式 AI 的性能和生成內容的質量。因此，訓練數據的收集、清理、標註和增強是生成式 AI 訓練過程中的重要步驟。

4. 訓練數據的收集與準備

訓練數據的收集是生成式 AI 訓練的第一步。這些數據可以來自多種來源，如公開數據集、網絡爬蟲、企業內部數據等。收集到的數據需要進行整理和準備，以確保其質量和適用性。
示例：假設我們要訓練一個生成圖像的 AI 模型，我們可以從網絡上收集大量的圖像數據。這些圖像需要按照一定的標準進行整理，如分辨率、格式等。

5. 訓練數據的清理與預處理

訓練數據的清理與預處理是確保數據質量的重要步驟。清理過程包括去除重複數據、修正錯誤數據、填補缺失數據等。預處理過程包括數據標準化、數據轉換等。
示例：在圖像數據的清理過程中，我們需要去除模糊或損壞的圖像，並將所有圖像轉換為統一的分辨率和格式。

6. 訓練數據的標註

訓練數據的標註是指為數據添加標籤或註釋，以便 AI 模型能夠理解和學習這些數據。標註過程可以是人工標註，也可以是自動標註。

示例：在圖像數據的標註過程中，我們可以為每張圖像添加標籤，如「貓」、「狗」、「車」等。

7. 訓練數據的增強

訓練數據的增強是指通過各種技術來增加數據的多樣性和質量。這些技術包括數據擴充、數據合成等。

示例：在圖像數據的增強過程中，我們可以通過旋轉、翻轉、裁剪等技術來生成更多的圖像數據。

8. 訓練數據的分割

訓練數據的分割是指將數據集分為**訓練集**、**驗證集**和**測試集**。訓練集用來訓練 AI 模型，驗證集用來調整模型參數，測試集用來評估模型性能。

示例：我們可以將收集到的圖像數據按照 80%訓練集、10%驗證集、10%測試集的比例進行分割。

9. 訓練數據的存儲與管理

訓練數據的存儲與管理是確保數據安全和可用性的關鍵。數據需要存儲在安全的地方，並進行定期備份和管理。

示例：我們可以將圖像數據存儲在雲端存儲服務中，並設置定期備份和訪問控制。

10. 示例與實施步驟

以下是訓練數據處理的詳細步驟示例：

- 1) **收集數據**：從網絡上收集大量的圖像數據。
- 2) **清理數據**：去除模糊或損壞的圖像，並將所有圖像轉換為統一的分辨率和格式。
- 3) **標註數據**：為每張圖像添加標籤，如「貓」、「狗」、「車」等。
- 4) **增強數據**：通過旋轉、翻轉、裁剪等技術來生成更多的圖像數據。
- 5) **分割數據**：將圖像數據按照 80%訓練集、10%驗證集、10%測試集的比例進行分割。
- 6) **存儲數據**：將圖像數據存儲在雲端存儲服務中，並設置定期備份和訪問控制。

結論與未來展望

生成式 AI 的訓練數據處理是其成功的關鍵之一。通過收集、清理、標註、增強、分割和存儲數據，我們可以確保 AI 模型能夠學習和生成高品質的內容。未來，隨著技術的進步，訓練數據處理將變得更加自動化和智能化，進一步提升生成式 AI 的性能和應用範圍。

3.2.2. 生成式 AI 的基本概念與市場價值(指引版)-考前指引之補充資訊-生成式 AI 的推理機制

生成式 AI 的推理機制

生成式 AI (Generative AI) 是一種能夠創造新內容的人工智慧技術。這些技術可以生成文本、圖像、音樂等多種形式的內容。生成式 AI 的推理機制是指在生成過程中如何選擇和生成內容。本文將介紹三種常見的推理機制：**溫度機制**、**頂部採樣 (Top-k Sampling)** 和**核採樣 (Nucleus Sampling)**。

溫度機制

溫度機制是一種控制生成內容隨機性的技術。溫度值 (Temperature) 是一個介於 0 到 1 之間的數值，用來調整生成內容的隨機性。當溫度值接近 0 時，生成內容會更加確定和一致；當溫度值接近 1 時，生成內容會更加隨機和多樣化。

示例：假設我們使用生成式 AI 生成一段文本，溫度值設定為 0.2 時，生成的文本可能會非常一致和有條理：

生成式 AI 是一種能夠創造新內容的人工智能技術。這些技術可以生成文本、圖像、音樂等多種形式的內容。

而當溫度值設定為 0.8 時，生成的文本可能會更加隨機和多樣化：

生成式 AI 是一種能夠創造新內容的人工智能技術。這些技術可以生成文本、圖像、音樂等多種形式的內容。生成的內容可能會非常有趣和創意。

頂部採樣 (Top-k Sampling)

頂部採樣是一種選擇生成內容的技術。它會從模型生成的所有可能選項中選擇概率最高的前 k 個選項，然後從這些選項中隨機選擇一個。這樣可以確保生成的內容既有一定的隨機性，又不會偏離主題。

示例：假設我們使用生成式 AI 生成一段文本，頂部採樣的 k 值設定為 5 時，模型會從概率最高的前 5 個選項中選擇一個：

生成式 AI 是一種能夠創造新內容的人工智能技術。這些技術可以生成文本、圖像、音樂等多種形式的內容。

而當 k 值設定為 10 時，模型會從概率最高的前 10 個選項中選擇一個：

生成式 AI 是一種能夠創造新內容的人工智能技術。這些技術可以生成文本、圖像、音樂等多種形式的內容。生成的內容可能會非常有趣和創意。

核採樣 (Nucleus Sampling) 也稱為 Top-p Sampling

核採樣 (Nucleus Sampling) 是一種生成式 AI 模型中常用的技術，用於選擇生成文本的下一個字詞。這種方法的核心思想是根據模型預測的概率分佈，選擇累積概率最高的一部分字詞，然後從中隨機選擇一個字詞。這樣可以避免生成文本過於機械化或重複，並且能夠保持一定的創造性和多樣性。

選擇累積概率的基本概念

選擇累積概率 (Cumulative Probability Selection) 是核採樣技術中的一個重要步驟。具體來說，模型會根據每個字詞的概率進行排序，然後計算累積概率，直到累積概率達到預設的閾值 (通常是 0.9 或 0.95)。這樣可以確保選擇的字詞集合包含了最有可能的字詞，同時也保留了一些不太可能但可能帶來創意的字詞。

核採樣的實施步驟與示例

- 模型預測概率分佈：**首先，生成式 AI 模型會根據上下文預測每個可能的下一個字詞的概率。
例如，假設模型預測的概率分佈如下：
 - "apple": 0.4
 - "banana": 0.3
 - "cherry": 0.2
 - "date": 0.1
- 排序並計算累積概率：**接下來，根據預測的概率進行排序，並計算累積概率：
 - "apple": 0.4 (累積概率: 0.4)
 - "banana": 0.3 (累積概率: 0.7)
 - "cherry": 0.2 (累積概率: 0.9)
 - "date": 0.1 (累積概率: 1.0)
- 選擇累積概率最高的一部分字詞：**假設預設的閾值是 0.9，那麼累積概率達到 0.9 的字詞集合為["apple", "banana", "cherry"]。
- 隨機選擇一個字詞：**最後，從選擇的字詞集合中隨機選擇一個字詞。例如，可能隨機選擇 "banana"。

選擇累積概率的實施步驟與示例

- 1. 模型預測概率分佈：同樣地，生成式 AI 模型會根據上下文預測每個可能的下一個字詞的概率。
- 2. 排序並計算累積概率：根據預測的概率進行排序，並計算累積概率。
- 3. 選擇累積概率最高的一部分字詞：根據預設的閾值選擇累積概率最高的一部分字詞。
- 4. 隨機選擇一個字詞：從選擇的字詞集中隨機選擇一個字詞。

結論

生成式 AI 的推理機制是控制生成內容隨機性和多樣性的關鍵。溫度機制、頂部採樣和核採樣是三種常見的推理機制，它們各有優缺點，可以根據具體需求選擇使用。**溫度機制**可以控制生成內容的隨機性，**頂部採樣**可以確保生成內容不偏離主題，**核採樣**可以確保生成內容既有隨機性又不偏離主題。

3.2.2.1. 在什麼情況下應該選擇使用頂部採樣而不是核採樣？

頂部採樣（Top-k Sampling）和核採樣（Nucleus Sampling）都是生成式 AI 中常用的推理機制，它們各有優缺點，適用於不同的情境。

	頂部採樣（Top-k Sampling）	核採樣（Nucleus Sampling）
適用的情境	需要更高的確定性： 當生成內容需要保持一定的主題一致性和確定性時，頂部採樣可以確保選擇概率最高的前 k 個選項，避免生成內容過於隨機。	需要更高的隨機性： 當生成內容需要更多的創意和隨機性時，核採樣可以通過選擇累積概率達到某個閾值的選項，生成更具多樣性的內容。
	生成內容的質量要求較高： 頂部採樣可以確保生成的內容質量較高，因為它只選擇概率最高的選項，避免生成低質量或不相關的內容。	生成內容的主題一致性要求較低： 核採樣可以生成更具創意和多樣性的內容，適合在主題一致性要求較低的情況下使用。
	需要控制生成內容的多樣性： 頂部採樣可以通過調整 k 值來控制生成內容的多樣性。較小的 k 值會生成更一致的內容，而較大的 k 值會生成更隨機的內容。	需要避免生成低概率選項： 核採樣可以通過設定閾值來避免生成低概率選項，確保生成的內容不會偏離主題。
結論	如果需要更高的確定性和質量，可以選擇頂部採樣	如果需要更多的創意和隨機性，可以選擇核採樣

3.2.3. 生成式 AI 的基本概念與市場價值(指引版)-考前指引之補充資訊-生成式 AI 實際應用面臨的挑戰

實際應用面臨的挑戰	說明	如何因應
大量計算資源需求	生成式 AI 的訓練和應用需要大量的計算資源，如 GPU、TPU 等。	雲計算服務可以提供高效的計算資源，但也需要考慮成本和可持續性問題。

	確保計算資源的充足和高效利用是生成式 AI 成功的關鍵。	
模型訓練和部署的硬體限制	生成式 AI 模型的訓練和部署需要高效的硬體支持。硬體限制可能會影響模型的性能和應用效果。	需要選擇合適的硬體配置，以確保模型的高效運行。
輸出內容的準確性保證	生成式 AI 生成的內容需要具備高準確性，以確保其應用效果。低準確性的內容可能會影響用戶體驗和應用效果。	需要採取措施來提高生成內容的準確性，如數據清理、模型優化等。
AI 幻覺 (AI hallucinations) 問題的防範	AI 幻覺是指生成式 AI 生成的內容可能包含虛假或錯誤的信息。這會影響生成內容的準確性和可靠性。	需要採取措施來防範 AI 幻覺問題，如數據驗證、模型監控等。
偏見與安全性考量	生成式 AI 的訓練數據可能包含偏見，這會影響生成內容的公平性和安全性。	需要採取措施來消除偏見和提高安全性，如數據多樣性、模型監控等。

- 3.3. L22*-2-AI 工具的技術進化及發展(指引版)
- 3.3.1. AI 工具的技術進化及發展(指引版)-概念介紹(僅補充)

AI 工具的技術進化及發展

1. 生成式 AI 工具的技術進化

生成式 AI (Generative AI) 是一種利用人工智慧技術生成新內容的技術。這些工具的技術進化主要包括以下幾個方面：

生成對抗網路 (Generative Adversarial Networks · GAN)

生成對抗網路 (GAN) 是一種由兩個神經網路組成的模型：生成器 (Generator) 和判別器 (Discriminator)。生成器負責生成新的數據，而判別器則負責判斷這些數據是否是真實的。這兩個網路相互競爭，生成器不斷改進其生成的數據，以欺騙判別器。GAN 在圖像生成、視頻生成等領域有廣泛應用。

自編碼器 (Autoencoder)

自編碼器 (Autoencoder) 是一種神經網路模型，主要用於數據的壓縮和特徵提取。它由兩個部分組成：編碼器 (Encoder) 和解碼器 (Decoder)。編碼器將輸入數據轉換為低維度的潛在表示 (Latent Representation)，而解碼器則根據這些潛在表示重建原始數據。自編碼器的目的是在保持數據主要特徵的同時，去除冗餘信息。

潛在表示 (Latent Representation) 是指在機器學習和生成式 AI 模型中，將原始數據轉換為低維度的隱藏特徵空間中的表示。這些潛在表示通常包含了數據的核心特徵和結構，並且可以用來進行數據生成、分類、聚類等任務。

變分自編碼器 (Variational Autoencoders · VAE)

變分自編碼器 (VAE) 是一種生成模型，它通過學習數據的潛在表示來生成新數據。VAE 使用編碼器 (Encoder) 將輸入數據轉換為潛在表示，然後使用解碼器 (Decoder) 將潛在表示轉換回原始數據。VAE 在圖像生成、文本生成等領域有廣泛應用。

基於流的生成模型/流式模型 (Flow-based Generative Models)

基於流的生成模型是一種生成模型，它通過學習數據的概率分佈來生成新數據。這些模型使用一系列可逆的變換來將輸入數據轉換為潛在表示，然後使用這些表示生成新數據。基於流的生成模型在圖像生成、文本生成等領域有廣泛應用。

變壓器 (Transformer)

變壓器 (Transformer) 是一種基於自注意力機制的模型，它在自然語言處理 (Natural Language Processing, NLP) 領域有廣泛應用。變壓器通過學習數據的上下文信息來生成新數據。這些模型在文本生成、機器翻譯等領域有廣泛應用。

強化學習與人類反饋 (Reinforcement Learning with Human Feedback, RLHF)

強化學習與人類反饋 (RLHF) 是一種生成模型，它通過學習人類反饋來改進生成的數據。這些模型使用強化學習技術來優化生成器，使其生成的數據更符合人類的期望。RLHF 在文本生成、圖像生成等領域有廣泛應用。

超大規模語言模型 (Very Large Language Models, vLLM)

超大規模語言模型 (vLLM) 是一種生成模型，它通過學習大量的文本數據來生成新文本。這些模型使用深度學習技術來學習文本的語義和上下文信息，並生成高質量的文本。vLLM 在文本生成、機器翻譯等領域有廣泛應用。

2. 生成式 AI 工具的發展方向

略

3. 生成式 AI 工具的發展與趨勢

略

4. 生成式 AI 各領域的應用與發展

略

3.3.1.1. 生成對抗網路 (GAN) 和變分自編碼器 (VAE) 有何不同？

生成對抗網路 (Generative Adversarial Networks, GAN) 和變分自編碼器 (Variational Autoencoders, VAE) 是兩種常見的生成式 AI 模型，它們在結構和應用上有顯著的不同。

生成對抗網路 (GAN)

GAN 由兩個神經網路組成：生成器 (Generator) 和判別器 (Discriminator)。生成器的目的是生成逼真的數據，而判別器的目的是區分生成數據和真實數據。這兩個網路通過對抗訓練來提高生成數據的質量。

工作原理

- **生成器**：生成器接收隨機噪聲作為輸入，並生成數據（例如圖像）。
- **判別器**：判別器接收生成數據和真實數據，並嘗試區分它們。
- **對抗訓練**：生成器和判別器通過對抗訓練來提高性能。生成器試圖生成更逼真的數據以欺騙判別器，而判別器則試圖更準確地區分生成數據和真實數據。

優缺點

- **優點：**GAN 能夠生成高質量的數據，特別是在圖像生成方面表現出色。
- **缺點：**GAN 的訓練過程可能不穩定，容易出現模式崩潰 (Mode Collapse)，即生成器只生成有限的幾種數據。

變分自編碼器 (VAE)

VAE 是一種基於自編碼器 (Autoencoder) 的生成模型。自編碼器由編碼器 (Encoder) 和解碼器 (Decoder) 組成，VAE 通過引入隨機性來生成數據。

工作原理

- **編碼器：**編碼器將輸入數據轉換為潛在變量 (Latent Variables)，這些潛在變量是隨機的。
- **解碼器：**解碼器接收潛在變量，並生成數據。
- **變分推理：**VAE 通過變分推理來估計潛在變量的分佈，並生成數據。

優缺點

- **優點：**VAE 的訓練過程相對穩定，能夠生成多樣化的數據。
- **缺點：**VAE 生成的數據質量可能不如 GAN 高，特別是在圖像生成方面。

結論

GAN 和 VAE 各有優缺點，適用於不同的應用場景。**GAN 適合生成高質量的圖像數據**，而 **VAE 適合生成多樣化的數據**。根據具體需求選擇合適的生成模型，可以更好地滿足生成內容的需求。

4. L22(評鑑主題 2-生成式 AI 應用領域與工具使用)

內容	備註	評鑑能力
生成式 AI 應用領域與常見工具	領域如文本、圖像和聲音等；工具如 OpenAI API、ChatGPT、Midjourney、Copilot Studio、VS Code for Copilot、Github Copilot 等	評鑑應考者是否熟悉生成式 AI 常見工具的基本操作，瞭解其應用領域及適用場景能有效選擇與應用。
如何善用生成式 AI 工具	如 Prompt、RAG 等	

4.1. 知識學習列表

生成式 AI 應用領域與常見工具

- 1. 文本生成
 - 應用領域：自動化寫作、內容創建、對話系統等。
 - 常見工具：OpenAI API、ChatGPT、Copilot Studio。
 - 學習內容：
 - 了解自然語言處理 (Natural Language Processing · NLP) 的基本概念。
 - 掌握如何使用 OpenAI API 進行文本生成。
 - 熟悉 ChatGPT 的操作和應用場景。
 - 探索 Copilot Studio 在編程輔助中的應用。
- 2. 圖像生成
 - 應用領域：藝術創作、設計輔助、圖像修復等。
 - 常見工具：Midjourney、DALL-E。
 - 學習內容：
 - 了解生成對抗網絡 (Generative Adversarial Networks · GANs) 的基本原理。
 - 掌握 Midjourney 的使用方法和應用場景。
 - 探索圖像生成技術在不同領域的應用。
- 3. 聲音生成：
 - 常見工具：Suno、Google TTS
 - 應用領域：語音合成、音頻生成
 - 相關技術：深度學習 (Deep Learning)
- 4. 音樂生成：
 - 常見工具：Amper Music、AIVA
 - 應用領域：音樂創作、背景音樂生成
 - 相關技術：機器學習 (Machine Learning)
- 5. 影片生成：
 - 常見工具：Synthesia、DeepBrain
 - 應用領域：影片製作、動畫生成
 - 相關技術：深度學習 (Deep Learning)
- 6. 程式碼生成：
 - 常見工具：Copilot Studio、VS Code for Copilot、Github Copilot
 - 應用領域：程式碼自動生成、程式碼補全
 - 相關技術：機器學習 (Machine Learning)

如何善用 Prompt、RAG 等生成式 AI 工具

1. Prompt 設計

- 應用領域：提升生成式 AI 模型的輸出質量。
- 學習內容：
 - 了解 Prompt 的基本概念和設計原則。
 - 掌握如何撰寫有效的 Prompt 以獲得高質量的生成結果。
 - 探索不同類型的 Prompt 在各種應用場景中的使用方法。

2. 檢索增強生成 (Retrieval-Augmented Generation · RAG)

- 應用領域：結合檢索技術提升生成式 AI 模型的性能。
- 學習內容：
 - 了解 RAG 的基本概念和工作原理。
 - 掌握如何實現 RAG 以提升生成結果的準確性和相關性。
 - 探索 RAG 在不同應用場景中的實際案例。

希望這些學習列表能夠幫助你全面掌握生成式 AI 應用領域的知識，並順利通過認證考試。如果有任何問題或需要進一步的幫助，請隨時告訴我！

4.2. L22-1-生成式 AI 應用領域與常見工具

4.2.1. 生成式 AI 應用領域與常見工具-概念介紹

生成式 AI 應用領域與常見工具

介紹

生成式 AI (Generative AI) 是一種利用人工智慧技術生成新內容的技術。這些內容可以是文本、圖像、聲音、音樂、影片、程式碼等。生成式 AI 的應用領域非常廣泛，涵蓋了自動化寫作、圖像修復、音樂創作等多種場景。本文將詳細介紹生成式 AI 的各個應用領域及其常見工具，並探討相關技術和知識。

➤ 生成式 AI 的應用領域

文本生成

文本生成是生成式 AI 的一個重要應用領域。它可以用來自動生成文章、詩歌、對話等。常見的文本生成工具包括：

- **OpenAI API**：OpenAI 提供了一系列 API，可以用來生成文本。這些 API 基於 GPT (Generative Pre-trained Transformer) 模型，能夠生成高質量的文本。
- **ChatGPT**：ChatGPT 是一種基於 GPT 模型的聊天機器人，可以用來生成對話和回答問題。

圖像生成

圖像生成是生成式 AI 的另一個重要應用領域。它可以用來生成新圖像、修復損壞的圖像、生成藝術作品等。常見的圖像生成工具包括：

- **Midjourney**：Midjourney 是一個基於生成對抗網路 (GANs) 的圖像生成工具，可以生成高質量的藝術作品。
- **DALL-E**：DALL-E 是一個基於 GPT 模型的圖像生成工具，可以生成各種風格的圖像。

聲音生成

聲音生成是生成式 AI 的一個重要應用領域。它可以用來生成音樂、語音、音效等。常見的聲音生成工具包括：

- **Suno**：Suno 是一個基於生成對抗網路 (GANs) 的聲音生成工具，可以生成高質量的音樂和音效。
- **Jukedek**：Jukedek 是一個基於深度學習的音樂生成工具，可以生成各種風格的音樂。

影片生成

影片生成是生成式 AI 的一個重要應用領域。它可以用來生成**新影片**、**修復損壞的影片**、**生成動畫**等。常見的影片生成工具包括：

- **RunwayML**：RunwayML 是一個基於**生成對抗網路 (GANs)** 的影片生成工具，可以生成高質量的動畫和影片。
- **Synthesia**：Synthesia 是一個基於**深度學習**的影片生成工具，可以生成各種風格的影片。

程式碼生成

程式碼生成是生成式 AI 的一個重要應用領域。它可以用來生成**新程式碼**、**修復錯誤的程式碼**、**生成自動化腳本**等。常見的程式碼生成工具包括：

- **Copilot Studio**：Copilot Studio 是一個基於 **GPT 模型** 的程式碼生成工具，可以生成高質量的程式碼。
- **VS Code for Copilot**：VS Code for Copilot 是一個基於 **GPT 模型** 的程式碼生成工具，可以生成高質量的程式碼。
- **Github Copilot**：Github Copilot 是一個基於 **GPT 模型** 的程式碼生成工具，可以生成高質量的程式碼。

➤ 生成式 AI 的相關技術和知識

Transformer 模型：

- Transformer 模型是一種基於自注意力機制的深度學習模型，它通過使用多頭自注意力機制來捕捉數據中的長距離依賴關係，特別適合處理序列數據。它們在自然語言處理 (NLP) 領域取得了巨大成功。
- 示例：假設我們希望生成一段文章。Transformer 模型會根據上下文信息來生成連貫的文章。
- 應用：文本生成、機器翻譯、文本摘要等。

自然語言處理 (NLP)

自然語言處理 (Natural Language Processing , NLP) 是生成式 AI 的一個重要技術。NLP 技術可以用來理解和生成文本。常見的 NLP 技術包括：

- **GPT 模型**：GPT (Generative Pre-trained Transformer) 模型是一種基於深度學習的**文本生成技術**，可以生成高質量的文本。
- **BERT 模型**：BERT (Bidirectional Encoder Representations from Transformers) 模型是一種基於深度學習的**文本理解技術**，可以用來理解文本。

✧**BERT 模型主要用於文本理解和處理，而非生成文本**。BERT 模型通過雙向編碼器來理解上下文，並在各種自然語言處理 (NLP) 任務中表現出色，如文本分類、命名實體識別、問答系統等。然而，**生成文本的任務通常由 GPT 模型來完成**，因為 GPT 模型專門設計用於生成高質量的文本。

生成對抗網路 (GANs)

生成對抗網路 (Generative Adversarial Networks , GANs) 是生成式 AI 的一個重要技術。GANs 由兩個神經網路組成：生成器 (Generator) 和判別器 (Discriminator)。生成器負責生成新的數據，判別器則負責區分真實數據和生成數據。這兩個網路相互競爭，最終生成器能夠生成逼真的數據。

示例： 假設我們希望生成逼真的人臉圖像。生成器會生成一張人臉圖像，判別器則判斷這張圖像是否是真實的。生成器和判別器不斷進行對抗訓練，生成器逐漸學會生成更逼真的人臉圖像。

GANs 技術可以用來生成圖像、聲音、影片等。常見的 GANs 技術包括：

- **DCGAN**：DCGAN (Deep Convolutional Generative Adversarial Networks) 是一種基於深度學習的圖像生成技術，可以生成高質量的圖像。
- **StyleGAN**：StyleGAN 是一種基於深度學習的圖像生成技術，可以生成高質量的藝術作品。

變分自編碼器 (Variational Autoencoders · VAEs)：

變分自編碼器 (VAEs) 是一種生成模型，它通過學習數據的潛在表示來生成新數據。VAEs 由編碼器 (Encoder) 和解碼器 (Decoder) 組成，編碼器將輸入數據轉換為潛在表示，解碼器則根據潛在表示生成新數據。

示例： 假設我們希望生成手寫數字。編碼器將手寫數字圖像轉換為潛在表示，解碼器根據潛在表示生成新的手寫數字圖像。

應用： 圖像生成、數據重建等。

流式生成模型 (Flow-based Generative Model)

流式生成模型是一種生成模型，通過一系列可逆變換來顯式建模數據的概率分佈。這些變換將簡單分佈 (如高斯分佈) 轉換為複雜分佈，從而生成新數據。流式生成模型在以下領域有廣泛應用：

- **密度估計**：精確建模數據的概率分佈。
- **數據生成**：生成高質量的圖像、語音等數據。

深度學習

深度學習 (Deep Learning) 是生成式 AI 的一個重要技術，一種基於神經網路的機器學習技術。深度學習模型通過多層神經網路來學習數據的特徵，並生成新數據。深度學習技術可以用來生成**文本、圖像、聲音、影片、程式碼**等。

示例： 假設我們希望生成一張貓的圖像。深度學習模型會根據大量貓的圖像來學習貓的特徵，生成逼真的貓的圖像。

常見的深度學習技術包括：

- **卷積神經網路 (CNNs)**：卷積神經網路 (Convolutional Neural Networks · CNNs) 是一種基於深度學習的圖像生成技術，可以生成高質量的圖像。
- **遞歸神經網路 (RNNs)**：遞歸神經網路 (Recurrent Neural Networks · RNNs) 是一種基於深度學習的文本生成技術，可以生成高質量的文本。

自回歸模型 (Autoregressive Models · AR Models)：

自回歸模型 (AR Model) 是一種基於時間序列數據的模型。它通過使用過去的數據點來預測未來的數據點。自回歸模型在生成式 AI 中常用於生成文本和音樂。

示例： 假設我們希望生成一段音樂。自回歸模型會根據之前的音符來預測下一個音符，逐步生成整段音樂。

擴散模型 (Diffusion Models)：

擴散模型是一種生成模型，它通過逐步添加噪聲來生成新數據。擴散模型在生成圖像和文本方面有很好的效果。

示例： 假設我們希望生成一張風景圖像。擴散模型會逐步添加噪聲，生成逼真的風景圖像。

應用：高質量圖像生成、圖像修復等。

強化學習 (Reinforcement Learning)：

強化學習是一種基於獎勵和懲罰的機器學習技術。強化學習模型通過與環境互動來學習生成新數據，使其能夠在不斷試錯中學習和改進。

示例：假設我們希望生成一段遊戲策略。強化學習模型會根據遊戲的規則和目標來生成最佳的遊戲策略。

應用：遊戲 AI、機器人控制等。

人類反饋強化學習 (Reinforcement Learning from Human Feedback , RLHF)

- 是一種機器學習技術，通過人類反饋來優化人工智能代理的性能[1][2]。具體來說，RLHF 訓練一個“獎勵模型”，該模型根據人類反饋來表示偏好，然後使用這個模型來改進其他模型的行為[1][2]。
- RLHF 的工作原理

獎勵模型訓練：首先，獎勵模型在監督學習下訓練，以預測某個響應是否符合人類偏好（高獎勵）或不符合（低獎勵）[1][2]。

強化學習：然後，這個獎勵模型作為獎勵函數，通過強化學習算法（如近端策略優化算法）來改進 AI 代理的策略[2]。
- RLHF 的應用

RLHF 在多個機器學習領域有應用，包括：

自然語言處理：如文本摘要、對話代理[1][2]。

計算機視覺：如文本到圖像模型[1]。

視頻遊戲：訓練 AI 系統來玩複雜的遊戲[2]。
- 挑戰

儘管 RLHF 是一種有效的訓練方法，但它也面臨一些挑戰，例如收集高質量的偏好數據和避免模型偏見[1][2]。

圖神經網路 (Graph Neural Networks , GNNs)：

圖神經網路 (GNNs) 是一種基於圖結構數據的生成模型。GNNs 通過學習圖結構數據的特徵來生成新數據。

示例：假設我們希望生成一張社交網絡圖。GNNs 會根據社交網絡的結構來生成新的社交網絡圖。

應用：推薦系統、社交網絡分析等。

稀疏編碼 (Sparse Coding)：

稀疏編碼是一種基於稀疏表示的生成模型。稀疏編碼通過學習數據的稀疏表示來生成新數據，用於生成高質量的數據表示，使生成式 AI 模型能夠生成逼真的數據。

示例：假設我們希望生成一段音樂。稀疏編碼會根據音樂的稀疏表示來生成新的音樂。

應用：圖像生成、數據重建等。

自注意力機制 (Self-Attention Mechanism)：

- 自注意力機制用於提高生成式 AI 模型的性能，使其能夠更好地處理序列數據。
- 應用：文本生成、機器翻譯等。

自注意力機制 (Self-Attention Mechanism)

自注意力機制是一種基於注意力的生成模型。自注意力機制通過捕捉數據中的長距離依賴關係來生成新數據。是一種在深度學習中用於處理序列數據的技術，特別是在自然語言處理（NLP）中非常重要。它能夠讓模型在處理每個輸入元素時，根據其他元素的相關性來動態調整其權重。

示例： 假設我們希望生成一段文章。自注意力機制會根據上下文信息來生成連貫的文章。

自注意力機制的工作原理：

計算注意力分數：對於每個輸入元素，計算它與其他所有元素的相似度（注意力分數）。這通常通過點積或其他相似度度量來完成。

權重分配：根據注意力分數，分配權重，使得與當前元素相關性高的元素獲得更高的權重。

加權求和：將所有元素的加權求和，生成新的表示。

優勢：

捕捉長距依賴：自注意力機制能夠有效捕捉序列中遠距離元素之間的依賴關係。

並行計算：相比於循環神經網絡（RNN），自注意力機制允許並行計算，提高了訓練效率。

靈活性：能夠動態調整權重，適應不同的上下文。

應用：

Transformer 模型：如 BERT、GPT 系列模型。

機器翻譯：提高翻譯質量和上下文理解。

文本摘要：生成更準確和連貫的摘要。

vLLM (virtual Large Language Model)

是一個開源代碼庫，旨在提高大型語言模型（LLM）的計算效率和規模[1][2]。它主要用於優化 LLM 的推理過程，使生成式 AI 應用能更高效地利用 GPU 內存[1][2]。

vLLM 引入了一種名為 PagedAttention 的記憶管理技術，這種技術受到操作系統中的虛擬內存和分頁系統的啟發[1][2]。PagedAttention 能夠更穩定地管理 LLM 的空間和計算能力，通過持續“批處理”用戶的響應來創建快捷方式[1][2]。

這使得 vLLM 成為一個高吞吐量且易於使用的 LLM 推理和服務引擎，能夠與流行的 HuggingFace 模型無縫集成[2][3]。

DALL-E

DALL-E 是一種生成模型，通過文本提示生成新圖像。它利用深度學習技術來理解和轉換描述性文字，生成與文本高度對應的圖像。DALL-E 在以下領域有廣泛應用：

- **圖像生成：**根據文本描述生成高質量的圖像。
- **數字藝術：**創作獨特的數字藝術作品。
- **設計：**生成創意設計和概念圖。

Stable Diffusion

Stable Diffusion 是一種基於擴散模型的生成模型，通過在潛在空間中進行擴散過程來生成新圖像。它利用擴散模型和自注意力機制來生成高分辨率的圖像。Stable Diffusion 在以下領域有廣泛應用：

- **圖像生成：**生成高質量的圖像。
- **文本到圖像：**根據文本提示生成圖像。
- **數字藝術：**創作獨特的數字藝術作品。

結論

生成式 AI 是一種利用人工智慧技術生成新內容的技術。它的應用領域非常廣泛，涵蓋了文本、圖像、聲音、音樂、影片、程式碼等多種場景。生成式 AI 的常見工具包括 OpenAI API、ChatGPT、Midjourney、Copilot Studio、VS Code for Copilot、Github Copilot、Suno 等。生成式 AI 的相關技術和知識包括自然語言處理 (NLP)、生成對抗網路 (GANs)、深度學習等。

➤ 如何確保生成式 AI 生成的文本內容的品質？

1. 使用高質量的訓練數據

生成式 AI 模型的品質很大程度上取決於訓練數據的品質。使用高質量、豐富且多樣化的訓練數據可以幫助模型生成更自然、更準確的文本。確保訓練數據涵蓋各種語言風格和主題，以提高模型的泛化能力。

2. 適當的模型選擇和調整

選擇適合的生成式 AI 模型並進行適當的調整是確保生成內容品質的關鍵。不同的模型有不同的特點和優勢，例如 GPT 模型在生成文本方面表現出色，而 BERT 模型則更適合文本理解。**根據具體需求選擇合適的模型，並進行超參數調整以優化模型性能。**

3. 撰寫有效的 Prompt

撰寫有效的 Prompt (提示詞) 可以顯著提高生成內容的品質。Prompt 應該清晰、具體，並提供足夠的上下文信息，以幫助模型理解生成任務。避免使用模糊或不明確的 Prompt，並根據生成需求進行適當的調整。

4. 結合檢索技術 (RAG)

結合檢索技術 (Retrieval-Augmented Generation, RAG) 可以提高生成內容的準確性和相關性。RAG 技術通過檢索相關信息並將其融入生成過程中，幫助模型生成更準確、更具相關性的文本。這種方法特別適合需要高準確性和高相關性的生成任務。

5. 人工審查和校對

雖然生成式 AI 可以自動生成文本，但人工審查和校對仍然是確保內容品質的重要步驟。人工審查可以幫助識別和修正生成內容中的錯誤、不一致或不適當的部分，並確保生成內容符合預期的品質標準。

6. 持續監控和改進

持續監控生成式 AI 模型的性能並進行改進是確保內容品質的關鍵。定期評估模型的生成結果，識別潛在問題並進行修正。根據生成需求和用戶反饋進行模型調整和優化，以持續提高生成內容的品質。

希望這些方法和策略能夠幫助您確保生成式 AI 生成的文本內容的品質。如果您有其他問題或需要進一步了解生成式 AI 的應用，請隨時告訴我！

➤ 何謂超參數調整

超參數調整是指在訓練機器學習模型時，對模型的超參數進行選擇和調整，以優化模型的性能。**超參數是指在模型訓練過程中需要手動設定的參數，而不是通過訓練數據自動學習的參數。**這些超參數對模型的性能有重要影響，因此需要進行適當的調整。

以下是一些常見的超參數及其調整方法：

1. 學習率 (Learning Rate)

學習率是指模型在每次迭代中更新權重的步伐大小。較高的學習率可能導致模型快速收斂，但也可能導致模型跳過最佳解；較低的學習率可能導致模型收斂速度慢，但更有可能找到最佳解。調整學習率可以通過試驗不同的值來找到最佳的學習率。

2. 批次大小 (Batch Size)

批次大小是指在每次迭代中使用的訓練樣本數量。較大的批次大小可以提高訓練速度，但需要更多的計算資源；較小的批次大小可以減少計算資源需求，但可能導致訓練速度變慢。調整批次大小可以通過試驗不同的值來找到最佳的批次大小。

3. 優化器 (Optimizer)

優化器是指在模型訓練過程中用來更新權重的算法。常見的優化器包括 SGD (隨機梯度下降)、Adam、RMSprop 等。不同的優化器有不同的特點和優勢，選擇合適的優化器可以提高模型的性能。

4. 正則化參數 (Regularization Parameters)

正則化參數是指在模型訓練過程中用來防止過擬合的參數。常見的正則化方法包括 L1 正則化、L2 正則化、Dropout 等。調整正則化參數可以通過試驗不同的值來找到最佳的正則化參數。

5. 隱藏層數量和大小 (Number and Size of Hidden Layers)

隱藏層是指在輸入層和輸出層之間的神經網路層。隱藏層的數量和大小對模型的性能有重要影響。較多的隱藏層和較大的隱藏層可以提高模型的表現能力，但也可能導致過擬合。調整隱藏層的數量和大小可以通過試驗不同的配置來找到最佳的隱藏層配置。

6. 激活函數 (Activation Function)

激活函數是指在神經網路中用來引入非線性特性的函數。常見的激活函數包括 ReLU、Sigmoid、Tanh 等。不同的激活函數有不同的特點和優勢，選擇合適的激活函數可以提高模型的性能。

超參數調整通常通過試驗不同的超參數組合來找到最佳的配置。這個過程可以通過網格搜索 (Grid Search)、隨機搜索 (Random Search) 或貝葉斯優化 (Bayesian Optimization) 等方法來進行。希望這些信息能夠幫助您了解超參數調整的概念和方法。如果您有其他問題或需要進一步了解生成式 AI 的應用，請隨時告訴我！

➤ 有哪些其他生成式 AI 工具可以用於生成文本、圖像、聲音、影片、程式碼？

以下是常見的生成式 AI 工具及其功能的表格，並以 Y 表示有支援，空白表示不支援：

生成式 AI 工具	功能簡述	廠商名稱	文本	圖像	聲音	影片	程式
OpenAI API	提供多種生成模型，用於生成文本和圖像	OpenAI	Y	Y (註)	Y (註)		Y
ChatGPT	基於 GPT 模型的聊天機器人，用於生成自然對話	OpenAI	Y				
Midjourney	根據描述生成逼真的圖像	Midjourney		Y			
Copilot Studio	根據描述生成程式碼，提高編程效率	GitHub					Y

生成式 AI 工具	功能簡述	廠商名稱	文本	圖像	聲音	影片	程式
VS Code for Copilot	集成在 VS Code 中的生成程式碼工具	GitHub					Y
Github Copilot	根據描述生成程式碼，提高編程效率	GitHub					Y
Claude	生成自然語言文本，用於編輯和對話	Anthropic	Y				
DeepAI	提供文本和圖像生成工具	DeepAI	Y	Y			
DALL-E	根據文本描述生成高質量圖像	OpenAI		Y			
Jukedek	根據需求生成原創音樂	Jukedek			Y		
AIVA	生成各種風格的音樂	AIVA Technologies			Y		
TabNine	基於 AI 的程式碼補全工具	TabNine					Y
Kite	AI 驅動的程式碼補全工具	Kite					Y

(註) OpenAI API 本身主要用於文本生成，但它也可以與其他專門的生成工具結合使用，以擴展其功能。例如，DALL-E 是一個專門用於圖像生成的工具，而 Jukebox 則是用於聲音生成的工具。這些工具都是由 OpenAI 開發的，並且可以與 OpenAI API 一起使用，以實現更豐富的生成式 AI 應用。除此之外，OpenAI API 也可以與 Midjourney 結合來生成圖片。

4.3. L22-2-如何善用生成式 AI 工具

4.3.1. 如何善用生成式 AI 工具-概念介紹

1. 生成式 AI 工具概述

生成式 AI 工具是指利用人工智慧技術生成文本、圖像、聲音、音樂、影片、程式碼等內容的工具。這些工具通常基於深度學習模型，如生成對抗網路 (GANs)、變分自編碼器 (VAEs) 和自然語言處理 (NLP) 技術。生成式 AI 工具在各種應用領域中具有廣泛的用途，包括自動化寫作、圖像修復、音樂創作等。

常見生成式 AI 工具

- **OpenAI API**：OpenAI 提供了一系列強大的 API，包括 GPT-3 和 GPT-4，這些 API 可以用於生成文本、回答問題、翻譯語言等。使用者可以通過簡單的 API 調用來獲取高質量的生成內容。
- **ChatGPT**：ChatGPT 是 OpenAI 的一款聊天機器人，基於 GPT-3 和 GPT-4 技術。它可以用於生成自然語言回應，適用於客服、教育、娛樂等多種場景。使用者可以通過與 ChatGPT 互動來獲取所需的信息和服務。
- **Midjourney**：是一款基於 GANs 技術的生成圖像 AI 工具，使用者可以通過提供文本描述來生成高質量的圖像。這款工具適用於設計、藝術創作、廣告等領域，幫助使用者快速生成所需的視覺內容。
- **Copilot Studio**：生成程式碼的工具，基於 GitHub Copilot。它可以幫助開發者自動生成程式碼片段、修復錯誤、提供程式碼建議，提升開發效率。
- **VS Code for Copilot**：是 GitHub Copilot 的擴展，集成在 Visual Studio Code 編輯器中。開發者可以在編輯器中直接使用 Copilot 的功能，獲取程式碼建議和自動生成程式碼片段。
- **Github Copilot**：生成程式碼的 AI 助手。

- **Suno**：生成音樂的工具，使用者可以通過提供音樂風格和元素來生成高質量的音樂作品。這款工具適用於音樂創作、影視配樂、遊戲音樂等領域，幫助使用者快速生成所需的音樂內容。

2. Prompt 的基本概念和設計原則

什麼是 Prompt？

Prompt 是指在使用生成式 AI 工具時，向 AI 提供的指令或提示。這些指令可以是文字、問題、或其他形式的輸入，目的是引導 AI 生成所需的內容。Prompt 的質量和精確度直接影響生成內容的品質，因此了解如何撰寫有效的 Prompt 是使用生成式 AI 工具的關鍵。

為什麼 Prompt 重要？

Prompt 的重要性在於它能夠決定 AI 生成內容的方向和質量。好的 Prompt 可以幫助 AI 更準確地理解使用者的需求，並生成符合預期的內容。反之，模糊或不精確的 Prompt 可能會導致生成的內容不符合使用者的期望。因此，學習如何撰寫有效的 Prompt 是提升生成式 AI 工具使用效果的必要技能。

如何撰寫有效的 Prompt？

撰寫有效的 Prompt 需要考慮以下幾個方面：

明確的指令：提供清晰、具體的指令，避免模糊或多義的語句。例如，與其說「寫一篇文章」，不如說「寫一篇關於生成式 AI 工具應用的文章，字數約 2000 字」。

上下文信息：提供足夠的上下文信息，幫助 AI 理解指令的背景。例如，若需要生成一篇介紹某個技術的文章，可以提供該技術的基本信息和應用場景。

示例和格式：提供示例或格式要求，幫助 AI 理解生成內容的結構。例如，若需要生成一篇報告，可以提供報告的標題、段落結構和示例內容。

示例：撰寫 Prompt 的步驟

假設使用者需要生成一篇關於人工智慧技術在醫療領域應用的文章。以下是撰寫 Prompt 的步驟：

確定目標：生成一篇關於人工智慧技術在醫療領域應用的文章。

提供上下文：人工智慧技術在醫療領域的應用包括疾病診斷、治療方案推薦、病患管理等。

具體指令：請生成一篇包括技術概述、應用案例和未來發展的文章。字數在 800 字以內

示例：例如，人工智慧技術可以通過分析病患數據來診斷疾病，並推薦最適合的治療方案。

根據以上資訊，Prompt 為：

請生成一篇關於人工智慧技術在醫療領域應用的文章，字數在 800 字以內。文章應包括技術概述、應用案例和未來發展。人工智慧技術在醫療領域的應用包括疾病診斷、治療方案推薦和病患管理。例如，人工智慧技術可以通過分析病患數據來診斷疾病，並推薦最適合的治療方案。

3. RAG 的基本概念和應用

RAG 的基本概念

檢索增強生成 (Retrieval-Augmented Generation, RAG) 是一種結合檢索技術和生成技術的生成式 AI 模型。RAG 模型通過檢索相關信息來輔助生成內容，從而提升生成結果的準確性和相關性。這種方法能夠有效地解決生成式 AI 模型在生成內容時可能遇到的準確性和相關性問題。

RAG 的運作原理

RAG 的運作原理可以分為以下幾個步驟：

- 檢索階段**：首先，系統會根據使用者的輸入進行檢索，從資料庫中找到與輸入相關的資料。這些資料可以是文本、圖像、音頻等各種形式。
- 生成階段**：接著，系統會將檢索到的資料作為生成模型的輸入，生成新的內容。生成模型可以是自然語言處理（Natural Language Processing，NLP）模型、圖像生成模型等。
- 整合階段**：最後，系統會將生成的內容與原始輸入進行整合，形成最終的輸出。

RAG 的應用場景

RAG 技術在許多領域都有廣泛的應用，以下是幾個典型的應用場景：

- 問答系統**：RAG 技術可以用於問答系統中，通過檢索相關資料並生成回答，提高回答的準確性和相關性。
- 內容生成**：在內容生成方面，RAG 技術可以幫助創作者生成更具質量的文章、報告等。
- 客服系統**：RAG 技術可以用於客服系統中，通過檢索相關資料並生成回應，提高客服的效率和準確性。

常見的檢索模型(僅支援初步檢索)及檢索增強生成 (RAG) 模型(支援初步檢索及增強生成)

常見的支援繁體中文的模型有以下幾個：

- EasyRAG**：支援初步檢索及增強生成。這是一個基於 LlamaIndex 和 OpenAI API 的繁體中文檢索增強生成系統。它可以從您的文件庫中尋找相關資訊並用繁體中文回答問題[1]。
- Voyage-multilingual-2**：支援初步檢索及增強生成。這是一個支援多語言的嵌入模型，在 RAG 系統中用於將文字轉換為語意向量。這個模型在繁體中文的檢索能力方面表現出色[2]。
- BGE-M3**：僅支援初步檢索。是基於 BERT 的稀疏嵌入模型，結合了稀疏表示和上下文語義理解的優點，特別是在多語言、多粒度(從短文本到長文本)和多功能(稠密檢索、稀疏檢索和多向量檢索)的應用場景中。在初步檢索階段，BGE-M3 模型可以根據使用者的查詢進行檢索，找到與查詢相關的高質量資料。這些資料可以作為增強生成階段的輸入，幫助生成模型生成更準確和相關的內容。
- TF-IDF 模型**：僅支援初步檢索。適合處理短文本資料，計算簡單，效率高。適用於需要快速檢索和精確匹配的場景。
- BM25 模型**：僅支援初步檢索。適合處理長文本資料，考慮詞語位置和上下文信息，提供更精確的檢索結果。適用於需要語義理解和上下文考慮的場景。
- BERT 模型**：僅支援初步檢索。基於深度學習的語言模型，能夠理解詞語的語義信息，提供高質量的檢索結果。適用於需要語義理解和上下文考慮的場景，但計算資源需求較高。

4. 如何選擇合適的生成式 AI 工具

選擇合適的生成式 AI 工具需要考慮多方面的因素，以確保工具能夠滿足你的需求並提供最佳的使用體驗。以下是一些關鍵考量點，幫助你做出明智的選擇：

了解你的需求

首先，明確你需要生成式 AI 工具來完成什麼任務。例如，你是需要生成文本、圖像、音樂還是程式碼？不同的工具專注於不同的應用場景，因此了解你的需求是選擇合適工具的第一步。

工具的功能和特點

不同的生成式 AI 工具有不同的功能和特點。你需要考慮工具是否具備你所需的功能，例如文本生成工具是否支持多語言，圖像生成工具是否能夠生成高解析度的圖像，音樂生成工具是否能夠生成多種風格的音樂等。

使用者體驗

使用者體驗是選擇生成式 AI 工具的重要考量點。工具的界面是否友好，操作是否簡便，是否有良好的技術支持和使用者社群，這些都會影響你的使用體驗。你可以參考其他使用者的評價和反饋，了解工具的優缺點。

成本和效益

生成式 AI 工具的成本也是需要考慮的因素。你需要了解工具的購買費用、訂閱費用以及可能的隱藏成本。同時，考慮工具能夠為你帶來的效益，例如提高工作效率、提升創作質量等，評估其性價比。

技術支持和社群資源

良好的技術支持和豐富的社群資源可以幫助你更好地使用生成式 AI 工具。你可以查看工具的官方文檔、教程和客服支持，了解是否有活躍的使用者社群，是否有豐富的資源可以參考和學習。

試用和評估

在選擇生成式 AI 工具之前，最好能夠進行試用和評估。許多工具提供免費試用或試用版，你可以通過試用來了解工具的功能和使用體驗，評估其是否符合你的需求。

結論

選擇合適的生成式 AI 工具需要綜合考慮多方面的因素，包括你的需求、工具的功能和特點、使用者體驗、成本和效益、技術支持和社群資源等。通過試用和評估，你可以找到最適合你的生成式 AI 工具，提升你的工作效率和創作質量。

5. 生成式 AI 技術或工具生成內容時，如何確保內容品質

生成式 AI 技術或工具生成內容時，確保內容品質是非常重要的。以下是一些方法可以幫助確保生成內容的品質：

適當標注引用來源

在使用生成式 AI 技術生成內容時，應該標注引用來源，以確保內容的可信度和透明度。這樣可以尊重原作者的知識產權，並且讓讀者能夠追溯到原始資料。

人工審查和驗證

生成的內容應該經過人工審查和驗證，以識別和修正其中的錯誤或不準確之處。人工審查可以幫助確保內容的準確性和可靠性。

使用多種資料來源

生成內容時應該使用多種資料來源，以確保內容的全面性和多樣性。這樣可以避免單一來源可能帶來的偏見或錯誤。

定期更新和維護

生成式 AI 技術應該定期更新和維護，以確保其生成的內容能夠反映最新的資訊和知識。這樣可以避免過時或不準確的內容。

透明度和解釋

在生成內容時，應該提供透明度和解釋，讓讀者了解生成內容的過程和方法。這樣可以增加內容的可信度和接受度。

6. 生成式 AI 工具在使用體驗方面的優化方向有那些?

生成式 AI 工具在使用體驗方面的優化方向有許多，以下是一些主要的方向：

直觀的操作設計：提供更直觀的操作設計，使使用者能夠輕鬆上手並使用工具。這包括簡化界面、清晰的指示和易於理解的選項。

自然語言指令支援：支援自然語言指令，使使用者能夠以自然的語言與工具互動，而不需要學習複雜的指令或語法。這可以提高使用者的便利性和效率。

智慧化的參數調整建議：提供智慧化的參數調整建議，幫助使用者更有效地使用工具並生成更高品質的內容。這可以包括根據使用者的需求和目標自動調整參數。

即時反饋和結果預覽：提供即時反饋和結果預覽，使使用者能夠立即看到生成的內容並進行必要的調整。這可以提高使用者的滿意度和生成內容的品質。

多語言支援：支援多種語言，使不同語言的使用者都能夠方便地使用工具。這可以擴大工具的使用範圍和受眾。

高效的性能和速度：優化工具的性能和速度，使生成內容的過程更加流暢和快速。這可以提高使用者的工作效率和使用體驗。

安全性和隱私保護：確保工具的安全性和隱私保護，保護使用者的數據和生成內容不被未授權的訪問或洩露。這可以增加使用者的信任和安心感。

這些優化方向可以幫助生成式 AI 工具提供更好的使用體驗，讓使用者能夠更方便、高效地生成高品質的內容。

7. 如何正確使用生成式 AI 工具

正確使用生成式 AI 工具的方法有許多，以下是一些主要的方向：

制定明確的使用規範：在使用生成式 AI 工具時，應訂立清晰的使用規範並進行說明，以確保使用者了解如何正確和負責地使用這些工具。

避免過度依賴：生成式 AI 工具應作為輔助工具，而非完全取代人類的思考和決策過程。

注意資訊安全：在使用生成式 AI 工具時，應注意保護使用者的數據和生成內容不被未授權的訪問或洩露。

仔細閱讀平台的使用條款：在使用生成式 AI 工具前，應仔細閱讀並理解平台的使用條款，以避免違反規定。

避免輸入機密或專有資訊：在使用生成式 AI 工具時，應避免輸入機密或專有資訊，以保護公司的機密信息。

選擇可靠且合適的平台：應選擇可靠且合適的生成式 AI 平台，以確保生成內容的品質和安全。

二次檢查 AI 生成的內容：生成的內容應該經過人工審查和驗證，以識別和修正其中的錯誤或不準確之處。

➤常見的檢索模型 TF-IDF、BM25

檢索模型是資訊檢索系統中的核心技術，用於從大量資料中找到與使用者查詢相關的資訊。常見的檢索模型包括 TF-IDF、BM25 等。本文將詳細介紹這些模型的概念、運作原理、應用場景以及實施步驟，並提供具體示例，幫助讀者理解並掌握這些技術。

➤TF-IDF 模型

TF-IDF (Term Frequency-Inverse Document Frequency) 是一種常見的**文本檢索模型**，用於衡量詞語在文件中的重要性。TF-IDF 模型的核心思想是通過計算詞語在文件中的出現頻率 (TF) 和詞語在整個文件集中的逆文檔頻率 (IDF)，來確定詞語的重要性。

TF-IDF 運作原理

- 1.**詞頻 (TF)：**詞頻是指某個詞語在文件中出現的次數。詞頻越高，表示該詞語在該文件中越重要。
- 2.**逆文檔頻率 (IDF)：**逆文檔頻率是指某個詞語在整個文件集中出現的頻率的倒數。詞語在越多文件中出現，表示該詞語的區分能力越低，逆文檔頻率越低。
- 3.**TF-IDF 值：**TF-IDF 值是詞頻和逆文檔頻率的乘積，用於衡量詞語在文件中的重要性。TF-IDF 值越高，表示該詞語在該文件中越重要。

示例

- 假設我們有三個文件：
- 文件 1：人工智慧正在改變世界。

- 文件 2：人工智慧在醫療領域的應用。
- 文件 3：人工智慧在教育領域的應用。

我們要計算「人工智慧」在這三個文件中的 TF-IDF 值。首先，我們計算詞頻 (TF)：

- 文件 1：「人工智慧」出現 1 次， $TF=1$ 。
- 文件 2：「人工智慧」出現 1 次， $TF=1$ 。
- 文件 3：「人工智慧」出現 1 次， $TF=1$ 。

接著，我們計算逆文檔頻率 (IDF)：

- 「人工智慧」在所有三個文件中都出現， $IDF=\log(3/3)=0$ 。

最後，我們計算 TF-IDF 值：

- 文件 1： $TF-IDF=1*0=0$ 。
- 文件 2： $TF-IDF=1*0=0$ 。
- 文件 3： $TF-IDF=1*0=0$ 。

由此可見，「人工智慧」在這三個文件中的 TF-IDF 值都是 0，表示該詞語在這些文件中並不重要。

TF-IDF 優點：

1. **簡單易懂**：TF-IDF 模型的計算方法相對簡單，容易理解和實施。它通過計算詞頻 (TF) 和逆文檔頻率 (IDF) 來衡量詞語的重要性。
2. **計算效率高**：由於 TF-IDF 模型的計算方法簡單，因此計算效率較高，適合處理大規模文本資料。
3. **適用範圍廣**：TF-IDF 模型適用於各種文本檢索任務，如文件分類、信息檢索等。

TF-IDF 缺點：

1. **忽略詞語位置**：TF-IDF 模型僅考慮詞語的出現頻率，忽略了詞語在文本中的位置和上下文信息，可能導致檢索結果不夠精確。
2. **無法處理長文本**：TF-IDF 模型在處理長文本時效果不佳，因為長文本中的詞語頻率可能會被稀釋，導致重要詞語的權重降低。
3. **無法處理語義信息**：TF-IDF 模型僅基於詞語的出現頻率，無法理解詞語的語義信息，可能導致檢索結果不夠相關。

➤BM25 模型

BM25 (Best Matching 25) 是一種改進的文本檢索模型，用於衡量詞語在文件中的重要性。BM25 模型的核心思想是通過計算詞語在文件中的出現頻率 (TF) 和詞語在整個文件集中的逆文檔頻率 (IDF)，並考慮文件長度和詞語位置等因素，來確定詞語的重要性。

BM25 運作原理

1. **詞頻 (TF)**：詞頻是指某個詞語在文件中出現的次數。詞頻越高，表示該詞語在該文件中越重要。
2. **逆文檔頻率 (IDF)**：逆文檔頻率是指某個詞語在整個文件集中出現的頻率的倒數。詞語在越多文件中出現，表示該詞語的區分能力越低，逆文檔頻率越低。
3. **BM25 值**：BM25 值是詞頻和逆文檔頻率的加權和，用於衡量詞語在文件中的重要性。BM25 值越高，表示該詞語在該文件中越重要。

示例

假設我們有三個文件：

- 文件 1：人工智慧正在改變世界。
- 文件 2：人工智慧在醫療領域的應用。
- 文件 3：人工智慧在教育領域的應用。

我們要計算「人工智慧」在這三個文件中的 BM25 值。首先，我們計算詞頻 (TF)：

- 文件 1：「人工智慧」出現 1 次， $TF=1$ 。
- 文件 2：「人工智慧」出現 1 次， $TF=1$ 。
- 文件 3：「人工智慧」出現 1 次， $TF=1$ 。

接著，我們計算逆文檔頻率 (IDF)：

- 「人工智慧」在所有三個文件中都出現， $IDF=\log(3/3)=0$ 。

最後，我們計算 BM25 值：

- 文件 1： $BM25=1*0=0$ 。
- 文件 2： $BM25=1*0=0$ 。
- 文件 3： $BM25=1*0=0$ 。

由此可見，「人工智慧」在這三個文件中的 BM25 值都是 0，表示該詞語在這些文件中並不重要。

BM25 優點：

1. **考慮詞語位置：**BM25 模型在計算詞語重要性時，考慮了詞語在文本中的位置和上下文信息，能夠提供更精確的檢索結果。
2. **適合長文本：**BM25 模型在處理長文本時效果較好，因為它考慮了文本長度和詞語位置，能夠更好地衡量詞語的重要性。
3. **語義信息：**BM25 模型能夠理解詞語的語義信息，提供更相關的檢索結果。

BM25 缺點：

1. **計算複雜：**BM25 模型的計算方法相對複雜，理解和實施難度較大，計算效率較低。
2. **需要調參：**BM25 模型需要調整多個參數，如 $k1$ 和 b ，以獲得最佳效果，這增加了模型的調試難度。
3. **適用範圍有限：**BM25 模型主要適用於文本檢索任務，對其他類型的檢索任務效果不佳。

結論

TF-IDF 和 BM25 是兩種常見的文本檢索模型，用於衡量詞語在文件中的重要性。這些模型通過計算詞頻和逆文檔頻率，並考慮文件長度和詞語位置等因素，來確定詞語的重要性。

5. L23(評鑑主題 3-生成式 AI 導入評估規劃)

內容	備註	評鑑能力
生成式 AI 導入評估	如技術或工具效能評估、適用解決方案選擇、成本效益分析等；經濟部產業發展署《AI 導入指引》相關資料等。	評鑑應考者是否能掌握生成式 AI 導入的初步規劃要領，包含需求確認、資源分配、試用測試等步驟等。
生成式 AI 導入規劃	如目標設置、資源分配等	
生成式 AI 風險管理	如生成式 AI 倫理風險、資料安全隱私與合規性等	

5.1. L23-1-生成式 AI 導入評估

5.1.1. 知識學習列表

生成式 AI 導入評估

1. **技術或工具效能評估**：了解生成式 AI 技術的效能，包括模型的準確性、速度、可擴展性等。
2. **適用解決方案選擇**：根據企業需求選擇最適合的生成式 AI 解決方案。
3. **成本效益分析**：評估生成式 AI 導入的成本與預期效益。
4. **經濟部產業發展署《AI 導入指引》**：了解並遵循官方指引，確保導入過程符合規範。

生成式 AI 導入規劃

1. **準備階段**：
 - **挑選 AI 應用方案**：掌握企業課題，檢視 AI 方案與企業資源，確定應用領域優先順序。
2. **設計**：
 - **確認 AI 生成規格**：確認導入最終目標、數據狀態、使用情境、估算 AI 導入成本。
3. **驗證 POC**：
 - **驗證 AI 效果**：模型開發至部署、導入實務運作流程、ROI 的計算方式。
4. **實施/營運**：
 - **持續發揮價值**：專案落地、模型監控與重新訓練、AI 價值擴散。

生成式 AI 風險管理

1. **生成式 AI 倫理風險**：了解並管理生成式 AI 可能帶來的倫理問題。
2. **資料安全隱私與合規性**：確保資料安全，遵循 GDPR、CCPA 等隱私法規。
3. **風險的種類與管理**：
 - **風險溯源**：追溯風險來源。
 - **風險文化**：建立風險管理文化。
 - **風險接受**：接受並管理風險。
 - **風險緩解**：減少風險影響。
 - **風險迴避**：避免風險。
 - **風險轉移**：將風險轉移給第三方。

5.1.2. 生成式 AI 導入評估-概念介紹

1. 生成式 AI 的基本概念

生成式 AI (Generative AI) 是一種利用機器學習技術生成新數據的人工智慧技術。這些技術可以用來創建文本、圖像、音樂等多種形式的內容。生成式 AI 的核心在於其能夠學習並模仿現有數據的模式，從而生成的、類似的數據。

生成式 AI 的應用

生成式 AI 在各個領域都有廣泛的應用，包括但不限於：

- **文本生成**：如自動寫作、聊天機器人等。
- **圖像生成**：如生成藝術作品、圖像修復等。
- **音樂生成**：如自動作曲、音樂風格轉換等。

2. 生成式 AI 導入的需求確認

在導入生成式 AI 之前，首先需要確認企業或組織的需求。這包括以下幾個方面：

- **目標設定**：明確生成式 AI 導入的目標，如提高生產效率、降低成本、提升產品質量等。
- **需求分析**：分析現有業務流程，找出可以通過生成式 AI 改進的環節。
- **資源評估**：評估現有資源是否足夠支持生成式 AI 的導入，包括人力、技術、資金等。

3. 技術或工具效能評估

在選擇生成式 AI 技術或工具時，需要對其效能進行評估。這包括以下幾個方面：

- 準確性：生成式 AI 生成內容的準確性和質量。
- 穩定性：生成式 AI 在不同環境下的穩定性和可靠性。
- 可擴展性：生成式 AI 技術或工具是否能夠隨著業務需求的增長而擴展。

4. 適用解決方案選擇

根據需求確認和效能評估的結果，選擇適合的生成式 AI 解決方案。這包括以下幾個方面：

- 技術適配：選擇與現有技術架構相容的生成式 AI 解決方案。
- 成本效益：選擇在成本和效益之間達到最佳平衡的解決方案。
- 供應商評估：評估生成式 AI 技術供應商的實力和服務質量。

5. 成本效益分析

在導入生成式 AI 之前，需要進行詳細的成本效益分析。這包括以下幾個方面：

- 初期投入：生成式 AI 導入的初期投入成本，包括硬體、軟體、培訓等。
- 運營成本：生成式 AI 運行過程中的持續成本，如維護、更新等。
- 效益預測：生成式 AI 導入後可能帶來的效益，如提高生產效率、降低運營成本等。

6. 經濟部產業發展署《AI 導入指引》

經濟部產業發展署提供了一份《AI 導入指引》，詳細介紹了 AI 導入的各個步驟和注意事項。這份指引對於企業或組織在導入生成式 AI 時具有重要的參考價值。具體內容可以參考[經濟部產業發展署《AI 導入指引》](#)。

7. 實施步驟與示例

1. 實施步驟
 1. 需求確認：明確生成式 AI 導入的目標和需求。
 2. 技術選擇：根據需求選擇適合的生成式 AI 技術或工具。
 3. 試用測試：在小範圍內進行試用測試，評估生成式 AI 的效能和穩定性。
 4. 全面導入：根據試用測試的結果，進行全面導入。
 5. 持續優化：根據實際運行情況，持續優化生成式 AI 的應用。

示例

假設某製造企業希望通過生成式 AI 提高產品質量，具體實施步驟如下：

1. 需求確認：企業希望通過生成式 AI 自動檢測產品缺陷，提高產品質量。
2. 技術選擇：選擇一款具備高準確性和穩定性的生成式 AI 圖像識別技術。
3. 試用測試：在一條生產線上進行試用測試，評估生成式 AI 的檢測效果。
4. 全面導入：根據試用測試的結果，將生成式 AI 技術全面導入到所有生產線。
5. 持續優化：根據實際運行情況，持續優化生成式 AI 的檢測算法，提高檢測準確性。

5.2. L23-2-生成式 AI 導入規劃

5.2.1. 生成式 AI 導入規劃-考前指引之補充

(1) 準備階段(挑選 AI 應用方案)	A. 掌握企業課題	設立明確的目標、選定應用範圍、提取改善項目
	B. 檢視 AI 方案與企業資源	生成式 AI 的必要性、AI 相關方案選擇、檢視企業資源
	C. 確定應用領域優先順序	評估導入容易程度、方案導入優先順序
	A. 確認導入最終目標	

(2) 設計(確認 AI 生成規格)	B. 確認數據狀態	
	C. 確認使用情境	
	D. 估算 AI 導入成本	
(3) 驗證 POC (驗證 AI 效果)	A. 模型開發至部署	a.模型架構與演算法、b.訓練模型與如何優化、c.驗證方案與檢查效能 詳指引 Page 3-39 ~ Page 3-42
	B. 導入實務運作流程	業務流程整合、試點運行、員工培訓、持續改進機、效益評估與推廣
	C. ROI 的計算方式	如淨現值 (Net Present Value, NPV) 與內部報酬率 (Internal Rate of Return, IRR) 藉由敏感性分析 (Sensitivity Analysis) 能有效模擬市場條件、業務情境或成本變動對方案收益的影響，幫助企業識別風險與機會，進而制定更靈活的投資策略。
(4) 實施/營運 (持續發揮價值)	A. 專案落地	
	B. 模型監控與重新訓練	首先，設定模型效能的監控指標，例如準確率 (Accuracy)、召回率 (Recall) 以及預測錯誤率 (Error Rate)，以便持續追蹤模型表現 其次，定期檢查數據漂移 (Data Drift)，分析輸入數據的分佈變化，特別是當業務場景或用戶行為改變時，數據漂移可能會導致模型預測準確性降低。 最後，實現自動化重新訓練流程非常重要。構建自動化的重新訓練管道 (Retraining Pipeline)，可縮短模型更新的周期
	C. AI 價值擴散	為實現生成式 AI 的全面應用，企業需制定明確的擴散策略，將 AI 技術由單點應用逐步推廣至全企業範圍。這一過程應注重促進技術內化，將生成式 AI 融入核心業務流程，成為驅動創新的關鍵動力。

5.2.2. 生成式 AI 導入規劃-概念介紹

1. 生成式 AI 導入的目標確認

在導入生成式 AI 之前，首先需要明確導入的目標。這些目標可以是多方面的，例如提高生產效率、降低運營成本、提升產品質量、增強客戶體驗等。明確的目標有助於制定具體的實施計劃，並在導入過程中進行有效的監控和評估。

目標設定的步驟

1. 識別業務需求：了解企業或組織的業務需求，確定生成式 AI 可以解決的問題。
2. 確定具體目標：將業務需求轉化為具體的目標，例如提高生產效率 20%、降低運營成本 15% 等。
3. 制定評估標準：確定如何評估生成式 AI 導入的效果，設置具體的 KPI (關鍵績效指標)。

2. 需求確認

需求確認是生成式 AI 導入規劃中的關鍵步驟。這一步驟包括對現有業務流程的分析，找出可以通過生成式 AI 改進的環節，並確定所需的技術和資源。

需求確認的步驟

1. 業務流程分析：詳細分析現有業務流程，找出瓶頸和改進點。
2. 技術需求確認：確定生成式 AI 技術在業務流程中的應用場景，例如文本生成、圖像生成等。
3. 資源需求確認：評估導入生成式 AI 所需的資源，包括人力、技術、資金等。

3. 資源分配

在確認需求後，需要進行資源分配。這包括人力資源、技術資源和財務資源的分配。合理的資源分配有助於確保生成式 AI 導入的順利進行。

資源分配的步驟

1. **人力資源分配：**確定參與生成式 AI 導入的團隊成員及其職責。
2. **技術資源分配：**確定所需的技術工具和平台，例如深度學習框架、數據處理工具等。
3. **財務資源分配：**制定預算，確保有足夠的資金支持生成式 AI 的導入和運營。

4. 試用測試

在全面導入生成式 AI 之前，進行試用測試是非常重要的。試用測試可以幫助評估生成式 AI 的效能和穩定性，並及時發現和解決問題。

試用測試的步驟

1. **選擇試用場景：**選擇一個或多個業務場景進行試用測試。
2. **設置測試標準：**確定試用測試的評估標準，例如準確性、穩定性、可擴展性等。
3. **進行測試：**在選定的業務場景中進行試用測試，收集數據並進行分析。
4. **問題解決：**根據測試結果，及時發現和解決問題，優化生成式 AI 的應用。

5. 風險管理

生成式 AI 導入過程中可能會面臨各種風險，包括技術風險、資源風險、倫理風險等。有效的風險管理有助於降低這些風險，確保生成式 AI 導入的成功。

風險管理的步驟

1. **識別風險：**識別生成式 AI 導入過程中可能面臨的風險。
2. **評估風險：**評估風險的可能性和影響，確定風險等級。
3. **制定應對措施：**制定針對不同風險的應對措施，例如技術風險的解決方案、資源風險的應急預案等。
4. **監控風險：**在生成式 AI 導入過程中，持續監控風險，及時調整應對措施。

6. 實施步驟與示例

實施步驟

1. **需求確認：**明確生成式 AI 導入的目標和需求。
2. **資源分配：**合理分配人力、技術和財務資源。
3. **試用測試：**在小範圍內進行試用測試，評估生成式 AI 的效能和穩定性。
4. **全面導入：**根據試用測試的結果，進行全面導入。
5. **持續優化：**根據實際運行情況，持續優化生成式 AI 的應用。

示例

假設某零售企業希望通過生成式 AI 提升客戶體驗，具體實施步驟如下：

1. **需求確認：**企業希望通過生成式 AI 自動生成個性化推薦，提高客戶滿意度。
2. **資源分配：**組建一個專門的 AI 團隊，選擇合適的技術平台，並制定預算。
3. **試用測試：**在部分客戶中進行試用測試，評估生成式 AI 的推薦效果。
4. **全面導入：**根據試用測試的結果，將生成式 AI 技術全面導入到所有客戶服務中。
5. **持續優化：**根據客戶反饋，持續優化生成式 AI 的推薦算法，提高推薦準確性。

5.3. L23-3-生成式 AI 風險管理

5.3.1. 生成式 AI 風險管理-概念介紹

1. 生成式 AI 風險管理的基本概念

生成式 AI (Generative AI) 技術在帶來創新和效率提升的同時，也伴隨著各種風險。這些風險包括技術風險、倫理風險、資料安全風險和合規性風險等。風險管理的目的是識別、評估和應對這些風險，以確保生成式 AI 技術的安全和可靠應用。

風險管理的重要性

風險管理在生成式 AI 導入過程中至關重要，因為它能夠幫助企業和組織：

- **識別潛在風險**：提前識別可能影響生成式 AI 應用的風險。
- **評估風險影響**：評估風險的可能性和影響程度，制定應對策略。
- **降低風險**：通過制定和實施風險應對措施，降低風險的發生概率和影響。

2. 生成式 AI 倫理風險

生成式 AI 倫理風險主要涉及 AI 技術在應用過程中可能引發的倫理問題。這些問題包括偏見、歧視、透明性和責任等。

偏見與歧視

生成式 AI 系統可能會在訓練數據中學習到偏見，並在生成內容時反映出這些偏見或歧視。例如，AI 生成的文本或圖像可能會帶有性別、種族或其他方面的偏見，對特定群體造成不公平的影響。

透明性與責任

生成式 AI 系統的決策過程往往是黑箱操作，缺乏透明性，這可能會導致責任歸屬問題。例如，當 AI 系統生成的內容引發爭議或造成損害時，難以確定責任應由誰承擔。

3. 資料安全與隱私風險

生成式 AI 技術需要大量的數據來進行訓練和生成內容，這些數據的安全和隱私保護至關重要。

資料洩露風險

生成式 AI 系統在處理和存儲數據的過程中，可能會面臨資料洩露的風險。例如，未經授權的訪問或攻擊可能會導致敏感數據的洩露，對個人和組織造成損害。

隱私保護

生成式 AI 技術在處理個人數據時，必須遵守相關的隱私保護法規。例如，歐盟的《通用數據保護條例》(GDPR) 要求企業在處理個人數據時，必須獲得數據主體的同意，並採取適當的技術和組織措施保護數據安全。

4. 合規性風險

生成式 AI 技術的應用必須遵守相關的法律法規和行業標準，否則可能會面臨合規性風險。

法律法規

不同國家和地區對生成式 AI 技術的應用有不同的法律法規要求。例如，歐盟的《人工智慧法案》對 AI 技術的應用提出了嚴格的合規要求，企業必須遵守這些法規，否則可能會面臨法律責任。

行業標準

除了法律法規外，生成式 AI 技術的應用還需要遵守相關的行業標準。例如，金融行業對 AI 技術的應用有特定的合規要求，企業在應用生成式 AI 技術時，必須遵守這些行業標準。

5. 風險管理的實施步驟

風險識別

風險識別是風險管理的第一步，目的是識別生成式 AI 技術應用過程中可能面臨的各種風險。

風險評估

風險評估是對識別出的風險進行分析和評估，確定風險的可能性和影響程度，並根據風險等級制定應對策略。

風險應對

風險應對是根據風險評估的結果，制定和實施具體的應對措施，以降低風險的發生概率和影響。

風險監控

風險監控是對風險應對措施的實施效果進行監控和評估，確保風險管理的有效性，並根據需要進行調整和改進。

6. 實施示例

示例

假設某醫療機構希望導入生成式 AI 技術進行病歷生成，具體實施步驟如下：

1. **風險識別**：識別生成式 AI 技術在病歷生成過程中可能面臨的風險，例如資料洩露、隱私保護、合規性等。
2. **風險評估**：評估資料洩露風險的可能性和影響程度，確定風險等級。
3. **風險應對**：制定資料洩露風險的應對措施，例如加強數據加密、限制訪問權限等。
4. **風險監控**：對資料洩露風險的應對措施進行監控和評估，確保風險管理的有效性。