

# 內容

|                                                                                                                                                        |    |
|--------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 壹、 AI 的定義與分類.....                                                                                                                                      | 3  |
| 一、 卷積神經網絡 ( Convolutional Neural Networks, CNN ) .....                                                                                                 | 3  |
| 二、 循環神經網絡 ( Recurrent Neural Networks, RNN ) .....                                                                                                     | 4  |
| 三、 梯度消失 ( Gradient Vanishing ) 、 梯度爆炸 ( Gradient Exploding ) .....                                                                                     | 6  |
| 四、 自編碼器 ( Autoencoders ) .....                                                                                                                         | 8  |
| 五、 機器學習各種演算法.....                                                                                                                                      | 9  |
| 貳、 資料處理與分析概念.....                                                                                                                                      | 12 |
| 一、 資料基本概念與來源.....                                                                                                                                      | 12 |
| 二、 大數據的特徵 ( 4V ) .....                                                                                                                                 | 13 |
| 三、 資料型態與結構.....                                                                                                                                        | 14 |
| 四、 資料整理與分析流程.....                                                                                                                                      | 15 |
| 五、 資料統計.....                                                                                                                                           | 15 |
| 1. 統計測量數之類別.....                                                                                                                                       | 15 |
| 2. 常見的統計方法.....                                                                                                                                        | 19 |
| 3. 常見的統計方法分類表 .....                                                                                                                                    | 23 |
| 六、 資料清理_資料標準化(標準化(Z-score), 正規化(Min-Max), Log 轉換.....                                                                                                  | 29 |
| 七、 資料挖掘技術.....                                                                                                                                         | 32 |
| 1. 分類-決策樹 ( Decision Tree )、 支持向量機 ( Support Vector Machine · SVM )、 隨機森林 ( Random Forest )、 神經網絡 ( Neural Network ) .....                             | 33 |
| 2. 回歸-線性回歸 ( Linear Regression )、 多項式回歸 ( Polynomial Regression )、 迴歸樹 ( Regression Tree ) .....                                                       | 34 |
| 3. 聚類/分群-K 均值聚類 ( K-Means Clustering )、 層次聚類 ( Hierarchical Clustering )、 DBSCAN ( Density-Based Spatial Clustering of Applications with Noise ) ..... | 35 |
| 4. 關連規則-Apriori、FP-Growth .....                                                                                                                        | 37 |
| 5. 降維-主成分分析 ( Principal Component Analysis · PCA )、 線性判別分析 ( Linear Discriminant Analysis · LDA ) .....                                                | 37 |
| 6. 降維_多重對應分析(MCA)、混合資料因子分析(FAMD)、t-SNE (t-Distributed Stochastic Neighbor Embedding)、UMAP(Uniform Manifold Approximation and Projection).....          | 38 |
| 7. 時間序列分析_長短期記憶網絡 ( LSTM )、 自回歸整合移動平均模型 ( ARIMA )、 指數平滑法 ( Exponential Smoothing ) .....                                                               | 39 |
| 八、 建立模型.....                                                                                                                                           | 40 |
| 1. 資料建模中的線性回歸、評估指標.....                                                                                                                                | 40 |
| 2. 留一法交叉驗證(Leave-One-Out CV · LOO-CV) vs Data Leaking .....                                                                                            | 42 |
| 九、 資料隱私與安全.....                                                                                                                                        | 43 |
| 參、 機器學習概念.....                                                                                                                                         | 45 |
| 一、 機器學習基本原理及類型.....                                                                                                                                    | 45 |
| 二、 機器學習的核心過程.....                                                                                                                                      | 46 |
| 三、 機器學習的定義與目的 .....                                                                                                                                    | 46 |
| 四、 機器學習的基本流程.....                                                                                                                                      | 47 |
| 五、 數據與特徵工程.....                                                                                                                                        | 49 |

|                                                        |    |
|--------------------------------------------------------|----|
| 六、模型訓練與評估.....                                         | 51 |
| 七、機器學習的應用領域.....                                       | 53 |
| 八、常見的機器學習模型及其常見算法和評估指標 .....                           | 54 |
| 1. 常見的機器學習模型-監督式學習 ( Supervised Learning ) .....       | 55 |
| 2. 常見的機器學習模型-非監督式學習 ( Unsupervised Learning ) .....    | 58 |
| 3. 常見的機器學習模型-半監督式學習 ( Semi-supervised Learning ) ..... | 64 |
| 4. 常見的機器學習模型-強化學習 ( Reinforcement Learning ) .....     | 67 |
| 肆、鑑別式 AI 與生成式 AI 概念) .....                             | 71 |
| 一、鑑別式 AI 與生成式 AI 的基本原理 .....                           | 71 |
| 1. 鑑別式 AI.....                                         | 71 |
| 2. 生成式 AI.....                                         | 72 |
| 二、鑑別式 AI 與生成式 AI 的技術差異 .....                           | 73 |
| 三、鑑別式 AI 與生成式 AI 的比較 .....                             | 74 |
| 四、鑑別式 AI 與生成式 AI 的整合應用 .....                           | 74 |
| 伍、附件.....                                              | 78 |
| 一、附件 1-資料分析使用的圖形 .....                                 | 78 |
| 1. 直方圖(Histogram).....                                 | 78 |
| 2. 盒形圖(Box Plot，或稱 盒鬚圖、盒狀圖、箱型圖).....                   | 79 |
| 3. 散佈圖(scatter plot).....                              | 79 |
| 4. 熱圖(heatmap) .....                                   | 80 |
| 二、References.....                                      | 80 |

## 壹、 AI 的定義與分類

### 一、卷積神經網絡 ( Convolutional Neural Networks, CNN )

卷積神經網絡 ( Convolutional Neural Networks, CNN ) 是一種深度學習 ( Deep Learning ) 模型，廣泛應用於圖像識別 ( Image Recognition )、自然語言處理 ( Natural Language Processing, NLP ) 等領域。本文將以淺顯易懂的方式介紹 CNN 的基本概念、運作原理及其應用。

#### 什麼是卷積神經網絡？

卷積神經網絡是一種專門用於處理具有網格結構數據的神經網絡 ( Neural Networks )，例如圖像。CNN 的靈感來自於生物視覺系統，特別是貓的視覺皮層 ( Visual Cortex )。在視覺皮層中，神經元對特定區域的視覺刺激有反應，這種特性被稱為局部感受野 ( Receptive Field )。

**CNN 的基本結構：**包括以下幾個主要層次：

1. **卷積層 ( Convolutional Layer )：**卷積層是 CNN 的核心組成部分。它通過卷積運算 ( Convolution Operation ) 提取輸入數據中的特徵。卷積運算是將一個小的矩陣 ( 稱為卷積核或濾波器 ) 在輸入數據上滑動，並計算點積 ( Dot Product )。這樣可以提取出輸入數據中的局部特徵。
2. **激活層 ( Activation Layer )：**激活層通常使用非線性激活函數 ( 如 ReLU, Rectified Linear Unit ) 來引入非線性特性，使得神經網絡能夠學習更複雜的模式。
3. **池化層 ( Pooling Layer )：**池化層通過下採樣 ( Subsampling ) 或降維 ( Dimensionality Reduction ) 來減少數據的空間維度，從而降低計算量並防止過擬合 ( Overfitting )。常見的池化操作包括最大池化 ( Max Pooling ) 和平均池化 ( Average Pooling )。  
※當一類資料很多、另一類很少時，模型容易偏向多的那一類。為了讓模型公平地看待每一類，我們可以減少多的(下採樣，Subsampling)或增加少的(過採樣，Oversampling)。
4. **全連接層 ( Fully Connected Layer )：**全連接層將前面層提取的特徵展平 ( Flatten ) 並傳遞給一個或多個全連接的神經元層。這些層通常用於最終的分類或回歸任務。

#### CNN 的運作原理

1. **輸入圖像：**首先，將輸入圖像轉換為數據矩陣。每個像素點對應一個數值，彩色圖像則有三個通道 ( 紅、綠、藍 )。
2. **卷積操作：**卷積層使用多個卷積核對輸入圖像進行卷積操作，提取不同的特徵。每個卷積核會生成一個特徵圖 ( Feature Map )。
3. **激活函數：**對卷積層的輸出應用激活函數，引入非線性特性。
4. **池化操作：**池化層對特徵圖進行下採樣，減少數據維度(即降維)。
5. **重複多次：**上述步驟可以重複多次，形成多層卷積和池化層的結構，以提取更高層次的特徵。
6. **全連接層：**將最終的特徵圖展平並傳遞給全連接層，進行分類或回歸。

**CNN 的應用：**卷積神經網絡在許多領域都有廣泛應用，以下是幾個典型例子：

1. **圖像分類 ( Image Classification ):** CNN 可以自動學習圖像中的特徵，並將圖像分類到不同的類別中。例如，識別貓和狗的圖片。
2. **物體檢測 ( Object Detection ):** CNN 可以在圖像中檢測並標記出特定物體的位置。例如，自動駕駛汽車中的行人檢測。
3. **圖像分割 ( Image Segmentation ):** CNN 可以將圖像分割成不同的區域，每個區域對應不同的物體或背景。例如，醫學影像中的腫瘤分割。
4. **自然語言處理 ( NLP ):** CNN 也可以應用於文本數據的處理，例如情感分析 ( Sentiment Analysis ) 和文本分類 ( Text Classification )。

※CNN 不僅可以用來做分類、辨識等鑑別式 AI 的任務，也可以用來生成資料，尤其是在影像領域。例：

- ✧ 生成對抗網路 ( GANs ) : CNN 可用於生成器或判別器。
- ✧ 自編碼器 ( Autoencoder ) 與變分自編碼器 ( VAE ) : CNN 可作為編碼器與解碼器，用來壓縮與重建影像。
- ✧ 圖像風格轉換 ( Style Transfer ) : 使用 CNN 提取風格與內容特徵，然後合成新圖像。
- ✧ 圖像修復/重建

## CNN 的優勢與挑戰

**優勢：**

1. **自動特徵提取：**CNN 可以自動從數據中學習特徵，無需手動設計特徵提取器。
2. **參數共享：**卷積核在整個輸入數據上共享參數，減少了模型的參數數量，提高了計算效率。
3. **局部連接：**卷積層只對局部區域進行操作，減少了計算量並保留了空間結構信息。

**挑戰：**

1. **計算資源需求高：**CNN 的訓練和推理過程需要大量的計算資源，特別是對於大規模數據集。
2. **過擬合風險：**由於 CNN 具有強大的學習能力，容易在小數據集上過擬合。需要使用正則化技術 ( 如 Dropout ) 來防止過擬合。
3. **解釋性差：**CNN 的內部運作較為複雜，難以解釋其決策過程，這在某些應用中可能會帶來挑戰。

## 結論

卷積神經網絡是一種強大的深度學習模型，能夠自動從數據中學習特徵，並在圖像識別、物體檢測、圖像分割和自然語言處理等領域取得了顯著的成果。儘管面臨計算資源需求高、過擬合風險和解釋性差等挑戰，CNN 的優勢使其成為現代人工智慧研究和應用中的重要工具。

## 二、循環神經網絡 ( Recurrent Neural Networks, RNN )

循環神經網絡 ( Recurrent Neural Networks, RNN ) 是一種專門用於處理序列數據的深度學習模型。它在自然語言處理 ( Natural Language Processing, NLP )、語音識別 ( Speech

Recognition) 和時間序列預測 (Time Series Prediction) 等領域有著廣泛的應用。本文將以淺顯易懂的方式介紹 RNN 的基本概念、運作原理及其應用。

### 什麼是循環神經網絡？

循環神經網絡是一種能夠處理和預測序列數據的神經網絡。與傳統的前饋神經網絡 (Feedforward Neural Networks) 不同，RNN 具有內部記憶 (Internal Memory)，能夠記住序列中的前後關係。這使得 RNN 特別適合處理時間序列數據和語言數據等具有順序性的數據。

### RNN 的基本結構

1. **輸入層 (Input Layer)**: 輸入層接收序列數據的每一個時間步 (Time Step) 的輸入。例如，在語音識別中，每一個時間步可能是一個音頻片段。
2. **隱藏層 (Hidden Layer)**: 隱藏層是 RNN 的核心部分。它不僅接收當前時間步的輸入，還接收前一個時間步的隱藏狀態 (Hidden State)。這樣，隱藏層就能夠記住序列中的前後關係。  
※傳統 RNN 隱藏層建議使用 tanh 激活函數，深層或卷積型 RNN，可考慮 ReLu 或其變體如 Leaky ReLu)。
3. **輸出層 (Output Layer)**: 輸出層根據隱藏層的狀態生成最終的輸出。例如，在語言模型中，輸出層可能生成下一個單詞的預測。

### RNN 的運作原理

1. **初始化隱藏狀態**: 在序列的第一個時間步，隱藏狀態通常初始化為零或隨機值。
2. **逐步處理序列數據**: 對於序列中的每一個時間步，RNN 根據當前的輸入和前一個時間步的隱藏狀態計算新的隱藏狀態。
3. **生成輸出**: 根據當前的隱藏狀態，RNN 生成對應的輸出。
4. **更新隱藏狀態**: 將新的隱藏狀態傳遞到下一個時間步，重複上述步驟，直到處理完所有的序列數據。

### RNN 的應用

1. **自然語言處理 (NLP)**: RNN 在機器翻譯 (Machine Translation)、文本生成 (Text Generation) 和情感分析 (Sentiment Analysis) 等任務中表現出色。例如，RNN 可以根據前面的單詞生成下一個單詞，從而生成連貫的句子。
2. **語音識別 (Speech Recognition)**: RNN 可以將語音信號轉換為文本。例如，語音助手 (如 Siri 和 Google Assistant) 使用 RNN 來識別和理解用戶的語音命令。
3. **時間序列預測 (Time Series Prediction)**: RNN 可以用於預測股票價格、天氣變化等時間序列數據。例如，RNN 可以根據過去的股票價格預測未來的價格走勢。

### RNN 的優勢與挑戰

#### 優勢：

1. **處理序列數據**: RNN 能夠記住序列中的前後關係，特別適合處理具有順序性的數據。
2. **靈活性**: RNN 可以處理不同長度的序列數據，無需固定的輸入長度。

#### 挑戰：

1. **梯度消失和梯度爆炸**：在訓練過程中，RNN 可能會遇到梯度消失 ( Gradient Vanishing ) 和梯度爆炸 ( Gradient Exploding ) 問題，導致模型難以學習長期依賴 ( Long-term Dependencies )。
2. **計算資源需求高**：RNN 的訓練和推理過程需要大量的計算資源，特別是對於長序列數據。

### 改進的 RNN 模型

1. **長短期記憶網絡 ( Long Short-Term Memory, LSTM )**：LSTM 通過引入門控機制 ( Gating Mechanism )，能夠有效地學習長期依賴，減少梯度消失和梯度爆炸問題。  
※LSTM、GRU 本身沒有從結構上直接解決梯度爆炸的問題，只是稍有幫助，要搭配梯度裁剪來解決。
2. **門控循環單元 ( Gated Recurrent Unit, GRU )**：GRU 是 LSTM 的簡化版本，具有類似的性能，但計算效率更高。
3. **雙向 RNN ( Bidirectional RNN )**：雙向 RNN 同時考慮序列的前向和後向信息，能夠更好地捕捉序列中的上下文信息。

### 結論

循環神經網絡是一種強大的深度學習模型，能夠處理和預測序列數據，在自然語言處理、語音識別和時間序列預測等領域取得了顯著的成果。儘管面臨梯度消失和梯度爆炸等挑戰，改進的 RNN 模型如 LSTM 和 GRU 提供了有效的解決方案，使得 RNN 在現代人工智慧研究和應用中具有重要地位。

## 三、梯度消失 ( Gradient Vanishing )、梯度爆炸 ( Gradient Exploding )

梯度消失 ( Gradient Vanishing ) 和梯度爆炸 ( Gradient Exploding ) 是深度學習中常見的問題，尤其是在訓練深層神經網路時。這些問題會影響模型的訓練效果和性能。

### 定義

**梯度消失 ( Gradient Vanishing )**：梯度消失是指在訓練深層神經網路時，隨著反向傳播過程中梯度逐層傳遞，梯度值逐漸變得非常小，最終導致模型的權重更新非常緩慢甚至停止。這使得模型難以學習和改進。

**梯度爆炸 ( Gradient Exploding )**：梯度爆炸是指在訓練深層神經網路時，隨著反向傳播過程中梯度逐層傳遞，梯度值逐漸變得非常大，最終導致模型的權重更新過度，導致模型不穩定和性能下降。

### 梯度消失與梯度爆炸的原因

梯度消失的原因：

1. **激活函數**：某些激活函數 ( 如 Sigmoid 和 Tanh ) 在輸入值非常大或非常小時，其導數值會變得非常小，導致梯度消失。  
※導數值：當  $x$  改變一點點， $y$  會改變多少。若導數值很大  $\rightarrow$  代表曲線變動很快(像斜坡很陡)
2. **深層網路**：隨著網路層數的增加，梯度在反向傳播過程中會逐層減小，最終導致梯度消失。

梯度爆炸的原因：

1. **激活函數**：某些激活函數（如 ReLU）在輸入值非常大時，其導數值會變得非常大，導致梯度爆炸。
2. **深層網路**：隨著網路層數的增加，梯度在反向傳播過程中會逐層增大，最終導致梯度爆炸。

### 梯度消失與梯度爆炸的影響

#### 梯度消失的影響：

1. **訓練速度慢**：梯度消失會導致模型的權重更新非常緩慢，訓練速度變慢。
2. **模型性能差**：梯度消失會導致模型難以學習和改進，最終影響模型的性能。

#### 梯度爆炸的影響：

1. **訓練不穩定**：梯度爆炸會導致模型的權重更新過度，訓練過程不穩定。
2. **模型性能差**：梯度爆炸會導致模型的性能下降，甚至無法收斂。

### 解決梯度消失與梯度爆炸的方法

#### 解決梯度消失的方法：

1. **使用 ReLU 激活函數**：ReLU 激活函數在輸入值非常大時，其導數值不會變得非常小，可以減少梯度消失的問題。
2. **使用批量歸一化 ( Batch Normalization )**：批量歸一化可以使輸入值保持在一個合理的範圍內，減少梯度消失的問題。  
※將每一層的輸出「標準化」，讓每個輸出變成平均為 0、標準差為 1。目的是不要讓每一層的輸出（也就是下一層的輸入）可能會因為權重的改變而變得忽大忽小，這會讓訓練變得不穩定、收斂變慢，甚至學不到東西。
3. **使用 LSTM 和 GRU**：LSTM 和門控循環單位(Gated Recurrent Unit, **GRU**)是專門設計用來解決梯度消失問題的循環神經網路。

#### 解決梯度爆炸的方法：

1. **使用梯度裁剪 ( Gradient Clipping )**：梯度裁剪可以限制梯度的最大值，防止梯度爆炸。
2. **使用批量歸一化 ( Batch Normalization )**：批量歸一化可以使輸入值保持在一個合理的範圍內，減少梯度爆炸的問題。
3. **使用正則化 ( Regularization )**：正則化可以防止模型過度擬合，減少梯度爆炸的問題。

### 示例與實施步驟

**梯度消失的示例**：假設我們有一個深層神經網路，使用 Sigmoid 激活函數。當輸入值非常大或非常小時，Sigmoid 激活函數的導數值會變得非常小，導致梯度消失。這時，我們可以使用 ReLU 激活函數來減少梯度消失的問題。

**梯度爆炸的示例**：假設我們有一個深層神經網路，使用 ReLU 激活函數。當輸入值非常大時，ReLU 激活函數的導數值會變得非常大，導致梯度爆炸。這時，我們可以使用梯度裁剪來限制梯度的最大值，防止梯度爆炸。

實施步驟：

1. **選擇合適的激活函數**：根據模型的需求選擇合適的激活函數，如 ReLU。  
※LSTM、GRU 不是激活函數，而是 RNN 的改進版。
2. **使用批量歸一化**：在每一層之間使用批量歸一化，保持輸入值在合理範圍內。
3. **使用梯度裁剪**：在反向傳播過程中使用梯度裁剪，限制梯度的最大值。
4. **使用正則化**：在模型中加入正則化項，防止模型過度擬合。

## 四、自編碼器 ( Autoencoders )

自編碼器 ( Autoencoders ) 是一種無監督學習 ( Unsupervised Learning ) 模型，主要用於數據降維 ( Dimensionality Reduction ) 和特徵提取 ( Feature Extraction )。它們在圖像處理、數據壓縮和異常檢測等領域有著廣泛的應用。本文將以淺顯易懂的方式介紹自編碼器的基本概念、運作原理及其應用。

**什麼是自編碼器？**

自編碼器是一種神經網絡 ( Neural Network )，其目的是學習數據的有效表示 ( Representation )。自編碼器由兩個主要部分組成：編碼器 ( Encoder ) 和解碼器 ( Decoder )。編碼器將輸入數據轉換為低維度的隱藏表示 ( Hidden Representation )，而解碼器則將隱藏表示重建回原始數據。

**自編碼器的基本結構**

1. **輸入層 ( Input Layer )**：輸入層接收原始數據。例如，在圖像處理中，輸入層接收圖像的像素值。
2. **編碼器 ( Encoder )**：編碼器由一系列神經元層組成，逐步將輸入數據壓縮到低維度的隱藏表示。這些隱藏表示包含了數據的主要特徵。
3. **隱藏層 ( Hidden Layer )**：隱藏層是自編碼器的核心部分，包含了數據的低維度表示。這些表示應該能夠保留數據的主要信息，同時去除冗餘信息。
4. **解碼器 ( Decoder )**：解碼器由一系列神經元層組成，逐步將隱藏表示重建回原始數據。解碼器的結構通常與編碼器對稱。
5. **輸出層 ( Output Layer )**：輸出層生成重建的數據，應該與原始輸入數據盡可能相似。

**自編碼器的運作原理**

1. **數據輸入**：將原始數據輸入到自編碼器的輸入層。
2. **編碼過程**：編碼器逐步將輸入數據壓縮到低維度的隱藏表示。這個過程可以看作是數據降維。
3. **隱藏表示**：隱藏層包含了數據的低維度表示，這些表示應該能夠保留數據的主要特徵。
4. **解碼過程**：解碼器逐步將隱藏表示重建回原始數據。這個過程可以看作是數據重建(重建成與訓練資料相近)。
5. **數據輸出**：輸出層生成重建的數據，應該與原始訓練數據盡可能相似。

**自編碼器的應用**



1. **數據降維**：自編碼器可以將高維度數據壓縮到低維度表示，從而減少數據的存儲和計算成本。例如，在圖像處理中，自編碼器可以將高分辨率圖像壓縮到低維度表示，然後再重建回高分辨率圖像。
2. **特徵提取**：自編碼器可以自動從數據中提取特徵，無需手動設計特徵提取器。例如，在自然語言處理 ( Natural Language Processing, NLP ) 中，自編碼器可以從文本數據中提取語義特徵。
3. **異常檢測**：自編碼器可以用於檢測數據中的異常點。通過比較重建數據與原始數據的差異，可以識別出異常數據。例如，在網絡安全中，自編碼器可以用於檢測異常的網絡流量。

※因輸入的異常資料沒被訓練過，故重建困難，誤差大，所以可以拿來作異常檢測。

4. **數據去噪**：自編碼器可以用於去除數據中的噪聲。通過訓練自編碼器在有噪聲的數據上進行重建，可以生成無噪聲的數據。例如，在圖像處理中，自編碼器可以用於去除圖像中的噪聲。

### 自編碼器的優勢與挑戰

#### 優勢：

1. **無監督學習**：自編碼器不需要標註數據，可以在無標註數據上進行訓練，適用於大量無標註數據的情況。
2. **自動特徵提取**：自編碼器可以自動從數據中提取特徵，無需手動設計特徵提取器。
3. **靈活性**：自編碼器可以應用於各種數據類型，包括圖像、文本和時間序列數據。

#### 挑戰：

1. **訓練難度**：自編碼器的訓練過程可能比較困難，特別是在高維度數據上。需要使用適當的訓練技術和正則化方法來提高訓練效果。
2. **過擬合風險**：自編碼器可能會過擬合訓練數據，導致在測試數據上的性能下降。需要使用正則化技術 ( 如 Dropout ) 來防止過擬合。
3. **解釋性差**：自編碼器的內部運作較為複雜，難以解釋其決策過程，這在某些應用中可能會帶來挑戰。

### 結論

自編碼器是一種強大的無監督學習模型，能夠自動從數據中學習有效表示，並在數據降維、特徵提取、異常檢測和數據去噪等領域取得了顯著的成果。儘管面臨訓練難度和過擬合風險等挑戰，自編碼器的優勢使其成為現代人工智慧研究和應用中的重要工具。

## 五、機器學習各種演算法

機器學習 ( Machine Learning, ML ) 是一種人工智慧 ( Artificial Intelligence, AI ) 技術，透過分析大量數據來訓練模型，使其能夠自動學習和改進。機器學習的演算法有很多種，每種演算法都有其特定的應用場景和優缺點。以下將介紹幾種常見的機器學習演算法，並以淺顯易懂的方式解釋其概念和應用。

### 1. 線性回歸 ( Linear Regression )

線性回歸是一種監督式學習 ( Supervised Learning ) 演算法，主要用於預測連續型變數。它假設自變數 ( Independent Variables ) 和應變數 ( Dependent Variable ) 之間存在線性關係，並通

過最小化誤差平方和來找到最佳的線性模型。舉例來說，線性回歸可以用來預測房價，根據房子的面積、房齡等特徵來預測其價格。

※  $y = ax + b$      $x$  是自變數、 $y$  是應變數。一個變數改變，另一個變數也會以固定的比例改變，稱為線性關係。

## 2. 邏輯回歸 ( Logistic Regression )

邏輯回歸也是一種監督式學習演算法，但主要用於分類問題 ( Classification Problems )。它通過使用邏輯函數 ( Logistic Function ) 將輸出值限制在 0 到 1 之間，從而預測某個事件發生的概率。例如，邏輯回歸可以用來預測一封電子郵件是否為垃圾郵件。

## 3. 決策樹 ( Decision Tree )

決策樹是一種非參數監督式學習演算法，適用於分類和回歸問題。它通過將數據集分割成不同的子集，並在每個節點上選擇最佳的分割特徵來構建樹狀模型。決策樹的優點是易於理解和解釋，但容易過擬合 ( Overfitting )。例如，決策樹可以用來預測客戶是否會購買某產品，根據其年齡、收入等特徵進行分類。

## 4. 隨機森林 ( Random Forest )

隨機森林是一種集成學習 ( Ensemble Learning ) 方法，通過結合多個決策樹來提高模型的準確性和穩定性。它通過隨機選擇特徵和數據樣本來訓練多個決策樹，並通過投票機制來決定最終的預測結果。隨機森林在處理高維數據和防止過擬合方面表現優異。例如，隨機森林可以用來預測股票價格，根據多個特徵進行綜合分析。

## 5. 支持向量機 ( Support Vector Machine , SVM )

支持向量機是一種監督式學習演算法，主要用於分類問題。它通過找到最佳的超平面 ( Hyperplane ) 來將數據分成不同的類別，並最大化類別之間的間隔 ( Margin )。SVM 在處理高維數據和非線性問題方面表現良好。例如，SVM 可以用來識別手寫數字，根據像素特徵進行分類。

## 6. K-最近鄰 ( K-Nearest Neighbors , KNN )

K-最近鄰是一種簡單且直觀的監督式學習演算法，適用於分類和回歸問題。它通過計算新數據點與訓練數據集中每個數據點的距離，並選擇距離最近的 K 個鄰居來進行預測。KNN 的優點是易於理解和實現，但在處理大規模數據時效率較低。例如，KNN 可以用來推薦電影，根據用戶的觀影歷史來推薦相似的電影。

## 7. 主成分分析 ( Principal Component Analysis , PCA )

主成分分析是一種無監督學習 ( Unsupervised Learning ) 演算法，主要用於降維 ( Dimensionality Reduction ) 和數據可視化。它通過將高維數據投影到低維空間，來保留數據的主要變異性。PCA 在處理高維數據和減少計算複雜度方面表現良好。例如，PCA 可以用來分析基因表達數據，將高維基因數據降維到可視化的二維或三維空間。

## 8. 聚類分析 ( Clustering )

聚類分析是一種無監督學習演算法，主要用於將數據分成不同的組 ( Clusters )，使得同一組內的數據點相似度較高，而不同組之間的數據點相似度較低。常見的聚類演算法包括 K-均值 ( K-Means )、層次聚類 ( Hierarchical Clustering ) 和 DBSCAN ( Density-Based Spatial Clustering of Applications with Noise )。例如，聚類分析可以用來客戶分群，根據購買行為將客戶分成不同的群體，以便進行針對性的營銷。

## 9. 神經網絡 ( Neural Networks )

神經網絡是一種模仿人腦結構和功能的監督式學習演算法，適用於分類和回歸問題。它由多層神經元 ( Neurons ) 組成，每層神經元通過權重 ( Weights ) 和激活函數 ( Activation Functions ) 進行連接和傳遞信息。神經網絡在處理複雜和非線性問題方面表現優異。例如，神經網絡可以用來進行圖像識別，根據像素特徵來識別物體。

## 10. 深度學習 ( Deep Learning )

深度學習是神經網絡的一種擴展，通過增加神經網絡的層數 ( 即深度 ) 來提高模型的表現能力。深度學習在處理大規模數據和複雜問題方面表現卓越，常用於圖像識別、語音識別和自然語言處理 ( Natural Language Processing, NLP ) 等領域。例如，深度學習可以用來進行自動駕駛，根據攝像頭和雷達數據來識別道路和障礙物。

## 結論

機器學習演算法在各個領域中都有廣泛的應用，從預測房價到自動駕駛，無處不在。了解不同演算法的基本概念和應用場景，有助於我們選擇合適的工具來解決實際問題。希望這篇文章能夠幫助你對機器學習有一個初步的了解，並激發你進一步探索這個充滿潛力的領域。

---

貳、 資料處理與分析概念

| 內容        | 備註                            | 評鑑能力                                                            |
|-----------|-------------------------------|-----------------------------------------------------------------|
| 資料基本概念與來源 | 大數據、資料型態與結構，如數值型資料、文字資料、圖像資料等 | 評鑑應考者是否具備基本的資料處理知識，包括資料收集、清洗、分析和視覺化等過程，並能夠理解資料在 AI 模型中扮演的角色與作用。 |
| 資料整理與分析流程 | 如資料收集、清理、分析和呈現等               |                                                                 |
| 資料隱私與安全   |                               |                                                                 |

一、 資料基本概念與來源

資料基本概念與來源

- 1. **大數據 ( Big Data )** : 了解大數據的定義、特徵 ( 如 4V : Volume、Velocity、Variety、Veracity ) 及其應用。
- 2. **資料型態與結構** : 熟悉不同資料型態，如數值型資料、文字資料、圖像資料等，以及資料結構 ( 如結構化資料、半結構化資料、非結構化資料 )。

資料整理與分析流程

- 1. **資料收集** : 學習如何從不同來源 ( 如網絡、數據庫、感測器等 ) 收集資料，並確保資料的完整性和準確性。
- 2. **資料清理** : 了解資料清理的重要性，學習如何處理缺失值、異常值、重複資料等問題。
- 3. **資料分析** : 掌握基本的資料分析方法，如描述性統計、探索性資料分析 ( EDA )、假設檢定等。
- 4. **資料視覺化** : 學習如何使用圖表和圖形來呈現資料，幫助理解和解釋資料分析結果。

資料隱私與安全

- 1. **資料隱私** : 了解資料隱私保護的重要性，學習如何遵守相關法律法規 ( 如 GDPR、CCPA 等 )。
- 2. **資料安全** : 掌握基本的資料安全措施，如資料加密、存取控制、資料備份等。

資料在 AI 模型中的角色

資料在 AI 模型中扮演著至關重要的角色。AI 模型的訓練過程需要大量的資料來進行學習和優化。資料的質量和數量直接影響模型的性能和準確性。以下是資料在 AI 模型中的幾個重要作用：

- 1. **訓練資料 ( Training Data )** : 用於訓練 AI 模型，使其能夠學習資料中的模式和特徵。
  - 2. **驗證資料 ( Validation Data )** : 用於調整模型參數，防止過擬合 ( Overfitting )。
  - 3. **測試資料 ( Test Data )** : 用於評估模型的性能和準確性。
-

## 二、大數據的特徵 ( 4V )

大數據 ( Big Data ) 是指數據量龐大、生成速度快、種類多樣且真實性高的數據集合。大數據的特徵通常被歸納為 4V : Volume ( 數量 )、Velocity ( 速度 )、Variety ( 多樣性 ) 和 Veracity ( 真實性 )。這些特徵使得大數據在處理和分析上具有挑戰性，但同時也帶來了巨大的潛力和機會。

### Volume ( 數量 )

大數據的第一個特徵是數量龐大。隨著互聯網、物聯網 ( IoT ) 和各種數字設備的普及，數據的生成量呈指數級增長。每天都有數以百萬計的數據被創建和存儲，這些數據來自於社交媒體、電子商務、感測器、移動設備等多種來源。例如，像 Facebook 這樣的社交媒體平台每天會產生數百 TB ( 兆字節 ) 的用戶數據，包括帖子、照片、影片等。這些龐大的數據量需要強大的存儲和處理能力。

### Velocity ( 速度 )

大數據的第二個特徵是生成和處理速度快。數據的生成速度和處理速度是大數據的一個重要方面。例如，金融市場中的股票交易數據每秒鐘都在變化，這些數據需要即時處理和分析，以便做出快速的投資決策。再例如，物聯網設備實時生成的數據需要即時處理，以便進行監控和控制。大數據技術需要能夠快速處理和分析這些高速生成的數據，以便及時做出反應。

### Variety ( 多樣性 )

大數據的第三個特徵是種類多樣。大數據來自於多種不同的來源和格式，包括結構化數據、半結構化數據和非結構化數據。結構化數據是指具有固定格式和結構的數據，如數據庫中的表格數據；半結構化數據是指具有一定結構但不完全固定的數據，如 XML、JSON 格式的數據；非結構化數據是指沒有固定格式和結構的數據，如文本、圖像、音頻、視頻等。例如，電子商務網站上的數據包括結構化的交易記錄、半結構化的用戶評論和非結構化的產品圖片。這些多樣化的數據需要不同的技術和方法來處理和分析。

### Veracity ( 真實性 )

大數據的第四個特徵是真實性。大數據的真實性指的是數據的準確性和可靠性。由於大數據來自於多種不同的來源，數據的質量可能參差不齊，存在噪音、錯誤和不一致的情況。例如，社交媒體上的數據可能包含虛假信息和垃圾數據；感測器數據可能受到環境因素的影響而產生誤差。因此，在處理和分析大數據時，需要對數據進行清理和過濾，以確保數據的真實性和可靠性。

## 結論

大數據的 4V 特徵 ( 數量、速度、多樣性和真實性 ) 使得大數據在處理和分析上具有挑戰性，但同時也帶來了巨大的潛力和機會。理解這些特徵，能夠幫助我們更好地收集、存儲、處理和分析大數據，從而在各個領域中取得更好的成果。無論是在商業、醫療、金融還是科學研究中，大數據都扮演著越來越重要的角色。掌握大數據的基本概念和技術，將為我們開啟更多的可能性和機會。

### 三、資料型態與結構

#### 資料型態與結構

在現代數據科學和人工智慧的領域中，資料是核心資源。理解資料的型態和結構是進行資料處理與分析的基礎。資料型態主要包括數值型資料、文字資料和圖像資料，而資料結構則分為結構化資料、半結構化資料和非結構化資料。

#### 資料來源：

- 1. 感測器 ( Sensors ):** 感測器可以實時收集環境數據，如溫度、濕度、壓力等。例如，氣象站使用感測器收集天氣數據。
  - 示例：某地區的每日溫度記錄。
- 2. 交易記錄 ( Transaction Records ):** 這類資料來自於商業交易，如購物、銀行交易等。例如，某顧客在超市的購物記錄。
  - 示例：某顧客在超市購買的商品清單及其價格。
- 3. 社交媒體 ( Social Media ):** 社交媒體平台生成大量的用戶數據，如帖子、評論、點讚等。例如，Twitter 上的推文、Facebook 上的評論等。
  - 示例：某用戶在 Twitter 上的一則推文：「今天的天氣真好！」
- 4. 公開數據集 ( Public Datasets ):** 許多機構和組織會公開其收集的數據集，供研究和分析使用。例如，政府機構公開的統計數據、學術研究中的數據集等。
  - 示例：某政府機構公開的年度人口統計數據。

#### 資料型態

- 1. 數值型資料 ( Numerical Data ):** 數值型資料是最常見的資料型態之一，主要包括整數和浮點數。這類資料可以進行數學運算和統計分析。例如，股票價格、溫度、人口數量等都是數值型資料。數值型資料又可以分為連續型資料和離散型資料。連續型資料可以取任意值，如溫度；而離散型資料只能取特定值，如人口數量。※因人口數量不會為小數值，故非連續型。
- 2. 文字資料 ( Text Data ):** 文字資料是由字母、數字和符號組成的資料，通常以字符串的形式存在。這類資料在自然語言處理 ( Natural Language Processing, NLP ) 中非常重要。例如，電子郵件、社交媒體帖子、文章等都是文字資料。文字資料的處理通常涉及分詞、詞頻統計、情感分析等技術。
- 3. 圖像資料 ( Image Data ):** 圖像資料是以像素矩陣形式存在的資料，每個像素都有顏色值。這類資料在計算機視覺 ( Computer Vision ) 中非常重要。例如，照片、醫學影像、衛星圖像等都是圖像資料。圖像資料的處理通常涉及圖像識別、圖像分割、特徵提取等技術。

#### 資料結構

- 1. 結構化資料 ( Structured Data ):** 結構化資料是指具有固定格式和結構的資料，通常存儲在關係型數據庫中。這類資料可以用表格的形式表示，每行代表一個記錄，每列代表一個屬性。例如，電子商務網站的產品目錄、銀行的交易記錄等都是結構化資料。結構化資料的優點是易於存儲、檢索和分析。
- 2. 半結構化資料 ( Semi-Structured Data ):** 半結構化資料是指具有一定結構但不完全固定的資料，通常以 XML、JSON 等格式存儲。這類資料既有結構化資料的特點，又具有一定的靈活性。例如，網頁的 HTML 內容、API 返回的 JSON 資料等都是半結構化資料。半結構化資料的優點是靈活性高，適合處理異構資料。

**3.非結構化資料 ( Unstructured Data ):** 非結構化資料是指沒有固定格式和結構的資料，通常以文本、圖像、音頻、視頻等形式存在。例如，電子郵件、社交媒體帖子、照片、影片等都是非結構化資料。非結構化資料的處理通常需要使用自然語言處理、計算機視覺等技術。

## 四、 資料整理與分析流程

### 資料整理與分析流程

資料整理與分析是人工智慧 ( Artificial Intelligence , AI ) 應用中的關鍵步驟。這些步驟包括資料收集、資料清理、資料分析和資料呈現。每個步驟都至關重要，因為它們共同確保資料的質量和準確性，從而提高 AI 模型的效能。

### 資料收集

資料收集是資料整理與分析的第一步。這個步驟涉及從各種來源獲取資料，例如網路、資料庫、感測器和用戶輸入。資料可以是結構化 ( 如數據庫中的表格資料 )、半結構化 ( 如 JSON 或 XML 格式的資料 ) 或非結構化 ( 如文字、圖像和影片 )。

**示例：** 假設我們要建立一個預測房價的模型，我們需要收集房屋的歷史銷售資料、地區的經濟指標、房屋的特徵 ( 如面積、房間數量 ) 等。

### 資料清理

資料清理是將收集到的資料轉換為可用格式的過程。這個步驟包括去除重複資料、處理缺失值、修正錯誤資料和標準化資料。資料清理的目的是提高資料的質量，確保資料的準確性和一致性。

**示例：** 在房價預測模型中，如果某些房屋的面積資料缺失，我們可以使用平均值或中位數來填補這些缺失值。

### 資料分析

資料分析是對清理後的資料進行探索和分析，以發現有用的資訊和模式。這個步驟可以使用統計方法、資料視覺化工具和機器學習演算法來進行。資料分析的目的是理解資料的特徵和關係，為後續的模型建立提供依據。

**示例：** 在房價預測模型中，我們可以使用資料視覺化工具來查看房屋面積與房價之間的關係，並使用迴歸分析來建立預測模型。

### 資料呈現

資料呈現是將分析結果以易於理解的方式展示給使用者。這個步驟可以使用圖表、報告和儀表板來進行。資料呈現的目的是幫助使用者理解分析結果，並做出明智的決策。

**示例：** 在房價預測模型中，我們可以使用圖表來展示不同地區的房價趨勢，並生成報告來總結分析結果。

## 五、資料統計

### 1. 統計測量數之類別

#### 1. 中央趨勢的衡量：



- 平均數 ( Mean ) : 所有數值的總和除以數值的個數。
- 中位數 ( Median ) : 將數值按大小排序後，位於中間的數值。
- 眾數 ( Mode ) : 出現頻率最高的數值。

## 2. 分散度的衡量：

- 四分位數 ( Quartile ) : 將數據分成四等份的值。
- 全距 ( Range ) : 最大值與最小值之間的差距。
- 四分位距 ( Interquartile Range , IQR ) : 第三四分位數與第一四分位數之間的差距。
- 平均差 ( Mean Deviation ) : 所有數值與平均數之間差距的平均值。
- 變異數 ( Coefficient of Variation ) : 標準差與平均數的比率。數值與平均數之間差距的平方和的平均值。
- 標準差 ( Standard Deviation ) : 數值與平均數之間差距的平方和的平均值的平方根。※即變異數的平方根。
- 百分位數 ( Percentile ) : 用來描述資料在某個特定百分比位置上的值。例如，第 25 百分位數表示資料中有 25% 的數據點小於或等於這個值，第 75 百分位數表示資料中有 75% 的數據點小於或等於這個值。

## 3. 其他測量數：

- 樣本平均數 ( Sample Mean ) : 樣本數值的平均數。
- 樣本標準差 ( Sample Standard Deviation ) : 樣本數值的標準差。

## 統計測量數之類別

統計測量數是資料分析中非常重要的一部分，它們幫助我們理解和描述資料的特徵。以下是統計測量數的詳細介紹，包括中央趨勢的衡量、分散度的衡量以及其他測量數。

## 中央趨勢的衡量

中央趨勢的衡量是用來描述資料集中位置的統計量。常見的中央趨勢衡量包括平均數、中位數和眾數。

### ● 平均數 ( Mean )

平均數是所有數值的總和除以數值的個數。它是最常用的中央趨勢衡量之一，適用於大多數資料分布。計算公式如下：

$$\text{平均數} = \frac{\sum_{i=1}^n x_i}{n}$$

其中， $x_i$  是第  $i$  個數值， $n$  是數值的個數。

示例：假設有一組考試成績：80, 85, 90, 95, 100。平均數計算如下：

$$\text{平均數} = \frac{80 + 85 + 90 + 95 + 100}{5} = 90$$

### ● 中位數 ( Median )

中位數是將數值按大小排序後，位於中間的數值。當資料分布不對稱或有極端值時，中位數能更準確地反映資料的中心趨勢。計算方法如下：

1. 將數值按大小排序。



2. 如果數值個數為奇數，則中位數為中間的數值。
3. 如果數值個數為偶數，則中位數為中間兩個數值的平均數。

示例： 假設有一組房屋價格：200, 250, 300, 350, 400。中位數計算如下：

排序後的數值為：200, 250, 300, 350, 400。中位數為 300。

### ● 眾數 ( Mode )

眾數是出現頻率最高的數值。當資料中有一個或幾個數值出現的頻率明顯高於其他數值時，眾數能較好地反映資料的集中趨勢。

示例： 假設有一組產品銷售量：10, 20, 20, 30, 40。眾數計算如下：

眾數為 20，因為它出現的頻率最高。

## 分散度的衡量

分散度的衡量是用來描述資料分布的廣度和變異程度的統計量。常見的分散度衡量包括四分位數、全距、四分位距、平均差、變異數和標準差。

### ● 四分位數 ( Quartile )

四分位數是將數據分成四等份的值。常見的四分位數包括第一四分位數 ( Q1 )、第二四分位數 ( Q2，即中位數 ) 和第三四分位數 ( Q3 )。

示例：

假設有一組學生的考試成績：55, 60, 65, 70, 75, 80, 85, 90, 95, 100。

#### 計算四分位數

##### 1. 排序數值：

- 排序後的數值為：55, 60, 65, 70, 75, 80, 85, 90, 95, 100。

##### 2. 計算第一四分位數 (Q1)：

- 第一四分位數是排序後數值中位於第一個四分位的位置。
- 由於數值個數為偶數 (10 個)，第一四分位數的位置為第  $\frac{10+1}{4}$  個數值，即第 2.75 個數值。
- 因此， $Q1 = 60 + 0.75 * (65 - 60) = 63.75$ 。

##### 3. 計算第二四分位數 (Q2，即中位數)：

- 第二四分位數是排序後數值中位於中間的位置。
- 由於數值個數為偶數 (10 個)，中位數的位置為第  $\frac{10+1}{2}$  個數值，即第 5.5 個數值。
- 因此， $Q2 = 75 + 0.5 * (80 - 75) = 77.5$ 。

#### 4. 計算第三四分位數 (Q3) :

- 第三四分位數是排序後數值中位於第三個四分位的位置。
- 由於數值個數為偶數 (10 個)，第三四分位數的位置為第  $\frac{3 \times (10 + 1)}{4}$  個數值，即第 8.25 個數值。
- 因此， $Q3 = 90 + 0.25 \times (95 - 90) = 91.25$ 。

#### 四分位數結果

- 第一四分位數 (Q1) : 63.75
- 第二四分位數 (Q2, 即中位數) : 77.5
- 第三四分位數 (Q3) : 91.25

#### ● 全距 ( Range )

全距是最大值與最小值之間的差距。它是最簡單的分散度衡量之一。

示例： 假設有一組數據：10, 20, 30, 40, 50。全距計算如下：

$$\text{全距} = 50 - 10 = 40$$

#### ● 四分位距 ( Interquartile Range · IQR )

四分位距是第三四分位數與第一四分位數之間的差距。它能更準確地反映資料的分散程度，特別是在資料分布不對稱或有極端值的情況下。

以前面四分位數的學生的考試成績為例，四分位距計算示例如下：

四分位距是第三四分位數 (Q3) 與第一四分位數 (Q1) 之間的差距。計算公式如下：

$$\text{四分位距} = Q3 - Q1$$

根據前面的計算結果：

$$\text{四分位距} = 91.25 - 63.75 = 27.5$$

#### 四分位距結果

- 第一四分位數 (Q1) : 63.75
- 第三四分位數 (Q3) : 91.25
- 四分位距 (IQR) : 27.5

#### ● 平均差 ( Mean Deviation )

平均差是所有數值與平均數之間差距的平均值。它能反映資料的分散程度。

示例： 假設有一組數據：10, 20, 30, 40, 50。平均數為 30。平均差為 12，計算如下：

示例： 假設有一組數據：10, 20, 30, 40, 50。平均數為 30。平均差計算如下：

$$\text{平均差} = \frac{|10 - 30| + |20 - 30| + |30 - 30| + |40 - 30|}{5}$$

#### ● 變異數 ( Variance )

變異數是用來衡量一組數據離平均值有多分散的一種統計指標。它能反映資料的相對分散程度。如果變異數很小，代表數據都很集中在平均值附近。如果變異數很大，代表數據分布得很分散。公式為：

- 對於整體母體資料：數值與平均數之間差距的平方和的平均值。

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

- $\sigma^2$ ：母體變異數
- $\mu$ ：母體平均值

- 對於一組樣本資料：

$$s^2 = \frac{1}{\underline{n-1}} \sum_{i=1}^n (x_i - \bar{x})^2$$

- $s^2$ ：樣本變異數
- $n$ ：樣本數
- $x_i$ ：第  $i$  個數據
- $\bar{x}$ ：樣本平均值

現實中，我們通常只拿到一部分資料（即樣本資料），這時候我們只能用樣本的平均值來代替真正的平均值  $\mu$ 。用樣本平均值來計算變異數，會低估真正的變異程度。為了補償這個低估，我們就少除 1，也就是除以  $n-1$ 。

## ● 標準差 (Standard Deviation)

標準差 (Standard Deviation) 就是變異數 (Variance) 的平方根。

- 變異數公式 (以樣本為例)：

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

- 標準差公式：

$$s = \sqrt{s^2}$$

因為變異數是「距離的平方」，單位會變得不直觀（例如：如果原本是公分，變異數單位會變成平方公分）。

開平方後，標準差的單位就會跟原始資料一樣，更容易理解和比較。

## ● 百分位數 (Percentile)

用來描述資料在某個特定百分比位置上的值。

示例：第 25 百分位數表示資料中有 25% 的數據點小於或等於這個值，第 75 百分位數表示資料中有 75% 的數據點小於或等於這個值。

## 2. 常見的統計方法

統計方法是資料分析中非常重要的一部分，它們幫助我們理解和描述資料的特徵，並進行推斷和預測。以下是常見的統計方法的詳細介紹：

1. **敘述性統計**：用於描述和總結數據的基本特徵。
2. **複選題分析**：分析多選題的回答情況。
3. **交叉分析**：分析兩個或多個變數之間的關係。

4. **卡方檢定**：檢驗觀察值與期望值之間的差異。
5. **主成份分析**：降維技術，用於減少數據的維度。
6. **因素分析**：識別數據中的潛在因素。
7. **集群分析**：將數據分成不同的組群。
8. **相關分析**：分析兩個變數之間的相關性。
9. **二元羅吉斯迴歸**：分析二元結果的迴歸模型。
10. **區別分析**：識別不同組群之間的差異。
11. **偏相關分析**：分析兩個變數之間的相關性，控制其他變數的影響。  
※與相關分析差異在，偏相關分析是在「控制其他變數的影響」的前提下。
12. **迴歸分析**：分析變數之間的線性關係。
13. **變異數分析**：分析多個組群之間的差異。
14. **偏最小平方迴歸**：迴歸技術，用於處理多重共線性問題。

### ● 敘述性統計 ( Descriptive Statistics )

敘述性統計是用於描述和總結數據的基本特徵。它包括中央趨勢的衡量（如平均數、中位數、眾數）和分散度的衡量（如標準差、四分位距）。敘述性統計能幫助我們快速了解數據的分布和特徵。

**示例：** 假設有一組學生的考試成績：80, 85, 90, 95, 100。敘述性統計可以幫助我們了解這組數據的平均數、中位數、眾數和標準差。

✧ 適用於描述和總結數據的基本特徵。

✧ 包括中央趨勢的衡量（如平均數、中位數、眾數）和分散度的衡量（如標準差、四分位距）。

### ● 複選題分析 ( Multiple Choice Analysis )

複選題分析是用於分析多選題的回答情況。它能幫助我們了解每個選項的選擇頻率，並進行進一步的分析。

**示例：** 假設有一組問卷調查，包含多選題：「你喜歡的水果有哪些？」選項包括蘋果、香蕉、橘子和葡萄。複選題分析可以幫助我們了解每個選項的選擇頻率。

※使用二元變數，選了為 1，沒選為 0 → 再作次數統計或交叉分析或羅吉斯迴歸

### ● 交叉分析 ( Cross Analysis )

交叉分析是用於分析兩個或多個類別變數之間的關係。它能幫助我們了解變數之間的相互影響，並進行進一步的分析。

**示例：** 假設有一組問卷調查，包含兩個變數：「性別」和「喜歡的水果」。交叉分析可以幫助我們了解不同性別的受訪者喜歡的水果有哪些。

### ● 卡方檢定 ( Chi-Square Test )      ※是交叉分析中常見的檢定方法

卡方檢定是用於檢驗觀察值與期望值之間的差異。它能幫助我們了解變數之間是否存在顯著的關係。

**示例：** 假設有一組問卷調查，包含兩個變數：「性別」和「喜歡的水果」。卡方檢定可以

幫助我們檢驗性別與喜歡的水果之間是否存在顯著的關係。

- ✧ 適用於檢驗觀察值與期望值之間的差異。
- ✧ 能幫助你了解變數之間是否存在顯著的關係。

※觀察值：在一次實驗/調查中實際觀察到的結果或數據

※期望值：是一個隨機變數在長期重覆實驗下，理論上的平均值。

※觀察值 vs 期望值：例：投一次骰子，觀察值可能是 1 ~6 的任何值（端看擲到多少），而期望值為  $(1+2+3+4+5+6) / 6 = 3.5$

※是否存在顯著的關係：p 值 < 顯著水準(e.g. 0.05)，拒絕  $H_0$ ，表示變數之間有統計顯著關係。

## ● 主成份分析 ( Principal Component Analysis, PCA )

主成份分析是降維技術，用於減少數據的維度。它能幫助我們提取數據中的主要特徵，並進行進一步的分析。

示例： 假設有一組問卷調查，包含多個變數：「性別」、「年齡」、「收入」、「教育程度」等。主成份分析可以幫助我們提取數據中的主要特徵，並進行進一步的分析。

- ✧ 適用於降維技術，用於減少數據的維度。
- ✧ 能幫助你提取數據中的主要特徵。

## ● 因素分析 ( Factor Analysis )

因素分析是用於識別數據中的潛在因素。它能幫助我們了解數據的結構，並進行進一步的分析。

※屬描述性統計方法，找出多個變數之間是否有共同趨動它們的潛在因子。常見於心理測驗、問券設計，將多題項歸類到幾個共通的構面，例：人格五大特質。

示例： 假設有一組問卷調查，包含多個變數：「性別」、「年齡」、「收入」、「教育程度」等。因素分析可以幫助我們識別數據中的潛在因素，並進行進一步的分析。

- ✧ 適用於識別數據中的潛在因素。
- ✧ 能幫助你了解數據的結構。

## ● 集群分析 ( Cluster Analysis )      ※常見方法：K-Means、層次聚類、DBSCAN

集群分析是用於將數據分成不同的組群。它能幫助我們了解數據的分布，並進行進一步的分析。

示例： 假設有一組問卷調查，包含多個變數：「性別」、「年齡」、「收入」、「教育程度」等。集群分析可以幫助我們將數據分成不同的組群，並進行進一步的分析。

- ✧ 適用於將數據分成不同的組群。
- ✧ 能幫助你了解數據的分布。

## ● 相關分析 ( Correlation Analysis )

相關分析是用於分析兩個變數之間的相關性。它能幫助我們了解變數之間的相互影響，並進行進一步的分析。

※分析二個變數之間的線性關係、強度、方向。常見的相關分析方法有：皮爾森積差相關係數( $r$ )  $r$  介於  $-1 \sim 1$ ， $r > 0$  正相關、 $r < 0$  負相關、 $r = 0$  無線性關係。

示例： 假設有一組問卷調查，包含兩個變數：「年齡」和「收入」。相關分析可以幫助我們了解年齡與收入之間的相關性。

✧ 適用於分析兩個變數之間的相關性。

✧ 能幫助你了解變數之間的相互影響。

## ● 二元羅吉斯迴歸 ( Binary Logistic Regression )

二元羅吉斯迴歸是用於分析二元結果的迴歸模型。它能幫助我們了解變數之間的相互影響，並進行進一步的分析。

示例： 假設有一組問卷調查，包含兩個變數：「性別」和「是否購買產品」。二元羅吉斯迴歸可以幫助我們了解性別與是否購買產品之間的關係。

※當應變數  $Y$  只有二個可能的結果， $Y$  或  $N$ 、成功 或 失敗...etc，而自變數  $X$  可以是類別 或 連續型變數時，適用此模型。案例：病患是否會罹病 ( $Y/N$ )、用戶是否會點擊廣告( $Y/N$ )，模型最後測試得到一個介於  $0 \sim 1$  的機率值(即為 Sigmoid  $S$  曲線)，再透過預定義的閾值 e.g. 0.5 進行二分類。

## ● 區別分析 ( Discriminant Analysis )

區別分析是用於識別不同組群之間的差異。它能幫助我們了解組群之間的相互影響，並進行進一步的分析。

示例： 假設有一組問卷調查，包含多個變數：「性別」、「年齡」、「收入」、「教育程度」等。區別分析可以幫助我們識別不同組群之間的差異，並進行進一步的分析。

※目的是找出變數組合，使得不同群組之間的差異最大化，運用此模型來預測觀察值屬於那個群組。案例：根據學生的成績、興趣、人格特質，判斷適合理組或文組。

## ● 偏相關分析 ( Partial Correlation Analysis )

偏相關分析是用於分析兩個變數之間的相關性，控制其他變數的影響。它能幫助我們了解變數之間的相互影響，並進行進一步的分析。

示例： 假設有一組問卷調查，包含三個變數：「年齡」、「收入」和「教育程度」。偏相關分析可以幫助我們了解年齡與收入之間的相關性，控制教育程度的影響。

## ● 迴歸分析 ( Regression Analysis )

迴歸分析是用於分析變數之間的線性關係。它能幫助我們了解變數之間的相互影響，並進行進一步的分析。

示例： 假設有一組問卷調查，包含兩個變數：「年齡」和「收入」。迴歸分析可以幫助我們了解年齡與收入之間的線性關係。

✧ 適用於分析變數之間的線性關係。

✧ 能幫助你了解變數之間的相互影響，並進行預測。

## ● 變異數分析 ( Analysis of Variance, ANOVA )

變異數分析是用於分析多個組群之間的差異。它能幫助我們了解組群之間的相互影響，並進行進一步的分析。

**示例：** 假設有一組問卷調查，包含多個組群：「性別」、「年齡」、「收入」、「教育程度」等。變異數分析可以幫助我們分析多個組群之間的差異。

✧ 適用於分析多個組群之間的差異。

✧ 能幫助你了解組群之間的相互影響。

※ANOVA 常用 F 檢定。例：三個教學方式(類別)對學生成績(連續型變數)之影響

### ● 偏最小平方迴歸 ( Partial Least Squares Regression, PLS )

偏最小平方迴歸是迴歸技術，用於處理多重共線性問題。它能幫助我們了解變數之間的相互影響，並進行進一步的分析。

**示例：** 假設有一組問卷調查，包含多個變數：「性別」、「年齡」、「收入」、「教育程度」等。偏最小平方迴歸可以幫助我們處理多重共線性問題，並進行進一步的分析。

## 3. 常見的統計方法分類表

常見的統計方法可做以下分類：

|       | 類別變數                                                                                              | 連續變數                                                                                                  |
|-------|---------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------|
| 無因果關係 | <ul style="list-style-type: none"><li>敘述性統計</li><li>複選題分析</li><li>(多重)交叉分析</li><li>卡方檢定</li></ul> | <ul style="list-style-type: none"><li>主成份分析</li><li>因素分析</li><li>集群分析</li><li>(偏)相關分析</li></ul>       |
| 有因果關係 | <ul style="list-style-type: none"><li>二元羅吉斯迴歸</li><li>區別分析</li></ul>                              | <ul style="list-style-type: none"><li>偏相關分析</li><li>迴歸分析</li><li>(多變量)變異數分析</li><li>偏最小平方迴歸</li></ul> |

※ 上表的類別型變數、連續型變數，指的是應變數的型態。

※ t-檢定：連續變數 & 無因果關係。比較二個連續變數的平均差異是否有顯著差異。例：比較男性與女性的數學成績是否有差異，自變數為性別（類別型，男/女）、應變數為數學成績（連續變數）

※ F 檢定：連續變數 & 有因果關係。比較三個或以上連續變數的平均差異是否有顯著差異。例：三個教學方式(類別型，自變數)對學生成績(連續型，應變數)之影響

※ 區別分析：應變數是類別、自變數是連續。例：預測學生是否會選擇理工科系，應變數（Y，學生選擇的科系，類別型，理工科為 1 或文科為 0）；自變數（X，連續數值型，數學成績、物理成績、對科學的興趣程度 1~5）

※ 是否有因果關係，不能單純以該統計方法有無自變數、應變數來判斷，因為即使證明 自變數與 應變數 之間的關係，並不代表其之間存在因果關係，可能二者有共同的潛在因素影響它們。

### 1. 假說檢定：

○ 流程：提出假設、選擇檢定方法、計算檢定統計量、決定拒絕域和接受域。



- 統計假設 ( Hypothesis ) : 對數據的假設。
  - 統計推論 ( Statistical Inference ) : 根據樣本數據推斷母體特徵。
  - 假設檢定 ( Testing Hypothesis ) : 檢驗假設是否成立。
  - 接受域 ( Acceptance Region ) : 假設成立的範圍。
  - 拒絕域 ( Rejection Region ) : 假設不成立的範圍。
  - 檢定 ( Test ) : 檢驗假設的方法。
  - 顯著水準 ( Significance Level ) : 檢定的顯著性標準。
  - 檢定統計量 ( Test Statistic ) : 檢驗假設的統計量。
  - p 值 ( p-value ) : 檢驗結果的顯著性指標。
2. 探索性資料分析 ( Exploratory Data Analysis, EDA ) : 用於初步分析數據，發現數據的特徵和模式。
  3. 驗證性資料分析 ( Confirmatory Data Analysis, CDA ) : 用於檢驗先前提出的假設，通常採用分類、分群、相關性分析或預測模型等方法進行深入分析。

## ● 假說檢定 ( Hypothesis Testing )

假說檢定 ( Hypothesis Testing ) 是統計學中用來判斷樣本資料是否能夠支持某一關於母體參數的主張或假設的方法。它是一個框架，一套嚴謹的邏輯與計算流程，廣泛應用於各種科學、醫學、經濟與社會科學研究中，目的在於從樣本推論母體的特性，並進行理性的決策。

假說檢定不等於證明一個主張為「真」，而是依據統計推論的原則，在一定風險容許下判定資料是否提供足夠證據來拒絕零假說。這是一種機率性的結論，強調「合理的懷疑」，而非「絕對的確定」。

以下是對假說檢定的完整說明與分析：

### 一、基本概念

假說檢定的核心在於比較兩個互相排斥的假設：

#### 1. 零假說 ( Null Hypothesis，記作 $H_0$ ) :

表示原始的、保守的假設，通常表示「沒有差異」、「沒有效果」或「無變化」。

例如：藥物 A 對治療血壓沒有顯著影響。

#### 2. 對立假說 ( Alternative Hypothesis，記作 $H_1$ 或 $H_a$ ) :

表示與零假說相反的主張，通常是研究者想要證明的。

例如：藥物 A 對治療血壓有顯著影響。

### 二、假說檢定的步驟

#### 1. 提出假說：

根據研究問題訂出  $H_0$  與  $H_1$ 。

#### 2. 選擇檢定統計量：

根據資料類型與研究目的選擇適合的統計方法 ( 如 t 檢定、z 檢定、卡方檢定等 )。

| 項目 | t 檢定<br>(t-test) | z 檢定<br>(z-test) | 卡方檢定<br>(Chi-square test) | F 檢定<br>(F-test) |
|----|------------------|------------------|---------------------------|------------------|
| 用途 | 比較兩組平均數          | 比較兩組平均數 ( 樣本 )   | 檢定類別變數之間的關                | 比較兩組變異數是否相       |

| 項目     | t 檢定<br>(t-test)          | z 檢定<br>(z-test)            | 卡方檢定<br>(Chi-square test)  | F 檢定<br>(F-test) |
|--------|---------------------------|-----------------------------|----------------------------|------------------|
|        |                           | 大或已知母體變異數 )                 | 聯性或適合度                     | 等                |
| 資料型態   | 連續變數                      | 連續變數                        | 類別變數                       | 連續變數             |
| 假設檢定   | 平均數差異                     | 平均數差異                       | 分布差異或變數關聯                  | 變異數差異            |
| 常見應用   | 比較兩組學生的成績                 | 比較兩組產品的平均壽命                 | 性別與購買意願是否有關                | 比較兩種教學法下成績的變異程度  |
| 樣本大小要求 | 小樣本也可用                    | 樣本數需大 ( $n > 30$ ) 或已知母體標準差 | 樣本數需足夠大 ( 每格期望值 $\geq 5$ ) | 樣本數不限，但需正態分布     |
| 分布假設   | t 分布                      | 常態分布                        | 卡方分布                       | F 分布             |
| 變數數量   | 1 個連續應變數，1 個類別自變數 ( 2 組 ) | 同上                          | 2 個或以上類別變數                 | 1 個連續變數，2 組以上    |
| 統計量符號  | T                         | Z                           | $\chi^2$ ( chi-square )    | F                |

- ✧ **t 檢定 vs z 檢定**：兩者都比較平均數，差別在於是否已知母體標準差與樣本大小。
- ✧ **卡方檢定**：適用於類別資料，例如交叉表分析。
- ✧ **F 檢定**：常用於變異數分析 ( ANOVA ) 中，也可用於檢定兩組變異數是否相等。

### 3. 設定顯著水準 ( $\alpha$ )：

常見的  $\alpha$  值為 0.05，表示願意接受 5% 的錯誤拒絕  $H_0$  的風險。

顯著水準 (  $\alpha$  ) 是假說檢定中一個極為關鍵的概念。它代表研究者在做統計推論時，願意接受錯誤拒絕零假說 (  $H_0$  ) 的最大機率，亦即發生 第一類錯誤(Type I Error)的風險。換句話說，當母體其實真的符合零假說的情況下，檢定卻錯誤地拒絕了它，這就是第一類錯誤。而  $\alpha$  就是這個錯誤發生的機率。

顯著水準通常在檢定開始前就先行設定，它決定了拒絕域的範圍。

例如：使用雙尾 t 檢定， $\alpha = 0.05$

則在 t 分布的左右兩端各分配 2.5% 的機率

若檢定統計值落在這 5% 的區域 ( 拒絕域 )，就拒絕  $H_0$

若統計值落在其餘 95% 的區域 ( 接受域 )，則不拒絕  $H_0$

### 4. 計算檢定統計值與 p 值：

根據樣本資料計算出對應的統計值與 p 值。

※p 值指在「虛無假設  $H_0$  為真」的前提下，觀察到目前樣本結果或更極端結果的機率，反應對虛無假設的反對程度。亦即「如果原本的假設是對的，那我們現在看到這樣的結果有多不尋常？」，例：

假設你想知道一枚硬幣是不是公平的 ( 正反面機率各 50% )，你丟了 10 次，結果出現了 9 次正面。

- 虛無假設 ( $H_0$ ): 這是公平的硬幣。

- $p$  值: 在硬幣公平的情況下, 出現 9 次或更多正面的機率是多少?

如果這個  $p$  值很小 (例如 0.02), 就代表這樣的結果在「硬幣公平」的情況下**很不尋常**, 你可能會懷疑硬幣不公平。

### 5. 做出結論:

若  $p$  值  $\leq \alpha$ , 則拒絕  $H_0$ , 支持  $H_1$ 。

若  $p$  值  $> \alpha$ , 則無法拒絕  $H_0$ , 代表資料不足以支持  $H_1$ 。

## 三、錯誤類型: Type I Error、Type II Error

|          | $H_0$ 為真                                                                                                                                                        | $H_0$ 為假                                                               |
|----------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------|
| 接受 $H_0$ | 正確                                                                                                                                                              | 第二類錯誤 (Type II Error) ( $\beta$ )<br>錯誤地接受了其實為假的 $H_0$ , 機率為 $\beta$ 。 |
| 拒絕 $H_0$ | 第一類錯誤 (Type I Error) ( $\alpha$ )<br>錯誤地拒絕了其實為真的 $H_0$ , 機率為 $\alpha$ 。<br><br>顯著水準 ( $\alpha$ ) 假設值為 0.05, 表示願意接受 5% 的錯誤拒絕 $H_0$ 的風險, 亦即 Type I Error 的機率為 5%。 | 正確                                                                     |

在研究設計中, 通常會希望減少這兩種錯誤的發生, 並提升檢定的力量 (Power), 即正確拒絕虛無假說的能力。

### 假說檢定 (Hypothesis Testing) 範例

假設某工廠聲稱生產的瓶裝水容量為 600 ml, 現隨機抽取 30 瓶做檢定:

$H_0: \mu = 600$  ml (瓶裝水平均容量為 600 ml)

$H_1: \mu \neq 600$  ml (瓶裝水平均容量不等於 600 ml)

使用  $t$  檢定計算樣本平均值是否與 600 有顯著差異, 依據  $p$  值與  $\alpha$  值來判斷是否接受這個主張。

#### 1. 提出假說: 根據研究問題訂出 $H_0$ 與 $H_1$

背景: 某瓶裝水標示平均容量為 600 ml, 現在抽取 30 瓶樣本, 想檢定實際平均容量是否與標示不同。

假設檢定目標: 檢定這些瓶裝水的平均容量是否「不等於」600 ml, 屬於雙尾檢定。

零假說  $H_0: \mu = 600$  ml (表示瓶裝水平均容量符合標示)

對立假說  $H_1: \mu \neq 600$  ml (表示平均容量有誤差, 不等於 600)

#### 2. 選擇檢定統計量: 根據資料類型與研究目的選擇適合的統計方法 (如 $t$ 檢定、 $z$ 檢定、卡方檢定等)。

單樣本  $t$  檢定。因為通常我們不知道母體的變異數 ( $\sigma^2$ )，且樣本數也未達大樣本的標準 ( $n < 30$ )。故使用的是 單樣本  $t$  檢定。

### 3. 設定顯著水準 ( $\alpha$ ):

顯著水準  $\alpha = 0.05$ ，表示願意接受 5% 的錯誤拒絕  $H_0$  的風險。

### 4. 計算檢定統計值與 $p$ 值：根據樣本資料計算出對應的統計值與 $p$ 值。

- 我們假設已抽取 30 瓶瓶裝水，量測後得到以下資訊：

樣本平均數 ( $\bar{x}$ ) = 596.5 ml

樣本標準差 ( $s$ ) = 5.5 ml

樣本數 ( $n$ ) = 30

- 計算統計量：單樣本  $t$  檢定

檢定統計量公式：

$$t = \frac{\bar{x} - \mu}{s / \sqrt{n}}$$

代入數值：

$$t = \frac{596.5 - 600}{5.5 / \sqrt{30}} = \frac{-3.5}{5.5 / 5.477} = \frac{-3.5}{1.0045} \approx \underline{\underline{-3.485}}$$

$t \approx$  (近似) -3.485

若用圖形表示：

X 軸： $t$  分布，中心為  $t = 0$

拒絕域：左側與右側各佔 2.5% ( $\alpha = 0.05$  的雙尾)

計算出來的  $t$  值為 -3.485，遠落在左側拒絕域中

### ● 決策準則與臨界值

1. 自由度  $df = n - 1 = 29$

2. 查表或使用軟體找對應的  $t$  臨界值 (雙尾  $\alpha = 0.05$ ， $df = 29$ ):

✧ 臨界值約為  $\pm 2.045$  (來自  $t$  分布表)

### 5. 做出結論：

✧  $|t| = 3.485 >$  臨界值 2.045，表示落在拒絕域

✧ 或使用  $p$  值 (使用統計軟體計算):

$p \approx$  (近似)  $0.0016 < 0.05$  (若  $p$  值  $\leq \alpha$ ，則拒絕  $H_0$ ，支持  $H_1$ 。)

因此，拒絕  $H_0$ ，代表有足夠證據支持瓶裝水容量不等於標示的 600 ml。

這個結果說明，樣本資料提供了足夠的統計證據，顯示實際平均容量與標示值存在顯著差異。換句話說，這批瓶裝水的生產品質可能有偏差，值得進一步品管或調查。

## ● 描述性統計和探索性資料分析 (EDA)

在資料科學和數據分析的領域中，描述性統計和探索性資料分析 (EDA) 是兩個非常重要的概念。幫助我們理解資料的集中趨勢、離散趨勢和分佈形狀；探索性資料分析 (EDA) 通過視覺化和統計方法，幫助我們發現資料中的模式、異常值和關係。這些方法幫助我們理解和總結資料的基本特徵，並為進一步的分析和建模提供基礎。

### 描述性統計 (或稱 敘述性分析) 相關圖形的介紹參附件 1

描述性統計是用來總結和描述資料基本特徵的一組方法。這些方法不涉及推論或預測，而是專注於資料的呈現和解釋。描述性統計主要包括以下幾個方面：

1. **集中趨勢：** 集中趨勢是描述資料集中位置的統計量，常見的有平均數、中位數和眾數。平均數是所有數值的總和除以數值的個數；中位數是將數值排序後位於中間的數值；眾數是出現頻率最高的數值。
2. **離散趨勢：** 離散趨勢是描述資料分散程度的統計量，常見的有範圍、四分位距、變異數和標準差。範圍是最大值與最小值之間的差；四分位距是上四分位數與下四分位數之間的差；變異數是所有數值與平均數之差的平方和的平均數；標準差是變異數的平方根。
3. **分佈形狀：** 分佈形狀是描述資料分佈形態的統計量，常見的有偏度和峰度。偏度是描述資料分佈的對稱性；峰度是描述資料分佈的尖銳程度。
4. **圖形表示：** 圖形表示是通過圖表來呈現資料的基本特徵，常見的有直方圖、盒形圖、散佈圖等。直方圖用來顯示資料的分佈情況；盒形圖用來顯示資料的集中趨勢和離散趨勢；散佈圖用來顯示兩個變數之間的關係。

### 探索性資料分析 (EDA) ※建模前作

探索性資料分析 (EDA) 是一組用來分析資料集特徵的技術，目的是在不做任何假設的情況下，通過視覺化和統計方法來發現資料中的模式、異常值和關係。EDA 是資料分析過程中的重要步驟，通常在建模之前進行。EDA 主要包括以下幾個方面：

1. **資料檢查：** 資料檢查是 EDA 的第一步，目的是了解資料的基本情況，包括資料的大小、變數的類型、缺失值和異常值等。這可以通過查看資料的摘要統計量和圖形表示來實現。
2. **資料清理：** 資料清理是指處理資料中的缺失值、異常值和重複資料。缺失值可以通過刪除、插補或替換來處理；異常值可以通過統計方法來檢測和處理；重複資料可以通過去重算法來清理。
3. **資料轉換：** 資料轉換是指對資料進行變換，以便更好地進行分析和建模。常見的資料轉換方法有標準化、正規化、對數變換等。標準化(Zero-Score)是將資料轉換為均值為 0、標準差為 1 的標準正態分佈；正規化(Min-Max)是將資料轉換為介於 0 和 1 之間的數值；對數變換是將資料取對數，以減少資料的偏度。
4. **資料視覺化：** 資料視覺化是 EDA 的重要組成部分，通過圖表來呈現資料的基本特徵和關係。常見的資料視覺化方法有直方圖、盒形圖、散佈圖、熱圖等。直方圖用來顯示資料的分佈情況；盒形圖用來顯示資料的集中趨勢和離散趨勢；散佈圖用來顯示兩個變數之間的關係；熱圖用來顯示多個變數之間的相關性。
5. **資料建模：** 資料建模是 EDA 的最後一步，目的是通過簡單的統計模型來檢驗資料中的模式和關係。常見的資料建模方法有線性回歸、邏輯回歸、決策樹等。線性回歸是用來

檢驗兩個變數之間的線性關係；邏輯回歸是用來檢驗二元變數之間的關係；決策樹是用來檢驗多個變數之間的關係。

- **驗證性資料分析 ( Confirmatory Data Analysis, CDA )**

驗證性資料分析是一種資料分析方法，用於檢驗先前提出的假設。它包括分類、分群、相關性分析和預測模型等方法。驗證性資料分析的主要目的是驗證資料中的模式和關係。

**驗證性資料分析步驟**

1. **提出假設：**提出假設，確定分析的目標和方向。
2. **選擇適當的分析方法：**根據資料的特性和分析的目的，選擇適當的分析方法。例如，分類、分群、相關性分析等。
3. **進行資料分析：**使用選擇的分析方法進行資料分析，檢驗假設。
4. **解釋分析結果：**解釋分析結果，得出結論。

**驗證性資料分析示例**

假設有一組學生的考試成績，想檢驗不同教學方法對學生成績的影響。提出假設：不同教學方法對學生成績有影響；選擇迴歸分析方法，進行資料分析，檢驗假設；解釋分析結果，得出結論。

---

## 六、 資料清理\_資料標準化(標準化(Z-score), 正規化(Min-Max), Log 轉換

在資料清理過程中，標準化資料是非常重要的一步。標準化資料的方法有多種，包括 Z-score 標準化、Min-Max 標準化和 Log 轉換。這些方法可以使資料的範圍和分佈更為一致，從而提高資料分析的準確性和模型的效能。以下是詳細說明及示例：

- **Z-score 標準化**

Z-score 標準化 ( 也稱為標準分數標準化 ) 是將資料轉換為均值為 0、標準差為 1 的分佈。這種方法適用於資料分佈接近正態分佈的情況。

公式：

$$Z = \frac{X - \mu}{\sigma}$$

其中， $X$  是原始資料， $\mu$  是資料的均值， $\sigma$  是資料的標準差。

示例： 假設我們有一組房屋價格的資料：

價格 (萬元) : 100, 150, 200, 250, 300, 350

首先計算均值和標準差：

均值 ( $\mu$ ) =  $(100 + 150 + 200 + 250 + 300 + 350) / 6 = 225$

標準差 ( $\sigma$ ) =  $\sqrt{((100-225)^2 + (150-225)^2 + (200-225)^2 + (250-225)^2 + (300-225)^2 + (350-225)^2) / 6} \approx 83.67$

然後對每個資料點進行 Z-score 標準化：

$Z(100) = (100 - 225) / 83.67 \approx -1.49$

$Z(150) = (150 - 225) / 83.67 \approx -0.90$

$Z(200) = (200 - 225) / 83.67 \approx -0.30$

$Z(250) = (250 - 225) / 83.67 \approx 0.30$

$Z(300) = (300 - 225) / 83.67 \approx 0.90$

$Z(350) = (350 - 225) / 83.67 \approx 1.49$

標準化後的資料：

Z-score 標準化後的價格：約為 -1.49, -0.90, -0.30, 0.30, 0.90, 1.49

- **Min-Max 標準化**

Min-Max 標準化是將資料縮放到一個固定的範圍 (通常是 0 到 1)。這種方法適用於資料分佈不均且需要保留資料的相對大小關係的情況。

公式：

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

其中， $X$  是原始資料， $X_{\min}$  是資料的最小值， $X_{\max}$  是資料的最大值。

示例： 假設我們有一組房屋價格的資料：

價格 (萬元) : 100, 150, 200, 250, 300, 350

首先找到最小值和最大值：

最小值 ( $X_{\min}$ ) = 100  
最大值 ( $X_{\max}$ ) = 350

然後對每個資料點進行 Min-Max 標準化：

$X'(100) = (100 - 100) / (350 - 100) = 0$   
 $X'(150) = (150 - 100) / (350 - 100) = 0.20$   
 $X'(200) = (200 - 100) / (350 - 100) = 0.40$   
 $X'(250) = (250 - 100) / (350 - 100) = 0.60$   
 $X'(300) = (300 - 100) / (350 - 100) = 0.80$   
 $X'(350) = (350 - 100) / (350 - 100) = 1$

標準化後的資料：

Min-Max 標準化後的價格：約為 0, 0.20, 0.40, 0.60, 0.80, 1

- Log 轉換

Log 轉換是將資料取對數，以減少資料的範圍和異常值的影響。這種方法適用於資料分佈偏斜且存在極端值的情況。

公式：

$$X' = \log(X)$$

其中， $X$  是原始資料。

示例： 假設我們有一組房屋價格的資料：

※下圖示例，因是以自然對數(以  $e$  為底)為例，而非以常用對數(以 10 為底)為例，故應是  $\ln(100)$  而非  $\log(100)$



|                                                                                                                                                                |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 價格 ( 萬元 ) : 100, 150, 200, 250, 300, 350                                                                                                                       |
| 對每個資料點進行 Log 轉換 ( 以自然對數為例 ) :                                                                                                                                  |
| Log(100) $\approx$ 4.61<br>Log(150) $\approx$ 5.01<br>Log(200) $\approx$ 5.30<br>Log(250) $\approx$ 5.52<br>Log(300) $\approx$ 5.70<br>Log(350) $\approx$ 5.86 |
| 轉換後的資料 :                                                                                                                                                       |
| Log 轉換後的價格 : 約為 4.61, 5.01, 5.30, 5.52, 5.70, 5.86                                                                                                             |

這些標準化方法各有優缺點，選擇適當的方法取決於資料的特性和具體情況。

## 七、資料挖掘技術

在資料分析過程中，常用的**資料挖掘技術**有許多，這些技術可以幫助我們從大量資料中發現有價值的資訊和模式。以下是資料挖掘技術中使用機器學習演算法(監督學習/非監督學習)、僅是單純的統計方法：

| 資料挖掘技術               | 用於                                   | 應用於                       | 演算法/方法                                                              | 監督 | 非監督 | 統計 |
|----------------------|--------------------------------------|---------------------------|---------------------------------------------------------------------|----|-----|----|
| 分類<br>Classification | 將資料分配到預定義的類別中                        | -信用評分<br>-醫療診斷<br>-垃圾郵件檢測 | 決策樹(Decision Tree)                                                  | Y  |     |    |
|                      |                                      |                           | 支持向量機(Support Vector Machine · SVM)                                 | Y  |     |    |
|                      |                                      |                           | 隨機森林(Random Forest)                                                 | Y  |     |    |
|                      |                                      |                           | 神經網絡(Neural Network)                                                | Y  |     |    |
| 回歸<br>Regression     | 預測連續數值                               | -房價預測<br>-銷售預測<br>-風險評估   | 線性回歸(Linear Regression)                                             | Y  |     |    |
|                      |                                      |                           | 多項式回歸(Polynomial Regression)                                        | Y  |     |    |
|                      |                                      |                           | 迴歸樹(Regression Tree)                                                | Y  |     |    |
| 聚類<br>Clustering     | 將資料分組，使得同一組內的資料點相似度高，而不同組之間的資料點相似度較低 | -市場細分<br>-圖像分割<br>-社交網絡分析 | K 均值聚類 ( K-Means Clustering )                                       |    | Y   |    |
|                      |                                      |                           | 層次聚類(Hierarchical Clustering)                                       |    | Y   |    |
|                      |                                      |                           | DBSCAN(Density-Based Spatial Clustering of Applications with Noise) |    | Y   |    |
| 關聯規則                 | 發現資料集中不同                             | -購物籃分析                    | Apriori                                                             |    | Y   |    |

| 資料挖掘技術                         | 用於                                | 應用於                      | 演算法/方法                                                                        | 監督 | 非監督 | 統計 |
|--------------------------------|-----------------------------------|--------------------------|-------------------------------------------------------------------------------|----|-----|----|
| Association Rule Learning      | 項目之間的關聯                           | -推薦系統<br>-網頁挖掘           | FP-Growth                                                                     |    | Y   |    |
| 降維<br>Dimensionality Reduction | 減少資料的維度，從而提高資料分析的效率和效果。是一種資料預處理技術 | -資料視覺化<br>-特徵選擇<br>-壓縮感知 | 主成分分析(Principal Component Analysis · PCA) (數值型)                               |    | Y   |    |
|                                |                                   |                          | 線性判別分析(Linear Discriminant Analysis · LDA) (類別型)                              | Y  |     |    |
|                                |                                   |                          | 多重對應分析(Multiple Correspondence Analysis · MCA)                                |    | Y   |    |
|                                |                                   |                          | 混合資料因子分析(Factor Analysis of Mixed Data · FAMD)                                |    | Y   |    |
|                                |                                   |                          | t 分佈隨機鄰嵌入(t-Distributed Stochastic Neighbor Embedding · t-SNE) (非線性降維，多用在視覺化) |    | Y   |    |
|                                |                                   |                          | Uniform Manifold Approximation and Projection(UMAP) (非線性降維，多用在視覺化)            |    | Y   |    |
| 時間序列分析<br>Time Series Analysis | 分析時間序列資料的方法，旨在發現資料中的趨勢、季節性和週期性模式  | -經濟預測<br>-銷售預測<br>-氣象預測  | 自回歸整合移動平均模型(ARIMA)                                                            |    |     | Y  |
|                                |                                   |                          | 指數平滑法(Exponential Smoothing)                                                  |    |     | Y  |
|                                |                                   |                          | 長短期記憶網絡(LSTM)                                                                 | Y  |     |    |

※關聯規則：核心是發掘「若 X，則 Y」的規則。是類別型。若 X 發生，Y 發生的機率有多高。

## 1. 分類-決策樹 (Decision Tree)、支持向量機 (Support Vector Machine, SVM)、隨機森林 (Random Forest)、神經網絡 (Neural Network)

### ● 決策樹 (Decision Tree)

決策樹是一種監督學習方法，用於分類和回歸任務。它的結構類似於一棵樹，每個節點代表一個特徵，每個分支代表一個決策，每個葉子節點代表一個結果。決策樹的優點在於其直觀易懂，能夠處理數值型和類別型資料。

**示例：** 假設我們要預測一個人的收入是否超過 50,000 美元，我們可以使用決策樹來根據年齡、教育程度和工作經驗等特徵進行預測。決策樹會根據這些特徵進行分裂，最終在葉子節點給出預測結果。

決策樹的構建過程包括選擇最佳分裂點、分裂資料集和遞迴構建子樹。常用的分裂標準包括基尼不純度 (Gini Impurity) 和信息增益 (Information Gain)。

- **支持向量機 ( Support Vector Machine · SVM )**

支持向量機是一種監督學習方法，用於分類和回歸任務。SVM 的基本原理是找到一條最佳的超平面 ( Hyperplane )，將資料點分成不同的類別。SVM 的優點在於其高效能，特別適用於高維度資料。

**示例：** 假設我們要分類一組花卉資料，根據花瓣長度和寬度將花卉分為不同的種類。我們可以使用 SVM 來找到一條最佳的超平面，將不同種類的花卉分開。

SVM 的訓練過程包括選擇核函數 ( Kernel Function )、最大化間隔 ( Margin ) 和最小化分類錯誤。常用的核函數包括線性核 ( Linear Kernel )、多項式核 ( Polynomial Kernel ) 和徑向基核 ( Radial Basis Function · RBF )。

- **隨機森林 ( Random Forest )**

隨機森林是一種集成學習方法，由多棵決策樹組成。每棵決策樹在訓練過程中隨機選擇特徵和資料樣本，最終通過投票或平均來給出預測結果。隨機森林的優點在於其高效能和抗過擬合能力。

**示例：** 假設我們要預測房價，我們可以使用隨機森林來根據房屋的特徵 ( 如面積、房間數量、地區等 ) 進行預測。隨機森林會構建多棵決策樹，最終通過投票或平均來給出預測結果。

隨機森林的訓練過程包括隨機選擇特徵和資料樣本、構建多棵決策樹和集成預測結果。隨機森林能夠有效減少過擬合，並提高模型的穩定性和準確性。

- **神經網絡 ( Neural Network )**

神經網絡是一種模仿人腦結構和功能的監督學習方法，由多層神經元組成。每個神經元接收輸入訊號，經過加權和激活函數處理後，傳遞給下一層神經元。神經網絡的優點在於其強大的學習能力，能夠處理複雜的非線性問題。

**示例：** 假設我們要識別手寫數字，我們可以使用神經網絡來根據手寫數字的像素值進行預測。神經網絡會通過多層神經元的計算，最終給出預測結果。

神經網絡的訓練過程包括前向傳播 ( Forward Propagation )、反向傳播 ( Backward Propagation ) 和權重更新。常用的激活函數包括 Sigmoid 函數、ReLU 函數和 Tanh 函數。

## 2. 回歸-線性回歸 ( Linear Regression )、多項式回歸 ( Polynomial Regression )、迴歸樹 ( Regression Tree )

- **線性回歸 ( Linear Regression )**

線性回歸是一種基本的監督學習方法，用於預測連續數值。其基本原理是找到一條最佳的直線，使得資料點到這條直線的距離總和最小。這條直線的方程式通常表示為：

$$y = \beta_0 + \beta_1 x$$

其中， $y$  是預測值， $x$  是自變數， $\beta_0$  是截距， $\beta_1$  是斜率。

**示例：** 假設我們要預測一個人的收入，根據其工作經驗 ( 年數 ) 進行預測。我們可以使用線性

回歸來找到收入與工作經驗之間的關係。通過訓練模型，我們可以得到一條最佳的直線，根據這條直線來預測收入。

線性回歸的優點在於其簡單易懂，計算效率高。然而，線性回歸僅適用於資料呈線性關係的情況，對於非線性資料效果較差。

- **多項式回歸 ( Polynomial Regression )**

多項式回歸是線性回歸的擴展，用於處理非線性資料。其基本原理是將自變數進行多項式變換，然後進行線性回歸。多項式回歸的方程式通常表示為：

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \cdots + \beta_n x^n$$

其中， $y$  是預測值， $x$  是自變數， $\beta_0, \beta_1, \beta_2, \beta_3, \cdots, \beta_n$  是多項式係數。

**示例：** 假設我們要預測房價，根據房屋面積進行預測。我們可以使用多項式回歸來找到房價與房屋面積之間的非線性關係。通過訓練模型，我們可以得到一條最佳的多項式曲線，根據這條曲線來預測房價。

多項式回歸的優點在於其能夠處理非線性資料，適用範圍較廣。然而，多項式回歸容易過擬合，特別是在多項式次數較高的情況下。

- **迴歸樹 ( Regression Tree )**

迴歸樹是一種監督學習方法，用於預測連續數值。其基本原理是將資料集分割成多個子集，每個子集對應一個預測值。迴歸樹的結構類似於決策樹，每個節點代表一個特徵，每個分支代表一個決策，每個葉子節點代表一個預測值。

**示例：** 假設我們要預測房價，根據房屋的特徵（如面積、房間數量、地區等）進行預測。我們可以使用迴歸樹來根據這些特徵進行分割，最終在葉子節點給出預測結果。

迴歸樹的優點在於其直觀易懂，能夠處理數值型和類別型資料，適用於非線性資料。然而，迴歸樹容易過擬合，特別是在樹的深度較大的情況下。

---

### 3. 聚類/分群-K 均值聚類 ( K-Means Clustering )、層次聚類 ( Hierarchical Clustering )、DBSCAN ( Density-Based Spatial Clustering of Applications with Noise )

- **K 均值聚類 ( K-Means Clustering )**

K 均值聚類是一種非監督學習方法，用於將資料分成 K 個聚類。其基本原理是通過迭代的方法，將資料點分配到最近的聚類中心，並更新聚類中心的位置，直到聚類結果穩定。K 均值聚類的優點在於其簡單易懂，計算效率高。

**示例：** 假設我們有一組顧客資料，包括年齡和消費金額。我們可以使用 K 均值聚類將顧客分成三個聚類，根據年齡和消費金額的相似性進行分組。通過迭代的方法，我們可以得到三個聚類中心，並將顧客分配到最近的聚類中心。

K 均值聚類的步驟如下：

1. 隨機選擇 K 個初始聚類中心。
2. 將每個資料點分配到最近的聚類中心。

3. 計算每個聚類的平均值，更新聚類中心的位置。

4. 重複步驟 2 和 3，直到聚類結果穩定或達到預定的迭代次數。

K-均值的優點是簡單易懂且計算效率高，但它也有一些缺點，如需要預先指定 K 值，對初始質心的選擇敏感，且容易受到離群值 ( Outliers ) 的影響。例如，K-均值可以用來將客戶分群，根據購買行為將客戶分成不同的群體，以便進行針對性的營銷。

## ● 層次聚類 ( Hierarchical Clustering )

層次聚類是一種非監督學習方法，用於將資料分成層次結構的聚類，分為自底向上

( Agglomerative ) 和自頂向下 ( Divisive ) 兩種方式。自底向上的層次聚類從每個數據點開始，逐步合併最近的兩個群集，直到所有數據點都在同一個群集中；自頂向下的層次聚類則從所有數據點開始，逐步將群集劃分為更小的群集，直到每個數據點都在單獨的群集中。

**示例：** 假設我們有一組顧客資料，包括年齡和消費金額。我們可以使用層次聚類將顧客分成層次結構的聚類，根據年齡和消費金額的相似性進行分組。通過計算資料點之間的相似度，我們可以逐步合併或分裂聚類，形成層次結構的樹狀圖。

層次聚類的步驟如下：

1. 計算所有數據點之間的距離矩陣。
2. 選擇最近的兩個群集，將它們合併為一個新群集。
3. 更新距離矩陣，計算新群集與其他群集之間的距離。
4. 重複步驟 2 和 3，直到所有數據點都在同一個群集中。

層次聚類的優點是無需預先指定群集數量，且能夠生成層次結構的樹狀圖 ( Dendrogram )，便於觀察數據的層次結構。但它的缺點是計算複雜度高，對大規模數據不太適用。例如，層次聚類可以用來分析基因表達數據，根據基因的相似性將它們分成不同的群集。。

## ● DBSCAN ( Density-Based Spatial Clustering of Applications with Noise )

DBSCAN 是一種基於密度的聚類演算法，能夠識別任意形狀的群集，並能夠處理離群值。它的基本思想是通過密度連通性來定義群集，將密度高的區域視為聚類，並將密度低的區域視為噪音。DBSCAN 的優點在於其能夠自動確定聚類數量，適用於形狀複雜的聚類，且對於噪音和異常值具有較強的魯棒性 (「魯棒性」 ( Robustness ) 是指系統、模型或方法在面對不確定性、干擾、錯誤或變化的情況下，仍能保持穩定、可靠表現的能力)。

**示例：** 假設我們有一組顧客資料，包括年齡和消費金額。我們可以使用 DBSCAN 將顧客分成密度相似的聚類，根據年齡和消費金額的相似性進行分組。通過計算資料點的密度，我們可以將密度高的區域視為聚類，並將密度低的區域視為噪音。

DBSCAN 的步驟如下：

1. 對每個數據點，計算其在指定半徑 ( Epsilon ) 內的鄰居數量。(※指定半徑，須事先預定義)
2. 如果鄰居數量大於等於最小鄰居數 ( MinPts )，則將該數據點標記為核心點 ( Core Point )，並將其鄰居標記為同一群集。(※最小鄰居數，須事先預定義)
3. 對每個核心點的鄰居重複步驟 2，直到所有核心點都被處理完畢。
4. 將未被標記為核心點且不屬於任何群集的數據點標記為離群值。

DBSCAN 的優點是無需預先指定群集數量，能夠識別任意形狀的群集，且能夠處理離群值。但它

的缺點是對參數 Epsilon 和 MinPts 的選擇較為敏感，且在高維數據中效果不佳。例如，DBSCAN 可以用來檢測地震數據中的異常點，根據地震事件的密度將其分成不同的群集。

#### 4. 關連規則-Apriori、FP-Growth

##### ● Apriori 演算法

Apriori 演算法是一種用於發現資料集中頻繁項目集和關聯規則的演算法。其基本原理是基於頻繁項目集的「反單調性」特性，即如果一個項目集是頻繁的，則它的所有子集也是頻繁的。

Apriori 演算法通過迭代的方法，逐步生成頻繁項目集，並從中提取關聯規則。

**示例：** 假設我們有一組購物籃資料，記錄了顧客購買的商品。我們可以使用 Apriori 演算法來發現哪些商品經常一起購買，並生成關聯規則。例如，如果顧客購買了麵包，則他們很可能也會購買牛奶。

Apriori 演算法的步驟如下：

1. 生成所有單項目集，並計算其支持度 ( Support )。
2. 選擇支持度大於或等於最小支持度閾值的頻繁單項目集。
3. 將頻繁單項目集組合成二項目集，並計算其支持度。
4. 重複步驟 2 和 3，直到無法生成新的頻繁項目集。
5. 從頻繁項目集中提取關聯規則，並計算其置信度 ( Confidence )。

Apriori 演算法的優點在於其簡單易懂，適用於小規模資料集。然而，Apriori 演算法的計算複雜度較高，對於大規模資料集效果較差。

##### ● FP-Growth 演算法

FP-Growth 演算法是一種用於發現資料集中頻繁項目集的演算法。其基本原理是通過構建頻繁模式樹 ( Frequent Pattern Tree, FP-Tree )，壓縮資料集中的頻繁項目，從而提高演算法的效率。FP-Growth 演算法不需要生成候選項目集，能夠有效處理大規模資料集。

**示例：** 假設我們有一組購物籃資料，記錄了顧客購買的商品。我們可以使用 FP-Growth 演算法來發現哪些商品經常一起購買，並生成關聯規則。例如，如果顧客購買了麵包，則他們很可能也會購買牛奶。

FP-Growth 演算法的步驟如下：

1. 掃描資料集，計算每個項目的支持度，並過濾掉支持度小於最小支持度閾值的項目。
2. 根據支持度對項目進行排序，構建 FP-Tree。
3. 從 FP-Tree 中提取頻繁項目集，並生成關聯規則。

FP-Growth 演算法的優點在於其高效能，適用於大規模資料集。然而，FP-Growth 演算法的實現較為複雜，對於資料結構的要求較高。

#### 5. 降維-主成分分析 ( Principal Component Analysis, PCA )、線性判別分析 ( Linear Discriminant Analysis, LDA )

##### ● 主成分分析 ( Principal Component Analysis, PCA )

主成分分析 ( PCA ) 是一種資料降維技術，用於將高維度資料轉換為低維度資料，同時保留資料的主要變異性。其基本原理是通過線性變換，將原始資料投影到一組新的正交基上，這些基稱為主成分。每個主成分都是原始資料的線性組合，並且按變異性大小排序。

**示例：** 假設我們有一組包含多個特徵的顧客資料，如年齡、收入、消費金額等。我們可以使用



PCA 將這些高維度資料轉換為低維度資料，從而更容易進行分析和視覺化。通過 PCA，我們可以找到資料中變異性最大的方向，並將資料投影到這些方向上，從而減少資料的維度。

PCA 的步驟如下：

1. 將資料中心化，即減去每個特徵的均值。 ※均值 → 數值型
2. 計算資料的協方差矩陣。
3. 計算協方差矩陣的特徵值和特徵向量。
4. 選擇前  $k$  個最大特徵值對應的特徵向量，作為主成分。
5. 將原始資料投影到這些主成分上，得到降維後的資料。

PCA 的優點在於其能夠有效減少資料的維度，從而提高資料分析的效率和效果。然而，PCA 僅適用於線性資料，對於非線性資料效果較差。

### ● 線性判別分析 ( Linear Discriminant Analysis · LDA )

線性判別分析 ( LDA ) 是一種監督學習方法，用於分類和降維。其基本原理是通過尋找一組線性組合，使得不同類別之間的距離最大化，同時類內距離最小化。LDA 的目的是找到一條最佳的投影方向，使得資料在這條方向上的投影能夠最大程度地區分不同類別。

**示例：** 假設我們有一組包含多個特徵的顧客資料，如年齡、收入、消費金額等，並且這些顧客分為不同的類別（如高消費者和低消費者）。我們可以使用 LDA 將這些高維度資料轉換為低維度資料，從而更容易進行分類和分析。通過 LDA，我們可以找到一條最佳的投影方向，使得不同類別的顧客在這條方向上的投影能夠最大程度地區分開來。

LDA 的步驟如下：

1. 計算每個類別的均值向量和總均值向量。
2. 計算類內散佈矩陣和類間散佈矩陣。
3. 計算類內散佈矩陣的逆矩陣，並與類間散佈矩陣相乘，得到 Fisher 判別準則。
4. 計算 Fisher 判別準則的特徵值和特徵向量。
5. 選擇前  $k$  個最大特徵值對應的特徵向量，作為投影方向。
6. 將原始資料投影到這些投影方向上，得到降維後的資料。

LDA 的優點在於其能夠有效區分不同類別，適用於分類和降維。然而，LDA 僅適用於線性可分的資料，對於非線性資料效果較差。

## 6. 降維\_多重對應分析(MCA)、混合資料因子分析(FAMD)、t-SNE (t-Distributed Stochastic Neighbor Embedding)、UMAP(Uniform Manifold Approximation and Projection)

MCA ( Multiple Correspondence Analysis，多重對應分析 )、FAMD ( Factor Analysis of Mixed Data，混合資料因子分析 )、t-SNE ( t-Distributed Stochastic Neighbor Embedding，t 分佈隨機鄰嵌入 ) 和 UMAP ( Uniform Manifold Approximation and Projection，統一流形近似與投影 ) 都是常用的降維技術，用於簡化高維資料並揭示其中的結構和模式。

### ● MCA ( Multiple Correspondence Analysis，多重對應分析 )

MCA 是一種用於分析多重類別資料的降維技術。它通過將類別資料轉換為數值資料，並使用主成分分析 ( PCA ) 來提取主要成分。MCA 常用於社會科學和市場研究中，用於分析問卷調查結

果和消費者行為。

- **FAMD ( Factor Analysis of Mixed Data · 混合資料因子分析 )**

FAMD 是一種用於分析混合型資料 ( 包括類別資料和數值資料 ) 的降維技術。它結合了 PCA 和 MCA 的特點，能夠同時處理類別資料和數值資料。FAMD 常用於社會科學和生物醫學研究中，用於分析包含多種資料類型的複雜資料集。

- **t-SNE ( t-Distributed Stochastic Neighbor Embedding · t 分佈隨機鄰嵌入 )**

t-SNE 是一種非線性降維技術，旨在捕捉高維資料中的局部結構。它通過將資料點之間的相似度轉換為概率分佈，並使用梯度下降法來最小化高維空間和低維空間之間的 Kullback-Leibler ( KL ) 散度。t-SNE 常用於生物學研究中，用於可視化單細胞 RNA 測序 ( scRNA-seq ) 和流式細胞術資料。

- **UMAP ( Uniform Manifold Approximation and Projection · 統一流形近似與投影 )**

UMAP 是一種非線性降維技術，旨在捕捉高維資料中的全局和局部結構。它通過構建流形近似，並使用優化技術來投影資料到低維空間。UMAP 比 t-SNE 更快且計算資源需求更低，常用於生物學和機器學習研究中，用於可視化基因表達和單細胞測序資料。

---

## 7. 時間序列分析\_長短期記憶網絡 ( LSTM )、自回歸整合移動平均模型 ( ARIMA )、指數平滑法 ( Exponential Smoothing )

- **長短期記憶網絡 ( Long Short-Term Memory · LSTM )**

長短期記憶網絡 ( LSTM ) 是一種特殊的遞歸神經網絡 ( Recurrent Neural Network · RNN )，用於處理和預測時間序列資料。LSTM 的設計目的是解決 RNN 中的長期依賴問題，即隨著時間步長的增加，RNN 無法有效記住早期的資訊。LSTM 通過引入記憶單元和門控機制，能夠有效地保留和更新長期資訊。

**示例：** 假設我們要預測股票價格，我們可以使用 LSTM 來根據歷史價格資料進行預測。LSTM 能夠捕捉價格變動的長期趨勢和短期波動，從而提高預測的準確性。

LSTM 的結構包括輸入門 ( Input Gate )、遺忘門 ( Forget Gate ) 和輸出門 ( Output Gate )。這些門控機制控制資訊的流入、流出和保留，使得 LSTM 能夠有效地處理長期依賴問題。

LSTM 的優點在於其強大的學習能力，能夠處理複雜的非線性問題。然而，LSTM 的訓練過程較為複雜，計算成本較高。

- **自回歸整合移動平均模型 ( Autoregressive Integrated Moving Average · ARIMA )**

自回歸整合移動平均模型 ( ARIMA ) 是一種統計方法，用於分析和預測時間序列資料。ARIMA 模型結合了自回歸 ( Autoregression · AR ) 和移動平均 ( Moving Average · MA ) 兩種方法，並通過差分運算 ( Differencing ) 來處理非平穩時間序列。

**示例：** 假設我們要預測銷售額，我們可以使用 ARIMA 來根據歷史銷售資料進行預測。

ARIMA 能夠捕捉銷售額的趨勢和季節性變化，從而提高預測的準確性。

ARIMA 模型的步驟如下：

1. 確定資料的平穩性，並通過差分運算使資料平穩。



- 選擇自回歸階數 (  $p$  )、差分階數 (  $d$  ) 和移動平均階數 (  $q$  )。
- 訓練 ARIMA 模型，並進行預測。

ARIMA 的優點在於其簡單易懂，適用於線性時間序列資料。然而，ARIMA 僅適用於平穩時間序列，對於非線性資料效果較差。

#### ● 指數平滑法 ( Exponential Smoothing )

指數平滑法 ( Exponential Smoothing ) 是一種統計方法，用於分析和預測時間序列資料。其基本原理是通過對歷史資料賦予指數遞減的權重，使得較新的資料對預測結果的影響更大。指數平滑法包括單指數平滑 ( Simple Exponential Smoothing )、雙指數平滑 ( Double Exponential Smoothing ) 和三指數平滑 ( Triple Exponential Smoothing )。

**示例：** 假設我們要預測電力需求，我們可以使用指數平滑法來根據歷史需求資料進行預測。指數平滑法能夠捕捉需求的趨勢和季節性變化，從而提高預測的準確性。

指數平滑法的步驟如下：

- 選擇平滑係數 (  $\alpha$  )，並計算加權平均值。
- 根據加權平均值進行預測。
- 更新平滑係數，並重複步驟 2。

指數平滑法的優點在於其簡單易懂，適用於線性和非線性時間序列資料。然而，指數平滑法對於長期預測效果較差，適用於短期預測。

## 八、建立模型

### 1. 資料建模中的線性回歸、評估指標

線性回歸 ( Linear Regression ) 是資料建模中最基本且最常用的統計方法之一。它用來描述兩個或多個變數之間的線性關係，並通過這種關係來預測一個變數的值(決定係數  $R^2$ 、均方誤差 MSE、均方根誤差 RMSE、殘差分析)。線性回歸的應用範圍非常廣泛，從經濟學、社會科學到工程學和醫學，都可以看到它的身影。本文將詳細介紹線性回歸的基本概念、數學原理、應用場景以及如何進行模型評估。

#### 基本概念

線性回歸的目的是找到一條直線，使得這條直線能夠最好地描述自變數 ( Independent Variable ) 和應變數 ( Dependent Variable ) 之間的關係。這條直線的方程式可以表示為：

$$y = \beta_0 + \beta_1 x + \epsilon$$

其中， $y$  是應變數， $x$  是自變數， $\beta_0$  是截距 ( Intercept )， $\beta_1$  是斜率 ( Slope )， $\epsilon$  是誤差項 ( Error Term )。截距  $\beta_0$  表示當自變數  $x$  為 0 時，應變數  $y$  的預測值。斜率  $\beta_1$  表示自變數  $x$  每增加一個單位，應變數  $y$  的變化量。誤差項  $\epsilon$  表示實際值與預測值之間的差異。

#### 數學原理

## 線性回歸的核心是最小二乘法 ( Ordinary Least Squares · OLS )

線性回歸的核心是最小二乘法 ( Ordinary Least Squares, OLS )，它的目的是找到一組參數  $\beta_0$  和  $\beta_1$ ，使得預測值與實際值之間的平方誤差和最小。具體來說，我們需要最小化以下目標函數：

$$\sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2$$

其中， $n$  是樣本數， $y_i$  是第  $i$  個樣本的應變數值， $x_i$  是第  $i$  個樣本的自變數值。

通過求解這個目標函數的偏導數，我們可以得到參數  $\beta_0$  和  $\beta_1$  的最優解：

$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

其中， $\bar{x}$  和  $\bar{y}$  分別是自變數和應變數的平均值。

## 應用場景

線性回歸在各個領域中都有廣泛的應用。以下是一些常見的應用場景：

- 經濟學**：線性回歸可以用來分析經濟變數之間的關係，例如收入與消費之間的關係、利率與投資之間的關係等。
- 社會科學**：線性回歸可以用來研究社會現象，例如教育水平與收入之間的關係、工作滿意度與工作績效之間的關係等。
- 醫學**：線性回歸可以用來分析醫學數據，例如藥物劑量與治療效果之間的關係、體重與血壓之間的關係等。
- 工程學**：線性回歸可以用來預測工程參數，例如溫度與壓力之間的關係、材料強度與應力之間的關係等。

## 模型評估

在建立線性回歸模型後，我們需要對模型進行評估，以確保模型的準確性和可靠性。常見的模型評估指標包括：

- 決定係數 ( R-squared )**：決定係數 ( $R^2$ ) 表示模型解釋變異的比例，取值範圍在 0 到 1 之間。 $(R^2)$  越接近 1，表示模型的解釋能力越強。
- 均方誤差 ( Mean Squared Error, MSE )**：均方誤差 (MSE) 表示預測值與實際值之間的平均平方誤差。 $(MSE)$  越小，表示模型的預測準確性越高。
- 均方根誤差 ( Root Mean Squared Error, RMSE )**：均方根誤差 (RMSE) 是均方誤差的平方根，表示預測值與實際值之間的平均誤差。 $(RMSE)$  越小，表示模型的預測準確性越高。
- 殘差分析**：殘差是指預測值與實際值之間的差異。通過分析殘差的分佈情況，我們可以檢查模型的假設是否成立，例如殘差是否服從正態分佈、殘差是否具有異方差性等。

## 結論

線性回歸是資料建模中最基本且最常用的統計方法之一。通過描述自變數和應變數之間的線性關係，線性回歸可以幫助我們進行預測和解釋。理解線性回歸的基本概念、數學原理、應用場

景以及如何進行模型評估，幫助我們更好地進行資料分析和建模，從而在各個領域中取得更好的成果。

## 2. 留一法交叉驗證(Leave-One-Out CV, LOO-CV) vs Data Leaking

在 LOO-CV 中，每次迭代都將一個樣本作為測試集，其餘樣本作為訓練集。這樣重複  $N$  次 ( $N$  是樣本數量)，每個樣本都會被用作一次測試集。

若根據上述的描述，那第二次迭代輪到作為測試集的那個樣本，不是"曾經"在第一次迭代時的訓練集內嗎？也就是第一次迭代的訓練集，含了第二次迭代的測試集資訊，這不是 Data Leaking 的意思嗎？

LOOCV 的主要用途是模型的評估與比較，而非訓練最終模型本身。LOOCV 目標是幫助我們選出一個泛化能力最強（對未知資料表現最好）的模型或設定。

標準流程說明（以 LOOCV 為例）

步驟 1：準備多種候選模型或參數組合，例如：

模型 A：邏輯迴歸 (Logistic Regression)

模型 B：支持向量機 (SVM)

模型 C：隨機森林 (Random Forest)

步驟 2：對每個模型進行 LOOCV 評估

對每個模型各自進行  $N$  次訓練與測試（每次留 1 筆當測試集，其餘作為訓練集）。記錄每次的誤差、準確率或其他指標。對每個模型算出平均分數。

每個模型各自進行  $N$  次訓練的本身，是否有 Data Leaking 的問題，即第二次迭代輪到作為測試集的那個樣本，曾經在第一次迭代時的訓練集內？

→ 因為 LOO-CV 每次迭代都是重新訓練一個新模型，不是沿用。也就是會產生出  $N$  個獨立的模型。故沒有 Data Leaking 的問題。

→ 這裡所謂的訓練，並不是訓練最終要拿來預測的模型，而是針對候選模型，透過這個訓練與測試的過程，得到這個候選模型的評分，以利後續根據評估指標選出表現最好的候選模型

步驟 3：比較各模型在 LOOCV 下的表現

模型 A：平均準確率 84%

模型 B：平均準確率 89%

模型 C：平均準確率 92%

→ 根據評估指標選出表現最好的模型，例如選模型 C

步驟 4：用「所有資料」重新訓練選出的模型

現在你已經知道模型 C 泛化能力較好。用整個資料集（全部  $N$  筆）訓練模型 C，得到最終模型，準備部署、預測或應用

這時的訓練，因為已經作過 LOOCV，所以可以不用再將資料集( $N$  筆)拆成訓練、驗證、測試集了。因 LOOCV 已充分驗證模型效能。可以直接使用所有資料訓練模型，提高學習量。

若資料數量足夠，可以保留一小部份作為測試集，這組資料不參與任何訓練、驗證或交叉驗證(如 LOOCV)，用來作「模型訓練完成後最後一次盲測」。

延伸觀念：交叉驗證不只 LOOCV

LOOCV 是一種極端的 K-Fold (  $K = N$  )，常見的替代方案：

K-Fold CV ( 例如  $K=5$  )：將資料分成 5 份，每次用 4 份訓練，1 份測試，輪流 5 次

Stratified K-Fold：保留各類別比例

Nested CV：外層做模型選擇，內層做參數調整，防止 overfitting

交叉驗證不只用來選擇最佳的候選模型，如上例的 模型 C，也用於選擇最佳的參數組合，例如最佳的候選模型 C 是一個 SVM 模型，透過交叉驗證可找出最佳的參數組合，e.g. 正則化參數 C (為一個懲罰係數)，及核函數參數  $\gamma$  (gamma) 例如：C=10, gamma = 0.01

使用最佳候選模型 + 最佳參數組合，用所有資料去訓練最終模型。

## 九、資料隱私與安全

在現代數位時代，資料隱私與安全成為了至關重要的議題。隨著資料量的爆炸性增長，如何保護個人資料和敏感資訊免受未經授權的訪問、洩露或濫用，成為了每個組織和個人都必須面對的挑戰。

### 資料隱私 ( Data Privacy )

資料隱私指的是保護個人資料不被未經授權的第三方訪問或使用。這包括確保個人資料在收集、存儲、處理和分享過程中的機密性和完整性。以下是一些關鍵概念：

1. **個人資料 ( Personal Data )**：任何可以識別個人身份的資訊，如姓名、地址、電話號碼、電子郵件地址、身份證號碼等。
2. **敏感資料 ( Sensitive Data )**：涉及個人隱私的資訊，如健康記錄、財務資訊、宗教信仰、種族背景等。
3. **資料保護法規 ( Data Protection Regulations )**：如歐盟的《通用資料保護條例》 ( General Data Protection Regulation, GDPR ) 和美國的《加州消費者隱私法》 ( California Consumer Privacy Act, CCPA )，這些法規規範了資料的收集、使用和分享方式，並賦予個人對其資料的控制權。

### 資料安全 ( Data Security )

資料安全指的是保護資料免受未經授權的訪問、洩露、修改或破壞。這包括技術措施和管理措施。以下是一些常見的資料安全措施：

1. **加密 ( Encryption )**：將資料轉換為只有授權方才能解讀的格式。常見的加密技術包括對稱加密和非對稱加密。
2. **存取控制 ( Access Control )**：限制誰可以訪問資料和系統。這包括身份驗證 ( Authentication ) 和授權 ( Authorization )。
3. **資料備份 ( Data Backup )**：定期備份資料，以防止資料丟失或損壞。
4. **防火牆 ( Firewall )**：監控和控制進出網絡的流量，防止未經授權的訪問。
5. **入侵檢測系統 ( Intrusion Detection System, IDS )**：監控網絡和系統活動，檢測並響應潛在的安全威脅。

### 資料隱私與安全的最佳實踐

1. **最小化資料收集**：僅收集必要的資料，減少潛在的風險。
2. **透明度**：告知資料主體其資料的收集和使用方式，並獲得其同意。
3. **資料匿名化 ( Data Anonymization )**：將個人資料轉換為無法識別個人身份的形式，以保護隱私。
4. **定期安全審計**：定期檢查和評估資料安全措施的有效性，及時發現和修補漏洞。
5. **員工培訓**：提高員工的資料隱私與安全意識，確保其遵守相關政策和程序。

### 資料隱私與安全在 AI 模型中的應用

在 AI 模型的開發和應用中，資料隱私與安全同樣至關重要。AI 模型通常需要大量的資料進行訓練，這些資料可能包含敏感資訊。因此，在 AI 項目中應採取以下措施：

1. **資料去識別化 ( Data De-identification )**：在使用資料前，去除或隱藏可以識別個人身份的資訊。
2. **差分隱私 ( Differential Privacy )**：通過添加噪音來保護個人資料，確保即使在分析結果中也無法識別個人。
3. **安全多方計算 ( Secure Multi-party Computation )**：允許多方在不洩露各自資料的情況下共同計算結果。
4. **聯邦學習 ( Federated Learning )**：在不共享原始資料的情況下，分散式地訓練 AI 模型。

參、機器學習概念

| 內容        | 備註                                    | 評鑑能力                                            |
|-----------|---------------------------------------|-------------------------------------------------|
| 機器學習基本原理  | 機器學習基本原理與目的                           | 評鑑應考者是否理解機器學習的基本原理及其在 AI 中的作用，並熟悉常見的機器學習方法及其應用。 |
| 常見的機器學習模型 | 機器學習模型與評估，如監督式學習、非監督式學習、半監督式學習、強化式學習。 |                                                 |

一、機器學習基本原理及類型

機器學習基本原理：

- 機器學習的特徵：機器學習是通過數據訓練模型，使其能夠進行預測或決策。
- 機器學習的技術優勢：能夠處理大量數據並從中提取有用信息。
- 挑戰與未來方向：數據質量、模型過擬合、計算資源需求等挑戰；未來方向包括更高效的算法、更強大的計算能力等。

機器學習的類型：

1. 監督式學習 ( Supervised Learning )
  - 使用標註數據進行訓練
  - 常見算法：線性回歸 ( Linear Regression )、決策樹 ( Decision Tree )、支持向量機 ( Support Vector Machine, SVM )
  - 評估指標：準確率 ( Accuracy )、精確率 ( Precision )、召回率 ( Recall )
2. 非監督式學習 ( Unsupervised Learning )
  - 使用未標註數據進行訓練
  - 常見算法：K 均值聚類 ( K-means Clustering )、主成分分析 ( Principal Component Analysis, PCA )
  - 評估指標：輪廓係數 ( Silhouette Coefficient )、聚類效果 ( Clustering Performance )
3. 半監督式學習 ( Semi-supervised Learning )
  - 結合標註和未標註數據進行訓練
  - 常見算法：自訓練 ( Self-training )、圖形正則化 ( Graph Regularization )
  - 評估指標：準確率 ( Accuracy )、F1 分數 ( F1 Score )
- 強化學習 ( Reinforcement Learning )
  - 通過獎勵和懲罰進行訓練，核心要素包括狀態、行動、獎勵等；強化學習的流程包括環境交互、策略更新等
  - 常見算法：Q 學習 ( Q-learning )、深度 Q 網絡 ( Deep Q Network, DQN )
  - 評估指標：累積獎勵 ( Cumulative Reward )、學習速率 ( Learning Rate )
  - 應用範例包括遊戲 AI、自動駕駛等

## 二、機器學習的核心過程

### 1. 數據處理：

- 數據清洗：處理缺失值、異常值等。
- 數據標準化：將數據轉換為統一尺度。
- 特徵選擇與降維：特徵工程 ( Feature Engineering ) · 選擇重要特徵，減少數據維度。
  - ✧ 特徵選擇，常見方法包括過濾法 ( Filter Methods ) 如皮爾遜 ( Pearson ) 相關係數 ( 數值型 )、卡方檢定 ( 類別型 )、互資訊 ( Mutual Information, MI ) ( 離散化數值 / 類別型 )；包裝法 ( Wrapper Methods ) 如遞迴特徵消除 ( Recursive Feature Elimination, RFE )；嵌入法 ( Embedded Methods ) 如 LASSO 正則化。
  - ✧ 降維技術，常用方法包括主成分分析 ( PCA )。

### 2. 模型訓練：

- 訓練集、驗證集與測試集的劃分
- 模型的訓練過程與超參數調整
- 損失函數 ( Loss Function )：損失函數是用於評估模型預測結果與真實值之間的差異。常見的損失函數包括均方誤差 ( Mean Squared Error, MSE ) 和交叉熵損失 ( Cross-Entropy Loss )。損失函數的選擇取決於具體的問題和模型。
- 優化演算法 ( Optimization Algorithm )：優化演算法是用於調整模型參數，以最小化損失函數。常見的優化演算法包括批次梯度下降 ( Batch Gradient Descent, BGD )、隨機梯度下降 ( Stochastic Gradient Descent, SGD ) 和 Adam 演算法。這些演算法透過計算損失函數相對參數的偏導數，調整模型參數使損失函數值逐漸減小。
- 過擬合的防範 ( Overfitting Prevention )：過擬合是指模型在訓練數據上表現良好，但在測試數據上表現不佳。過擬合的防範方法包括正則化 ( Regularization )、交叉驗證 ( Cross-Validation ) 和早停 ( Early Stopping )。正則化是指在損失函數中加入懲罰項，以防止模型過度擬合訓練數據。交叉驗證是指將數據分成多個子集，分別用於訓練和測試模型，以評估模型的性能。早停是指在模型訓練過程中監控損失函數，當損失函數不再減小時停止訓練。

### 3. 模型評估與優化：

- 效能評估指標：包括準確率、F1 Score、均方誤差 ( MSE ) 等。
- 交叉驗證：如 K 折交叉驗證 ( K-Fold Cross-Validation )。
- 模型調參：包括網格搜索 ( Grid Search )、隨機搜索 ( Random Search )、貝葉斯優化 ( Bayesian Optimization )。

### 4. 模型部署與監控

---

## 三、機器學習的定義與目的

### 什麼是機器學習 ( Machine Learning, ML )

機器學習 ( Machine Learning, ML ) 是一種人工智慧 ( Artificial Intelligence, AI ) 的技術，通過使用數據和算法來模擬人類學習的過程。簡單來說，機器學習是讓計算機能夠從數據中學習，並在沒有明確編程指令的情況下做出決策或預測。這種技術的核心在於利用數據來訓練模型，使其能夠識別模式並從中得出結論。



## 機器學習的主要目的

機器學習的主要目的是通過自動化數據分析來解決複雜問題，從而提高效率和準確性。具體來說，機器學習的目標包括：

1. **自動化決策**：機器學習可以幫助企業和組織自動化決策過程，例如信用評估、風險管理等。
2. **預測未來趨勢**：通過分析歷史數據，機器學習模型可以預測未來的趨勢和行為，例如銷售預測、股票市場分析等。
3. **模式識別**：機器學習能夠識別數據中的模式，這對於圖像識別、語音識別等應用非常重要。
4. **個性化推薦**：機器學習可以根據用戶的行為和偏好，提供個性化的推薦服務，例如電影推薦、商品推薦等。

## 機器學習與傳統編程的區別

機器學習與傳統編程有著本質的區別。在傳統編程中，開發者需要明確地編寫每一步的指令，告訴計算機如何完成特定的任務。而在機器學習中，開發者不需要編寫具體的指令，而是提供大量的數據和一個學習算法，讓計算機從數據中學習並自行推導出解決方案。

例如，在傳統編程中，如果我們要開發一個垃圾郵件過濾器，我們需要編寫一系列的規則來識別垃圾郵件。而在機器學習中，我們只需要提供大量的標記為垃圾郵件和非垃圾郵件的電子郵件，然後使用機器學習算法來訓練模型，讓模型學會如何區分垃圾郵件和非垃圾郵件。

## 機器學習與人工智慧 ( Artificial Intelligence , AI ) 的關係

機器學習是人工智慧的一個子領域。人工智慧是一個更廣泛的概念，涵蓋了所有讓計算機能夠模擬人類智能的技術和方法。這包括機器學習、深度學習 ( Deep Learning )、自然語言處理 ( Natural Language Processing, NLP ) 等。

機器學習是實現人工智慧的一種方法。通過機器學習，計算機可以從數據中學習並改進其性能，而不需要明確的編程指令。深度學習則是機器學習的一個子領域，使用多層神經網絡來處理和分析數據，特別適用於圖像和語音識別等複雜任務。

**示例：**為了更好地理解機器學習，我們來看一個簡單的示例：房價預測。假設我們有一個數據集，包含了過去幾年中某個城市的房價、房屋面積、房屋位置等信息。我們可以使用這些數據來訓練一個機器學習模型，使其能夠根據房屋的面積和位置來預測未來的房價。

首先，我們需要收集數據，然後對數據進行預處理，例如去除缺失值、標準化數據等。接下來，我們選擇一個合適的機器學習算法，例如線性回歸 ( Linear Regression )，並使用數據來訓練模型。訓練完成後，我們可以使用模型來預測新房屋的價格。

這個過程展示了機器學習的基本原理和應用。通過使用數據和算法，我們可以自動化地解決複雜問題，並提高預測的準確性。

## 四、機器學習的基本流程

### 機器學習的基本流程

機器學習是一個複雜且多步驟的過程，從數據收集到模型部署，每一步都至關重要。以下是機器學



習的基本流程，並以淺顯易懂的方式詳細解釋每個步驟。

### 數據收集與準備

數據是機器學習的基礎。沒有數據，機器學習模型無法學習和預測。數據收集的過程包括從各種來源獲取數據，例如數據庫、網絡爬蟲、API 等。數據收集後，需要對數據進行清洗和預處理，以確保數據的質量和一致性。

例如，假設我們要開發一個房價預測模型，我們需要收集房屋的歷史價格、面積、位置等數據。這些數據可能來自房地產網站、政府數據庫等。收集到數據後，我們需要處理缺失值、去除異常值、標準化數據等。

### 特徵工程 ( Feature Engineering )

特徵工程是將原始數據轉換為適合機器學習模型使用的特徵的過程。這一步驟非常重要，因為特徵的質量直接影響模型的性能。特徵工程包括特徵選擇、特徵提取和特徵轉換等。

※標準化特徵範圍數值：Zero-Score 均值為 0 標準差為 1；正規化 Min-Max 0 ~ 1 or -1 ~ 1。

類別：獨熱編碼 ( One-Hot Encoding )

例如，在房價預測模型中，我們可以將房屋的面積、位置、建造年份等作為特徵。此外，我們還可以創建一些新的特徵，例如每平方公尺的價格、房屋的年齡等。這些特徵可以幫助模型更好地理解數據中的模式。

### 模型選擇與訓練

模型選擇是指選擇適合解決特定問題的機器學習算法。常見的機器學習算法包括線性回歸、決策樹、支持向量機 ( SVM ) 等。選擇合適的算法後，我們需要使用數據來訓練模型，使其能夠學習數據中的模式和規律。

例如，在房價預測模型中，我們可以選擇線性回歸算法，因為房價與房屋面積、位置等特徵之間可能存在線性關係。訓練過程中，我們將數據分為訓練集和測試集，使用訓練集來訓練模型，使用測試集來評估模型的性能。

### 模型評估與調整

模型訓練完成後，我們需要對模型進行評估，以確保其性能達到預期。常見的評估指標包括準確率、精確率、召回率等。根據評估結果，我們可能需要調整模型的參數或選擇不同的算法，以提高模型的性能。

例如，在房價預測模型中，我們可以使用均方誤差 ( Mean Squared Error, MSE ) 來評估模型的預測準確性。如果模型的 MSE 較高，我們可以嘗試調整模型的參數，或者選擇其他算法，如決策樹或支持向量機。

### 模型部署與監控

當模型的性能達到預期後，我們需要將模型部署到生產環境中，以便實際應用。模型部署的過程包括將模型轉換為可執行的代碼，並將其集成到現有的系統中。此外，我們還需要對模型進行監控，以確保其在生產環境中的性能穩定。

例如，在房價預測模型中，我們可以將訓練好的模型部署到房地產網站上，為用戶提供房價預測服

務。部署後，我們需要定期監控模型的性能，並根據需要進行更新和調整。

**示例：**為了更好地理解機器學習的基本流程，我們來看一個具體的示例：開發一個垃圾郵件過濾器。

1. **數據收集與準備：**我們需要收集大量的電子郵件數據，包括標記為垃圾郵件和非垃圾郵件的樣本。這些數據可以來自電子郵件服務提供商或公開數據集。收集到數據後，我們需要對數據進行清洗和預處理，例如去除重複的郵件、處理缺失值等。
2. **特徵工程：**我們需要將電子郵件轉換為適合機器學習模型使用的特徵。例如，我們可以提取電子郵件的詞頻、標題中的關鍵詞、發件人的域名等作為特徵。此外，我們還可以使用自然語言處理技術來提取更多的特徵。
3. **模型選擇與訓練：**我們可以選擇適合垃圾郵件分類的機器學習算法，例如朴素貝葉斯 ( Naive Bayes ) 或支持向量機 ( SVM )。使用訓練集來訓練模型，使其能夠學習垃圾郵件和非垃圾郵件之間的區別。
4. **模型評估與調整：**使用測試集來評估模型的性能，並根據評估結果調整模型的參數或選擇不同的算法。例如，我們可以使用準確率、精確率和召回率來評估模型的分類效果。
5. **模型部署與監控：**將訓練好的模型部署到電子郵件服務中，為用戶提供垃圾郵件過濾服務。部署後，我們需要定期監控模型的性能，並根據需要進行更新和調整。

## 五、數據與特徵工程

在機器學習中，數據與特徵工程是至關重要的步驟。這些步驟確保我們擁有高質量的數據和適當的特徵，從而提高模型的性能。以下是對數據收集與準備、特徵選擇與特徵提取以及數據預處理技術的詳細介紹。

### 數據的收集與準備

數據是機器學習的基礎，沒有數據，模型無法學習和預測。數據收集的過程包括從各種來源獲取數據，例如數據庫、網絡爬蟲、API 等。數據收集後，需要對數據進行清洗和預處理，以確保數據的質量和一致性。

例如，假設我們要開發一個房價預測模型，我們需要收集房屋的歷史價格、面積、位置等數據。這些數據可能來自房地產網站、政府數據庫等。收集到數據後，我們需要處理缺失值、去除異常值、標準化數據等。

數據準備的過程包括以下幾個步驟：

1. **數據清洗 ( Data Cleaning )：**數據清洗是指去除數據中的錯誤、缺失值和異常值。這些問題可能會影響模型的準確性，因此需要在訓練模型之前進行處理。常見的數據清洗方法包括填補缺失值、去除異常值和糾正錯誤數據。
2. **數據標準化 ( Data Standardization )：**數據標準化是指將數據轉換為統一的尺度，以便模型能夠更好地學習數據中的模式。常見的數據標準化方法包括最小-最大標準化 ( Min-Max Normalization ) 和 Z-score 標準化。
3. **特徵選擇與降維 ( Feature Selection and Dimensionality Reduction )：**特徵選擇是指選擇對模型訓練最有用的特徵，以減少模型的計算複雜度並提高模型的性能。降維是指將高維數據轉換為低維數據，以便模型能夠更好地學習數據中的模式。常見的降維方法包括主成分分析 ( Principal Component Analysis · PCA ) 和線性判別分析 ( Linear Discriminant Analysis · LDA )。

## 特徵選擇與特徵提取

特徵工程是將原始數據轉換為適合機器學習模型使用的特徵的過程。這一步驟非常重要，因為特徵的質量直接影響模型的性能。特徵工程包括特徵選擇、特徵提取和特徵轉換等。

**特徵選擇**是指從原始數據中選擇對模型有用的特徵。這可以通過統計方法、相關性分析等技術來實現。例如，在房價預測模型中，我們可以選擇房屋的面積、位置、建造年份等作為特徵。

**特徵提取**是指從原始數據中創建新的特徵，以提高模型的性能。例如，我們可以將房屋的面積和位置結合起來，創建一個新的特徵，表示每平方公尺的價格。此外，我們還可以使用自然語言處理技術來提取文本數據中的特徵。

## 數據預處理技術

數據預處理是指在訓練模型之前對數據進行處理，以提高模型的性能和穩定性。常見的數據預處理技術包括標準化、正規化、缺失值處理等。

**標準化**是指將數據縮放到相同的範圍內，通常是將數據轉換為均值为 0，標準差為 1 的分佈。這可以消除不同特徵之間的量級差異，從而提高模型的性能。

**正規化**是指將數據縮放到固定的範圍內，例如 0 到 1 之間。這可以防止某些特徵對模型的影響過大，從而提高模型的穩定性。

**缺失值處理**是指處理數據中的缺失值，通常有兩種方法：刪除包含缺失值的樣本，或者用其他值（例如均值、中位數）填補缺失值。

**示例：**為了更好地理解數據與特徵工程，我們來看一個具體的示例：開發一個垃圾郵件過濾器。

1. **數據收集與準備：**我們需要收集大量的電子郵件數據，包括標記為垃圾郵件和非垃圾郵件的樣本。這些數據可以來自電子郵件服務提供商或公開數據集。收集到數據後，我們需要對數據進行清洗和預處理，例如去除重複的郵件、處理缺失值等。
2. **特徵選擇與特徵提取：**我們需要將電子郵件轉換為適合機器學習模型使用的特徵。例如，我們可以提取電子郵件的詞頻、標題中的關鍵詞、發件人的域名等作為特徵。此外，我們還可以使用自然語言處理技術來提取更多的特徵。
3. **數據預處理：**我們需要對數據進行標準化和正規化，以消除不同特徵之間的量級差異，並提高模型的性能和穩定性。例如，我們可以將詞頻轉換為均值为 0，標準差為 1 的分佈，或者將其縮放到 0 到 1 之間。

## 特徵選擇方法概述

特徵選擇是指在機器學習中選擇對模型訓練有用的特徵，去除那些無關或冗餘的特徵。這樣可以提高模型的性能，減少計算成本，並且使模型更易於解釋。特徵選擇方法主要包括過濾法、包裝法和嵌入法。

### 1. 過濾法

過濾法是使用相關性或統計量篩選特徵，不依賴於任何機器學習模型。常見的過濾法包括卡方檢驗 ( Chi-Square Test )、皮爾遜相關係數 ( Pearson Correlation Coefficient ) 和互信息 ( Mutual Information, MI )。

### 2. 包裝法

透過模型效能指標評估特徵組合的效果。常見的包裝法包括遞歸特徵消除 ( Recursive

Feature Elimination, RFE) 和前向選擇 ( Forward Selection )、遺傳演算法。

#### 示例：遞歸特徵消除 ( RFE )

遞歸特徵消除是一種常見的包裝法，用於逐步消除那些對模型性能影響較小的特徵。以下是 RFE 的實施步驟：

- (1) **訓練模型**：使用所有特徵訓練機器學習模型。
- (2) **消除特徵**：根據模型的特徵重要性，逐步消除那些對模型性能影響較小的特徵。
- (3) **重複步驟**：重複上述步驟，直到選擇出最佳特徵集。

### 3. 嵌入法

嵌入法是通過機器學習模型內部的特徵重要性進行選擇。常見的嵌入法包括 L1 正則化 ( L1 Regularization ) 和決策樹 ( Decision Tree )。

示例：L1 正則化：L1 正則化是一種常見的嵌入法，用於選擇那些對模型性能影響較大的特徵。以下是 L1 正則化的實施步驟：

- (1) **訓練模型**：使用所有特徵訓練機器學習模型。
- (2) **選擇特徵**：根據模型的 L1 正則化係數，選擇那些對模型性能影響較大的特徵。

## 六、模型訓練與評估

在機器學習中，模型訓練與評估是至關重要的步驟。這些步驟確保我們能夠構建出高效且準確的模型，從而解決實際問題。以下是對訓練集、驗證集與測試集的劃分、模型的訓練過程與超參數調整以及模型評估指標的詳細介紹。

### 訓練集、驗證集與測試集的劃分

在開始模型訓練之前，我們需要將數據集劃分為三個部分：訓練集、驗證集和測試集。這樣做的目的是為了確保模型能夠在不同的數據上進行學習和評估，從而提高模型的泛化能力。

1. **訓練集**：用於訓練模型的數據集。模型通過學習訓練集中的數據來調整其參數，以便能夠識別數據中的模式和規律。
2. **驗證集**：用於調整模型超參數的數據集。超參數是指在訓練過程中需要手動設置的參數，例如學習率、正則化參數等。通過在驗證集上評估模型的性能，我們可以選擇最佳的超參數組合。
3. **測試集**：用於最終評估模型性能的數據集。測試集中的數據在訓練過程中從未被模型見過，因此可以用來評估模型的泛化能力，即模型在新數據上的表現。

例如，假設我們有一個包含 1000 個樣本的數據集，我們可以將其劃分為訓練集 ( 70% )、驗證集 ( 15% ) 和測試集 ( 15% )。這樣，我們可以使用 700 個樣本來訓練模型，150 個樣本來調整超參數，150 個樣本來評估模型的最終性能。

### 模型的訓練過程與超參數調整

模型訓練是指通過數據來調整模型參數的過程，使其能夠識別數據中的模式和規律。這個過程通常包括以下幾個步驟：

1. **初始化模型參數**：在訓練開始之前，我們需要初始化模型的參數。這些參數可以是隨機的，也可以是根據某些規則設置的。
2. **前向傳播**：將訓練集中的數據輸入模型，通過模型的計算過程得到預測結果。

3. **計算損失**：根據預測結果和真實標籤之間的差異，計算損失函數的值。損失函數是用來衡量模型預測結果與真實值之間差異的指標。
4. **反向傳播**：根據損失函數的值，計算模型參數的梯度，並通過梯度下降算法來更新模型參數。
5. **重複步驟 2-4**：不斷重複前向傳播、計算損失和反向傳播的過程，直到損失函數的值收斂到一個較小的範圍內。

超參數調整是指在訓練過程中調整模型的超參數，以提高模型的性能。常見的超參數包括學習率、正則化參數、批量大小等。超參數調整通常通過在驗證集上評估模型的性能來進行。我們可以使用網格搜索 ( Grid Search ) 或隨機搜索 ( Random Search ) 等方法來選擇最佳的超參數組合。

### 模型評估指標

在模型訓練完成後，我們需要對模型進行評估，以確保其性能達到預期。常見的模型評估指標包括準確率、精確率、召回率和 F1-score 等。

1. **準確率 ( Accuracy )**：指模型預測正確的樣本數量佔總樣本數量的比例。準確率適用於樣本數量平衡的情況，但在樣本數量不平衡的情況下，準確率可能會導致誤導性的結果。
2. **精確率 ( Precision )**：指模型預測為正類的樣本中，實際為正類的比例。精確率適用於關注預測結果為正類的準確性的情況。  
※著重在預測為正的品質，常用在垃圾郵件預測系統的評估，因為不想將重要郵件錯歸成垃圾郵件。
3. **召回率 ( Recall )**：指實際為正類的樣本中，被模型正確預測為正類的比例。召回率適用於關注實際正類樣本被正確預測的情況。  
※著重在有抓到所有的正類，常用在維修預測系統的評估，因為不想漏抓了該維修的設備。
4. **F1-score**：精確率和召回率的調和平均數，用於綜合評估模型的性能。F1-score 適用於樣本數量不平衡的情況。  
$$\text{F1-score} = 2 * (\text{精} * \text{召}) / (\text{精} + \text{召})$$

例如，假設我們開發了一個垃圾郵件過濾器，我們可以使用準確率、精確率、召回率和 F1-score 來評估模型的性能。如果模型的準確率高，但精確率和召回率低，說明模型在預測垃圾郵件時存在問題。我們可以通過調整模型的超參數或選擇不同的算法來提高模型的性能。

**示例**：為了更好地理解模型訓練與評估，我們來看一個具體的示例：開發一個垃圾郵件過濾器。

1. **訓練集、驗證集與測試集的劃分**：我們需要收集大量的電子郵件數據，包括標記為垃圾郵件和非垃圾郵件的樣本。將數據集劃分為訓練集 ( 70% )、驗證集 ( 15% ) 和測試集 ( 15% )。
2. **模型的訓練過程**：選擇適合垃圾郵件分類的機器學習算法，例如朴素貝葉斯 ( Naive Bayes ) 或支持向量機 ( SVM )。使用訓練集來訓練模型，使其能夠學習垃圾郵件和非垃圾郵件之間的區別。
3. **超參數調整**：使用驗證集來調整模型的超參數，例如學習率、正則化參數等。通過網格搜索或隨機搜索來選擇最佳的超參數組合。
4. **模型評估**：使用測試集來評估模型的性能，並根據評估結果調整模型的參數或選擇不同的算法。例如，我們可以使用準確率、精確率、召回率和 F1-score 來評估模型的分類效果。

### 模型評估與優化

模型評估與優化是機器學習的最後一步，旨在評估模型的性能並進行優化。模型評估與優化包括以下幾個步驟：

1. **效能評估指標 ( Performance Evaluation Metrics )**：效能評估指標是用於評估模型性能的標準。常見的效能評估指標包括準確率 ( Accuracy )、F1 Score 和均方誤差 ( Mean Squared Error, MSE )。準確率是指模型預測正確的比例，F1 Score 是指模型的精確率和召回率的調和平均數，均方誤差是指模型預測結果與真實值之間的平均平方差。
2. **交叉驗證 ( Cross-Validation )**：交叉驗證是指將數據分成多個子集，分別用於訓練和測試模型，以評估模型的性能。常見的交叉驗證方法包括 K 折交叉驗證 ( K-Fold Cross-Validation ) 和留一交叉驗證 ( Leave-One-Out Cross-Validation )。交叉驗證能夠有效地評估模型的性能，並防止過擬合。
3. **模型調參 ( Hyperparameter Tuning )**：模型調參是指調整模型的超參數，以提高模型的性能。常見的模型調參方法包括網格搜索 ( Grid Search )、隨機搜索 ( Random Search ) 和貝葉斯優化 ( Bayesian Optimization )。網格搜索是指在超參數空間中進行遍歷搜索，以找到最佳的超參數組合。隨機搜索是指在超參數空間中進行隨機搜索，以找到最佳的超參數組合。貝葉斯優化是指利用貝葉斯定理進行超參數搜索，以找到最佳的超參數組合。

## 七、機器學習的應用領域

機器學習 ( Machine Learning, ML ) 是一種強大的技術，已經在許多領域中得到了廣泛應用。以下是一些主要的應用領域，包括自然語言處理 ( Natural Language Processing, NLP )、圖像識別 ( Image Recognition )、語音識別 ( Speech Recognition ) 和推薦系統 ( Recommendation Systems )。這些應用不僅展示了機器學習的潛力，還為我們的日常生活帶來了許多便利。

### 1. 自然語言處理 ( Natural Language Processing, NLP )

自然語言處理 ( NLP ) 是機器學習的一個重要應用領域，旨在使計算機能夠理解、解釋和生成人類語言。NLP 技術被廣泛應用於語音助手、聊天機器人、翻譯系統等。

例如，語音助手如 Apple 的 Siri 和 Google Assistant 使用 NLP 技術來理解用戶的語音指令，並提供相應的回應。這些系統首先將語音轉換為文本，然後使用 NLP 技術來分析文本的語義，最後生成適當的回應。

另一個例子是自動翻譯系統，如 Google 翻譯。這些系統使用 NLP 技術來分析源語言的句子結構和語義，然後生成目標語言的翻譯文本。這些技術使得跨語言交流變得更加便捷。

### 2. 圖像識別 ( Image Recognition )

圖像識別是機器學習的另一個重要應用領域，旨在使計算機能夠識別和分類圖像中的物體。這項技術被廣泛應用於人臉識別、安全監控、自動駕駛等領域。

例如，人臉識別技術被廣泛應用於手機解鎖和身份驗證。這些系統使用機器學習算法來分析人臉的特徵點，並將其與存儲在數據庫中的人臉圖像進行比對，以確定用戶的身份。

在自動駕駛領域，圖像識別技術被用來識別道路上的行人、車輛和交通標誌。這些系統使用攝像頭捕捉道路圖像，然後使用機器學習算法來分析圖像中的物體，從而幫助自動駕駛汽車做出正確的駕駛決策。

3.語音識別 ( Speech Recognition )

語音識別是機器學習的一個重要應用領域，旨在使計算機能夠將語音轉換為文本。這項技術被廣泛應用於語音助手、語音輸入、語音轉文字等。

例如，語音助手如 Amazon 的 Alexa 和 Microsoft 的 Cortana 使用語音識別技術來理解用戶的語音指令，並提供相應的回應。這些系統首先將語音信號轉換為文本，然後使用 NLP 技術來分析文本的語義，最後生成適當的回應。

語音輸入技術被廣泛應用於手機和電腦上，使用戶可以通過語音輸入文本，而不需要手動打字。這些系統使用機器學習算法來分析語音信號，並將其轉換為對應的文本。

4.推薦系統 ( Recommendation Systems )

推薦系統是機器學習的一個重要應用領域，旨在根據用戶的行為和偏好，提供個性化的推薦服務。這項技術被廣泛應用於電子商務、影音平台、社交媒體等。

例如，電子商務平台如 Amazon 使用推薦系統來向用戶推薦商品。這些系統分析用戶的購買歷史、瀏覽記錄等數據，並使用機器學習算法來預測用戶可能感興趣的商品，從而提高銷售量。影音平台如 Netflix 和 YouTube 使用推薦系統來向用戶推薦影片和音樂。這些系統分析用戶的觀看歷史、評分等數據，並使用機器學習算法來預測用戶可能感興趣的內容，從而提高用戶的滿意度。

八、常見的機器學習模型及其常見算法和評估指標

| 類 型         | 常見算法                                                                                                                                                                                                                                                                                                                                                | 評估指標                                                                                                                                                                                                                                                                                                                 | 評估方法                                                                                                                                               |
|-------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------|
| 監 督 式 學 習   | <ul style="list-style-type: none"><li>- 線性回歸 ( Linear Regression )</li><li>- 支持向量機 ( Support Vector Machine, SVM )</li><li>- 決策樹 ( Decision Tree )</li><li>- 隨機森林 ( Random Forest )</li><li>- 神經網絡 ( Neural Network )</li></ul>                                                                                                                     | <p>分類：</p> <ul style="list-style-type: none"><li>- 準確率 ( Accuracy )</li><li>- 精確率 ( Precision )</li><li>- 召回率 ( Recall )</li><li>- F1 分數 ( F1 Score )</li></ul> <p>回歸：</p> <ul style="list-style-type: none"><li>- 均方誤差 ( Mean Squared Error, MSE )</li></ul>                                                        | <ul style="list-style-type: none"><li>-交叉驗證 ( Cross-Validation )</li><li>-混淆矩陣 ( Confusion Matrix )</li><li>- ROC 曲線 ( ROC Curve )</li></ul>       |
| 非 監 督 式 學 習 | <p>聚類：</p> <ul style="list-style-type: none"><li>- K 均值聚類 ( K-Means Clustering )</li><li>-層次聚類 ( Hierarchical Clustering )</li></ul> <p>降維：</p> <ul style="list-style-type: none"><li>-主成分分析 ( Principal Component Analysis, PCA )</li></ul> <p>聚類 &amp;降維：</p> <ul style="list-style-type: none"><li>-自組織映射 ( Self-Organizing Map, SOM )</li></ul> | <p>-內部指標：</p> <ul style="list-style-type: none"><li>.輪廓係數 ( Silhouette Coefficient )</li><li>.聚類內部距離 ( Within-Cluster Sum of Squares, WCSS )</li><li>.戴維斯-鮑丁指數 ( Davies-Bouldin Index )</li><li>.同質性 ( Homogeneity )</li></ul> <p>-外部指標：</p> <ul style="list-style-type: none"><li>.Rand 指數 ( Rand Index )</li></ul> | <ul style="list-style-type: none"><li>-聚類有效性指標 ( Clustering Validity Indices )</li><li>-降維可視化 ( Dimensionality Reduction Visualization )</li></ul> |



| 類型     | 常見算法                                                                                                                                                                                                                 | 評估指標                                                                                                                   | 評估方法                                                                      |
|--------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------|
|        |                                                                                                                                                                                                                      | .調整後 Rand 指數 ( Adjusted Rand Index, ARI )<br>.互信息 ( Mutual Information, MI )<br>.標籤分配準確率 ( Label Assignment Accuracy ) |                                                                           |
| 半監督式學習 | -自訓練 ( Self-training )<br>-圖形正則化 ( Graph Regularization )<br>-生成對抗網絡 ( Generative Adversarial Networks, GANs )<br>-半監督支持向量機 ( Semi-Supervised SVM )<br>-半監督 K 均值 ( Semi-Supervised K-means )<br>-共訓練 ( Co-Training ) | - 準確率 ( Accuracy )<br>- 精確率 ( Precision )<br>- 召回率 ( Recall )<br>- F1 分數 ( F1 Score )                                  | -交叉驗證 ( Cross-Validation )<br>-混淆矩陣 ( Confusion Matrix )                  |
| 強化學習   | -Q 學習 ( Q-Learning )<br>-深度 Q 網絡 ( Deep Q-Network, DQN )<br>-策略梯度 ( Policy Gradient )<br>-近端策略優化 ( Proximal Policy Optimization, PPO )<br>-Actor-Critic 方法                                                           | -累積獎勵(Cumulative Reward)<br>-平均獎勵(Average Reward)<br>-學習速率(Learning Rate)<br>-收斂速度(Convergence Rate)                   | -模擬環境測試 ( Simulation Environment Testing )<br>-策略評估 ( Policy Evaluation ) |

## 1. 常見的機器學習模型-監督式學習 ( Supervised Learning )

### 定義與應用場景

監督式學習的核心思想是使用已標記的數據來訓練模型。這些數據包含輸入特徵和對應的標籤，模型通過學習這些數據中的模式來預測新的數據。監督式學習的應用場景包括分類問題和回歸問題。

**分類問題**是指將數據分為不同的類別，例如垃圾郵件分類、圖像識別等。模型通過學習已標記的數據來預測新數據的類別。

**回歸問題**是指預測連續數值，例如房價預測、股票價格預測等。模型通過學習已標記的數據來預測新數據的數值。

**常見算法**(線性回歸、決策樹、支持向量機 SVM、隨機森林、神經網絡)

**評估指標**(準確率、精確率、召回率、F1 分數、均方誤差 MSE)

- **準確率 ( Accuracy )** ※ 0 ~ 1 越大越好

準確率是指模型正確預測的樣本數量佔總樣本數量的比例。它是最簡單且最常用的評估指標之一，適用於類別分佈均衡的情況。

公式：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

其中，TP ( True Positive ) 是真陽性，TN ( True Negative ) 是真陰性，FP ( False Positive ) 是假陽性，FN ( False Negative ) 是假陰性。

**示例：** 假設我們有一個二元分類模型，用於預測郵件是否為垃圾郵件。在 100 封郵件中，模型正確預測了 90 封 ( 包括 80 封正常郵件和 10 封垃圾郵件 )，錯誤預測了 10 封 ( 包括 5 封正常郵件被誤判為垃圾郵件，5 封垃圾郵件被誤判為正常郵件 )。則準確率為：

$$Accuracy = \frac{80 + 10}{100} = 0.9$$

● **精確率 ( Precision )** ※預測為正且實際為正(TP) / 所有預測為正(TP + FP)

精確率是指模型正確預測的正類樣本數量佔所有預測為正類樣本數量的比例。它適用於關注假陽性 ( False Positive ) 的情況。

公式：

$$Precision = \frac{TP}{TP + FP}$$

**示例：** 在上述郵件分類示例中，假設模型預測了15封郵件為垃圾郵件，其中10封是正確的 ( TP )，5封是錯誤的 ( FP )。則精確率為：

$$Precision = \frac{10}{10 + 5} = 0.67$$

● **召回率 ( Recall )** ※預測為正且實際為正(TP) / 所有實際為正(TP + FN)

召回率是指模型正確預測的正類樣本數量佔所有實際為正類樣本數量的比例。它適用於關注假陰性 ( False Negative ) 的情況。

公式：

$$Recall = \frac{TP}{TP + FN}$$

**示例：** 在上述郵件分類示例中，假設實際有20封垃圾郵件，其中10封被正確預測 ( TP )，10封被錯誤預測為正常郵件 ( FN )。則召回率為：

$$Recall = \frac{10}{10 + 10} = 0.5$$

● **F1 分數 ( F1 Score )**

F1 分數是精確率和召回率的調和平均數，適用於類別分佈不平衡的情況。它綜合考慮了精確率和召回率，提供了一個平衡的評估指標。

公式：

$$F1Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

示例：在上述郵件分類示例中，精確率為0.67，召回率為0.5。則F1分數為：

$$F1Score = 2 \times \frac{0.67 \times 0.5}{0.67 + 0.5} = 0.57$$

### ● 均方誤差 ( Mean Squared Error, MSE )

均方誤差是指預測值與實際值之間誤差的平方和的平均值。它適用於回歸問題，衡量模型預測的準確性。

公式：

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

其中， $y_i$  是實際值， $\hat{y}_i$  是預測值， $n$  是樣本數量。

示例：假設我們有一個房價預測模型，實際房價為[200, 250, 300]，預測房價為[210, 240, 310]。則均方誤差為：

$$MSE = \frac{1}{3} [(200 - 210)^2 + (250 - 240)^2 + (300 - 310)^2] = \frac{1}{3} [100 + 100 + 100] = 100$$

### 評估方法(交叉驗證 CV、混淆矩陣、ROC 曲線)

#### ● 交叉驗證 ( Cross-Validation )

交叉驗證是一種評估模型性能的方法，通過將數據集分成多個子集，輪流使用其中一個子集作為驗證集，其餘子集作為訓練集，來獲得模型的穩定性和泛化能力。最常見的交叉驗證方法是 K 折交叉驗證 ( K-Fold Cross-Validation )，其中數據集被分成 K 個子集，模型被訓練 K 次，每次使用不同的子集作為驗證集，其餘子集作為訓練集。

示例：假設我們有一個包含 100 個樣本的數據集，我們可以使用 5 折交叉驗證將數據集分成 5 個子集，每個子集包含 20 個樣本。模型將被訓練 5 次，每次使用不同的子集作為驗證集，其餘子集作為訓練集。這樣可以確保模型在不同數據集上的性能穩定，並減少過擬合的風險。

#### ● 混淆矩陣 ( Confusion Matrix )

混淆矩陣是一種可視化工具，用於評估分類模型的性能。它展示了真實標籤與預測標籤的對比情況，包括真陽性 ( True Positive, TP )、假陽性 ( False Positive, FP )、真陰性 ( True Negative, TN ) 和假陰性 ( False Negative, FN )。通過分析混淆矩陣，我們可以計算出多種評估指標，如準確率 ( Accuracy )、精確率 ( Precision )、召回率 ( Recall ) 和 F1 分數 ( F1 Score )。

示例：假設我們有一個二元分類模型，用於預測郵件是否為垃圾郵件。在 100 封郵件中，模型的預測結果如下：

|         | 實際為垃圾郵件 | 實際為正常郵件 |
|---------|---------|---------|
| 預測為垃圾郵件 | 40 (TP) | 10 (FP) |

|         | 實際為垃圾郵件 | 實際為正常郵件 |
|---------|---------|---------|
| 預測為正常郵件 | 5 (FN)  | 45 (TN) |

在這個混淆矩陣中，TP=40，FP=10，TN=45，FN=5。我們可以計算出準確率、精確率、召回率和F1分數：

- 準確率： $Accuracy = \frac{TP+TN}{TP+TN+FP+FN} = \frac{40+45}{40+45+10+5} = 0.85$
- 精確率： $Precision = \frac{TP}{TP+FP} = \frac{40}{40+10} = 0.8$
- 召回率： $Recall = \frac{TP}{TP+FN} = \frac{40}{40+5} = 0.89$
- F1分數： $F1Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} = 2 \times \frac{0.8 \times 0.89}{0.8 + 0.89} = 0.84$

## ● ROC 曲線 ( ROC Curve )

ROC 曲線 ( Receiver Operating Characteristic Curve ) 是一種評估二元分類模型性能的工具，通過繪製真陽性率 ( True Positive Rate, TPR ) 與假陽性率 ( False Positive Rate, FPR ) 之間的關係來展示模型的區分能力。曲線下面積 ( AUC, Area Under Curve ) 越大，模型性能越好。

示例：假設我們有一個二元分類模型，用於預測某種疾病的發生。模型的預測結果如下：

|       | 實際為陽性   | 實際為陰性   |
|-------|---------|---------|
| 預測為陽性 | 50 (TP) | 10 (FP) |
| 預測為陰性 | 5 (FN)  | 35 (TN) |

在這個例子中，我們可以計算出不同閾值下的 TPR 和 FPR，並繪製 ROC 曲線。假設我們選擇的閾值為 0.5，則 TPR 和 FPR 分別為：

- TPR： $TPR = \frac{TP}{TP+FN} = \frac{50}{50+5} = 0.91$
- FPR： $FPR = \frac{FP}{FP+TN} = \frac{10}{10+35} = 0.22$

※真陽性率 ( TPR ) = 判為陽且實為陽 / 實為陽 = TP / (TP + FN)

※假陽性率 ( FPR ) = 判為陽且實為陰 / 實為陰 = FP / (FP + TN)

通過繪製不同閾值下的 TPR 和 FPR，我們可以得到 ROC 曲線，並計算曲線下面積 ( AUC )。AUC 越大，模型的區分能力越強。

## 2. 常見的機器學習模型-非監督式學習 ( Unsupervised Learning )

### 定義與應用場景

非監督式學習的核心思想是使用未標記的數據來訓練模型，從而發現數據中的模式和結構。這種方法不需要事先知道數據的標籤，因此在處理大量未標記數據時非常有用。非監督式學習的應用場景包括聚類分析和降維。

**聚類分析**是指將數據分為不同的組，這些組中的數據具有相似的特徵。例如，客戶細分、圖像分割等。模型通過學習數據中的模式來將數據分為不同的組。

**降維**是指將高維數據轉換為低維數據，同時保留數據中的重要信息。例如，數據可視化、特徵選擇等。模型通過學習數據中的結構來將高維數據轉換為低維數據。

常見算法(K 均值聚類、層次聚類、主成分分析 PCA、自組織映射 SOM)

### ● K 均值聚類 ( K-Means Clustering )

K 均值聚類是一種常見的聚類算法，用於將數據點分成 K 個互不重疊的群集。算法通過迭代地更新群集中心 ( centroids ) 來最小化群集內的平方誤差和 ( sum of squared errors, SSE )。

**應用場景：**客戶分群。根據客戶的購買行為和特徵，將客戶分成不同的群體，以便進行針對性的營銷策略。

**示例：** 假設我們有一組客戶數據，其中包含年齡和年收入。我們可以使用 K 均值聚類將客戶分成三個群集。首先，隨機選擇三個初始群集中心，然後將每個數據點分配到最近的群集中心。接著，更新群集中心為群集中所有數據點的平均值。重複這個過程，直到群集中心不再變化。

### ● 層次聚類 ( Hierarchical Clustering )

層次聚類是一種基於樹狀結構的聚類算法，它通過逐步合併或分割數據點來形成層次結構。層次聚類分為凝聚層次聚類 ( Agglomerative Hierarchical Clustering ) 和分裂層次聚類 ( Divisive Hierarchical Clustering )。

**應用場景：**基因表達數據分析。根據基因表達數據，將基因分成不同的群集，以便研究基因之間的關聯性。

**示例：** 假設我們有一組基因表達數據，我們可以使用凝聚層次聚類將基因分成不同的群集。首先，將每個基因作為一個單獨的群集，然後逐步合併最近的群集，直到所有基因都被合併到一個群集中。這個過程可以用樹狀圖 ( dendrogram ) 來表示，樹狀圖的高度表示合併的距離。

### ● 主成分分析 ( Principal Component Analysis, PCA )

主成分分析是一種數據降維技術，用於將高維數據投影到低維空間，同時保留數據的主要變異信息。PCA 通過計算數據的協方差矩陣，找到數據的主成分 ( principal components )，這些主成分是數據變異最大的方向。

**應用場景：**圖像壓縮。將高維的圖像數據降維到低維空間，以減少存儲空間和計算成本。

**示例：** 假設我們有一組圖像數據，每張圖像由 1000 個像素組成。我們可以使用 PCA 將圖像數據降維到 50 個主成分。首先，計算圖像數據的協方差矩陣，然後找到協方差矩陣的特徵值和特徵向量。選擇前 50 個特徵向量作為主成分，將圖像數據投影到這些主成分上，得到降維後的數據。

### ● 自組織映射 ( Self-Organizing Map, SOM )

自組織映射是一種基於神經網絡的聚類算法，用於將高維數據映射到低維空間 ( 通常是二維 )，同時保留數據的拓撲結構。SOM 通過競爭學習 ( competitive learning ) 來更新神經元的權重，使得相似的數據點在映射後的空間中相鄰。

**應用場景：**文本分類。將高維的文本數據映射到二維空間，以便進行可視化和分類。

**示例：** 假設我們有一組文本數據，每個文本由詞頻向量表示。我們可以使用 SOM 將文本數據映射到二維空間。首先，初始化神經網絡的權重，然後對每個文本數據點，找到與其最接近的神經元，並更新該神經元及其鄰近神經元的權重，使其更接近該數據點。重複這個過程，直到權重不再顯著變化。

### 內部評估指標(輪廓係數、聚類內部距離、戴維斯-鮑丁指數、同質性)

非監督式學習 ( Unsupervised Learning ) 是一種機器學習方法，主要用於從未標記的數據中發現隱含的模式和結構。與監督式學習不同，非監督式學習不依賴於預先標記的數據，而是通過算法自

動識別數據中的模式。這種方法在數據探索、降維、聚類等方面有廣泛應用。本文將介紹幾種常見的非監督式學習內部評估指標，包括輪廓係數 ( Silhouette Coefficient )、聚類內部距離 ( Within-Cluster Sum of Squares, WCSS )、戴維斯-鮑丁指數 ( Davies-Bouldin Index ) 和同質性 ( Homogeneity )。

● **輪廓係數 ( Silhouette Coefficient )**      ※ -1 ~ 1 越大越好

輪廓係數是一種用於評估聚類質量的指標。它通過計算每個數據點與其所屬聚類內其他數據點的平均距離 ( 稱為  $a$  )，以及該數據點與最近的其他聚類的平均距離 ( 稱為  $b$  )，來衡量聚類的緊密性和分離性。輪廓係數的計算公式如下：

$$S = \frac{b - a}{\max(a, b)}$$

其中， $S$ 的取值範圍在-1到1之間。當 $S$ 接近1時，表示該數據點被正確地聚類；當 $S$ 接近-1時，表示該數據點可能被錯誤地聚類；當 $S$ 接近0時，表示該數據點位於兩個聚類的邊界上。

**示例：**假設我們有一組數據點，經過 K-means 聚類後，我們可以計算每個數據點的輪廓係數，並取其平均值作為整體聚類質量的評估指標。如果平均輪廓係數較高，則表示聚類效果較好。

● **聚類內部距離 ( Within-Cluster Sum of Squares, WCSS )**      ※ 越小越好

聚類內部距離 ( WCSS ) 是另一種評估聚類質量的指標。它通過計算每個數據點與其所屬聚類中心的距離平方和，來衡量聚類的緊密性。WCSS 的計算公式如下：

$$WCSS = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

其中， $k$ 是聚類的數量， $C_i$ 是第 $i$ 個聚類， $x$ 是聚類中的數據點， $\mu_i$ 是第 $i$ 個聚類的中心。WCSS越小，表示聚類內部的數據點越接近其中心，聚類效果越好。

**示例：**在 K-means 聚類中，我們可以通過計算不同  $k$  值下的 WCSS，來選擇最佳的聚類數量。通常，WCSS 會隨著  $k$  值的增加而減少，但當  $k$  值達到某個臨界點後，WCSS 的減少幅度會顯著減小，這個臨界點即為最佳聚類數量。

● **戴維斯-鮑丁指數 ( Davies-Bouldin Index )**      ※ 越小越好

戴維斯-鮑丁指數是一種用於評估聚類質量的指標。它通過計算每個聚類的緊密性和聚類間的分離性，來衡量聚類的效果。戴維斯-鮑丁指數的計算公式如下：

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left( \frac{\sigma_i + \sigma_j}{d_{ij}} \right)$$

其中， $k$ 是聚類的數量， $\sigma_i$ 和 $\sigma_j$ 分別是第 $i$ 和第 $j$ 個聚類的緊密性， $d_{ij}$ 是第 $i$ 和第 $j$ 個聚類之間的距離。DB值越小，表示聚類效果越好。

**示例：**在 K-means 聚類中，我們可以計算不同 k 值下的 DB 指數，來選擇最佳的聚類數量。通常，DB 指數較小的 k 值表示聚類效果較好。

### ● 同質性 ( Homogeneity ) ※越大越好

同質性是一種用於評估聚類質量的指標。它衡量的是每個聚類中的數據點是否屬於同一類別。具體來說，如果每個聚類中的數據點都屬於同一類別，則該聚類具有完全的同質性。同質性的計算公式如下：

$$H = 1 - \frac{H(C|K)}{H(C)}$$

其中， $H(C|K)$ 是給定聚類結果K的條件下，類別C的熵， $H(C)$ 是類別C的熵。同質性值範圍在0到1之間，值越大表示聚類效果越好。

**示例：**在文本聚類中，我們可以計算每個聚類的同質性，來評估聚類效果。如果同質性較高，則表示聚類效果較好。

### 外部評估指標(Rand 指數、調整後 Rand 指數、互信息、標籤分配準確率)

※所謂的外部是指跟真實標籤比。真實標籤是拿來評估模型性能，並非貼標來參與訓練，故仍為非監督式學習。

非監督式學習 ( Unsupervised Learning ) 是一種機器學習方法，主要用於從未標記的數據中發現隱含的模式和結構。與監督式學習不同，非監督式學習不依賴於預先標記的數據，而是通過算法自動識別數據中的模式。這種方法在數據探索、降維、聚類等方面有廣泛應用。本文將介紹幾種常見的非監督式學習外部評估指標，包括 Rand 指數 ( Rand Index )、調整後 Rand 指數 ( Adjusted Rand Index, ARI )、互信息 ( Mutual Information, MI ) 和標籤分配準確率 ( Label Assignment Accuracy )。

### ● Rand 指數 ( Rand Index )

Rand 指數是一種用於評估聚類結果與真實標籤之間一致性的指標。它通過計算聚類結果中正確分類的數據點比例來衡量聚類效果。Rand 指數的計算公式如下：

$$RI = \frac{TP + TN}{TP + TN + FP + FN}$$

Rand 指數的取值範圍在 0 到 1 之間，值越大表示聚類效果越好。

**示例：**假設我們有一組數據點，經過 K-means 聚類後，我們可以計算聚類結果與真實標籤之間的 Rand 指數。如果 Rand 指數較高，則表示聚類效果較好。

※ **示例：**假設有 7 筆資料 ( A, B, C, D, E, F, G )

真實分群：{A, B}, {C, D, E}, {F, G}

預測模型分群：{A, B}, {C, D}, {E, F, G}



所有資料點對及其分類：

| 類型 | 資料點對 (任意兩筆資料組成資料點對/一組數據點)            | 資料點對的二筆資料 |          |
|----|--------------------------------------|-----------|----------|
|    |                                      | 在真實分群中    | 在預測模型分群中 |
| TP | 3 對。('A', 'B')、('C', 'D')、('F', 'G') | 屬同一群      | 屬同一群     |
| TN | 14 對。Others                          | 屬不同群      | 屬不同群     |
| FN | 2 對。('C', 'E')、('D', 'E')            | 屬同一群      | 屬不同群     |
| FP | 2 對。('E', 'F')、('E', 'G')            | 屬不同群      | 屬同一群     |

$$7 * (7 - 1) / 2 = 21 \text{ 個資料點對}$$

$$RI = (3 + 14) / 21 = 0.81$$

### ● 調整後 Rand 指數 ( Adjusted Rand Index, ARI )

調整後 Rand 指數 ( ARI ) 是一種改進的 Rand 指數，它考慮了隨機聚類結果的影響。ARI 通過調整 Rand 指數，使其在隨機聚類結果下的期望值為 0，從而更準確地評估聚類效果。ARI 的計算公式如下：

$$ARI = \frac{RI - E[RI]}{\max(RI) - E[RI]}$$

其中，E[RI]表示隨機聚類結果下的期望 Rand 指數。ARI 的取值範圍在-1 到 1 之間，值越大表示聚類效果越好。

示例：在 K-means 聚類中，我們可以計算聚類結果與真實標籤之間的 ARI。如果 ARI 較高，則表示聚類效果較好。

### ● 互信息 ( Mutual Information, MI )

※衡量若知道變數 X 的資訊，能減少多少對變數 Y 的不確定性。

互信息 ( MI ) 是一種用於衡量兩個隨機變量之間相互依賴程度的指標。在聚類評估中，MI 用於衡量聚類結果與真實標籤之間的信息共享程度。MI 的計算公式如下：

$$MI(U, V) = \sum_{i=1}^{|U|} \sum_{j=1}^{|V|} P(U_i, V_j) \log \frac{P(U_i, V_j)}{P(U_i)P(V_j)}$$

其中，U 和 V 分別表示聚類結果和真實標籤，P(U<sub>i</sub>, V<sub>j</sub>)表示 U<sub>i</sub> 和 V<sub>j</sub> 同時出現的概率，P(U<sub>i</sub>)和 P(V<sub>j</sub>)分別表示 U<sub>i</sub> 和 V<sub>j</sub> 出現的概率。MI 的取值範圍在 0 到 1 之間，值越大表示聚類效果越好。

示例：在 K-means 聚類中，我們可以計算聚類結果與真實標籤之間的 MI。如果 MI 較高，則表示聚類效果較好。

### ● 標籤分配準確率 ( Label Assignment Accuracy )

標籤分配準確率是一種用於評估聚類結果與真實標籤之間一致性的指標。它通過計算聚類結果中正確分類的數據點比例來衡量聚類效果。標籤分配準確率的計算公式如下：

$$Accuracy = \frac{\text{Number of correctly assigned labels}}{\text{Total number of labels}}$$

標籤分配準確率的取值範圍在 0 到 1 之間，值越大表示聚類效果越好。

**示例：**假設我們有一組數據點，經過 K-means 聚類後，我們可以計算聚類結果與真實標籤之間的標籤分配準確率。如果標籤分配準確率較高，則表示聚類效果較好。

※※Rand 指數與標籤分配準確率的不同之處

1. **計算方式：**Rand 指數通過計算聚類結果與真實標籤之間的一致性來衡量聚類的質量，而標籤分配準確率通過計算樣本標籤分配的準確性來衡量聚類的質量。
2. **評估角度：**Rand 指數側重於評估聚類結果與真實標籤之間的相似度，而標籤分配準確率側重於評估樣本標籤分配的準確性。
3. **應用場景：**Rand 指數常用於評估聚類結果的整體質量，而標籤分配準確率常用於評估聚類結果中樣本標籤分配的準確性。

評估方法(聚類有效性指標、降維可視化)

#### ● 聚類有效性指標 (Clustering Validity Indices)

聚類有效性指標是一種用於評估聚類結果質量的指標。這些指標可以幫助我們判斷聚類結果是否合理，並選擇最佳的聚類算法和參數。常見的聚類有效性指標包括內部指標和外部指標。內部指標主要基於數據本身的特性來評估聚類結果，而外部指標則基於聚類結果與真實標籤之間的一致性來評估。

內部指標：

1. **輪廓係數 (Silhouette Coefficient)：**衡量每個數據點與其所屬聚類內其他數據點的平均距離 (a)，以及該數據點與最近的其他聚類的平均距離 (b)。輪廓係數的取值範圍在 -1 到 1 之間，值越大表示聚類效果越好。
2. **聚類內部距離 (Within-Cluster Sum of Squares, WCSS)：**計算每個數據點與其所屬聚類中心的距離平方和。WCSS 越小，表示聚類內部的數據點越接近其中心，聚類效果越好。
3. **戴維斯-鮑丁指數 (Davies-Bouldin Index)：**通過計算每個聚類的緊密性和聚類間的分離性來衡量聚類效果。DB 值越小，表示聚類效果越好。
4. **同質性 (Homogeneity)：**衡量每個聚類中的數據點是否屬於同一類別。同質性值範圍在 0 到 1 之間，值越大表示聚類效果越好。

外部指標：

1. **Rand 指數 (Rand Index)：**通過計算聚類結果中正確分類的數據點比例來衡量聚類效果。Rand 指數的取值範圍在 0 到 1 之間，值越大表示聚類效果越好。
2. **調整後 Rand 指數 (Adjusted Rand Index, ARI)：**考慮了隨機聚類結果的影響，通過調整 Rand 指數，使其在隨機聚類結果下的期望值為 0，從而更準確地評估聚類效果。ARI 的取值範圍在 -1 到 1 之間，值越大表示聚類效果越好。
3. **互信息 (Mutual Information, MI)：**衡量聚類結果與真實標籤之間的信息共享程度。MI 的取值範圍在 0 到 1 之間，值越大表示聚類效果越好。
4. **標籤分配準確率 (Label Assignment Accuracy)：**通過計算聚類結果中正確分類的數據點比例來衡量聚類效果。標籤分配準確率的取值範圍在 0 到 1 之間，值越大表示聚類效果越好。

- **降維可視化 ( Dimensionality Reduction Visualization )**

降維可視化是一種用於將高維數據投影到低維空間的方法，以便於可視化和理解數據結構。常見的降維方法包括主成分分析 ( Principal Component Analysis, PCA )、t-SNE ( t-Distributed Stochastic Neighbor Embedding ) 和 UMAP ( Uniform Manifold Approximation and Projection )。

- (1) **成分分析 ( PCA ) :**

PCA 是一種線性降維方法，通過尋找數據中方差最大的方向 ( 主成分 )，將數據投影到低維空間。PCA 的優點是計算簡單，結果易於解釋，但對於非線性數據效果較差。

**示例：**假設我們有一組高維數據，通過 PCA 將其降維到二維空間，然後繪製散點圖。我們可以觀察數據點在二維空間中的分佈情況，從而了解數據的結構和模式。

- (2) **t-SNE :**

t-SNE 是一種非線性降維方法，通過最小化高維數據和低維數據之間的分佈差異，將數據投影到低維空間。t-SNE 的優點是能夠很好地保留數據的局部結構，但計算複雜，對於大規模數據效果較差。

**示例：**假設我們有一組高維數據，通過 t-SNE 將其降維到二維空間，然後繪製散點圖。我們可以觀察數據點在二維空間中的分佈情況，從而了解數據的結構和模式。

- (3) **UMAP :**

UMAP 是一種非線性降維方法，通過構建數據的拓撲結構，將數據投影到低維空間。UMAP 的優點是計算速度快，能夠很好地保留數據的局部和全局結構。

**示例：**假設我們有一組高維數據，通過 UMAP 將其降維到二維空間，然後繪製散點圖。我們可以觀察數據點在二維空間中的分佈情況，從而了解數據的結構和模式。

## **結論**

非監督式學習的評估方法在評估聚類質量和理解數據結構方面具有重要作用。聚類有效性指標和降維可視化是兩種常見的評估方法，它們分別從不同角度衡量聚類效果和數據結構。通過這些方法，我們可以選擇最佳的聚類算法和參數，並更好地理解數據的結構和模式。

## **3. 常見的機器學習模型-半監督式學習 ( Semi-supervised Learning )**

### **定義與應用場景**

半監督式學習的核心思想是利用少量已標記的數據和大量未標記的數據來訓練模型。這種方法通過結合監督式學習和非監督式學習的優點，能夠在標記數據有限的情況下仍然取得良好的性能。半監督式學習的應用場景包括文本分類、圖像分類和語音識別等。

例如，在文本分類中，我們可能只有少量已標記的文本數據，但有大量未標記的文本數據。通過半監督式學習，我們可以利用這些未標記的數據來提高模型的性能。

**常見算法(自訓練、圖形正則化、生成對抗網絡、半監督支持向量機、半監督 K 均值、共訓練)**

- **自訓練 ( Self-training )**

自訓練是一種簡單而有效的半監督學習方法。它首先使用標記數據訓練一個初始模型，然後用該模型對未標記數據進行預測，並將高置信度的預測結果作為新的標記數據加入訓練集中，重複這一過

程直到模型收斂。

**示例：**假設我們有一個分類問題，初始模型在標記數據上訓練後，對未標記數據進行預測，將置信度高於某個閾值的預測結果作為新的標記數據，並重新訓練模型。這樣可以逐步擴大標記數據集，提高模型的分類效果。

### ● 圖形正則化 ( Graph Regularization )

圖形正則化是一種利用數據之間的圖形結構信息來進行半監督學習的方法。它通過構建數據點之間的圖形結構，將相似的數據點連接起來，並在圖形上進行正則化，以保持相似數據點的標籤一致性。

**示例：**在圖像分類問題中，我們可以構建圖像之間的相似性圖，將相似的圖像連接起來，並在圖形上進行正則化，使得相似圖像的標籤保持一致。這樣可以利用未標記數據的結構信息，提高分類效果。

### ● 生成對抗網絡 ( Generative Adversarial Networks, GANs )

生成對抗網絡 ( GANs ) 是一種由生成器和判別器組成的模型。生成器負責生成偽造數據，判別器負責區分真實數據和偽造數據。通過對抗訓練，生成器和判別器相互提升，最終生成器能夠生成與真實數據相似的數據。

**示例：**在圖像生成問題中，生成器生成偽造圖像，判別器判斷圖像是真實還是偽造。通過對抗訓練，生成器逐漸生成與真實圖像相似的偽造圖像，最終可以用於數據增強和半監督學習。

### ● 半監督支持向量機 ( Semi-Supervised SVM )

半監督支持向量機 ( Semi-Supervised SVM ) 是一種結合了標記數據和未標記數據的支持向量機模型。它通過在標記數據上進行分類訓練，同時在未標記數據上進行邊界最大化，以提高分類效果。

**示例：**在文本分類問題中，我們可以使用標記文本進行初始訓練，然後在未標記文本上進行邊界最大化，使得分類邊界遠離未標記文本的密集區域，從而提高分類效果。

### ● 半監督 K 均值 ( Semi-Supervised K-means )

半監督 K 均值是一種結合了標記數據和未標記數據的 K 均值聚類算法。它通過在標記數據上進行初始聚類，然後在未標記數據上進行迭代更新，以提高聚類效果。

**示例：**在客戶分群問題中，我們可以使用標記客戶數據進行初始聚類，然後在未標記客戶數據上進行迭代更新，使得聚類結果更加準確。

### ● 共訓練 ( Co-Training )

共訓練是一種利用多個分類器進行半監督學習的方法。它通過將數據分成多個視角，使用不同的分類器在不同視角上進行訓練，並相互交換高置信度的預測結果作為新的標記數據。

**示例：**在網頁分類問題中，我們可以將網頁的文本內容和超鏈接分別作為兩個視角，使用不同的分類器在這兩個視角上進行訓練，並相互交換高置信度的預測結果，逐步擴大標記數據集，提高分類效果。

**評估指標(準確率、精確率、召回率、F1 分數)**

準確率 ( Accuracy )、精確率 ( Precision )、召回率 ( Recall )、F1 分數 ( F1 Score ) 與 監督式學習 的評估指標相同。

**評估方法(交叉驗證 CV、混淆矩陣)**

● **交叉驗證 ( Cross-Validation )**

交叉驗證是一種用於評估模型性能的技術，通過將數據集分成多個子集，反覆訓練和測試模型，以獲得更穩健的性能評估結果。交叉驗證的主要目的是減少模型過擬合的風險，並提供對模型在未見數據上的泛化能力的估計。

步驟：

1. **數據分割**：將數據集分成 k 個子集 ( 通常稱為 folds )，其中 k 是預先設定的參數。
2. **訓練和測試**：對於每個子集，將其作為測試集，其餘 k-1 個子集作為訓練集，訓練模型並在測試集上評估性能。
3. **性能平均**：計算 k 次訓練和測試的性能指標的平均值，作為模型的最終性能評估結果。

**示例**：假設我們有一個分類問題，使用 10 折交叉驗證 ( k=10 ) 來評估模型性能。我們將數據集分成 10 個子集，進行 10 次訓練和測試，最終計算 10 次測試結果的平均值，作為模型的性能評估結果。

交叉驗證的優點是能夠充分利用數據集，提供更穩健的性能評估結果。然而，交叉驗證的計算成本較高，特別是在大規模數據集上。

● **混淆矩陣 ( Confusion Matrix )**

混淆矩陣是一種用於可視化分類模型性能的工具，展示了真實標籤和預測標籤之間的對比情況。混淆矩陣可以幫助我們了解模型在哪些類別上表現較好，哪些類別上表現較差。

結構：

混淆矩陣是一個方陣，其中每個元素表示真實標籤和預測標籤的組合情況。常見的混淆矩陣包括以下四個元素：

- **TP ( True Positive )**：真實標籤為正類，且模型預測為正類的數據點數量。
- **TN ( True Negative )**：真實標籤為負類，且模型預測為負類的數據點數量。
- **FP ( False Positive )**：真實標籤為負類，但模型預測為正類的數據點數量。
- **FN ( False Negative )**：真實標籤為正類，但模型預測為負類的數據點數量。

**示例**：假設我們有一個二分類問題，模型的混淆矩陣如下：

|      | 預測正類    | 預測負類    |
|------|---------|---------|
| 真實正類 | 50 (TP) | 10 (FN) |
| 真實負類 | 5 (FP)  | 35 (TN) |

從這個混淆矩陣中，我們可以看到模型在真實正類上的預測效果較好，但在真實負類上的預測效果稍差。

**評估指標：**

根據混淆矩陣，我們可以計算多種評估指標，包括：

- 準確率 ( Accuracy ) : 衡量模型在測試數據上的正確預測比例。

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- 精確率 ( Precision ) : 衡量模型預測為正類的數據點中實際為正類的比例。

$$Precision = \frac{TP}{TP + FP}$$

- 召回率 ( Recall ) : 衡量實際為正類的數據點中被模型正確預測為正類的比例。

$$Recall = \frac{TP}{TP + FN}$$

- F1分數 ( F1 Score ) : 精確率和召回率的調和平均數。

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

## 結論

交叉驗證和混淆矩陣是兩種常見的半監督式學習評估方法。交叉驗證通過多次訓練和測試，提供更穩健的性能評估結果，而混淆矩陣則通過可視化展示真實標籤和預測標籤之間的對比情況，幫助我們了解模型的分類性能。這兩種方法結合使用，可以更全面地評估半監督式學習模型的性能。

## 4. 常見的機器學習模型-強化學習 ( Reinforcement Learning )

### 定義與應用場景

強化學習的核心思想是通過試錯法來學習最佳行動策略。代理 ( Agent ) 在環境中執行動作 ( Action )，並根據環境的反饋 ( Reward ) 來更新其策略 ( Policy )，以最大化累積獎勵 ( Cumulative Reward )。這種方法特別適用於需要連續決策的問題。

### 應用場景

1. **遊戲**：強化學習在遊戲中得到了廣泛應用，例如 AlphaGo 使用強化學習來擊敗人類圍棋冠軍。
2. **機器人控制**：強化學習可以用來訓練機器人完成複雜的任務，例如行走、抓取物體等。
3. **自動駕駛**：強化學習可以用來訓練自動駕駛汽車在不同的道路和交通情況下做出最佳決策。

### 學習 ( Reinforcement Learning ) 常見算法介紹

強化學習 ( Reinforcement Learning, RL ) 是一種機器學習方法，通過與環境的互動來學習最佳行為策略。RL 的核心概念是智能體 ( Agent ) 在環境中執行動作 ( Action )，並根據獲得的獎勵 ( Reward ) 來調整策略，以最大化累積獎勵。以下將介紹幾種常見的強化學習算法，包括 Q 學習 ( Q-Learning )、深度 Q 網絡 ( Deep Q-Network, DQN )、策略梯度 ( Policy Gradient )、近端策略優化 ( Proximal Policy Optimization, PPO ) 和 Actor-Critic 方法。

- Q 學習 ( Q-Learning )



Q 學習是一種無模型 ( model-free ) 的強化學習算法，通過學習狀態-行動值函數 ( Q 函數 ) 來指導智能體選擇最佳行動。Q 函數表示在給定狀態下執行某個行動後，預期能夠獲得的累積獎勵。Q 學習的更新公式如下：

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

其中， $s$  和  $a$  分別表示當前狀態和行動， $r$  是獎勵， $\alpha$  是學習率， $\gamma$  是折扣因子， $s'$  和  $a'$  分別表示下一狀態和下一行動。

**示例：**假設我們有一個簡單的迷宮遊戲，智能體需要找到從起點到終點的最短路徑。智能體在每一步行動後會獲得一個獎勵 ( 例如，到達終點獲得正獎勵，撞到牆壁獲得負獎勵 )。通過 Q 學習，智能體可以逐漸學會選擇最佳路徑。

### ● 深度 Q 網絡 ( Deep Q-Network, DQN )

深度 Q 網絡 ( DQN ) 是 Q 學習的擴展，使用深度神經網絡 ( Deep Neural Network, DNN ) 來逼近 Q 函數。DQN 通過經驗回放 ( Experience Replay ) 和固定目標網絡 ( Fixed Target Network ) 來穩定訓練過程。經驗回放是將智能體的經驗存儲在記憶庫中，並隨機抽取小批量樣本進行訓練；固定目標網絡則是定期更新目標 Q 值，以減少訓練過程中的不穩定性。

**示例：**在遊戲《Atari》中的應用，DQN 可以通過學習遊戲畫面中的像素信息，來決定下一步的最佳行動。智能體通過不斷與遊戲環境互動，逐漸學會如何在遊戲中獲得高分。

### ● 策略梯度 ( Policy Gradient )

策略梯度方法直接學習策略函數 ( Policy Function )，即在給定狀態下選擇行動的概率分佈。策略梯度方法通過最大化累積獎勵的期望來更新策略參數。常見的策略梯度算法包括 REINFORCE 和 Actor-Critic 方法。

**示例：**在機器人控制中，策略梯度方法可以用來學習機器人在不同情況下應該如何移動，以完成特定任務 ( 例如，抓取物體或避開障礙物 )。

### ● 近端策略優化 ( Proximal Policy Optimization, PPO )

近端策略優化 ( PPO ) 是一種改進的策略梯度算法，通過限制策略更新的幅度來提高訓練穩定性。PPO 使用剪切概率比 ( Clipped Probability Ratio ) 來限制策略更新，從而避免策略過度更新導致的性能下降。

**示例：**在自駕車應用中，PPO 可以用來學習車輛在不同交通情況下的駕駛策略，以確保行駛安全和效率。

### ● Actor-Critic 方法

Actor-Critic 方法結合了策略梯度和價值函數逼近的優點。Actor ( 演員 ) 負責選擇行動，Critic ( 評論員 ) 負責評估當前策略的價值。Actor-Critic 方法通過同時更新策略和價值函數來提高學習效率。

**示例：**在多智能體系統中，Actor-Critic 方法可以用來協調多個智能體的行動，以完成協作任務 ( 例如，多機器人協作搬運物體 )。



## 評估指標(累積獎勵、平均獎勵、學習速率、收斂速度)

強化學習 ( Reinforcement Learning, RL ) 是一種機器學習方法，通過與環境的互動來學習最佳行為策略。在強化學習中，評估智能體 ( Agent ) 表現的指標非常重要，這些指標可以幫助我們了解智能體的學習進展和效果。本文將介紹幾個常見的強化學習評估指標，包括累積獎勵

( Cumulative Reward )、平均獎勵 ( Average Reward )、學習速率 ( Learning Rate ) 和收斂速度 ( Convergence Rate )。

### ● 累積獎勵 ( Cumulative Reward )

累積獎勵是指智能體在一段時間內獲得的總獎勵。這是一個衡量智能體整體表現的重要指標，因為它反映了智能體在整個學習過程中所獲得的回報。累積獎勵的計算公式如下：

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}$$

其中， $G_t$  是從時間步  $t$  開始的累積獎勵， $\gamma$  是折扣因子（通常介於0和1之間）， $r_{t+k}$  是在時間步  $t+k$  獲得的獎勵。

**示例：**假設我們有一個簡單的迷宮遊戲，智能體需要找到從起點到終點的最短路徑。每一步行動後，智能體會獲得一個獎勵（例如，到達終點獲得正獎勵，撞到牆壁獲得負獎勵）。通過計算累積獎勵，我們可以評估智能體在整個遊戲過程中的表現。

### ● 平均獎勵 ( Average Reward )

平均獎勵是指智能體在一段時間內每一步行動所獲得的平均獎勵。這是一個衡量智能體短期表現的指標，因為它反映了智能體在每一步行動中的回報情況。平均獎勵的計算公式如下：

$$\bar{r} = \frac{1}{T} \sum_{t=0}^{T-1} r_t$$

其中， $\bar{r}$  是平均獎勵， $T$  是總時間步數， $r_t$  是在時間步  $t$  獲得的獎勵。

**示例：**在一個自駕車應用中，智能體需要學習如何在不同交通情況下駕駛車輛。通過計算平均獎勵，我們可以評估智能體在每一步行動中的駕駛表現，例如是否能夠安全避開障礙物和遵守交通規則。

### ● 學習速率 ( Learning Rate )

學習速率是指智能體在學習過程中的更新步伐。學習速率的選擇對於強化學習算法的效果有著重要影響。過高的學習速率可能導致智能體無法穩定收斂，而過低的學習速率則可能導致學習過程過於緩慢。學習速率通常用符號 ( $\alpha$ ) 表示。

**示例：**在一個機器人控制應用中，智能體需要學習如何抓取物體。通過調整學習速率，我們可以控制智能體的學習速度，從而找到一個平衡點，使得智能體既能夠快速學習，又能夠穩定收斂。

### ● 收斂速度 ( Convergence Rate )

收斂速度是指智能體在學習過程中達到穩定狀態的速度。收斂速度越快，表示智能體能夠在較短時

間內學會最佳策略。收斂速度通常通過觀察累積獎勵或平均獎勵的變化趨勢來評估。

**示例：**在一個遊戲應用中，智能體需要學習如何在遊戲中獲得高分。通過觀察累積獎勵或平均獎勵的變化趨勢，我們可以評估智能體的收斂速度，從而了解智能體在多長時間內能夠學會最佳策略。

## 評估方法(模擬環境測試、策略評估)、模擬工具 ( OpenAI Gym、Unity ML-Agents ) 模擬環境測試 ( Simulation Environment Testing )、策略評估 ( Policy Evaluation )

強化學習 ( Reinforcement Learning, RL ) 是一種機器學習方法，通過與環境的互動來學習最佳行為策略。在強化學習中，評估智能體 ( Agent ) 表現的方法非常重要，這些方法可以幫助我們了解智能體的學習進展和效果。本文將介紹兩種常見的強化學習評估方法，包括模擬環境測試

( Simulation Environment Testing ) 和策略評估 ( Policy Evaluation )。

### ● 模擬環境測試 ( Simulation Environment Testing )

模擬環境測試是一種常見的強化學習評估方法，通過在模擬環境中測試智能體的表現來評估其學習效果。模擬環境可以是虛擬的遊戲、機器人模擬器或其他可控的測試環境。這種方法的優點是在安全、可控的環境中進行測試，避免了在真實環境中可能帶來的風險和成本。

**示例：**假設我們有一個自駕車智能體，我們可以在模擬的交通環境中測試其駕駛策略。模擬環境可以包括各種不同的交通情況，如紅綠燈、行人、其他車輛等。通過觀察智能體在模擬環境中的表現，我們可以評估其駕駛策略的效果。

#### 實施步驟：

1. **建立模擬環境：**選擇合適的模擬工具 ( 如 OpenAI Gym、Unity ML-Agents 等 ) 來建立模擬環境。
2. **訓練智能體：**在模擬環境中訓練智能體，讓其學習最佳行為策略。
3. **測試智能體：**在不同的模擬場景中測試智能體的表現，記錄其獲得的獎勵和行為。
4. **分析結果：**根據測試結果評估智能體的表現，找出其優勢和不足之處。

### ● 策略評估 ( Policy Evaluation )

策略評估是另一種常見的強化學習評估方法，通過評估智能體的策略來了解其學習效果。策略評估可以分為兩種：離線評估 ( Offline Evaluation ) 和在線評估 ( Online Evaluation )。離線評估是在不與環境互動的情況下評估策略，而在線評估則是在與環境互動的過程中評估策略。

**示例：**假設我們有一個機器人智能體，我們可以通過策略評估來了解其抓取物體的策略效果。離線評估可以通過分析歷史數據來評估策略，而在線評估則可以通過實時觀察機器人的行為來評估策略。

#### 實施步驟：

1. **選擇評估方法：**根據應用場景選擇合適的策略評估方法 ( 離線評估或在線評估 )。
2. **收集數據：**在離線評估中，收集歷史數據；在在線評估中，實時記錄智能體的行為和獲得的獎勵。
3. **計算評估指標：**根據收集的數據計算評估指標，如累積獎勵、平均獎勵等。
4. **分析結果：**根據評估指標分析智能體的策略效果，找出其優勢和不足之處。

肆、 鑑別式 AI 與生成式 AI 概念)

| 內容                   | 備註                        | 評鑑能力                                                    |
|----------------------|---------------------------|---------------------------------------------------------|
| 鑑別式 AI 與生成式 AI 的基本原理 | 基本原理、運用技術、目的與特性           | 評鑑應考者是否能夠區分鑑別式 AI 和生成式 AI 的特性，並理解生成式 AI 的概念、基本原理及其相關應用。 |
| 鑑別式 AI 與生成式 AI 的整合應用 | 應用場域與情境，如電腦視覺、語音辨識、生成技術等。 |                                                         |

一、 鑑別式 AI 與生成式 AI 的基本原理

1. 鑑別式 AI

鑑別式 AI ( Discriminative AI ) 是一種用於分類和辨識的人工智慧技術。它的主要目的是在給定輸入數據的情況下，預測該數據所屬的類別。鑑別式 AI 通常使用標籤數據進行訓練，並學習輸入數據與其標籤之間的關係。

鑑別式 AI 的基本原理

鑑別式 AI ( Discriminative AI ) 是一種專注於學習數據的條件概率  $P(y|x)$  的技術。這意味著在給定輸入  $x$  的情況下，預測輸出  $y$  的概率。鑑別式 AI 的目標是區分不同類別的數據，並且通常用於分類和迴歸任務。以下是一些常見的鑑別式 AI 模型：

- 1. 支援向量機 ( Support Vector Machine · SVM ) :
  - 原理：SVM 通過找到最佳的超平面來分隔不同類別的數據。這個超平面最大化了類別之間的間隔，從而提高分類的準確性。
  - 應用場景：SVM 常用於圖像分類、文本分類和生物信息學等領域。
- 2. 邏輯迴歸 ( Logistic Regression ) :
  - 原理：邏輯迴歸是一種線性模型，用於預測二元分類問題。它通過學習數據的特徵來估計事件發生的概率。
  - 應用場景：邏輯迴歸常用於市場分析、醫療診斷和社會科學研究等領域。
- 3. 隨機森林 ( Random Forest ) :
  - 原理：隨機森林是一種集成學習方法，通過多個決策樹的投票來提高分類的準確性。每個決策樹都是在隨機選擇的數據子集上訓練的。
  - 應用場景：隨機森林常用於金融分析、醫療診斷和環境科學等領域。

鑑別式 AI 使用的技術

- 特徵提取 ( Feature Extraction ) : 從原始數據中提取有用的特徵，以便模型能夠更好地學習和預測。
- 模型訓練 ( Model Training ) : 使用標籤數據來訓練模型，使其能夠準確地預測輸入數據的類別。
- 模型評估 ( Model Evaluation ) : 使用測試數據來評估模型的性能，確保其在實際應用中的準確性。

## 目的與特性

鑑別式 AI 的主要目的是進行分類和辨識，其特性包括：

- **高準確性**：通過學習輸入數據與標籤之間的關係，鑑別式 AI 能夠準確地預測數據的類別。
- **依賴標籤數據**：鑑別式 AI 需要大量的標籤數據來進行訓練，以確保模型的準確性。
- **適用於各種分類問題**：鑑別式 AI 可用於解決各種分類和辨識問題，如圖像分類、語音辨識等。

## 2. 生成式 AI

生成式 AI ( Generative AI ) 是一種用於生成新數據的人工智慧技術。它的主要目的是在給定輸入數據的情況下，生成與輸入數據相似的新數據。生成式 AI 通常使用無標籤數據進行訓練，並學習輸入數據的分佈。

### 生成式 AI 的基本原理

生成式 AI ( Generative AI ) 是一種專注於學習數據的聯合概率  $P(x,y)$  的技術。這意味著生成式 AI 能夠生成新數據，並且通常用於創造性任務。以下是一些常見的生成式 AI 模型：

#### 1. 生成對抗網路 ( Generative Adversarial Networks · GAN )：

- **原理**：GAN 由兩個神經網路組成：生成器 ( Generator ) 和鑑別器 ( Discriminator )。生成器負責生成新數據，鑑別器負責判斷數據的真實性。兩者通過對抗訓練來提高生成數據的質量。
- **應用場景**：GAN 常用於圖像生成、文本生成和音樂創作等領域。

#### 2. 變分自編碼器 ( Variational Autoencoders · VAE )：

- **原理**：VAE 通過學習數據的潛在表示來生成新數據。它使用編碼器 ( Encoder ) 將數據轉換為潛在表示，然後使用解碼器 ( Decoder ) 生成新數據。
- **應用場景**：VAE 常用於圖像生成、文本生成和數據增強等領域。

#### 3. 自回歸模型 ( Autoregressive Models · AR Model )：

是一種用於時間序列預測和自然語言生成的模型。AR 模型通過逐步生成序列中的每個元素，從左到右生成序列中的每個元素，而不是一次性生成整個序列。這樣的架構允許模型在生成過程中根據已生成的部分來動態調整下一個元素的預測，減少累積錯誤的風險。

通過學習數據的條件分佈來生成新數據，如 GPT ( Generative Pre-trained Transformer ) 模型。(P.S. GPT 模型屬於自回歸模型的一種)

### 生成式 AI 使用的技術

生成式 AI 使用的技術包括：

- **數據生成 ( Data Generation )**：通過學習輸入數據的分佈，生成與輸入數據相似的新數據。
- **模型訓練 ( Model Training )**：使用無標籤數據來訓練模型，使其能夠生成高質量的新數據。

- **模型評估 ( Model Evaluation )**：使用各種評估指標來評估生成數據的質量，如生成數據的真實性和多樣性。

## 目的與特性

生成式 AI 的主要目的是生成新數據，其特性包括：

- **創造性**：生成式 AI 能夠生成與輸入數據相似的新數據，具有很高的創造性。
- **依賴無標籤數據**：生成式 AI 通常使用無標籤數據進行訓練，這使得其在數據獲取上更加靈活。
- **適用於各種生成問題**：生成式 AI 可用於解決各種生成問題，如圖像生成、文本生成等。

## 二、鑑別式 AI 與生成式 AI 的技術差異

鑑別式 AI 和生成式 AI 之間存在一些技術差異：

**模型目標：**

- 鑑別式 AI 的目標是區分不同類別的數據，而生成式 AI 的目標是生成逼真的新數據。

**輸出特性：**

- 鑑別式 AI 的輸出是分類或迴歸結果，而生成式 AI 的輸出是新生成的數據。

**技術挑戰：**

- 鑑別式 AI 的挑戰在於提高分類或迴歸的準確性，而生成式 AI 的挑戰在於生成高質量且逼真的數據。

## 應用場景

鑑別式 AI 和生成式 AI 在不同的應用場景中發揮著重要作用：

### 1. 鑑別式 AI：

- **圖像分類**：鑑別式 AI 可以用於識別圖像中的物體，如人臉識別、車牌識別等。
- **文本分類**：鑑別式 AI 可以用於分類文本，如垃圾郵件檢測、情感分析等。
- **預測分析**：鑑別式 AI 可以用於預測未來事件，如股票價格預測、天氣預測等。

### 2. 生成式 AI：

- **圖像生成**：生成式 AI 可以用於生成逼真的圖像，如藝術創作、虛擬現實等。
- **文本生成**：生成式 AI 可以用於生成自然流暢的文本，如新聞報導、自動寫作等。
- **音樂創作**：生成式 AI 可以用於創作音樂，如自動作曲、音樂風格轉換等。

## 技術挑戰

鑑別式 AI 和生成式 AI 在技術上面臨一些挑戰：

### 1. 鑑別式 AI：

- **提高準確性**：鑑別式 AI 需要不斷改進模型，以提高分類或迴歸的準確性。

- **處理大規模數據**：鑑別式 AI 需要處理大量的數據，這對計算資源提出了挑戰。

## 2. 生成式 AI：

- **生成高質量數據**：生成式 AI 需要生成逼真的數據，這對模型的設計和訓練提出了挑戰。
- **訓練穩定性**：生成式 AI 的訓練可能不穩定，需要採用改進的模型如 Wasserstein GAN ( WGAN ) 來提高穩定性。

## 三、鑑別式 AI 與生成式 AI 的比較

### 主要區別

- **目的**：鑑別式 AI 的主要目的是分類和辨識，而生成式 AI 的主要目的是生成新數據。
- **數據需求**：鑑別式 AI 需要標籤數據進行訓練，而生成式 AI 通常使用無標籤數據進行訓練。
- **應用場景**：鑑別式 AI 適用於分類和辨識問題，如圖像分類、語音辨識等；生成式 AI 適用於生成問題，如圖像生成、文本生成等。

### 共同點

- **使用神經網絡**：鑑別式 AI 和生成式 AI 都使用神經網絡來進行數據的學習和預測。
- **需要大量數據**：無論是鑑別式 AI 還是生成式 AI，都需要大量的數據來進行訓練，以確保模型的準確性和生成數據的質量。
- **應用廣泛**：鑑別式 AI 和生成式 AI 都在各種領域中得到了廣泛的應用，如計算機視覺、自然語言處理等。

## 實例與應用

### 鑑別式 AI 的應用

- **圖像分類**：使用鑑別式 AI 模型（如卷積神經網絡，Convolutional Neural Networks, CNNs）來對圖像進行分類，如識別圖像中的物體。
- **語音辨識**：使用鑑別式 AI 模型（如長短期記憶網絡，Long Short-Term Memory, LSTM）來對語音進行辨識，如語音轉文字。
- **垃圾郵件過濾**：使用鑑別式 AI 模型（如支持向量機，SVM）來過濾垃圾郵件，提升郵件系統的安全性。

### 生成式 AI 的應用

- **圖像生成**：使用生成式 AI 模型（如 GANs）來生成高質量的圖像，如生成虛擬人臉。
- **文本生成**：使用生成式 AI 模型（如 GPT）來生成自然流暢的文本，如自動撰寫文章。
- **音樂生成**：使用生成式 AI 模型來生成音樂，如自動作曲。

## 四、鑑別式 AI 與生成式 AI 的整合應用

### 整合應用的價值

- **數據增強與分析的協同效應：**生成式 AI 可以生成多樣化的數據，增強鑑別式 AI 的訓練效果，提高模型的準確性。
- **多模態數據的處理與應用：**整合應用可以處理多種形式的數據，如圖像、文本、音頻等，提升模型的泛化能力。
- **提升模型的泛化能力：**生成式 AI 可以生成更多樣化的訓練數據，幫助鑑別式 AI 更好地泛化到未見過的數據。

鑑別式 AI 和生成式 AI 的整合應用在許多領域中展現了巨大的價值。首先，生成式 AI 可以生成多樣化的數據，這些數據可以用來增強鑑別式 AI 的訓練效果。這種協同效應可以提高模型的準確性，並且在數據稀缺的情況下尤為重要。例如，在醫學影像分析中，生成式 AI 可以生成更多的訓練樣本，幫助鑑別式 AI 更好地識別病變。

其次，整合應用可以處理多模態數據，即同時處理多種形式的數據，如圖像、文本、音頻等。這種能力使得模型在面對複雜的任務時能夠更好地泛化。例如，在自動駕駛中，整合應用可以同時處理來自攝像頭、雷達和激光雷達的數據，提高車輛的感知能力。

最後，生成式 AI 可以生成更多樣化的訓練數據，幫助鑑別式 AI 更好地泛化到未見過的數據。這種泛化能力在許多應用中都非常重要，例如在金融分析中，生成式 AI 可以生成更多的市場數據，幫助鑑別式 AI 更好地預測未來的市場趨勢。

### 整合應用的技術優勢

- **數據生成與判斷的融合：**生成式 AI 生成數據，鑑別式 AI 判斷數據的真實性，兩者結合可以提高模型的整體效能。
- **即時分析與回饋機制：**整合應用可以實現即時數據生成與分析，提供快速回饋，提升系統的靈活性。
- **系統的靈活性與適應性：**整合應用可以根據不同需求靈活調整模型，提高系統的適應性。

鑑別式 AI 和生成式 AI 的整合應用具有許多技術優勢。首先，數據生成與判斷的融合使得模型能夠更好地處理複雜的任務。生成式 AI 生成數據，鑑別式 AI 判斷數據的真實性，兩者結合可以提高模型的整體效能。例如，在醫學影像分析中，生成式 AI 可以生成更多的病變樣本，鑑別式 AI 可以更準確地識別病變。

其次，即時分析與回饋機制使得整合應用能夠提供快速回饋，提升系統的靈活性。這種機制在許多應用中都非常重要，例如在自動駕駛中，整合應用可以即時分析來自多個感知器的數據，提供快速回饋，幫助車輛做出更準確的決策。

最後，整合應用的系統靈活性與適應性使得模型能夠根據不同需求靈活調整。這種能力在許多應用中都非常重要，例如在金融分析中，整合應用可以根據市場的變化靈活調整模型，提高預測的準確性。

### 整合應用的技術與方法

- **生成對抗網絡 (GANs)**

生成對抗網絡 (Generative Adversarial Networks, GANs) 是一種典型的整合應用技術。GANs 由生成器 (Generator) 和鑑別器 (Discriminator) 兩個神經網絡組成，生成器負責生成新數據，鑑別器負責區分生成數據和真實數據。這兩個網絡通過對抗訓練來提升彼此的性能。

- **自編碼器與分類器的結合**



自編碼器 ( Autoencoders ) 是一種生成式 AI 技術，可以用於數據壓縮和生成。將自編碼器與分類器結合，可以實現數據的生成和分類。例如，變分自編碼器 ( Variational Autoencoders, VAEs ) 可以生成新數據，然後使用分類器對生成的數據進行分類和辨識。

- **混合模型**

混合模型是指將鑑別式 AI 和生成式 AI 結合使用的模型。例如，將支持向量機 ( Support Vector Machine, SVM ) 與生成對抗網絡 ( GANs ) 結合，可以實現數據的生成和分類。這種混合模型可以提升模型的性能和準確性。

## 整合應用的實例與場景

- **電腦視覺**

在電腦視覺領域，鑑別式 AI 和生成式 AI 的整合應用非常廣泛。例如，在圖像生成和分類的應用中，可以先使用生成對抗網絡 ( GANs ) 生成高質量的圖像，再使用卷積神經網絡 ( Convolutional Neural Networks, CNNs ) 對生成的圖像進行分類和辨識。

- **語音辨識**

在語音辨識領域，鑑別式 AI 和生成式 AI 的整合應用也非常常見。例如，可以使用生成對抗網絡 ( GANs ) 生成高質量的語音數據，再使用長短期記憶網絡 ( Long Short-Term Memory, LSTM ) 對生成的語音數據進行辨識和轉換。

- **生成技術**

在生成技術領域，鑑別式 AI 和生成式 AI 的整合應用可以實現更高質量的數據生成。例如，在文本生成的應用中，可以使用生成對抗網絡 ( GANs ) 生成自然流暢的文本，再使用鑑別式 AI 模型對生成的文本進行分類和辨識。

## 整合應用的挑戰與未來發展

### 挑戰

- **模型的複雜性**：整合應用需要結合多個模型，增加了模型的複雜性和計算成本。
- **數據的質量**：整合應用需要高質量的數據來進行訓練，確保模型的性能和準確性。
- **技術的融合**：整合應用需要將不同的技術進行融合，這對技術的理解和應用提出了更高的要求。

### 未來發展

- **提升模型性能**：通過不斷改進和優化模型，提升整合應用的性能和準確性。
- **擴展應用範圍**：探索新的應用場景和功能，擴展整合應用的範圍和影響力。
- **推動技術創新**：通過整合應用，推動 AI 技術的創新發展，實現更多的技術突破和應用創新。

## 整合應用的挑戰與解決策略

- **模型訓練穩定性**：生成式 AI 的訓練可能不穩定，需採用改進的模型如 Wasserstein GAN ( WGAN ) 來提高穩定性。
  - **數據偏差與公平性**：需確保生成的數據不偏向某一類別，保持數據的公平性。
  - **整合架構的設計與實現**：需設計高效的整合框架，實現生成與鑑別模型的協同工作。
- 鑑別式 AI 和生成式 AI 的整合應用面臨一些技術挑戰。首先，生成式 AI 的訓練可能不穩定，需

採用改進的模型如 Wasserstein GAN ( WGAN ) 來提高穩定性。WGAN 通過改進損失函數，提高了 GAN 模型的訓練穩定性，避免**模式崩潰**。



其次，數據偏差與公平性是整合應用面臨的一個重要挑戰。生成的數據可能偏向某一類別，這會影響模型的公平性。為了解決這個問題，可以採用數據增強技術，生成更多樣化的數據，保持數據的公平性。

最後，整合架構的設計與實現是整合應用面臨的一個重要挑戰。需要設計高效的整合框架，實現生成與鑑別模型的協同工作。這種框架需要具備高效的數據處理能力和靈活的模型調整能力，以應對不同的應用需求。

伍、 附件


一、 附件 1-資料分析使用的圖形

1. 直方圖(Histogram)

|      |                                                                                   |                                                                                    |
|------|-----------------------------------------------------------------------------------|------------------------------------------------------------------------------------|
|      |  |  |
| 差異性  | 直方圖 ( Histogram )                                                                 | 長條圖 ( Bar chart )                                                                  |
| 呈現結果 | 資料分布                                                                              | 資料大小                                                                               |
| 橫軸變數 | 數值                                                                                | 類別                                                                                 |
| 變數型態 | 連續變數 ( continuous variable )                                                      | 離散變數 ( discrete variable )                                                         |
| 組距間隔 | 連接、無間隔                                                                            | 有間隔                                                                                |
| 組距順序 | 有順序不可置換                                                                           | 無順序可置換                                                                             |
| 組距寬度 | 寬度可一致或不一致                                                                         | 寬度一致                                                                               |

## 2. 盒形圖(Box Plot，或稱 盒鬚圖、盒狀圖、箱型圖)

箱子的頂端和底端分別代表了資料的上四分位數 (Q3) 和下四分位數 (Q1)。箱子中間的線代表中位數 (Q2)，即資料的中間值，將箱子一分為二。




箱型圖箱子的外部延伸的線條展示了上下四分位數之外的資料範圍。有時在箱型圖上會出現在鬚鬚末端值以外的個別點。這些代表離羣值，也稱為異常值。


## 3. 散佈圖(scatter plot)

`plot(x, y)`

下面是`plot(x, y)`畫出的散步圖，可以發現這十個點好像呈現一條線的樣子(從左下到右上)，可以發現好像 $x$ 增加了， $y$ 也增加。但是兩個變數的相關性強還是弱，在統計上無法直接用圖形來解釋，我們可以使用相關係數知道他們的關係。



#### 4. 熱圖(heatmap)



## 二、References

- [1] 金融業運用人工智慧(AI) - [fsc.gov.tw](http://fsc.gov.tw)
- [2] 金融業運用人工智慧(AI)指引
- [3] 數位發展部公部門人工智慧應用參考手冊 (草案)
- [4] 解密歐盟人工智慧法案 - KPMG Taiwan
- [1] 企業在使用無代碼 / 低代碼 (No Code) 開發之前應該問的 5 個問題
- [5] No-Code vs. Low-Code — A Full Guide to No-Code for 2025!
- [6] Free Open Source Low-Code/No-Code Platforms Guide
- [7] Reinforcement learning from human feedback - Wikipedia
- [8] What is reinforcement learning from human feedback (RLHF)? - IBM
- [9] Reinforcement learning from human feedback - Wikipedia
- [10] What is reinforcement learning from human feedback (RLHF)? - IBM
- [11] What is vLLM? - [redhat.com](https://redhat.com)
- [12] Welcome to vLLM — vLLM - vLLM Blog
- [13] What is vLLM and what problem does it solve? – Collabnix
- [14] LichtLiu/EasyRAG: 繁體中文 RAG 檢索系統 - GitHub
- [15] 愛好 AI Engineer 電子報 檢索增強生成 RAG ... - ihowor